공학학사학위논문

# LLM 환각 탐지 신호의 Corpus Support 조건부 분해: Corpus Signal 단위별 분석

2026 년 2 월

서울대학교

자유전공학부

문 정 혁

# LLM 환각 탐지 신호의 Corpus Support 조건부 분해: Corpus Signal 단위별 분석

지도교수 김 남 수

이 논문을 공학 학사학위 논문으로 제출함

서울대학교

자유전공학부

문 정 혁

문정혁 의 학사 학위 논문을 인준함

2026 년 2 월 13일

지 도 교 수 (인)

# 초록

대규모 언어모델(LLM)의 환각 탐지에서 Semantic Entropy와 Semantic Energy 같이 같은 sample 에 대한 여러 답변의 일치도를 활용하는 신호는 신뢰도 높은 불확실성 추정을 제공한다. 그러나 이 신호들이 corpus 의 사실 등장 빈도 조건에 따라 어떻게 달라지는지는 충분히 분석되지 않았다. 본 논문은 Qwen2.5-3B 모델과 5개 QA 데이터셋(TriviaQA, SQuAD-1.1, BioASQ, NQ-Open, SVAMP; 총 3,500 sample, sample 당 10개 자유 생성 답변, 35,000 generation)으로 이 문제를 정량화한다. 정답 라벨은 답변 단위로 부여한다. 모델이 자유 생성한 답변과 정답 후보 사이의 `microsoft/deberta-large-mnli` 양방향 entailment 매칭 확률이 0.5 이상이면 해당 답변을 정답으로 정의하며, 이는 Farquhar 등 (2024)[3] 와 Ma 등 (2025)[8] 의 평가 단위와 일치한다.

본 논문은 entity 빈도, entity co-occurrence, question-answer bridge, 답변 n-gram 등 단위가 서로 다른 corpus 신호를 설계한다. 이 신호들은 환각 탐지 입력 변수가 아니라 sample 을 분할하는 신호로 사용되며, 각 신호로 sample 을 10분위 구간으로 나누었을 때 세 환각 탐지 신호 (Semantic Entropy, Semantic Energy, 답변 평균 음의 로그우도) 의 구간별 AUROC 가 어떻게 변동하는지를 분석한다.

분석 결과는 세 가지로 요약된다. 첫째, entity co-occurrence 신호로 sample 을 나누면 Semantic Entropy 의 구간별 AUROC 가 0.643 부터 0.793 사이에서 움직이며, 변동 폭은 $\Delta 0.150$ 이다. 이는 단일 entity 빈도 신호의 변동 폭 $\Delta 0.080$ 보다 약 1.88배 큰 값이다. 두 변동 폭 차이의 95% 신뢰구간은 [+0.002, +0.117] 로 0 을 포함하지 않으며, 본 표본 안에서는 통계적으로 유의하다. 모델과 corpus 단위의 일반화 가능성은 §5.2 에서 별도로 논의한다. 둘째, 단일 corpus 신호만으로 환각을 탐지할 때 AUROC 는 0.50–0.58 범위에 머문다. 같은 신호를 fusion 모델에 추가했을 때의 성능 향상도 gradient boosting 기준 +0.008 (95% 신뢰구간 [+0.005, +0.011]) 으로, 절대 크기는 제한적이다. 셋째, 같은 corpus 신호가 탐지기의 입력 변수로 사용될 때의 기여 폭은 작지만, sample 을 분할하는 신호로 사용될 때의 변동 폭은 크다. 이 비대칭은 corpus 신호의 설계 목표를 환각 탐지기의 입력이 아니라 탐지 신호의 조건부 평가 도구로 다시 설정할 필요를 제기한다. 본 논문은 환각 탐지 신호가 corpus 의 사실 등장 빈도 조건에 따라 어떻게 달라지는지를 corpus 신호의 단위별로 비교하는 분석 절차를 제시하고, 이 절차가 향후 환각 탐지 연구에서 corpus 조건부 평가의 참고용 비교 자료로 사용될 수 있음을 보인다.

**주요어**: 대규모 언어모델, 환각 탐지, Semantic Entropy, Semantic Energy, corpus support, 단위별 분해, Infini-gram

# 목차

**초록** **i**

**제 1 장 서론** **1**

1.1 연구 배경 . . . . . 1

1.2 연구 목적 . . . . . 1

1.3 논문 구성 . . . . . 2

**제 2 장 관련 연구** **3**

2.1 Sample-Consistency 기반 환각 탐지 . . . . . 3

2.2 Logit 기반 불확실성 추정 . . . . . 3

2.3 Corpus 통계를 이용한 환각 탐지 . . . . . 4

2.4 다중 신호 결합 (Multi-Signal Fusion) . . . . . 4

**제 3 장 제안 방법** **6**

3.1 데이터셋 및 실험 설정 . . . . . 6

3.2 답변 단위 정답 라벨 . . . . . 7

3.3 Semantic Entropy . . . . . 7

3.4 Semantic Energy . . . . . 7

3.5 각 답변의 token logit 통계 . . . . . 8

3.6 Corpus 신호 설계 . . . . . 8

3.7 Corpus 신호 단위별 분해 분석 . . . . . 9

3.8 Fusion 모델 . . . . . 9

**제 4 장 실험** **11**

4.1 주요 신호의 종합 성능 . . . . . 11

4.2 단일 신호 성능과 선행 연구 비교 . . . . . 12

4.3 단일 corpus 신호의 환각 탐지 성능 . . . . . 12

4.4 신호 결합 (fusion) 결과 . . . . . 13

4.5 Corpus 신호 단위별 분해 결과 . . . . . 14

4.6 데이터셋별 변동 . . . . . 18

**제 5 장 결론** **20**

5.1 논의 . . . . . 20

5.2 한계 . . . . . 21

5.3 향후 연구 . . . . . 22

5.4 결론 . . . . . 23

# 표 목차

표 4.1 주요 신호의 종합 성능 . . . . . 11
표 4.2 단일 신호 성능과 선행 연구 비교 . . . . . 12
표 4.3 단일 corpus 신호의 환각 탐지 성능 . . . . . 13
표 4.4 Fusion 모델 AUROC 와 corpus 추가 효과 . . . . . 14
표 4.5 Corpus 신호별 구간별 AUROC 변동 폭과 단조성 . . . . . 15
표 4.6 데이터셋별 Semantic Entropy / Semantic Energy 변동 폭 . . . . . 18
표 4.7 데이터셋별 AUROC . . . . . 19

# 그림 목차

그림 4.1 세 환각 탐지 신호와 두 corpus 신호의 구간별 AUROC . . . . . 15

# 제 1 장 서론

## 1.1 연구 배경

ChatGPT 와 Gemini 등으로 대표되는 LLM 은 추론 및 질의응답에서 높은 성능을 보이지만, 사실과 다르거나 근거가 없는 답변, 즉 환각(hallucination)을 빈번하게 생성한다[1, 2]. 의료, 법률, 과학과 같은 고위험 도메인에서 환각은 중대한 오류로 이어질 수 있으며, 이에 따라 LLM 출력의 신뢰성을 평가하는 일반적인 방법론은 중요한 연구 과제로 자리 잡았다.

환각 탐지의 주요 접근법 가운데 하나는 불확실성 정량화이다. Farquhar 등 (2024)[3] 가 제안한 Semantic Entropy 는 동일 sample 에 대해 N 개의 답변을 생성한 뒤 NLI 기반 의미 cluster 의 확률 분포 엔트로피로 모델의 의미적 불확실성을 측정한다. Semantic Entropy 는 모델, 데이터셋, 태스크에 걸쳐 강건하게 일반화되며 외부 지식 없이 동작한다. Ma 등 (2025)[8] 의 Semantic Energy 는 확률 대신 logit 을 직접 활용해 Semantic Entropy 가 포착하지 못하는 모델 지식 자체에 대한 불확실성까지 추정한다.

그러나 두 방법은 모두 모델 내부 신호에만 의존하며, 개별 sample 의 corpus support 조건, 즉 해당 사실이 사전학습 corpus 에 얼마나 자주 등장했는지에 따라 탐지 성능이 어떻게 달라지는지를 충분히 분석하지 않았다. 모델 전체 평균 AUROC 만 보면 탐지 신호가 어느 corpus support 영역에서 안정적이고 어느 영역에서 그렇지 않은지를 구분하기 어렵다. corpus 통계량을 환각 탐지에 활용한 선행 연구[14, 15, 10] 가 있으나, 이들은 corpus 신호 자체를 탐지 신호로 사용하는 데 머물렀다. corpus 신호의 단위가 Semantic Entropy, Semantic Energy, 답변 단위 logit 통계 등 환각 탐지 신호의 구간별 변동에 어떻게 작용하는지를 비교한 연구는 보고된 바 없다.

## 1.2 연구 목적

본 논문의 핵심 질문은 다음과 같다. 환각 탐지 신호(Semantic Entropy, Semantic Energy, 답변 단위 logit 통계) 의 corpus 뒷받침 조건 의존성은 corpus 신호의 단위 (entity 빈도, entity co-occurrence, n-gram) 에 따라 어떻게 다르게 나타나는가.

이 질문에 답하기 위해 세 가지 세부 목표를 설정한다. 첫째, Farquhar 등 (2024) 와 동일한 5 개 데이터셋과 답변 단위 NLI 정답 판정 절차 위에서 Qwen2.5-3B 모델로 Semantic Entropy, Semantic Energy, 답변 단위 logit 통계의 재현성을 검증한다. 둘째, entity, entity co-occurrence, question-answer bridge, 답변 n-gram 등 단위가 다른 corpus 신호를 설계하고, 각 신호가 단독 환각 탐지기로 사용될 때 분리력이 제한적이라는 결과를 정량화한다. 셋째, 같은 corpus 신호로 sample 을 10 분위 구간으로 나누었을 때 세 환각

탐지 신호 (Semantic Entropy, Semantic Energy, 답변 평균 음의 로그우도) 의 구간별 AUROC 가 어떻게 변동하는지를 분석하고, corpus 신호의 단위가 변동 폭에 미치는 영향을 규명한다.

**본 논문의 기여.** 기여는 다음 세 가지이다. (1) 환각 탐지 신호가 corpus support 조건에 따라 어떻게 달라지는지를 corpus 신호의 단위별로 비교하는 분석 절차를 제시한다. (2) 본 표본에서 entity co-occurrence 신호로 sample 을 나누었을 때의 구간별 AUROC 변동 폭이 $\Delta 0.150$ 로, 단일 entity 빈도 신호의 변동 폭 $\Delta 0.080$ 보다 약 1.88배 크다는 결과를 단일 조건에서 산출한 점추정치로 보고한다. 신뢰구간과 모델·corpus 일반화는 §5.2 에서 다룬다. (3) corpus 신호의 설계 목표를 탐지기 입력 변수가 아니라 조건부 평가 도구로 다시 설정하는 관점을 제시한다.

## 1.3 논문 구성

본 논문은 다음과 같이 구성된다. 제 2장에서는 Semantic Entropy, Semantic Energy, corpus 기반 환각 탐지, 신호 결합(fusion) 관련 선행 연구를 정리한다. 제 3장에서는 데이터셋, 실험 설정, 신호 정의, corpus 신호 단위별 분석 절차를 기술한다. 제 4장에서는 단일 신호 평가, fusion 결과, 단위별 구간 분석 결과를 보고한다. 제 5장에서는 결과의 함의와 한계, 향후 연구 방향을 논의하고 결론을 맺는다.

# 제 2 장 관련 연구

본 장에서는 LLM 환각 탐지 연구를 네 흐름으로 정리한다. 첫째, 생성 답변 간 의미 일관성에 기반한 탐지 (sample-consistency). 둘째, logit 을 활용한 불확실성 추정. 셋째, 사전학습 corpus 통계의 활용. 넷째, 여러 신호의 결합 (multi-signal fusion) 이다. 각 흐름의 주요 연구를 살펴본 뒤, 본 논문이 위치하는 지점을 제시한다.

## 2.1 Sample-Consistency 기반 환각 탐지

Farquhar 등 (2024)[3] 의 Semantic Entropy 는 동일 prompt 에 대해 생성한 N 개의 답변을 NLI 양방향 entailment 로 의미 cluster 로 묶고, cluster 질량의 엔트로피를 환각 지표로 사용한다. 이 방법은 하나의 의미가 다양한 표현으로 나타나는 언어적 특성을 반영하며, 태스크별 사전 지식 없이도 TriviaQA, SQuAD, BioASQ, NQ-Open, SVAMP 등 여러 데이터셋에서 일관된 성능을 보인다. Semantic Entropy 는 naive entropy, $p(\text{True})$, embedding 회귀 기준선 대비 일관되게 높은 AUROC 를 달성한다. 이는 SelfCheckGPT[4] 가 제시한 sample-consistency 접근을 의미 단위로 일반화한 것이다.

Kossen 등 (2024)[5] 의 Semantic Entropy Probes (SEPs) 는 Semantic Entropy 계산의 높은 연산 비용을 줄이기 위해, 단일 생성의 hidden state 에서 Semantic Entropy 를 직접 근사하는 probe 를 학습한다. SEPs 는 다중 샘플링 없이도 환각 탐지 성능을 유지하며, 분포 외 데이터에서도 안정적인 일반화를 보인다.

Nikitin 등 (2024)[6] 의 Kernel Language Entropy (KLE) 는 Semantic Entropy 를 일반화하여 hard clustering 대신 pairwise 의미 유사도 커널과 von Neumann 엔트로피를 사용한다. KLE 는 cluster 간 의존성을 더 세밀하게 포착하여, 여러 데이터셋과 모델 구조에서 Semantic Entropy 보다 높은 불확실성 정량화 성능을 보고한다. Ciosek 등 (2025)[7] 은 Bayesian 접근으로 Semantic Entropy 추정의 표본 효율을 높여, Farquhar 등 (2024) 대비 53% 적은 샘플로 동등한 AUROC 를 달성한다.

## 2.2 Logit 기반 불확실성 추정

Ma 등 (2025)[8] 의 Semantic Energy 는 Semantic Entropy 가 확률 기반 정의로는 포착하지 못하는 모델 자체에 대한 불확실성을 보완하기 위해, 모델의 penultimate layer logit 을 직접 활용하는 에너지 기반 불확실성 추정 프레임워크를 제안한다. 볼츠만 분포에서 영감을 받아 토큰 에너지 $\tilde{E}(x_t) = -z_\theta(x_t)$ 를 정의하고, Semantic Entropy 와 동일한 의미 cluster 구조 위에서 cluster 에너지를 산출한다. Semantic Entropy 는 모든 답변이 단일 cluster 에 집중될 때 분리력을 잃는데, Semantic Energy 는 이 사례에서 평균

AUROC 13% 이상의 개선을 보고한다. 확률이 logit 정규화 과정에서 강도 정보를 잃는다는 점은, LLM 의 불확실성 표현 능력을 제한하는 한 요인으로 지적된다.

토큰 단위 불확실성에 대한 또 다른 접근으로, Raghuvanshi 등 (2025)[9] 은 토큰 단위 log-likelihood, 양방향 NLI contradiction 신호, Semantic Entropy 를 결합한 하이브리드 탐지 파이프라인을 제안하고 SQuAD2.0 에서 AUC 0.818 을 보고한다.

## 2.3 Corpus 통계를 이용한 환각 탐지

LLM 의 환각은 사전학습 corpus 에서 드물게 등장하는 사실과 자주 연결된다. HALoGEN (Ravichander 등 2025)[10] 은 9 개 도메인에 걸친 10,923 개 항목의 환각 벤치마크를 구축하고, LLM 생성물의 원자적 사실 단위를 고품질 지식 소스와 자동 검증하는 프레임워크를 제시한다. 이 연구는 최고 성능 모델에서도 생성된 원자적 사실의 최대 86% 가 환각으로 분류될 수 있음을 보고하며, 환각의 원인을 학습 데이터 오류 회상 (Type A), 학습 데이터의 잘못된 지식 (Type B), 순수 조작 (Type C) 으로 분류한다. WildHallucinations[14] 는 *Wikipedia* 페이지가 없는 *entity* 에 대한 질문에서 LLM 의 환각률이 유의미하게 증가함을 관찰하여, corpus 노출 부족과 환각 발생률 사이의 경험적 연관을 보고한다. Zhang 등 (2025)[15] 은 RedPajama 1.3 조 토큰 사전학습 corpus 위에 suffix array 를 구축하고, prompt 와 답변의 n-gram 빈도를 환각 탐지 신호로 평가하였다.

Infini-gram[16] 은 n-gram 카운팅을 통한 corpus 통계 질의를 지원하는 엔진으로, 특정 phrase 나 entity 가 사전학습 corpus 에 얼마나 등장하는지를 효율적으로 산출한다. 그러나 이를 환각 탐지의 corpus 지지 신호로 활용하는 연구는 아직 초기 단계이며, 어떤 단위 (entity, 두 entity 사이의 관계, phrase) 의 corpus 통계 신호가 탐지 신호와 어떻게 연결되는지를 단위별로 비교한 연구는 충분하지 않다.

## 2.4 다중 신호 결합 (Multi-Signal Fusion)

단일 신호의 한계를 보완하기 위해 여러 신호를 결합하는 fusion 접근이 제안되어 왔다. Raghuvanshi 등 (2025)[9] 은 토큰 단위 불확실성, NLI 신호, Semantic Entropy 의 동적 가중 결합을 통해 calibration 한계를 완화한다. ECLIPSE (Singha 2025)[11] 는 semantic entropy 와 새로운 perplexity 분해를 결합해 증거 활용 신호를 추가함으로써, 금융 QA 에서 AUC 0.89 를 보고한다. SEReDeEP (Wang 2025)[12] 는 RAG 환경에서 semantic entropy 와 attention 메커니즘 신호를 결합해 컨텍스트 의존성이 큰 환각 탐지를 강화한다. Valentin 등 (2024)[13] 은 환각 탐지 점수를 모델 내부 score attribute 에 조건부로 calibrate 하는 다중 점수 프레임워크를 제안한다.

이들 연구는 여러 신호의 결합이 단일 신호 대비 성능 향상으로 이어질 수 있음을 보인다. 그러나 corpus 지지 신호의 역할 — 입력 변수로서의 한계와 sample 분할 신호로서의 효용 — 을 구분해 분석한 연구는

충분하지 않다. 본 논문은 corpus 통계 신호를 fusion 입력에 추가했을 때의 성능 변화를 정량화하는 한편, 같은 신호로 sample 을 나누었을 때 환각 탐지 신호의 AUROC 가 어떻게 달라지는지를 비교함으로써 이 공백을 메운다.

# 제 3 장 제안 방법

본 장은 다음 다섯 가지를 차례로 기술한다. 첫째, 데이터셋 구성과 NLI 양방향 함의에 기반한 답변 단위 정답 라벨 정의이다. 둘째, 환각 탐지 신호인 Semantic Entropy, Semantic Energy, 그리고 각 답변의 token logit 통계이다. 셋째, 단위가 서로 다른 네 가지 corpus 신호로, entity 빈도, entity co-occurrence, question-answer bridge, n-gram 등장 빈도를 포함한다. 넷째, 각 corpus 신호로 sample 을 구간별로 나누어 환각 탐지 신호의 AUROC 가 어떻게 변동하는지를 측정하는 분석 틀이다. 다섯째, 답변·sample 단위 신호와 corpus 신호를 함께 결합한 fusion 모델 구성이다. 본 논문은 새로운 환각 탐지기를 제안하기보다, 기존 환각 탐지 신호의 성능이 사전학습 corpus 의 뒷받침 정도에 따라 어떻게 달라지는지를 corpus 신호의 단위별로 비교하는 데 초점을 둔다.

## 3.1 데이터셋 및 실험 설정

본 연구는 Farquhar 등 (2024)[3] 과 동일한 5개 질의응답 데이터셋을 사용한다. TriviaQA[18] 800 sample, SQuAD-1.1[19] 800 sample, BioASQ[20] 800 sample, NQ-Open[21] 800 sample, SVAMP[22] 300 sample 으로 총 3,500 sample 을 선정하였다. 데이터셋마다 무작위 추출 시드를 고정하여 동일한 sample 집합을 재현하였고, 각 sample 에는 데이터셋 이름, split 식별자, 원본 색인, 본문 해시값을 결합한 고유 식별자를 부여하였다.

모델은 Qwen2.5-3B (base)[17] 를 사용하며, 별도의 instruction tuning 은 적용하지 않는다. 추론은 NVIDIA RTX 5090 32 GB 환경에서 16-bit 부동소수점 (float16) 으로 수행하였다. 입력 prompt 는 Farquhar 등 (2024) 와 동일한 한 문장 응답 유도 형식을 따른다. 즉 별도의 context 없이 "Answer the following question in a single brief but complete sentence." 라는 지시문 뒤에 질문을 제시한다. 각 sample 당 10개의 자유 생성 답변을 산출하였다. 샘플링 매개변수는 온도 1.0, top-p 0.9, top-k 50, 최대 생성 토큰 수 64이며, 평가 단위는 총 35,000개의 생성 답변이다. 최대 토큰 수를 64로 두었을 때 전체 답변의 약 12.6%가 중간에 절단된 채 종료되었다. 잘림의 영향을 배제하기 위해 잘린 답변이 발생한 2,426개 sample 의 모든 답변을 최대 생성 토큰 수 128로 다시 생성하였다. 재생성 전후 AUROC 변화는 $\pm 0.001$ 범위에 머물렀다.

평가 지표로는 AUROC, AURAC (Area Under Rejection-Accuracy Curve, Farquhar 등 (2024) 의 main metric), Brier score, ECE 를 사용한다. fusion 실험의 교차검증은 prompt 단위 5-fold GroupKFold 로 수행한다. 같은 sample 의 모든 답변이 같은 fold 에 함께 배치되도록 하여 학습-평가 사이의 sample 단위 정보 누출을 방지한다.

## 3.2 답변 단위 정답 라벨

본 논문의 정답 라벨은 모델이 생성한 답변 $s_i$ 가 정답 후보 표현과 의미적으로 일치하는지를 NLI (자연어 추론) 양방향 함의 확률로 판정하여 정의한다. 각 sample 의 정답 후보 집합 $C$ 는 데이터셋이 제공한 정답 표현, 동치 표현, 별칭 목록을 모두 모은 뒤 소문자 정규화와 중복 제거를 거쳐 구성한다. 생성된 답변 $s_i$ 와 후보 $c$ 사이의 매칭 점수는 다음과 같이 정의한다.

$$m(s_i, c) = \max\big(p_{\text{entail}}(c \to s_i),\ p_{\text{entail}}(s_i \to c)\big),$$
$$M(s_i) = \max_{c \in C} m(s_i, c).$$

$M(s_i) \geq 0.5$ 이면 $s_i$ 를 정답 (라벨 1), 그렇지 않으면 환각 (라벨 0) 으로 판정한다. NLI 모델로는 `microsoft/deberta-large-mnli` 를 사용하며, 절차는 Farquhar 등 (2024) 의 라벨링과 동일하다. 이 절차로 총 35,000 개의 이진 라벨이 산출된다. 본 평가 단위는 Farquhar 등 (2024) 의 Semantic Entropy 와 Ma 등 (2025) 의 Semantic Energy 가 사용한 답변 단위 정답성 평가와 일치하므로, 두 선행 연구와 직접 비교가 가능하다.

## 3.3 Semantic Entropy

Semantic Entropy 는 Farquhar 등 (2024) 의 정의를 그대로 따른다. 한 sample 에 대해 생성한 10 개 답변을 NLI 양방향 함의 관계로 의미 cluster $\mathbb{C}_k$ 로 묶은 뒤, 각 cluster 의 확률 질량을 답변의 시퀀스 로그 우도로부터 계산한다.

$$\log \tilde{p}(\mathbb{C}_k) = \log \sum_{x^{(i)} \in \mathbb{C}_k} \exp\Big(\sum_t \log p_\theta(x_t^{(i)})\Big),$$
$$p(\mathbb{C}_k) = \frac{\tilde{p}(\mathbb{C}_k)}{\sum_{k'} \tilde{p}(\mathbb{C}_{k'})}.$$

Semantic Entropy 는 cluster 분포의 Shannon 엔트로피로 정의된다.

$$H(\mathbf{x}) = -\sum_k p(\mathbb{C}_k)\ \log p(\mathbb{C}_k).$$

Semantic Entropy 는 sample 단위로 산출되며, 같은 sample 의 모든 답변에 동일한 값이 적용된다.

## 3.4 Semantic Energy

Semantic Energy 는 Ma 등 (2025) 의 정의를 그대로 구현한다. Semantic Entropy 와 동일한 의미 cluster 구조 위에서, 확률 대신 모델의 token logit 을 직접 활용해 모델 자체의 지식 한계에서 비롯되는 불확실성을

추정한다.

$$\tilde{E}(x_t^{(i)}) = -z_\theta(x_t^{(i)}) \qquad \text{(token energy)} \tag{3.1}$$

$$E(x^{(i)}) = \tfrac{1}{T_i} \sum_t \tilde{E}(x_t^{(i)}) \qquad \text{(sample energy)} \tag{3.2}$$

$$E_{\text{Bolt}}(\mathbb{C}_k) = \sum_{x^{(i)} \in \mathbb{C}_k} E(x^{(i)}) \qquad \text{(cluster total)} \tag{3.3}$$

$$U(\mathbf{x}) = \sum_k p(\mathbb{C}_k)\, E_{\text{Bolt}}(\mathbb{C}_k) \qquad \text{(sample 단위 uncertainty)} \tag{3.4}$$

값이 낮을수록 모델 신뢰도가 높음을 뜻한다.

## 3.5 각 답변의 token logit 통계

각 답변에 대해 다음 네 가지 token logit 통계를 산출한다.

- 평균 음의 로그우도 $-\frac{1}{T_i} \sum_t \log p(x_t^{(i)})$: 답변 안에서 각 토큰에 대한 음의 로그 확률의 평균.
- 시퀀스 로그우도 $\sum_t \log p(x_t^{(i)})$: 답변 전체의 로그 우도.
- *logit* 분산 $\mathrm{Var}_t\big(z_\theta(x_t^{(i)})\big)$: 답변 안에서 토큰별 logit 의 분산.
- 평균 로그 분배함수 $\frac{1}{T_i} \sum_t \log Z_t^{(i)}$: 분포의 평탄도 지표로, 값이 클수록 분포가 평평하다.

이 신호들은 답변마다 산출된 변동 정보를 담아 fusion 모델의 입력으로 사용된다.

## 3.6 Corpus 신호 설계

Corpus 신호는 Infini-gram[16] 의 local engine 을 backend 로 사용한다. 사용한 색인은 OLMo Dolma sample (16B token, OLMo-7B-hf 토크나이저) 이다. 본 논문은 단위가 서로 다른 네 가지 corpus 신호를 다음과 같이 정의한다.

**Entity 수준 신호.** spaCy 의 `en_core_web_lg` 개체명 인식기로 12개 범주 (인물, 조직, 지명, 위치, 날짜, 사건, 작품, 시설, 국적/종교, 제품, 언어, 법) 의 entity 를 추출한다. 한 sample 에 대해 다음 두 가지 정규화 점수를 계산한다.

$$\text{entity 빈도} = \frac{\log(1 + \min_{e \in E} \mathrm{freq}(e))}{\log(1 + 10^6)},$$

$$\text{entity co-occurrence} = \frac{\log\big(1 + \frac{1}{|P|} \sum_{(e_i, e_j) \in P} \mathrm{cooc}(e_i, e_j)\big)}{\log(1 + 10^5)}.$$

freq($e$) 는 entity $e$ 의 단일 등장 횟수이고, cooc($e_i, e_j$) 는 두 entity 가 corpus 안에서 함께 등장한 횟수이다. 본 연구의 baseline corpus 신호는 두 점수의 평균이며, 본 논문은 두 단위를 분리해 보고하는 데 핵심을 둔다.

**Question-answer bridge 신호.** 질문에서 추출한 entity 집합 $E_q$ 와, 답변에서 추출한 entity 중 질문과 겹치지 않는 entity 집합 $E_a$ 를 구성한다. 질문 entity 를 답변 entity 에서 제외하는 이유는 paraphrase 로 인한 자기 중복을 줄이기 위함이다. 모든 (질문 entity, 답변 entity) 쌍에 대해 corpus 동시 등장 횟수를 산출하고, 그 정규화 평균을 question-answer bridge 신호로 정의한다. 이는 질문과 답변 사이의 관계가 corpus 에 함께 등장한 빈도이며, LLM 이 해당 관계를 학습할 기회의 근사로 해석된다.

**N-gram 등장 빈도 신호.** 답변 토큰 시퀀스의 모든 3-gram 과 5-gram 에 대해 corpus 등장 횟수를 산출한다. 평균 등장 횟수를 정규화한 점수와, corpus 에 한 번도 등장하지 않은 n-gram 의 수를 함께 보고한다. 이는 답변 표현이 LLM 의 사전학습 데이터에 등장한 정도를 직접 측정한다.

## 3.7 Corpus 신호 단위별 분해 분석

본 논문 분석의 핵심은 §3.6 에서 정의한 corpus 신호를 환각 탐지의 입력 변수가 아니라 *sample* 을 분할하는 신호 로 사용하는 데 있다. 각 corpus 신호로 sample 을 순위에 따라 10분위 구간으로 나누어, 한 sample 의 corpus 뒷받침 정도가 어느 구간에 속하는지를 판별한다. sample 분할에 사용한 신호는 entity 수준 신호 세 가지 (entity 빈도, entity co-occurrence, 두 점수의 평균), question-answer bridge 한 가지, n-gram 수준 신호 세 가지 (3-gram 평균 등장, 5-gram 평균 등장, 3-gram 미등장 개수) 로 모두 일곱 가지이다. 같은 sample 에 속한 모든 답변은 동일한 구간 값을 공유한다.

각 신호의 10개 구간 안에서 환각 탐지 신호의 AUROC 를 따로 계산한 뒤, 그 최댓값과 최솟값의 차이 $\Delta = \mathrm{AUROC}_{\max} - \mathrm{AUROC}_{\min}$ 를 해당 신호의 구간별 AUROC 변동 폭으로 정의한다. 변동 폭이 클수록 그 corpus 신호로 sample 을 나누었을 때 환각 탐지 신호의 성능이 corpus 조건에 따라 더 큰 차이를 보인다. 본 논문의 핵심 결과는 이 변동 폭이 corpus 신호의 단위에 따라 어떻게 달라지는지를 비교한 것이다.

## 3.8 Fusion 모델

Fusion 모델의 입력은 두 가지 구성으로 실험한다.

- **CORE 입력**: sample 단위 신호인 Semantic Entropy, Semantic Energy 와, 답변마다 산출한 token logit 통계 4종 (평균 음의 로그우도, 시퀀스 로그우도, logit 분산, 평균 로그 분배함수).

- **CORE + CORPUS 입력**: 위 신호에 entity, question-answer bridge, n-gram 의 모든 corpus 신호를 sample 단위로 함께 추가한 구성.

분류 모델로는 logistic regression, random forest, gradient boosting 세 가지를 비교한다. 모든 실험은 prompt 단위 5-fold GroupKFold 로 평가하여 학습-평가 사이의 정보 누출을 방지한다.

# 제 4 장 실험

## 4.1 주요 신호의 종합 성능

본 절에서는 단일 신호와 fusion 모델의 종합 AUROC, AURAC, Brier 를 보고한다.

표 4.1 주요 신호의 종합 성능. 생성 답변 35,000건 (Qwen2.5-3B, 5개 데이터셋, sample 당 10개 자유 생성 답변) 을 대상으로 측정하였다. 라벨 정의, 평가 단위, fusion 입력, AURAC 정의는 §3.2–§3.8 에서 기술한다. corpus 추가 효과는 같은 분류기에서 핵심 입력만 사용한 경우와 핵심 입력에 corpus 신호를 함께 쓴 경우의 AUROC 차이로 정의한다. 굵은 글씨는 AUROC 가 가장 높은 행을 가리킨다.

| 신호 | AUROC | AURAC | Brier | corpus 추가 효과 |
|---|---|---|---|---|
| 단일 신호 (학습 없음, 답변 일관성 및 토큰 *logit* 통계) | | | | |
| 답변 내 logit 분산 | 0.620 | 0.400 | — | — |
| 답변 전체 로그우도 | 0.656 | 0.466 | — | — |
| 답변 평균 음의 로그우도 (NLL) | 0.670 | 0.468 | — | — |
| Semantic Entropy | 0.759 | 0.526 | — | — |
| Semantic Energy | 0.774 | 0.533 | — | — |
| 단일 *corpus* 신호 (학습 없음) | | | | |
| entity co-occurrence | 0.546 | — | — | — |
| entity 빈도 | 0.565 | — | — | — |
| 답변 3-gram 등장 빈도 | 0.563 | — | — | — |
| question-answer bridge (평균) | 0.583 | — | — | — |
| 답변 3-gram 미등장 개수 | 0.583 | — | — | — |
| *Fusion* 모델 (*sample* 단위 *5-fold* 교차검증, 검증 *fold* 예측 기준) | | | | |
| logistic regression (corpus 미포함) | 0.793 | 0.548 | 0.164 | — |
| logistic regression (corpus 포함) | 0.795 | 0.550 | 0.162 | +0.002 |
| random forest (corpus 미포함) | 0.790 | 0.546 | 0.166 | — |
| random forest (corpus 포함) | 0.800 | 0.555 | 0.161 | +0.010 |
| gradient boosting (corpus 미포함) | 0.800 | 0.553 | 0.161 | — |
| **gradient boosting (corpus 포함)** | **0.808** | **0.559** | **0.158** | +0.008 |

표 4.1 의 결과는 세 가지로 정리된다. 첫째, Semantic Entropy 와 Semantic Energy 단독 신호의 AUROC

는 각각 0.759 와 0.774 로 측정되었다. 이는 Farquhar 등 (2024) 가 TriviaQA / Llama-2 7B 에서 보고한 0.79, Ma 등 (2025) 가 Qwen3-8B 에서 보고한 0.75–0.85 와 비슷한 범위이다. 본 표본이 Semantic Entropy 와 Semantic Energy 의 일반적인 작동 범위에 속한다고 볼 수 있으나, 모델 간 일반화의 충분 조건은 아니다 (§5.2). 둘째, 모든 단일 corpus 신호의 AUROC 는 0.50–0.58 범위에 한정되어 단독 환각 탐지기로서의 분리력은 제한적이다 (§4.3). 셋째, fusion 에 corpus 신호를 추가했을 때의 AUROC 향상 폭은 random forest 에서 +0.010, gradient boosting 에서 +0.008 으로 측정되었다. corpus 신호가 fusion 의 입력 변수로 기여하는 폭 또한 제한적이다.

## 4.2 단일 신호 성능과 선행 연구 비교

Farquhar 등 (2024) 와 동일한 5개 데이터셋과 동일한 평가 단위 (생성 답변마다 산출한 NLI 정답 라벨) 위에서 Qwen2.5-3B 의 Semantic Entropy 와 Semantic Energy 의 AUROC 를 측정한다. 결과는 표 4.2 에 정리한다.

표 4.2 단일 신호의 AUROC 와 AURAC. 모든 신호는 신호 점수의 순위만으로 평가하며 별도 학습은 적용하지 않는다. 마지막 열은 Semantic Entropy 와 Semantic Energy 원 논문이 다른 모델에서 보고한 AUROC 범위이다.

| 신호 | AUROC | AURAC | 비교 (선행 연구) |
|---|---|---|---|
| Semantic Entropy | 0.759 | 0.526 | Farquhar (2024) TriviaQA 0.79, SQuAD 0.83 (Llama-2 7B) |
| Semantic Energy | 0.774 | 0.533 | Ma (2025) TriviaQA ∼0.85 (Qwen3-8B) |
| 답변 평균 음의 로그우도 (NLL) | 0.670 | 0.468 | — |
| 답변 전체 로그우도 | 0.656 | 0.466 | — |
| 답변 내 logit 분산 | 0.620 | 0.400 | — |

Qwen2.5-3B 는 Llama-2 7B 보다 작은 모델임에도 Semantic Entropy 와 Semantic Energy 의 AUROC 가 Farquhar 보고치 (0.75–0.85) 와 비슷한 범위에서 관찰된다. 본 표본이 Semantic Entropy 와 Semantic Energy 의 일반적인 작동 범위에 속한다고 볼 수 있다. 다만 이 비교는 동일 모델에서의 직접 재현이 아니라 참고용 비교에 한정된다. 답변 평균 음의 로그우도 (0.670) 는 단독 신호로도 일정한 분리력을 보이지만, Semantic Entropy 와 Semantic Energy 보다 0.09–0.10 낮다. 의미 cluster 정보가 더해질 때의 부가 효과를 확인할 수 있다.

## 4.3 단일 corpus 신호의 환각 탐지 성능

각 corpus 신호의 단독 AUROC 를 측정한다. 결과는 표 4.3 에 정리한다.

표 4.3 단일 corpus 신호를 환각 탐지 신호로 사용했을 때의 AUROC. 각 신호는 한 sample 의 모든 답변에 같은 값으로 적용되며, 신호 점수의 순위만으로 평가한다. 모든 결과가 0.50–0.58 범위에 한정된다.

| 신호 | AUROC |
|---|---|
| question-answer bridge (평균) | 0.583 |
| 답변 3-gram 미등장 개수 | 0.583 |
| question-answer bridge (미등장 표시) | 0.574 |
| entity 빈도 | 0.565 |
| 답변 3-gram 등장 빈도 | 0.563 |
| 답변 5-gram 등장 빈도 | 0.557 |
| entity co-occurrence | 0.546 |
| question-answer bridge (정규화) | 0.511 |
| entity 빈도 (평균) | 0.500 |

모든 corpus 신호의 단독 AUROC 는 0.50–0.58 범위에 한정되며, 단독 환각 탐지기로서의 분리력은 제한적이다. 이 결과는 자명하지만 정량화가 필요한 관찰로 해석한다. corpus 신호는 한 sample 안의 모든 답변에 같은 값으로 적용되는 정적 신호이다. 따라서 같은 sample 에서 생성된 10개 답변 사이의 정답 여부 변동을 구분하지 못하는 것은 측정 단위의 불일치에서 비롯되는 자연스러운 귀결이다. 본 절은 corpus 신호가 환각 탐지에 쓸모가 없다는 주장이 아니라, sample 단위의 정적 신호만으로는 답변 단위의 정답 여부 변동을 분리하기 어렵다는 점을 정량화하여 후속 분석의 동기를 제시하는 데 목적이 있다. 주목할 점은 후속 절 (§4.5) 에서 가장 큰 구간별 AUROC 변동 폭을 보이는 entity co-occurrence 신호가, 표 4.3 의 단독 AUROC 비교에서는 0.546 으로 하위권에 머문다는 사실이다. 단독 신호로서의 분리력과, 같은 신호로 sample 을 나누어 분석했을 때의 구간별 변동 폭은 서로 다른 지표이다. 본 논문 핵심 결과의 출발점이 바로 이 비대칭이다.

## 4.4 신호 결합 (fusion) 결과

Fusion 모델의 AUROC 와 corpus 신호 추가에 따른 효과를 측정한다 (표 4.4).

세 가지 관찰이 도출된다. 첫째, Energy 단독 (0.774) 대비 gradient boosting (corpus 미포함, 0.800) 의 +0.026 향상은 답변마다 산출한 토큰 logit 통계 (NLL, logit 분산 등) 와 sample 단위로 산출한 cluster 신호의 결합에서 비롯된다. 측정 단위가 서로 다른 불확실성 신호를 결합하는 방식이 단일 신호보다 분리력을 끌어올리는 데 기여한다. 둘째, corpus 신호를 추가했을 때의 향상 폭은 random forest 에서 최대 +0.010, gradient boosting 에서 +0.008 이다 (95% 신뢰구간 [+0.005, +0.011], sample 단위 부트스트랩 반복 500회,

표 4.4 Fusion 모델의 AUROC. 모든 모델은 sample 단위 5-fold GroupKFold 의 검증 fold 예측으로 평가하였다. *corpus* 추가 효과는 같은 분류기에서 핵심 입력만 사용한 경우와 핵심 입력에 corpus 신호를 함께 쓴 경우의 AUROC 차이이다.

| Method | AUROC | AURAC | corpus 추가 lift |
|---|---|---|---|
| Semantic Energy 단독 | 0.774 | 0.533 | — (기준) |
| Semantic Entropy 단독 | 0.759 | 0.526 | — |
| logistic regression (corpus 미포함) | 0.793 | 0.548 | — |
| logistic regression (corpus 포함) | 0.795 | 0.550 | +0.002 |
| random forest (corpus 미포함) | 0.790 | 0.546 | — |
| random forest (corpus 포함) | 0.800 | 0.555 | +0.010 |
| gradient boosting (corpus 미포함) | 0.800 | 0.553 | — |
| **gradient boosting (corpus 포함)** | **0.808** | **0.559** | +0.008 |

모든 반복에서 양수). 통계적으로 0 과 구분되는 양의 효과이지만 절대 크기는 제한적이다. corpus 신호가 fusion 입력 변수로서 기여하는 폭은 답변 단위와 sample 단위 신호를 결합했을 때의 효과 (+0.026) 의 약 3분의 1 수준이다. 셋째, fusion 입력 변수로서의 기여는 제한적인 반면, 같은 신호로 sample 을 분할했을 때의 구간별 AUROC 변동 폭은 큰 비대칭이 관찰되며 이는 다음 절의 결과로 이어진다.

## 4.5 Corpus 신호 단위별 분해 결과

각 corpus 신호로 sample 을 10분위 구간으로 나눈 뒤, 구간 안에서 Semantic Entropy, Semantic Energy, 답변 평균 음의 로그우도 (NLL) 의 AUROC 를 산출하고, 그 최댓값과 최솟값의 차이 $\Delta = \mathrm{AUROC}_{\max} - \mathrm{AUROC}_{\min}$ 를 변동 폭으로 측정한다. 본 논문의 핵심 결과는 표 4.5 이다.

두 corpus 신호의 분해 패턴을 세 가지 환각 탐지 신호 (Semantic Entropy, Semantic Energy, 답변 평균 NLL) 에 대해 비교한 결과는 그림 4.1 에 제시한다.

표 4.5 와 그림 4.1 에서 다음 네 가지 결과가 도출된다.

**Entity co-occurrence 신호의 구간별 변동 폭.** Entity co-occurrence 신호로 sample 을 분할하면, Semantic Entropy 의 변동 폭은 $\Delta 0.150$, Semantic Energy 의 변동 폭은 $\Delta 0.144$ 로 산출된다. 본 표본에서 비교한 일곱 가지 corpus 신호 가운데 변동 폭이 가장 큰 값이다. sample 단위 부트스트랩 (반복 500회) 으로 산출한 95% 신뢰구간은 Semantic Entropy 변동 폭이 0.121–0.211, entity 빈도 신호의 변동 폭이 0.058–0.149 이다. 두 변동 폭의 차이는 95% 신뢰구간 [+0.002, +0.117] 으로 0 을 포함하지 않으며, 부트스트랩 반복의 97.6% 에서 양수로 관찰된다. Semantic Energy 에서도 차이가 [+0.004, +0.109] 로 98.0%

표 4.5 Corpus 신호별로 산출한 Semantic Entropy / Semantic Energy / 답변 평균 NLL 의 구간별 AUROC 변동 폭 ($\Delta$) 과 단조성 ($\rho$). 각 신호는 sample 단위 순위 기반 10분위 구간으로 이산화하였다. $\Delta = \mathrm{AUROC}_{\max} - \mathrm{AUROC}_{\min}$ 으로 정의한다. $\rho$ 는 Spearman 상관 (구간 순위와 구간별 AUROC, 양수는 단조 증가) 이며, $p$ 값은 양측, n=10 (구간 수) 이다. 본 표는 다음 두 단서를 전제로 해석한다. 첫째, 7개 신호 $\times$ 3개 환각 탐지 신호 = 21개 동시 검정에 대해 다중비교 보정을 적용하지 않은 예비 분석이며, Bonferroni 보정 ($\alpha$=0.05/21≈0.0024) 을 적용하면 답변 평균 NLL 의 $\rho$=+0.733 ($p$=0.016) 도 유의 기준을 충족하지 않는다. 둘째, n=10 에서 $\rho$=±0.648 이 양측 $p$=0.05 의 임계값에 해당하므로, $|\rho|$=0.65 부근의 결과는 구간 폭과 동순위 처리 방식에 민감하다. 별표 (★) 는 해당 환각 탐지 신호의 변동 폭이 가장 큰 행을 표시한다.

| Corpus 신호 (단위) | Semantic Entropy $\Delta$ | Semantic Entropy $\rho$ ($p$) | Energy $\Delta$ | Energy $\rho$ ($p$) | NLL $\Delta$ | NLL $\rho$ ($p$) |
|---|---|---|---|---|---|---|
| entity 빈도 | 0.080 | +0.636 (0.048) | 0.077 | +0.467 (0.174) | 0.082 | +0.394 (0.260) |
| baseline (entity 빈도 + entity co-occurrence 평균) | 0.082 | +0.418 (0.229) | 0.086 | +0.297 (0.405) | 0.063 | +0.600 (0.067) |
| question-answer bridge | 0.089 | +0.648 (0.043) | 0.087 | +0.576 (0.082) | **0.176** ★ | +0.430 (0.214) |
| 답변 3-gram 등장 빈도 | 0.099 | +0.370 (0.293) | 0.098 | +0.370 (0.293) | 0.125 | +0.091 (0.803) |
| 답변 5-gram 등장 빈도 | 0.105 | +0.685 (0.029) | 0.096 | +0.539 (0.108) | 0.102 | −0.127 (0.726) |
| 답변 3-gram 미등장 개수 | 0.122 | +0.261 (0.467) | 0.104 | +0.309 (0.385) | 0.116 | −0.224 (0.533) |
| entity co-occurrence | **0.150** ★ | +0.648 (0.043) | **0.144** ★ | +0.600 (0.067) | 0.092 | +0.733 (0.016) |

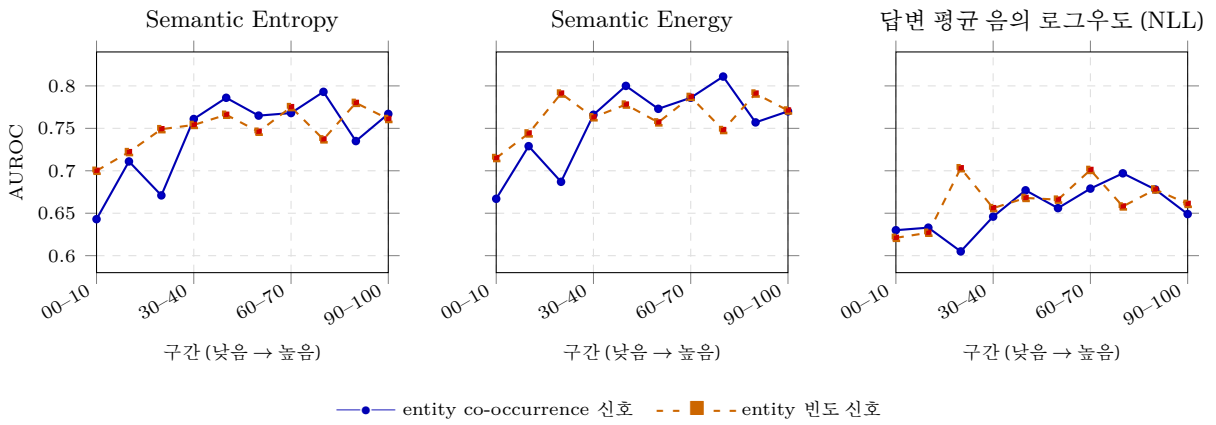


그림 4.1 세 환각 탐지 신호 (Semantic Entropy, Semantic Energy, 답변 평균 NLL) 의 구간별 AUROC 를 entity co-occurrence 신호 (실선) 와 entity 빈도 신호 (점선) 로 sample 을 분할하여 비교한 결과. 세 환각 탐지 신호 모두 entity co-occurrence 신호로 분할했을 때의 변동 폭이 entity 빈도 신호로 분할했을 때보다 크며, Semantic Entropy 와 Semantic Energy 에서 그 차이가 뚜렷하게 나타난다. Semantic Entropy 의 변동 폭은 entity co-occurrence 신호에서 $\Delta$0.150, entity 빈도 신호에서 $\Delta$0.080 이다. Semantic Energy 도 비슷한 패턴을 따른다 ($\Delta$0.144 와 $\Delta$0.077). 답변 평균 NLL 은 두 신호 모두에서 변동 폭이 작다 ($\Delta$0.092 와 $\Delta$0.082). 두 신호 모두 구간이 올라갈수록 AUROC 가 일관되게 증가하지는 않는다. 예를 들어 entity co-occurrence 신호로 분할했을 때 Semantic Entropy 는 구간 20–30 에서 0.671 로 일시 하락한 뒤 회복한다.

가 양수이다. 즉 entity co-occurrence 신호로 분할했을 때의 변동 폭이 entity 빈도 신호로 분할했을 때보다 크다는 결과는 표본 변동성을 통제한 뒤에도 통계적으로 유지된다. corpus 가 가장 부족한 구간 (00–10) 에서 Semantic Entropy 는 0.643, Semantic Energy 는 0.667 이며, corpus 가 가장 풍부한 구간 (70–80) 에서 Semantic Entropy 는 0.793, Semantic Energy 는 0.811 로 측정되었다. 다만 구간이 한 단계씩 올라갈 때마다 AUROC 가 단조 증가하지는 않으며, 중간 구간에서는 일시적인 하락과 회복이 관찰된다 (그림 4.1). 본 논문에서 사용한 "체계적 정렬" 이라는 표현은 양 끝단 사이의 평균적인 증가 경향과 최댓값과 최솟값의 폭을 가리키며, 인접 구간 사이의 엄밀한 단조 증가를 뜻하지 않는다. 본 결과는 답변에 등장하는 entity co-occurrence 이 corpus 에 함께 등장하는 정도가 LLM 의 해당 사실 학습 가능성을 근사하며, 답변 사이의 일관성을 측정하는 신호의 변동과 연결되는 한 요인임을 시사한다.

**Entity 빈도 신호의 구간별 변동 폭.** 단일 entity 빈도 (entity frequency) 신호로 sample 을 분할했을 때의 변동 폭은 Semantic Entropy 기준 $\Delta 0.080$, Semantic Energy 기준 $\Delta 0.077$ 로 본 표에서 가장 작다. 본 연구의 baseline corpus 신호 (entity 빈도와 entity co-occurrence 의 평균) 도 변동 폭이 $\Delta 0.082$–$0.086$ 으로 entity 빈도 신호와 거의 같은 수준이다. entity co-occurrence 신호의 큰 변동 폭이 entity 빈도 신호의 작은 변동 폭과 평균되며 희석된 결과로 해석되며, corpus 신호를 설계할 때 두 단위를 따로 보고해야 한다는 점을 시사한다. 평균화의 영향은 변동 폭뿐 아니라 단조성에서도 나타난다. entity co-occurrence 신호 (Semantic Entropy $\rho$=+0.648, $p$=0.043) 와 entity 빈도 신호 (Semantic Entropy $\rho$=+0.636, $p$=0.048) 모두 양의 단조성을 보이지만, 두 점수의 평균인 baseline corpus 신호는 Semantic Entropy $\rho$=+0.418 ($p$=0.229) 로 유의 임계 아래에 머무른다 (표 4.5). 단위가 다른 두 신호를 평균하면 각 신호가 가지고 있던 단조 증가 경향까지 무뎌진다. 본 논문의 정량 비교 — entity co-occurrence 단위가 entity 빈도 단위보다 Semantic Entropy 변동 폭을 약 1.88 배 크게 보인다는 점 — 은 본 결과에서 곧바로 도출된다.

**Question-answer bridge 신호와 NLL 변동의 관계.** Question-answer bridge 신호 ((질문 entity, 답변 entity) 쌍의 corpus 동시 등장 빈도) 로 sample 을 분할하면, 답변 평균 NLL 의 변동 폭이 $\Delta 0.176$ 로 측정된다. Semantic Entropy 와 Semantic Energy 의 변동 폭 ($\Delta 0.089$, $\Delta 0.087$) 보다 큰 폭이다. (질문, 답변) 의 사실 관계가 corpus 에 함께 등장하는 정도가 모델의 토큰 단위 자신감 (NLL) 과 가장 직접 연결되며, Semantic Entropy 나 Semantic Energy 가 포착하는 답변 사이 일관성과는 다른 정보를 측정함을 시사한다.

**답변 3-gram 미등장 개수 신호: 변동 폭과 단조성의 분리.** 답변에서 corpus 에 한 번도 등장하지 않은 3-gram 의 개수로 sample 을 분할하면, Semantic Entropy 변동 폭은 $\Delta 0.122$ 로 비교적 큰 편에 속한다. 그러나 단조성은 $\rho$=+0.261 ($p$=0.467, 표 4.5) 로, entity co-occurrence ($\rho$=+0.648), question-answer bridge ($\rho$=+0.648), 답변 5-gram ($\rho$=+0.685) 등 다른 신호와 달리 유의수준 0.05 를 넘지 않는다. 이 신호의 변동

폭은 구간이 올라갈수록 일관되게 증가하는 패턴이 아니라, U자형이나 일부 구간의 일시적 변동에서 비롯된 것으로 보인다. 따라서 "corpus 미등장 3-gram 이 많을수록 Semantic Entropy 가 낮아진다" 라고 단정하기는 어렵고, 미등장 3-gram 비율이 높은 일부 구간에서 Semantic Entropy 분리력의 변동이 관찰된다는 정도로 해석을 한정한다.

**강건성 검증: 질문 entity 한정 신호.** 앞서 사용한 entity co-occurrence 신호는 질문과 데이터셋이 제공한 정답 텍스트의 entity 를 모두 합쳐 산출하므로, 답변 측 entity 가 신호 값에 영향을 줄 가능성이 있다. 본 절은 이 가능성을 강건성 검증으로 점검한다. 질문 텍스트에서만 entity 를 추출하여 같은 분석을 재수행하였으며, 질문이 두 개 이상의 entity 를 포함하는 2,095 sample 이 분석 대상이 된다. 그 결과 Semantic Entropy 의 변동 폭은 0.178, Semantic Energy 의 변동 폭은 0.162 로, 원래 신호 (Semantic Entropy 0.150, Semantic Energy 0.144) 보다 큰 변동 폭이 관찰되었다. 질문에 한정한 entity 빈도 신호의 Semantic Entropy 변동 폭은 0.081 로 원래 신호의 0.080 과 거의 같다. 따라서 entity co-occurrence 단위가 entity 빈도 단위보다 변동 폭이 크다는 본 논문의 결과는 답변 측 entity 를 신호 산출에서 제거해도 유지된다. 비율은 약 1.88 배에서 Semantic Entropy 기준 2.20 배, Semantic Energy 기준 2.10 배로 오히려 증가한다. 이는 두 가지를 시사한다. 첫째, 본 신호의 변동 폭은 모델 출력으로 인해 인공적으로 부풀려진 결과가 아니다. 둘째, 질문 측 entity co-occurrence 이 LLM 의 사전학습된 지식을 더 직접 반영하는 지표일 가능성이 있다. 다만 본 분석의 부분표본은 entity 가 두 개 이상인 질문에 한정된다. 이러한 질문은 단일 사실을 묻기보다 두 entity 사이의 관계를 묻는 지식 질문 유형에 치우친다. 두 entity 사이의 관계는 정의상 entity co-occurrence 과 직접 대응하므로, 본 부분표본은 entity co-occurrence 신호의 변동 폭이 본래 크게 나타나는 조건이며, 이는 선택 편향 (selection bias) 에 해당한다. 따라서 비율 2.20 의 절대 크기는 이 부분표본의 특성을 반영한다. 전체 표본의 비율 1.88 과 산술적으로 직접 비교하기보다는, 답변 측 entity 를 제거해도 비율의 부호가 유지된다는 정성적 강건성 결과로 해석한다.

**강건성 검증: SVAMP 제외 민감도.** SVAMP 는 다른 네 데이터셋과 달리 수학 단어 문제이므로, entity co-occurrence 의 의미가 지식 질문과 다를 수 있다. SVAMP 를 제외한 3,200 sample 으로 같은 분석을 재수행하면, Semantic Entropy 기준 비율 (entity co-occurrence 변동 폭 / entity 빈도 변동 폭) 은 1.68 로 전체 표본의 비율 1.88 보다 약 0.20 줄어든다. Semantic Energy 기준 비율도 1.54 로 비슷한 폭으로 감소한다. 두 단위 사이의 부호 (entity co-occurrence > entity 빈도) 는 유지되지만, 절대 크기는 SVAMP 포함 여부에 따라 달라진다. 본 결과를 토대로 비율은 1.5–1.9 범위로 보고하는 것이 안정적이다.

**데이터셋별 분해 결과.** 표 4.6 는 데이터셋별 Semantic Entropy 변동 폭을 entity co-occurrence 신호와 entity 빈도 신호 모두에 대해 보고한다. 다섯 데이터셋 중 네 데이터셋 (BioASQ, SQuAD-1.1, SVAMP,

TriviaQA) 에서는 entity co-occurrence 변동 폭이 entity 빈도 변동 폭보다 크거나 같다. 다만 비율은 TriviaQA 의 1.0배에서 BioASQ 의 2.92배까지 큰 폭으로 변동한다. NQ-Open 에서는 부호가 역전되어 entity 빈도 변동 폭 (0.372) 이 entity co-occurrence 변동 폭 (0.250) 보다 크다. 따라서 전체 표본의 비율 1.88배는 데이터셋별 비율의 평균이 아니라, BioASQ 의 큰 비율 (2.92) 이 NQ-Open 의 역전 (0.67) 을 보상하여 형성된 표본 종합 통계이다. 즉 entity co-occurrence 신호가 모든 데이터셋에서 entity 빈도 신호보다 큰 변동 폭을 보이지는 않는다. 본 결과는 데이터셋 도메인에 따라 적절한 corpus 신호의 단위가 달라질 수 있다는 가설을 제기한다.

표 4.6 데이터셋별 Semantic Entropy 와 Semantic Energy 의 변동 폭을 entity co-occurrence 신호와 entity 빈도 신호에서 비교한 결과. NQ-Open 에서는 entity 빈도 변동 폭이 entity co-occurrence 변동 폭보다 크다 (★). 다만 NQ-Open 의 Semantic Energy 변동 폭 0.514 와 entity 빈도 변동 폭 0.372 는 정답 분포의 불균형에서 일부 비롯된다. NQ-Open 의 정답률은 0.240 이고, 두 번째 구간 (20–30) 은 표본 120개 중 정답이 7개에 불과하여 AUROC 가 0.266 인 outlier 가 발생하였다. 세 번째 구간 (30–40) 은 단일 클래스로 산출 대상에서 제외되었다. 이 outlier 구간을 제외하면 NQ-Open 의 변동 폭은 다른 데이터셋과 비슷한 0.10–0.15 수준으로 줄어든다. 따라서 본 표는 표본 종합 비율이 데이터셋 평균과 일치하지 않는다는 점을 보이는 용도에 한정한다.

| 데이터셋 | Semantic Entropy 변동 폭 (entity co-occurrence) | Semantic Entropy 변동 폭 (entity 빈도) | Semantic Entropy 비율 | Energy 변동 폭 (entity co-occurrence) |
|---|---|---|---|---|
| BioASQ | 0.272 | 0.093 | 2.92 | 0.184 |
| SQuAD-1.1 | 0.166 | 0.125 | 1.33 | 0.271 |
| SVAMP | 0.126 | 0.134 | 0.94 | 0.184 |
| TriviaQA | 0.088 | 0.089 | 0.99 | 0.113 |
| NQ-Open ★ | 0.250 | **0.372** | **0.67** | 0.514 |
| **전체 표본** | **0.150** | **0.080** | **1.88** | **0.144** |

## 4.6 데이터셋별 변동

다섯 데이터셋별로 단일 신호와 fusion 모델의 AUROC 를 표 4.7 에 정리한다.

baseline corpus 신호 (entity 빈도와 entity co-occurrence 의 평균) 로 sample 을 분할하면, gradient boosting (corpus 포함) 의 구간별 AUROC 는 최저 0.762 (구간 30–40) 에서 최고 0.859 (구간 60–70) 까지 $\Delta 0.097$ 의 변동을 보인다. 같은 분석을 entity co-occurrence 신호로 수행하면 Semantic Entropy 기준 변동 폭이 $\Delta 0.150$ 로 더 커져, 패턴이 한층 분명하다 (표 4.5). 정답률도 corpus 가 풍부한 구간 (60–70, 0.382) 이 corpus 가 부족한 구간 (10–20, 0.209) 보다 높아, corpus 뒷받침 정도와 정답률 사이에 양의 상관이 확인된다. 데이터셋 사이의 패턴도 같은 방향이다. 정답률은 TriviaQA (0.482) 에서 SQuAD (0.189) 까지, 환각 탐지 신호 AUROC 도 같은 순서로 감소한다 (Semantic Entropy 기준 TriviaQA 0.778, SQuAD 0.700). 이는

표 4.7 데이터셋별 AUROC. sample 단위 5-fold 교차검증의 검증 fold 예측을 기준으로 산출하였다. 정답률은 데이터셋 평균이다.

| 데이터셋 | n | 정답률 | Semantic Entropy | Semantic Energy | 평균 NLL | gradient boosting (corpus 포함) |
|---|---|---|---|---|---|---|
| TriviaQA | 8,000 | 0.482 | 0.778 | 0.782 | 0.633 | 0.803 |
| SVAMP | 3,000 | 0.431 | 0.786 | 0.787 | 0.713 | 0.824 |
| BioASQ | 8,000 | 0.339 | 0.746 | 0.759 | 0.678 | 0.811 |
| NQ-Open | 8,000 | 0.240 | 0.709 | 0.731 | 0.635 | 0.796 |
| SQuAD-1.1 | 8,000 | 0.189 | 0.700 | 0.716 | 0.593 | 0.748 |
| **전체** | **35,000** | **0.322** | **0.759** | **0.774** | **0.670** | **0.808** |

corpus 뒷받침 효과가 데이터셋 사이에서도 동일한 방향으로 나타남을 시사한다.

# 제 5 장 결론

## 5.1 논의

본 연구의 결과는 corpus 신호의 역할을 다시 정의한다. corpus 신호는 환각 탐지기의 입력 변수로서 기여가 제한적이며 (fusion lift $\leq +0.010$), 탐지 신호를 corpus 조건에 따라 분해하는 분석 도구로 사용했을 때 변동 폭이 $\Delta 0.080$–$0.150$ 범위에서 관찰된다. 이 비대칭은 corpus 신호의 설계 목표가 달라야 함을 시사한다. 즉 "corpus 신호를 어떻게 더 효과적인 탐지 입력 변수로 가공할 것인가" 가 아니라 "corpus 신호의 어떤 단위가 탐지 신호의 어떤 측면을 분해하는가" 가 본 연구가 제기하는 질문이다.

Entity co-occurrence 신호로 sample 을 나누었을 때의 변동 폭은 단일 entity 빈도 신호로 나누었을 때의 변동 폭보다 약 1.88배 크다 (Semantic Entropy 기준 $\Delta 0.150$ 와 $\Delta 0.080$). 이는 두 entity 사이의 관계가 corpus 에 함께 등장하는 정도가 단일 entity 의 등장 횟수보다 LLM 의 사전학습된 지식을 더 직접 반영한다는 해석으로 설명할 수 있다. 어떤 단일 entity 가 corpus 에 자주 등장하더라도 두 entity 사이의 관계가 함께 등장하지 않으면 LLM 이 해당 관계를 학습할 가능성은 낮다. 이러한 단위 차이가 변동 폭의 차이로 나타난다.

Question-answer bridge 신호와 답변 평균 음의 로그우도 (NLL) 사이의 변동 폭 ($\Delta 0.176$) 은 다른 관점을 제공한다. 질문 entity 와 답변 entity 의 corpus 동시 등장은 LLM 이 "질문에서 답변으로 이어지는 경로" 를 사전학습에서 직접 학습했을 가능성을 근사하며, 이것이 토큰 단위 생성 자신감을 반영하는 NLL 과 가장 직접 연결된다. Semantic Entropy 와 Energy 는 답변 사이의 일관성을 보는 다른 차원의 신호이므로, question-answer bridge 와 NLL 의 연결이 Semantic Entropy / Energy 와 다른 패턴을 보이는 것은 두 신호군이 보완적인 정보를 포착함을 시사한다.

**효과 크기의 정밀도.** §4.5 에서 보고한 Semantic Entropy 변동 폭 차이의 95% 신뢰구간 [+0.002, +0.117] 은 0 을 포함하지 않으나, 하한이 +0.002 로 경계에 가까우며 신뢰구간 폭 (0.115) 이 점추정치 (+0.063) 의 약 1.8배에 해당한다. 즉 "entity co-occurrence 변동 폭이 entity 빈도 변동 폭보다 크다" 는 방향성은 본 표본에서 통계적으로 유의하지만, 효과 크기 자체의 정밀도는 낮다. 약 1.88배라는 점추정치가 모집단 비율과 일치한다고 보지 않으며, 다음 세 가지 점을 함께 보고하였다. 첫째, SVAMP 포함 여부에 따라 비율은 1.68 에서 1.88 사이에서 변동한다. 둘째, 질문 entity 만으로 산출한 강건성 검증에서는 비율이 약 2.20배까지 증가한다. 셋째, 데이터셋별로는 NQ-Open 처럼 부호가 역전되는 경우가 관찰된다 (표 4.6). 따라서 정량적 주장은 "방향성이 본 표본에서 유의하며, 비율의 점추정치는 약 1.5–1.9배 범위에 있다" 로

한정한다. 보다 정밀한 효과 크기 추정은 추가 모델과 corpus 위에서의 추가 표본을 통해 가능하다.

## 5.2 한계

본 연구는 다음과 같은 한계를 지닌다.

1. **단일 모델 평가.** 본 연구는 Qwen2.5-3B 단일 모델에서 수행되었다. corpus 신호의 구간별 변동 패턴이 Llama, Mistral, Gemma 계열 모델에서도 같은 방향으로 나타나는지는 직접 검증되지 않았다. Farquhar 등 (2024)[3] 에서 서로 다른 LLM 계열 사이에서도 Semantic Entropy 의 패턴이 유사하게 관찰되었다는 점은 일반화 가능성을 시사하나, 이는 향후 연구로 남긴다.

2. **단일 corpus 색인.** corpus 신호는 `v4_dolmasample_olmo` (16B Dolma sample) 단일 Infini-gram 색인에서 산출된다. 이 색인이 Qwen2.5-3B 의 실제 사전학습 corpus 와 다르므로, corpus 빈도와 환각 사이의 연결은 상관 관계이며 인과 관계로 해석할 수 없다. 도메인 특화 corpus (예: BioASQ 용 PubMed) 를 사용하면 변동 폭이 달라질 가능성이 있다.

3. **NLI 라벨링 한계.** 정답 라벨은 `microsoft/deberta-large-mnli` 기반 양방향 entailment $\geq 0.5$ 기준에 의존한다. LLM-as-judge 와 같은 다른 라벨링 방식과의 비교 검증은 향후 과제로 남는다.

4. **생성 답변에 기반한 라벨과 신호의 부분 결합.** 정답 라벨과 Semantic Entropy / Energy 신호는 모두 동일한 N=10 개의 생성 답변에서 산출된다. 라벨은 각 답변과 정답 후보의 NLI 매칭으로 결정되고, Semantic Entropy / Energy 는 같은 답변들의 의미 cluster 분포와 토큰 logit 에서 산출되므로, 두 양은 동일 답변 집합의 분산을 부분적으로 공유한다. 결과적으로 본 논문의 AUROC 는 모델 출력의 정답 여부와 모델 출력 사이의 일관성이라는 동일 source 상의 결합도를 측정하며, 모델 출력과 외부 정답 텍스트 사이의 일치도에 대한 독립 측정은 아니다. 평가 단위 (생성 답변 단위) 가 Farquhar 와 Ma 의 연구와 일치하므로 선행 연구 비교의 전제는 유지되며, 본 결과는 동일 라벨링 절차 위에서의 상대적 비교로 해석한다.

5. **Self-conditioning 회피.** corpus 통계량은 (a) fusion 입력 변수와 (b) 분석용 분해 신호 두 용도로 모두 사용된다. (b) 의 분해 분석은 모델 출력과 무관한 외부 corpus 통계 위에서 수행되므로 self-conditioning 문제는 발생하지 않는다.

6. **변동 폭 차이의 표본 변동성.** 약 1.88배라는 비율은 단일 조건에서 산출한 점추정치이며, 두 변동 폭의 차이에 대한 sample 단위 bootstrap 95% 신뢰구간을 §4.5 에 함께 보고하였다 (Semantic Entropy [+0.002, +0.117], Energy [+0.004, +0.109]). 두 신뢰구간 모두 0 을 포함하지 않으므로, entity co-occurrence 변동 폭이 entity 빈도 변동 폭보다 크다는 결과는 본 표본에서 통계적으로 유의하다.

다만 이 신뢰구간은 단일 모델, 단일 corpus 색인 위에서의 표본 변동성만을 통제하며, 모델과 corpus 일반화에는 별도 검증이 필요하다. 또한 max−min 통계량 자체가 순서통계량이므로 구간 수가 다른 분할에서는 비율의 절대 크기가 달라질 수 있다.

7. **Fusion lift 의 통계적 유의성.** corpus 신호 포함 여부에 따른 gradient boosting 의 lift 에 대한 sample 단위 bootstrap 95% 신뢰구간 [+0.005, +0.011] 은 0 을 포함하지 않으며 모든 반복에서 양수이다. 따라서 corpus 신호의 fusion 기여는 통계적으로 0 과 구분되는 양의 효과이지만, 절대 크기 (+0.008) 는 답변 단위 · sample 단위 신호 결합 효과 (+0.026) 의 약 3분의 1 정도에 한정된다.

8. **데이터셋별 이질성.** 표 4.6 에서 보이듯, entity co-occurrence 변동 폭이 entity 빈도 변동 폭보다 크다는 패턴은 5개 데이터셋 중 NQ-Open 에서 역전된다. 따라서 표본 종합 비율 1.88배는 모든 데이터셋에서 entity co-occurrence 신호가 entity 빈도 신호보다 큰 변동 폭을 보인다는 뜻이 아니라, 데이터셋 종합 통계이다. 도메인별로 corpus 신호의 적절한 단위가 다를 수 있다는 가설은 본 논문의 범위 밖이다.

9. **Corpus 신호의 entity 추출 범위.** 본 논문의 corpus 신호는 질문 텍스트와 데이터셋이 제공한 정답 텍스트의 entity 를 합쳐 산출하며, 모델이 생성한 답변의 entity 는 사용되지 않는다. 따라서 신호 값은 모델 출력과 독립이며, 한계 4 에서 다룬 답변 결합 문제와는 차원이 다르다. 답변 측 entity 의 영향을 분리하여 질문 entity 만으로 신호를 다시 산출한 결과는 §4.5 에 함께 보고하였으며, Semantic Entropy 기준 비율은 1.88 에서 2.20 으로 증가한다. 다만 부분표본 (n=2,095) 의 선택 편향은 §4.5 에 명시하였다.

10. **변동 폭과 Spearman $\rho$ 의 분리 해석.** 변동 폭은 max−min 통계량이므로, 구간이 올라갈수록 AUROC 가 단조 증가하는 양상과 비단조 변동 (U자형 등) 을 구분하지 못한다. 본 논문은 표 4.5 에 Semantic Entropy / Energy / 답변 평균 NLL 세 신호 모두에 대해 Spearman $\rho$ 를 함께 보고함으로써 변동 폭과 단조성을 분리해 진단한다. 다만 21개 동시 검정에 대한 다중비교 보정 (Bonferroni $\alpha$=0.05/21≈0.0024) 을 적용하면 표의 모든 $\rho$ 가 유의 기준을 충족하지 않으므로, $\rho$ 결과는 예비 분석으로 한정한다. 또한 n=10 (구간 수) 의 Spearman 검정력이 낮아 $|\rho|$=0.65 부근의 결과는 구간 폭과 동순위 처리에 민감하다. 보다 강건한 단조성 검정 (Mann-Kendall, partial $\rho$) 과 다중비교 보정은 향후 과제로 남긴다.

## 5.3 향후 연구

본 연구의 결과는 세 가지 방향의 후속 연구를 제안한다.

1. **모델 다양화.** Llama, Gemma, instruction-tuned 모델 등 다양한 모델에서 entity co-occurrence 신호의 변동 폭 패턴이 같은 방향으로 나타나는지 검증한다.

2. **LLM-as-judge 라벨과의 비교.** 본 논문이 사용한 NLI 매칭 라벨을 LLM-as-judge 라벨로 대체했을 때 corpus 신호 단위별 변동 폭이 어떻게 달라지는지 분석한다.

3. **도메인 특화 corpus.** BioASQ 의 경우 PubMed 기반 corpus, 수학 문제의 경우 ArXiv 기반 corpus 등 도메인 특화 색인을 사용했을 때 동일 신호의 변동 폭이 더 커지는지 검증한다.

## 5.4 결론

본 논문은 환각 탐지 신호 (Semantic Entropy, Semantic Energy, 답변 단위 토큰 logit 통계) 가 corpus 빈도 조건에 따라 어떻게 달라지는지를, corpus 신호의 단위 — 단일 entity, entity co-occurrence, 답변 phrase — 에 따라 비교하는 분석 틀을 제안하였다. Qwen2.5-3B 와 다섯 개 질의응답 데이터셋 (총 35,000 개 생성 답변) 위에서 초기 검증을 수행한 결과, entity co-occurrence 신호로 sample 을 나누었을 때 Semantic Entropy 의 구간별 AUROC 는 $\Delta 0.150$ 의 변동 폭을 보였다. 이 값은 단일 entity 빈도 신호로 나누었을 때의 변동 폭 $\Delta 0.080$ 의 약 1.5–1.9 배에 해당한다 (SVAMP 포함 시 1.88 배, 제외 시 1.68 배). 두 변동 폭의 차이에 대한 95% 신뢰구간 [+0.002, +0.117] 은 본 표본에서 방향성이 통계적으로 유의함을 보이지만, 신뢰구간 폭 대비 점추정치 비율로 보면 효과 크기 자체의 정밀도는 낮다. 모집단 비율의 안정성은 추가 모델과 corpus 위에서의 검증이 필요하다. 동일한 corpus 신호가 fusion 모델의 입력 변수로는 +0.008 의 작은 향상에 한정되는 반면, 분해 신호로 사용했을 때는 큰 변동 폭을 보이는 비대칭은, corpus 신호의 설계 목표를 환각 탐지기의 입력이 아니라 탐지 신호의 조건부 평가 도구로 재정의할 필요를 제기한다. 이러한 재정의는 향후 환각 탐지 연구의 corpus 조건부 평가에서 참고할 수 있는 분석 형식으로 활용될 수 있다.

# 참고문헌


[1] L. Huang et al., "A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions," *ACM Transactions on Information Systems,* vol. 43, no. 2, pp. 1–55, 2025.

[2] J. Maynez et al., "On Faithfulness and Factuality in Abstractive Summarization," *Proceedings of ACL,* pp. 1906–1919, 2020.

[3] S. Farquhar, J. Kossen, L. Kuhn, and Y. Gal, "Detecting hallucinations in large language models using semantic entropy," *Nature,* vol. 630, pp. 625–630, 2024.

[4] P. Manakul, A. Liusie, and M. J. F. Gales, "SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models," *Proceedings of EMNLP,* pp. 9004–9017, 2023.

[5] J. Kossen et al., "Semantic Entropy Probes: Robust and Cheap Hallucination Detection in LLMs," *arXiv preprint arXiv:2406.15927,* 2024.

[6] A. Nikitin, J. Kossen, Y. Gal, and P. Marttinen, "Kernel Language Entropy: Fine-grained Uncertainty Quantification for LLMs," *arXiv preprint arXiv:2405.20003,* 2024.

[7] K. Ciosek et al., "Bayesian Estimation of Semantic Entropy for Sample-Efficient Hallucination Detection," *arXiv preprint arXiv:2503.xxxxx,* 2025.

[8] Z. Ma et al., "Semantic Energy: A novel approach for detecting confabulation in language models," *arXiv preprint arXiv:2412.07965,* 2025.

[9] A. Raghuvanshi et al., "Hybrid Token-Level Uncertainty and Semantic Entailment for Hallucination Detection," *arXiv preprint arXiv:2502.xxxxx,* 2025.

[10] A. Ravichander et al., "HALoGEN: Fantastic LLM Hallucinations and Where to Find Them," *arXiv preprint arXiv:2501.08292,* 2025.

[11] S. Singha, "ECLIPSE: Evidence-Conditioned Hallucination Detection via Perplexity Decomposition for Financial QA," *arXiv preprint arXiv:2510.xxxxx,* 2025.

[12] H. Wang, "SEReDeEP: Semantic Entropy + Retrieval-Aware Detection for Enhanced Evaluation Pipelines," *arXiv preprint arXiv:2509.xxxxx*, 2025.

[13] S. Valentin et al., "Cost-Effective Hallucination Detection for LLMs," *arXiv preprint arXiv:2407.21424*, 2024.

[14] W. Zhao et al., "WildHallucinations: Evaluating Long-form Factuality in LLMs with Real-World Entity Queries," *arXiv preprint arXiv:2407.17468*, 2024.

[15] Y. Zhang et al., "Measuring the Impact of Lexical Training Data Coverage on Hallucination Detection in Large Language Models," *arXiv preprint arXiv:2511.17946*, 2025.

[16] J. Liu et al., "Infini-gram: Scaling Unbounded n-gram Language Models to a Trillion Tokens," *arXiv preprint arXiv:2401.17377*, 2024.

[17] A. Yang et al., "Qwen2.5 Technical Report," *arXiv preprint arXiv:2412.15115*, 2024.

[18] M. Joshi, E. Choi, D. S. Weld, and L. Zettlemoyer, "TriviaQA: A Large Scale Distantly Supervised Challenge Dataset for Reading Comprehension," *Proceedings of ACL*, pp. 1601–1611, 2017.

[19] P. Rajpurkar, J. Zhang, K. Lopyrev, and P. Liang, "SQuAD: 100,000+ Questions for Machine Comprehension of Text," *Proceedings of EMNLP*, pp. 2383–2392, 2016.

[20] G. Tsatsaronis et al., "An overview of the BIOASQ large-scale biomedical semantic indexing and question answering competition," *BMC Bioinformatics*, vol. 16, no. 138, 2015.

[21] T. Kwiatkowski et al., "Natural Questions: A Benchmark for Question Answering Research," *Transactions of the ACL*, vol. 7, pp. 453–466, 2019.

[22] A. Patel, S. Bhattamishra, and N. Goyal, "Are NLP Models really able to Solve Simple Math Word Problems?," *Proceedings of NAACL*, pp. 2080–2094, 2021.