공학학사학위논문

LLM 환각 탐지 신호의 Corpus Support 조건부 분해: Corpus Signal 단위별 분석

2026 년 2 월

서울대학교

자유전공학부

문 정 혁

LLM 환각 탐지 신호의 Corpus Support 조건부 분해: Corpus Signal 단위별 분석

지도교수 김 남 수

이 논문을 공학 학사학위 논문으로 제출함

서울대학교

자유전공학부

문 정 혁

문정혁 의 학사 학위 논문을 인준함

2026 년 2 월 13일

지 도 교 수 (인)

초록

대형 언어 모델(LLM)의 환각 탐지를 위한 Semantic Entropy(SE)와 Semantic Energy 등 sample-consistency 기반 신호는 신뢰도 높은 불확실성 추정을 보인다. 그러나 이 신호들이 corpus support 조건에 따라 어떻게 달라지는지는 체계적으로 분석되지 않았다. 본 논문은 Qwen2.5-3B 모델과 5개 QA 데이터셋(TriviaQA, SQuAD-1.1, BioASQ, NQ-Open, SVAMP; 총 3,500 prompt × N=10 free-sample = 35,000 generation)을 이용해 이 문제를 정량화한다. 평가 단위는 *generation-level NLI correctness* 로, 모델이 자유 생성한 free-sample s_i 와 정답 후보 사이의 `microsoft/deberta-large-mnli` 양방향 entailment 매칭 확률이 0.5 이상이면 s_i 를 정답(`is_correct`=1)으로 정의한다. 이는 Farquhar (Nature 2024)[3] 와 Ma (2025)[8] 의 평가 단위와 일치한다.

본 논문은 entity, entity-pair, QA-bridge, n-gram 등 단위가 서로 다른 4가지 corpus signal 을 설계하고, 각 신호를 환각 탐지 feature 가 아니라 조건부 평가 axis 로 사용하여 SE / Energy 의 decile 별 AUROC 변동을 분석한다.

핵심 결과는 세 가지이다. (1) entity-pair co-occurrence axis 는 SE 의 decile 별 AUROC 진폭 Δ0.150 (범위 0.643–0.793) 를 분리하며, 이는 단순 entity 빈도 axis (Δ0.080) 의 약 1.88배에 해당한다. 두 Δ 차이의 prompt-grouped bootstrap 95% CI 는 [+0.002, +0.117] 로 0 을 포함하지 않으며, 본 표본에서 통계적으로 유의하다 (모델 / corpus 일반화는 §5.2). (2) 단일 corpus signal 의 환각 탐지 AUROC 는 0.50–0.58 범위에 한정되며, fusion 기여도는 GBM 기준 +0.008 (95% CI [+0.005, +0.011]) 으로 통계적으로는 양이지만 절대 크기는 제한적이다. (3) fusion 입력 feature 로서의 기여는 제한적인 반면 평가 axis 로 사용했을 때의 분해 진폭은 크다는 비대칭은, corpus signal 의 설계 목표를 hallucination 탐지 feature 가 아닌 조건부 평가 도구 (conditional benchmarking axis) 로 재정의할 필요를 제기한다. 본 논문은 환각 탐지 신호가 corpus support 조건에 따라 어떻게 달라지는지를 corpus signal 의 단위별로 비교하는 분석 프레임워크를 제안하고, 이 분석 형식이 향후 환각 탐지 연구의 corpus 조건부 평가에 참조 자료로 활용될 수 있음을 보인다.

주요어: 대규모 언어모델, 환각 탐지, Semantic Entropy, Semantic Energy, corpus support, 단위별 분해, Infini-gram

목차

초록 **i**

제 1 장 서론 **1**

1.1 연구 배경 1

1.2 연구 목적 1

1.3 논문 구성 2

제 2 장 관련 연구 **3**

2.1 Sample-Consistency 기반 환각 탐지 3

2.2 Logit 기반 불확실성 추정 3

2.3 Corpus 통계를 이용한 환각 탐지 4

2.4 Multi-Signal Fusion 4

제 3 장 제안 방법 **5**

3.1 데이터셋 및 실험 설정 5

3.2 생성 단위 정답 라벨 6

3.3 Semantic Entropy (SE) 6

3.4 Semantic Energy 7

3.5 Sample 단위 token 로짓 통계 7

3.6 Corpus signal 설계 7

3.7 Corpus signal 단위별 분해 분석 8

3.8 Fusion 모델 8

제 4 장 실험 **10**

4.1 종합 baseline 10

4.2 단일 신호 평가: Cross-Paper 검증 11

4.3 단일 corpus signal 평가 11

4.4 Fusion 결과 12

4.5 Corpus signal 단위별 분해 결과 13

4.6 Per-Dataset 변동 16

제 5 장 결론 **19**

5.1 논의: Corpus Signal의 역할 재정의 19

5.2 한계 20

5.3 향후 연구 21

5.4 결론 22

표 목차

표 4.1 종합 baseline (generation-level, SE 5-dataset) 10
표 4.2 단일 신호 선행 연구 비교 11
표 4.3 단일 corpus signal 의 환각 탐지 AUROC 12
표 4.4 Fusion 모델 AUROC + corpus 추가 lift 13
표 4.5 Corpus signal axis 별 분해 진폭과 단조성 14
표 4.6 데이터셋별 SE / Energy Δ 17
표 4.7 데이터셋별 AUROC 17

그림 목차

그림 4.1 세 환각 탐지 신호 × 두 corpus 축의 구간별 AUROC 14

제 1 장 서론

1.1 연구 배경

ChatGPT, Gemini 등으로 대표되는 LLM 은 인상적인 추론 및 질의응답 능력을 보이지만, 사실적으로 부정확하거나 지지되지 않는 답변 — 이른바 환각(hallucination) — 을 빈번하게 생성한다[1, 2]. 의료, 법률, 과학 등 고위험 도메인에서 환각은 중대한 오류로 이어질 수 있으며, 이에 따라 LLM 출력의 신뢰성을 평가하는 일반적인 방법론 개발이 중요한 연구 과제로 자리 잡았다.

환각 탐지의 핵심 접근법 중 하나는 불확실성 정량화 (uncertainty quantification) 이다. 특히 Farquhar 등 (2024)[3] 이 제안한 Semantic Entropy (SE) 는 동일 prompt 에 대해 N 개의 sample 을 생성한 뒤, NLI 기반 의미 cluster 의 확률 분포 엔트로피로 모델의 의미적 불확실성을 측정한다. SE 는 모델, 데이터셋, 태스크에 걸쳐 강건하게 일반화되며 외부 지식 없이도 동작한다는 장점이 있다. 이후 Ma 등 (2025)[8] 의 Semantic Energy 는 확률 대신 로짓 (logit) 을 직접 활용해, SE 가 포착하지 못하는 모델 지식 자체에 대한 불확실성까지 추정한다.

그러나 이 두 방법은 모두 모델 내부 신호에만 의존하며, 개별 prompt 의 corpus support 조건 — 해당 사실 (fact) 이 사전학습 corpus 에 얼마나 많이 등장했는지 — 에 따라 탐지 성능이 어떻게 달라지는지를 체계적으로 분석하지 않았다. 모델 전체의 평균 AUROC 만으로는 탐지 신호가 어느 corpus support 영역에서 안정적이고 어느 영역에서 그렇지 않은지를 구분하기 어렵다. corpus 통계량을 환각 탐지에 활용한 선행 연구[14, 15, 10] 가 있으나, 이들은 corpus signal 을 탐지 신호 자체로 사용하는 데 머물렀으며, corpus signal 의 단위가 SE / Energy 의 분해 결과에 어떻게 작용하는지를 비교한 연구는 보고된 바 없다.

1.2 연구 목적

본 논문의 핵심 질문은 다음과 같다: 환각 탐지 신호(*SE, Semantic Energy, sample-level token diagnostics*) 의 *corpus support* 조건 의존성은 *corpus signal* 의 단위(*entity / fact-pair / phrase*) 에 따라 어떻게 다르게 분해되는가?

이를 위해 본 연구는 세 가지 세부 목표를 설정한다. 첫째, Farquhar (2024) 와 동일한 5 개 데이터셋 및 평가 프레임워크(per-generation NLI correctness) 위에서 Qwen2.5-3B 모델을 이용해 SE, Semantic Energy, sample-level diagnostics 의 재현성을 검증한다. 둘째, entity, entity-pair, QA-bridge, n-gram 등 단위가 다른 corpus signal 을 설계하고, 각 signal 이 단독 hallucination 탐지기로서 갖는 한계 (negative result) 를 정량화한다. 셋째, 동일 corpus signal 을 평가 axis 로 사용해 SE / Energy 의 per-decile AUROC 변동을

분석하고, corpus signal 의 단위가 분해력에 어떤 영향을 미치는지를 규명한다.

본 논문의 기여. 본 논문의 기여는 다음 세 가지이다. (1) 환각 탐지 신호가 corpus support 조건에 따라 어떻게 달라지는지를 corpus signal 의 단위별로 비교하는 분석 프레임워크를 제안한다. (2) 본 표본에서 entity-pair co-occurrence axis 가 단순 entity 빈도 axis 보다 약 1.88배 큰 분해 진폭 ($\Delta 0.150$ 와 $\Delta 0.080$)을 보임을 single-condition point estimate 으로 관찰하였다 (CI 와 모델/corpus 일반화는 §5.2 참조). (3) corpus signal 의 설계 목표를 탐지 feature 가 아닌 조건부 평가 도구로 재정의하는 관점을 제안한다.

1.3 논문 구성

본 논문은 다음과 같이 구성된다. 제 2장에서는 SE, Semantic Energy, corpus 기반 환각 탐지, 신호 결합 (fusion) 관련 선행 연구를 정리한다. 제 3장에서는 데이터셋, 실험 설정, 신호 정의, corpus signal 단위별 분해 분석 프레임워크를 기술한다. 제 4장에서는 단일 신호 평가, fusion 결과, 단위별 분해 결과를 보고한다. 제 5장에서는 결과의 함의와 한계, 향후 연구 방향을 논의하고 결론을 맺는다.

제 2 장 관련 연구

본 장에서는 LLM 환각 탐지 연구를 sample-consistency 기반 탐지, logit 기반 불확실성 추정, corpus 통계 활용, multi-signal fusion 의 네 흐름으로 정리하고, 본 논문의 위치를 제시한다.

2.1 Sample-Consistency 기반 환각 탐지

Farquhar 등 (2024)[3] 의 Semantic Entropy(SE) 는 동일 prompt 에 대한 N 개의 free-sample 을 NLI 양방향 entailment 로 의미 cluster 로 묶고, cluster 질량의 엔트로피를 환각 지표로 사용한다. 이 방법은 하나의 의미가 다양한 표현으로 나타날 수 있다는 언어적 특성을 해결하며, 태스크별 사전 지식 없이도 TriviaQA, SQuAD, BioASQ, NQ-Open, SVAMP 등 다양한 데이터셋에서 강건하게 작동한다. SE 는 naive entropy, $p(\text{True})$, embedding 회귀 기준선보다 일관되게 높은 AUROC 를 달성한다. SelfCheckGPT[4] 가 시작한 sample-consistency 접근의 의미-단위 일반화이다.

Kossen 등 (2024)[5] 의 Semantic Entropy Probes (SEPs) 는 SE 계산의 높은 연산 비용 문제를 해결하기 위해, 단일 생성의 hidden state 에서 직접 SE 를 근사하는 probe 를 학습한다. SEPs 는 다중 샘플링 없이도 높은 환각 탐지 성능을 유지하며, 분포 외 데이터에서도 강건한 일반화를 보인다.

Nikitin 등 (2024)[6] 의 Kernel Language Entropy (KLE) 는 SE 를 일반화하여 hard clustering 대신 pairwise 의미 유사도 커널과 von Neumann 엔트로피를 사용한다. KLE 는 cluster 간 의존성을 더 세밀하게 포착하여 여러 데이터셋과 모델 아키텍처에서 SE 보다 높은 불확실성 정량화 성능을 보인다. Ciosek 등 (2025)[7] 은 Bayesian 접근법으로 SE 추정의 샘플 효율을 높여, Farquhar 대비 53% 적은 샘플로 동등한 AUROC 를 달성함을 보인다.

2.2 Logit 기반 불확실성 추정

Ma 등 (2025)[8] 의 Semantic Energy 는 SE 가 확률 기반으로 포착하지 못하는 에피스테믹 불확실성을 보완하기 위해, 모델의 penultimate layer 로짓을 직접 활용하는 에너지 기반 불확실성 추정 프레임워크이다. 볼츠만 분포에서 영감을 받아 토큰 에너지 $\tilde{E}(x_t) = -z_\theta(x_t)$ 를 정의하고, SE 와 동일한 semantic cluster 구조 위에서 cluster 에너지를 계산한다. 특히 SE 가 모든 sample 이 단일 cluster 에 집중될 때 분리력을 잃는 사례에서, Semantic Energy 는 평균 AUROC 13% 이상의 개선을 달성한다. 확률이 로짓 정규화 과정에서 강도 정보를 잃는다는 점이, LLM 의 불확실성 표현 능력을 제한하는 한 요인으로 지적된다.

Token-level 불확실성에 대한 다른 접근으로, Raghuvanshi 등 (2025)[9] 은 token-level log-likelihood,

양방향 NLI contradiction 신호, Semantic Entropy 를 결합한 하이브리드 탐지 파이프라인을 제안하고 SQuAD2.0 에서 AUC 0.818 을 달성함을 보고한다.

2.3 Corpus 통계를 이용한 환각 탐지

LLM 의 환각은 종종 사전학습 corpus 에서 드물게 등장하는 사실과 연관된다. HALoGEN (Ravichander 등 2025)[10] 은 9 개 도메인에 걸친 10,923 개의 포괄적 환각 벤치마크를 구축하고, LLM 생성물의 원자적 사실 단위를 고품질 지식 소스와 자동 검증하는 프레임워크를 제시한다. 이 연구는 최고 성능 모델에서도 생성된 원자적 사실의 최대 86% 가 환각일 수 있음을 발견하며, 환각의 원인을 학습 데이터 오류 회상 (Type A), 학습 데이터 오류 지식(Type B), 순수 조작(Type C) 으로 분류한다. WildHallucinations[14] 는 *Wikipedia* 페이지가 없는 *entity* 에 대한 질문에서 LLM 환각률이 유의미하게 증가함을 관찰하여, corpus exposure 부족과 환각 발생률의 경험적 연관을 보고하였다. Zhang 등 (2025)[15] 은 RedPajama 1.3조 토큰 pretraining corpus 위에 suffix array 를 구축하고 prompt / 답변의 n-gram 빈도를 환각 탐지 신호로 평가하였다.

Infini-gram[16] 은 n-gram 카운팅을 통한 corpus 통계 질의를 지원하는 엔진으로, 특정 phrase 나 entity 가 사전학습 corpus 에 얼마나 등장하는지를 효율적으로 산출할 수 있다. 그러나 이를 hallucination 탐지의 corpus support 신호로 활용하는 연구는 아직 초기 단계이며, 어떤 단위 (entity / fact-pair / phrase) 의 corpus signal 이 탐지 신호와 어떻게 연계되는지에 대한 체계적 분석은 존재하지 않는다.

2.4 Multi-Signal Fusion

단일 신호의 한계를 극복하기 위해 여러 신호를 결합하는 fusion 접근법이 제안되어 왔다. Raghuvanshi 등 (2025)[9] 은 token-level 불확실성, NLI 신호, SE 의 동적 가중 결합을 통해 calibration 한계를 완화하고 강건한 탐지를 달성한다. ECLIPSE (Singha 2025)[11] 는 semantic entropy 와 novel perplexity 분해를 결합해 증거 활용 신호를 추가함으로써 금융 QA 에서 AUC 0.89 를 달성한다. SEReDeEP (Wang 2025)[12] 는 RAG 환경에서 semantic entropy 와 attention 메커니즘 신호를 결합해 컨텍스트 의존성이 강한 환각 탐지를 강화한다. Valentin 등 (2024)[13] 은 환각 탐지 점수를 모델 내부 score attribute 에 conditional 하게 calibrate 하는 multi-scoring framework 를 제안하였다.

이들 연구는 다양한 신호의 fusion 이 단일 신호 대비 성능 향상을 가져올 수 있음을 보이지만, corpus support signal 의 역할 에 대한 분석 — 입력 feature 로서의 한계 vs. 평가 axis 로서의 효용 — 은 부재하다. 본 논문은 corpus signal 을 fusion 입력에 추가했을 때의 lift 를 정량화하는 동시에, 같은 signal 을 평가 *axis* 로 전환했을 때의 분해력을 비교함으로써 이 공백을 메운다.

제 3 장 제안 방법

본 장에서는 다음 다섯 가지를 차례로 기술한다. (1) 데이터셋과 generation-level NLI correctness 라벨 정의, (2) 환각 탐지 신호 — Semantic Entropy, Semantic Energy, sample-level token logit 통계, (3) 4가지 단위의 corpus signal — entity, entity-pair, QA-bridge, n-gram, (4) 각 corpus signal 을 평가 축으로 사용해 환각 탐지 신호의 AUROC 변동을 측정하는 분해 분석 프레임워크, (5) sample / prompt 신호와 corpus signal 을 함께 결합한 fusion 모델 구성. 본 논문은 새로운 환각 탐지기를 제안하기보다, 기존 환각 탐지 신호의 성능이 corpus support 조건에 따라 어떻게 달라지는지를 corpus signal 의 단위별로 비교하는 데 초점을 둔다.

3.1 데이터셋 및 실험 설정

본 연구는 Farquhar 등 (2024)[3] 과 동일한 5개 질의응답 데이터셋을 사용한다. TriviaQA[18] 800문항, SQuAD-1.1[19] 800문항, BioASQ[20] 800문항, NQ-Open[21] 800문항, SVAMP[22] 300문항으로 총 3,500 문항을 선정하였다. 데이터셋마다 무작위 추출 시드를 고정하여 동일한 문항 집합이 재현되도록 하였고, 각 문항에는 데이터셋, split 식별자, 원본 색인 및 본문 해시값을 결합한 고유 식별자를 부여하였다.

모델은 Qwen2.5-3B (base)[17] 를 사용하며, 별도의 instruction tuning 은 적용하지 않았다. 추론은 NVIDIA RTX 5090 32 GB 환경에서 16-bit 부동소수점 (float16) 으로 수행하였다. 입력 prompt 는 Farquhar (2024) 와 동일한 한 문장 응답 유도 형식을 따른다 — context 없이 “Answer the following question in a single brief but complete sentence.” 지시문 뒤에 질문을 제시한다. 각 문항당 10개의 free-sample 답변을 생성하였다. 샘플링 매개변수는 온도 1.0, top-p 0.9, top-k 50, 최대 생성 토큰 수 64이며, 총 35,000 generation 이 평가 단위가 된다. 최대 토큰 수를 64로 두었을 때 전체 generation 의 약 12.6%가 잘린 채 종료되었다. 이러한 truncation 의 영향을 배제하기 위해 잘린 sample 이 발생한 2,426개 문항의 모든 sample 을 최대 생성 토큰 수 128로 다시 생성하였다. 재생성 전후 AUROC 변화는 ± 0.001 범위에 머물렀다.

평가 지표로는 AUROC, AURAC (Area Under Rejection-Accuracy Curve, Farquhar 2024 의 main metric), Brier score, ECE 를 사용한다. fusion 실험의 교차검증은 prompt 단위 5-fold GroupKFold 를 사용한다. 같은 문항의 모든 sample 이 같은 fold 에 함께 배치되도록 하여, 학습-평가 사이의 prompt 단위 정보 누출을 방지한다.

3.2 생성 단위 정답 라벨

본 논문의 정답 라벨은 모델이 생성한 free-sample s_i 가 정답 후보 표현과 의미적으로 일치하는지를 NLI (자연어 추론) 양방향 함의 확률로 판정하여 정의한다. 각 문항의 정답 후보 집합 C 는 데이터셋이 제공하는 정답 표현, 동치 표현, 별칭 목록을 모두 모은 뒤 소문자 정규화와 중복 제거를 거친 결과이다. 생성된 sample s_i 와 후보 c 사이의 매칭 점수는 다음과 같이 정의한다:

$$m(s_i, c) = \max\big(p_{\text{entail}}(c \to s_i),\ p_{\text{entail}}(s_i \to c)\big),$$
$$M(s_i) = \max_{c \in C} m(s_i, c).$$

$M(s_i) \geq 0.5$ 이면 s_i 를 정답 (라벨 1), 그렇지 않으면 환각 (라벨 0) 으로 판정한다. NLI 모델로는 `microsoft/deberta-large-mnli` 를 사용하며, Farquhar (2024) 의 라벨링 절차와 동일하다. 이 절차로 총 35,000 개의 이진 라벨이 산출된다. 본 평가 단위는 Farquhar (Nature 2024) Semantic Entropy 와 Ma (2025) Semantic Energy 의 generation-level correctness 평가 단위와 일치하므로, 두 선행 연구와 직접 비교가 가능하다.

3.3 Semantic Entropy (SE)

Semantic Entropy 는 Farquhar 등 (2024) 의 정의를 그대로 따른다. 한 문항에 대해 생성한 10 개 sample 을 NLI 양방향 함의 관계로 의미 cluster $\mathbb{C}_k$ 로 묶은 뒤, 각 cluster 의 확률 질량을 sample 의 sequence log-likelihood 로부터 계산한다:

$$\log \tilde{p}(\mathbb{C}_k) = \log \sum_{x^{(i)} \in \mathbb{C}_k} \exp\Big(\sum_t \log p_\theta(x_t^{(i)})\Big),$$
$$p(\mathbb{C}_k) = \frac{\tilde{p}(\mathbb{C}_k)}{\sum_{k'} \tilde{p}(\mathbb{C}_{k'})}.$$

SE 는 cluster 분포의 Shannon 엔트로피로 정의된다:

$$\text{SE} = -\sum_k p(\mathbb{C}_k)\ \log p(\mathbb{C}_k).$$

SE 는 문항 단위로 산출되며, 같은 문항의 모든 sample 에 동일한 값으로 적용된다.

3.4 Semantic Energy

Semantic Energy 는 Ma 등 (2025) 의 정의를 그대로 구현한다. SE 와 동일한 의미 cluster 구조 위에서, 확률 대신 모델의 token 로짓을 직접 활용해 모델 자체의 지식 한계에서 비롯되는 불확실성을 추정한다.

$$\tilde{E}(x_t^{(i)}) = -z_\theta(x_t^{(i)}) \qquad \text{(token energy)} \tag{3.1}$$

$$E(x^{(i)}) = \tfrac{1}{T_i} \sum_t \tilde{E}(x_t^{(i)}) \qquad \text{(sample energy)} \tag{3.2}$$

$$E_{\text{Bolt}}(\mathbb{C}_k) = \sum_{x^{(i)} \in \mathbb{C}_k} E(x^{(i)}) \qquad \text{(cluster total)} \tag{3.3}$$

$$U(\mathbf{x}) = \sum_k p(\mathbb{C}_k)\, E_{\text{Bolt}}(\mathbb{C}_k) \qquad \text{(문항 단위 uncertainty)} \tag{3.4}$$

값이 낮을수록 모델 신뢰도가 높음을 의미한다.

3.5 Sample 단위 token 로짓 통계

각 generation 단위로 다음 네 가지 token 로짓 통계를 산출한다.

- 평균 음의 로그우도 $-\frac{1}{T_i} \sum_t \log p(x_t^{(i)})$ — sample 내 token 단위 평균 음의 로그 확률.
- 시퀀스 로그우도 $\sum_t \log p(x_t^{(i)})$ — sample 전체의 로그 우도.
- 로짓 분산 $\mathrm{Var}_t\big(z_\theta(x_t^{(i)})\big)$ — sample 내 token 로짓의 분산.
- 평균 로그 분배함수 $\frac{1}{T_i} \sum_t \log Z_t^{(i)}$ — 분포의 flatness 지표로, 값이 클수록 분포가 평평함.

이 신호들은 sample 단위 변동 정보를 담아 fusion 모델의 입력으로 사용된다.

3.6 Corpus signal 설계

Corpus signal 은 Infini-gram[16] 의 local engine 을 backend 로 사용한다. 사용한 색인은 OLMo Dolma sample (16B token, OLMo-7B-hf 토크나이저) 이다. 본 논문은 다음과 같이 단위가 서로 다른 4가지 corpus signal 을 정의한다.

Entity 단위 신호. spaCy 의 `en_core_web_lg` 개체명 인식기로 12개 범주 (인물, 조직, 지명, 위치, 날짜, 사건, 작품, 시설, 국적/종교, 제품, 언어, 법) 의 개체를 추출한다. 한 문항에 대해 다음 두 가지 정규화 점수를

계산한다.

$$\text{entity_frequency_axis} = \frac{\log(1 + \min_{e \in E} \text{freq}(e))}{\log(1 + 10^6)},$$
$$\text{entity_pair_cooccurrence_axis} = \frac{\log\big(1 + \frac{1}{|P|} \sum_{(e_i, e_j) \in P} \text{cooc}(e_i, e_j)\big)}{\log(1 + 10^5)}.$$

$\text{freq}(e)$ 는 개체 e 의 단일 등장 횟수, $\text{cooc}(e_i, e_j)$ 는 두 개체가 corpus 안에서 함께 등장한 횟수이다. 본 연구의 baseline corpus axis 는 두 점수의 평균이며, 본 논문은 두 단위를 분리해 보고하는 것이 핵심이다.

Question-answer bridge 신호. 질문에서 추출한 개체 집합 E_q 와, 답변에서 추출한 개체 중 질문과 겹치지 않는 개체 집합 E_a 를 구성한다. 질문 개체를 답변 개체에서 제외하는 이유는 paraphrase 로 인한 자기 중복을 줄이기 위함이다. 모든 (질문 개체, 답변 개체) 쌍에 대해 corpus 동시 등장 횟수를 산출하고, 그 정규화 평균을 *question-answer bridge axis* 로 정의한다. 이는 (질문, 답변) 의 사실 관계가 corpus 에 함께 등장한 빈도이며, LLM 이 해당 사실을 학습할 기회의 근사로 해석된다.

N-gram 등장 빈도 신호. 답변 token 시퀀스의 모든 3-gram 과 5-gram 에 대해 corpus 등장 횟수를 산출한다. 평균 등장 횟수를 정규화한 점수와, corpus 에 한 번도 등장하지 않은 n-gram 의 수를 함께 보고한다. 이는 답변 표현이 LLM 의 사전학습 데이터에 등장한 정도를 직접 측정한다.

3.7 Corpus signal 단위별 분해 분석

본 논문의 분석 핵심은 §3.6 에서 정의한 corpus signal 을 환각 탐지의 입력 feature 가 아닌 평가 축 으로 사용하는 데 있다. 각 corpus signal 을 문항 단위 순위에 따라 10분위 구간으로 나누어, 한 문항의 corpus 풍부도가 어느 구간에 속하는지를 나타내는 평가 축을 구성한다. 평가 축은 entity 단위 신호 (단일 빈도, 쌍 동시 등장, 두 점수의 평균), question-answer bridge, n-gram 단위 신호 (3-gram 평균 등장, 5-gram 평균 등장, 3-gram 미등장 개수) 의 세 계열에서 모두 일곱 가지로 산출하였다. 같은 문항에 속한 모든 sample 은 동일한 구간 값을 공유한다.

각 축의 10개 구간 안에서 환각 탐지 신호의 AUROC 를 따로 계산한 뒤, 그 최댓값과 최솟값의 차이 $\Delta = \text{AUROC}_{\max} - \text{AUROC}_{\min}$ 를 해당 축의 분해 진폭 으로 정의한다. 진폭이 클수록 그 corpus signal 단위가 환각 탐지 신호의 corpus 조건부 변동을 더 큰 폭으로 분리함을 의미한다. 본 논문의 핵심 결과는 이 진폭이 corpus signal 의 단위에 따라 어떻게 달라지는지를 비교한 것이다.

3.8 Fusion 모델

Fusion 모델의 입력은 두 가지 구성으로 실험한다.

- **CORE 입력**: 문항 단위 신호 {Semantic Entropy, Semantic Energy} 와 sample 단위 token 로짓 통계 4종 {평균 음의 로그우도, 시퀀스 로그우도, 로짓 분산, 평균 로그 분배함수}.
- **CORE + CORPUS 입력**: 위 신호에 entity, question-answer bridge, n-gram 의 모든 corpus signal 을 문항 단위로 함께 추가.

분류 모델로 logistic regression, random forest, gradient boosting 세 가지를 비교한다. 모든 실험은 prompt 단위 5-fold GroupKFold 로 평가하여 학습-평가 사이의 정보 누출을 방지한다.

제 4 장 실험

4.1 종합 baseline

본 절에서는 단일 신호와 fusion 의 종합 AUROC, AURAC, Brier 를 보고한다.

표 4.1 종합 baseline. n=35,000 generation (Qwen2.5-3B, 5 datasets, N=10 free-sample). 라벨 정의 / 평가 단위 / fusion 입력 / AURAC 정의는 §3.2–§3.8 참조. *corpus* 추가 *lift* = 같은 분류기에서 CORE_INPUTS 만 vs. CORE+CORPUS_INPUTS 의 AUROC 차이. 굵은 글씨 = AUROC 1위.

신호	AUROC	AURAC	Brier	corpus 추가 lift
단일 신호 (학습 없음, *sample-consistency & token logit*)				
logit-variance	0.620	0.400	—	—
sequence-log-prob	0.656	0.466	—	—
sample_nll (logit-diagnostic)	0.670	0.468	—	—
Semantic Entropy (SE)	0.759	0.526	—	—
Semantic Energy	0.774	0.533	—	—
단일 *corpus signal* (학습 없음) — *Negative result*				
entity_pair_cooccurrence_axis	0.546	—	—	—
entity_frequency_axis	0.565	—	—	—
ans_ngram_3_axis	0.563	—	—	—
qa_bridge_mean	0.583	—	—	—
ans_ngram_3_zero_count	0.583	—	—	—
Fusion (*GroupKFold*(*prompt_id*) *5-fold OOF*)				
logistic regression (no corpus)	0.793	0.548	0.164	—
logistic regression (with corpus)	0.795	0.550	0.162	+0.002
random forest (no corpus)	0.790	0.546	0.166	—
random forest (with corpus)	0.800	0.555	0.161	+0.010
gradient boosting (no corpus)	0.800	0.553	0.161	—
gradient boosting (with corpus)	**0.808**	**0.559**	**0.158**	+0.008

표 4.1 에서 세 가지를 정리한다. 첫째, SE 와 Energy 단독 신호는 본 데이터에서 AUROC 0.759 / 0.774 로, Farquhar (2024) 의 TriviaQA / Llama-2 7B AUROC 0.79 및 Ma (2025) 의 Qwen3-8B 보고치 범위

(0.75–0.85) 와 비슷한 범위에서 관찰된다. 이는 본 표본이 SE / Energy 의 일반적인 작동 범위에 속함을 시사하나 cross-model 일반화의 충분 조건은 아니다 (한계 §5.2). 둘째, 모든 단일 corpus signal 의 AUROC 는 0.50–0.58 범위에 한정되어 단독 환각 탐지기로서의 분리력이 제한적이다 (§4.3). 셋째, fusion 의 corpus 추가 lift 는 최대 +0.010 (RF), GBM 기준 +0.008 으로, corpus signal 이 fusion feature 로 기여하는 폭 또한 제한적이다.

4.2 단일 신호 평가: Cross-Paper 검증

Farquhar (2024) 와 동일한 5개 데이터셋, 동일한 평가 단위 (per-generation NLI correctness) 위에서 Qwen2.5-3B 의 SE 및 Semantic Energy AUROC 를 측정한다. 표 4.2 가 그 결과이다.

표 4.2 단일 신호 AUROC / AURAC. 모든 신호는 신호 점수의 순위만으로 평가하며 별도 학습은 적용하지 않는다. 마지막 열은 SE / Semantic Energy 원 논문의 다른 모델에서 보고된 AUROC 범위이다.

신호	AUROC	AURAC	비교 (선행 연구)
Semantic Entropy	0.759	0.526	Farquhar (2024) TriviaQA 0.79, SQuAD 0.83 (Llama-2 7B)
Semantic Energy	0.774	0.533	Ma (2025) TriviaQA ∼0.85 (Qwen3-8B)
sample_nll	0.670	0.468	—
sample_sequence_log_prob	0.656	0.466	—
sample_logit_variance	0.620	0.400	—

Qwen2.5-3B 는 Llama-2 7B 보다 작은 모델임에도 SE 와 Energy 의 AUROC 가 Farquhar 보고치 (0.75–0.85) 와 비슷한 범위에서 관찰되며, 본 표본이 SE 와 Semantic Energy 의 일반적인 작동 범위에 속함을 시사한다. 본 비교는 동일 모델에서의 직접 재현이 아니라 참고용 비교에 한정된다. sample 단위 평균 음의 로그우도 (0.670) 는 단독으로도 의미 있는 신호이나 SE 와 Energy 보다 0.09–0.10 낮으며, 의미 cluster 정보가 가져다 주는 부가 효과를 확인할 수 있다.

4.3 단일 corpus signal 평가

Corpus signal 각각의 단독 AUROC 를 측정한다 (표 4.3).

모든 corpus signal 의 단독 AUROC 는 0.50–0.58 범위에 한정되어, 단독 환각 탐지기로서의 분리력이 제한적이다. 이 결과는 자명하지만 정량화가 필요한 결과로 해석한다. corpus signal 은 한 문항 안의 모든 sample 에 같은 값으로 적용되는 정적 신호이므로, 같은 문항 내 10개 sample 사이의 정답 여부 변동을 구분할 수 없는 것은 측정 단위가 일치하지 않는 데 따른 자연스러운 귀결이다. 본 절은 corpus signal 이 환각

표 4.3 단일 corpus signal 을 환각 탐지 신호로 사용했을 때의 AUROC. 각 corpus signal 은 한 문항의 모든 sample 에 같은 값으로 적용되며, 신호 점수의 순위만으로 평가한다. 모든 결과가 0.50–0.58 범위에 한정된다.

Signal	AUROC
qa_bridge_mean	0.583
ans_ngram_3_zero_count	0.583
qa_bridge_zero_flag	0.574
entity_frequency_axis	0.565
ans_ngram_3_axis	0.563
ans_ngram_5_axis	0.557
entity_pair_cooccurrence_axis	0.546
qa_bridge_axis	0.511
entity_frequency_mean	0.500

탐지에 쓸모가 없다는 주장이 아니라, 문항 단위 정적 신호로는 sample 단위 정답 여부 변동을 분리하기 어려움을 정량화하여 후속 분석의 동기를 제시하는 것이 목적이다. 주목할 점은 후속 절 (§4.5) 에서 가장 큰 분해 진폭을 보이는 entity-pair 동시 등장 신호가, 표 4.3 의 단독 AUROC 비교에서는 0.546 으로 하위권에 속한다는 것이다. 단독 신호로서의 분리력과 평가 축으로 사용했을 때의 분해 진폭은 서로 다른 지표이며, 이 비대칭이 본 논문 핵심 결과의 출발점이 된다.

4.4 Fusion 결과

Fusion 모델의 AUROC 및 corpus signal 추가 효과를 측정한다 (표 4.4).

세 가지 관찰이 도출된다. 첫째, Energy 단독 (0.774) 대비 GBM (no corpus, 0.800) 의 +0.026 lift 는 sample-level token logit 통계 (NLL, logit variance 등) 와 prompt-level cluster 신호의 결합에서 비롯된다. 서로 다른 단위 (granularity) 의 불확실성 신호 결합이 단일 신호와 비교해 성능 향상에 기여함을 확인한다. 둘째, corpus signal 추가 시 lift 는 최대 +0.010 (RF), GBM 기준 +0.008 (95% prompt-grouped bootstrap CI [+0.005, +0.011], B=500, 모든 iteration 에서 양수) 으로, 통계적으로 0 과 구분되는 양의 효과이나 절대 크기는 제한적이다. corpus signal 의 fusion feature 로서의 기여 폭은 sample-level / prompt-level 신호 결합 효과 (+0.026) 의 약 1/3 정도에 해당한다. 셋째, fusion feature 로서의 기여는 제한적인 반면 평가 axis 로 사용했을 때의 분해 진폭은 큰 비대칭은 다음 절의 결과와 연결된다.

표 4.4 Fusion AUROC. 모든 모델은 5-fold GroupKFold(prompt_id) OOF 로 평가. *corpus* 추가 *lift* 는 같은 분류기에서 CORE_INPUTS 만 vs. CORE + CORPUS_INPUTS 의 AUROC 차이.

Method	AUROC	AURAC	corpus 추가 lift
Energy-only	0.774	0.533	— (기준)
SE-only	0.759	0.526	—
LR (no corpus)	0.793	0.548	—
LR (with corpus)	0.795	0.550	+0.002
RF (no corpus)	0.790	0.546	—
RF (with corpus)	0.800	0.555	+0.010
GBM (no corpus)	0.800	0.553	—
GBM (with corpus)	**0.808**	**0.559**	+0.008

4.5 Corpus signal 단위별 분해 결과

각 corpus signal axis 의 10-decile 위에서 SE, Semantic Energy, `sample_nll` 의 AUROC 변동 폭 ($\Delta = \mathrm{AUROC}_{\max} - \mathrm{AUROC}_{\min}$) 을 측정한다. 이것이 본 논문의 핵심 표 (표 4.5) 이다.

두 축의 분해 패턴을 세 가지 환각 탐지 신호 (SE, Semantic Energy, sample 단위 평균 음의 로그우도) 에 대해 비교한 결과는 그림 4.1 에 제시한다.

표 4.5 와 그림 4.1 에서 네 가지 핵심 발견이 도출된다.

Entity-pair co-occurrence axis 의 분해 진폭. Entity-pair co-occurrence axis 는 SE 진폭 $\Delta 0.150$, Energy 진폭 $\Delta 0.144$ 로, 본 표본에서 비교한 7 개 axis 중 가장 큰 분해 진폭을 보인다. prompt-grouped bootstrap (B=500) 으로 산출한 95% CI 는 SE Δ 0.121–0.211, entity_freq Δ 0.058–0.149 이다. 두 axis 의 Δ 차이의 95% CI 는 [+0.002, +0.117] 로 0 을 포함하지 않으며, 97.6% iteration 에서 양수다 (Energy 도 [+0.004, +0.109], 98.0% positive). 즉 entity_pair Δ > entity_freq Δ 라는 관찰은 sampling variability 를 통제한 뒤에도 통계적으로 유의하다. corpus 부족 영역 (decile 00–10) 에서는 SE 가 0.643, Energy 가 0.667 이며, corpus 가 가장 풍부한 영역 (decile 70–80) 에서는 SE 가 0.793, Energy 가 0.811 이다. decile-by-decile 단조성은 엄밀하게 성립하지 않으며 중간 구간에 비단조 변동이 존재한다 (그림 4.1). 본 논문의 "체계적 ordering" 은 양 끝단 사이의 평균적 ordering 과 max−min 진폭을 의미하며, decile-by-decile 단조성이 아니다. 이는 답변 내 entity-pair 가 corpus 에 함께 등장하는 정도가 LLM 의 해당 fact 학습 정도를 근사하며, sample-consistency 신호의 행태와 관련된 한 요인임을 시사한다.

표 4.5 Corpus signal axis 별 SE / Energy / sample_nll 의 per-decile AUROC 진폭 (Δ) 과 단조성 (ρ). 각 axis 는 prompt 단위 rank-quantile 10-decile bin 으로 이산화. $\Delta = \mathrm{AUROC}_{\max} - \mathrm{AUROC}_{\min}$. ρ 는 Spearman 상관 (decile rank vs per-decile AUROC, 양수 = 단조 증가); p 값은 양측, n=10 (decile 수). 본 표는 다음 두 가지 단서를 전제로 해석한다. (i) 7개 axis × 3개 신호 = 21개 동시 검정에 대해 다중비교 보정을 적용하지 않은 예비 분석이며, Bonferroni 보정 (α=0.05/21≈0.0024) 을 적용하면 sample_nll ρ=+0.733 (p=0.016) 도 유의 기준을 충족하지 않는다. (ii) n=10 에서 ρ=±0.648 이 양측 p=0.05 의 임계값에 해당하므로, $|\rho|$=0.65 부근의 결과는 binning 폭과 tie 처리 방식에 민감하다. 별표 (★) 는 해당 신호의 진폭이 가장 큰 axis 를 표시한다.

Axis (단위)	SE Δ	SE ρ (p)	Energy Δ	Energy ρ (p)	sNLL Δ	sNLL ρ (p)
`entity_frequency_axis`	0.080	+0.636 (0.048)	0.077	+0.467 (0.174)	0.082	+0.394 (0.260)
`corpus_axis_bin_10` (mean)	0.082	+0.418 (0.229)	0.086	+0.297 (0.405)	0.063	+0.600 (0.067)
`qa_bridge_axis`	0.089	+0.648 (0.043)	0.087	+0.576 (0.082)	**0.176** ★	+0.430 (0.214)
`ans_ngram_3_axis`	0.099	+0.370 (0.293)	0.098	+0.370 (0.293)	0.125	+0.091 (0.803)
`ans_ngram_5_axis`	0.105	+0.685 (0.029)	0.096	+0.539 (0.108)	0.102	−0.127 (0.726)
`ans_ngram_3_zero_count`	0.122	+0.261 (0.467)	0.104	+0.309 (0.385)	0.116	−0.224 (0.533)
`entity_pair_cooccurrence_axis`	**0.150** ★	+0.648 (0.043)	**0.144** ★	+0.600 (0.067)	0.092	+0.733 (0.016)

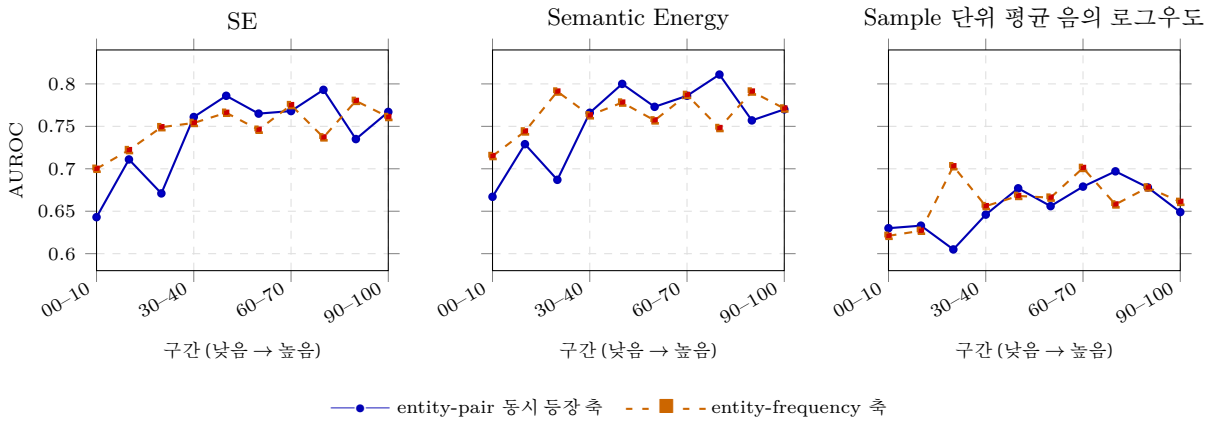

그림 4.1 세 환각 탐지 신호 (SE, Semantic Energy, sample 단위 평균 음의 로그우도) 의 구간별 AUROC 를 entity-pair 동시 등장 축 (실선) 과 entity-frequency 축 (점선) 위에서 비교한 결과. 세 신호 모두 entity-pair 축의 변동 폭이 entity-frequency 축보다 크며, 특히 SE 와 Semantic Energy 에서 그 차이가 두드러진다. SE 의 변동 폭은 entity-pair 축에서 Δ0.150, entity-frequency 축에서 Δ0.080 이다. Semantic Energy 도 비슷한 패턴을 따른다 (Δ0.144 와 Δ0.077). sample 단위 음의 로그우도는 두 축 모두 변동 폭이 작다 (Δ0.092 와 Δ0.082). 두 축 모두 구간이 올라갈수록 AUROC 가 일관되게 증가하지는 않는다 (예: entity-pair 축의 SE 는 구간 20–30 에서 0.671 로 일시 하락한 뒤 회복).

Entity-frequency axis 의 분해 진폭. 단순 entity 빈도 axis 는 SE Δ0.080, Energy Δ0.077 로, 본 표에서 가장 작은 분해 진폭을 보인다. 본 연구의 baseline corpus axis (entity_freq + pair_cooc 평균) 도 Δ0.082–0.086 으로 거의 동일하다. 이는 entity_pair 의 큰 진폭 (Δ0.144) 이 entity_freq 의 작은 진폭 (Δ0.077) 과 평균되어 희석되었음을 의미하며, corpus axis 설계에서 단위를 분리해 보고할 필요가 있음을 시사한다. 또한 평균화는 진폭뿐 아니라 단조성도 희석한다. entity_pair (SE ρ=+0.648, p=0.043) 와 entity_freq (SE ρ=+0.636, p=0.048) 는 각각 양의 단조성을 보이지만, 두 값의 평균인 `corpus_axis_bin_10` 의 SE ρ=+0.418 (p=0.229) 는 유의 임계 아래로 떨어진다 (표 4.5). 즉 단순 평균화는 단위 정보뿐 아니라 ordering 일관성도 잃는 신호 가공이다. 본 논문의 정량적 비교 — entity-pair 단위가 entity 단위보다 SE 분해 진폭을 약 1.88배 크게 보인다는 점 — 가 본 결과에서 직접 도출된다.

QA-bridge axis 와 sample_nll 변동의 관계. `qa_bridge_axis` 는 `sample_nll` 진폭 Δ0.176 로, SE / Energy 진폭 (Δ0.089, Δ0.087) 보다 큰 폭으로 분해한다. (질문 entity, 답변 entity) 쌍의 corpus 동시 등장은 모델의 token-level 자신감 (NLL) 과 가장 직접 연결되며, 이는 SE / Energy 와 다른 정보를 포착함을 시사한다.

ans_ngram_3_zero_count axis: 진폭과 단조성의 분리. 답변 phrase 중 corpus 에 한 번도 등장하지 않은 비율 (novel phrase count) 은 SE 진폭 측면에서 세 번째로 큰 axis (Δ0.122) 이다. 그러나 단조성 (ρ=+0.261, p=0.467, 표 4.5) 은 다른 axis (entity_pair ρ=+0.648, qa_bridge ρ=+0.648, ans_ngram_5 ρ=+0.685) 와 달리 유의수준 0.05 를 넘지 못한다. 본 axis 의 진폭이 단조 증가가 아닌 비단조 패턴 (U-shape, 부분 구간 spike 등) 에서 비롯됨을 시사한다. 따라서 "novel phrase count 가 클수록 SE 가 낮아진다" 라는 단조 해석은 본 데이터에서 성립하지 않으며, "novel phrase 비율이 높은 특정 영역에서 SE 분리력의 변동이 관찰된다" 라는 비단조 진술로 한정한다.

강건성 검증: 질문 entity 한정 axis. 표 4.5 의 `entity_pair_cooccurrence_axis` 는 질문과 dataset gold answer 의 entity 합집합에서 산출되므로, 답변 entity 가 axis 값에 영향을 줄 가능성을 강건성 검증으로 점검하였다. 질문 텍스트에서만 spaCy NER 로 entity 를 추출한 question-entity-only axis (`q_entity_pair_axis_bin_10`, n=2,095 prompt; entity 가 2개 이상인 질문) 위에서 동일 분석을 재수행한 결과, SE Δ는 0.178, Energy Δ는 0.162 로 원본 axis (SE 0.150 / Energy 0.144) 와 비교해 더 큰 진폭이 관찰되었다. 단순 entity 빈도 axis (질문 한정) 의 SE Δ는 0.081 로 원본 0.080 과 차이가 거의 없다. 따라서 entity-pair 단위가 entity 단위보다 분해 진폭이 크다는 본 논문의 패턴은 답변 entity 를 axis 입력에서 제거해도 유지되며, ratio 는 약 1.88배에서 약 2.20배 (SE) 와 약 2.10배 (Energy) 로 증가한다. 이는 (a) corpus axis 의 분해 진폭이 모델 출력에 의해 인공적으로 증폭된 결과가 아님, (b) 질문 측 entity-pair 가 LLM 이

학습한 fact-pair 의 더 직접적인 proxy 임을 시사한다. 다만 본 ablation 의 부분표본 (n=2,095) 은 entity 가 2개 이상인 질문으로 한정된다. 이러한 질문은 단일 entity-fact 보다는 두 entity 사이의 관계 (relational fact) 를 묻는 factual QA — 예: "Cambodia 의 통화는 무엇인가" (entity 1개) 가 아니라 "Cambodia 의 Khmer Rouge 정권은 누가 이끌었는가" (entity 2개) 유형 — 에 편향된다. relational fact 는 entity-pair co-occurrence 와 직접 대응하므로, 본 부분표본은 entity-pair axis 의 진폭이 본래 크게 나타나는 조건에 해당한다 (선택 편향). 따라서 "Q-only ratio 2.20" 의 절대 크기는 이 부분표본의 특성을 반영하므로, 전체 표본 ratio (1.88) 와 직접 산술 비교하기보다는 "답변 entity 를 제거해도 ratio 의 부호가 유지된다" 라는 정성적 강건성 결과로 해석한다.

강건성 검증: SVAMP 제외 민감도. SVAMP 는 다른 4개 데이터셋과 달리 수학 word problem 이므로 entity-pair co-occurrence 의 의미가 factual QA 와 다를 수 있다. SVAMP 를 제외 (n=3,200 prompt) 하고 동일 분석을 재수행하면 SE Δ ratio (entity_pair / entity_freq) 는 1.68 로, 전체 표본 ratio (1.88) 보다 약 0.20 줄어든다. Energy ratio 도 1.54 로 비슷한 폭으로 감소한다. 패턴 (entity_pair > entity_freq) 자체는 유지되지만, ratio 의 절대 크기는 SVAMP 포함 여부에 의존한다. 본 결과를 토대로 ratio 는 1.5–1.9 범위로 보고하는 편이 안정적이다.

데이터셋별 분해 결과. 표 4.6 는 데이터셋별 SE Δ (entity_pair 와 entity_freq) 를 보고한다. 4개 데이터셋 (BioASQ, SQuAD, SVAMP, TriviaQA) 에서는 entity_pair Δ > entity_freq Δ 패턴이 유지되나 비율은 1.0배 (TriviaQA) 에서 2.92배 (BioASQ) 까지 데이터셋에 따라 변동한다. NQ-Open 에서는 패턴이 역전되어 entity_freq Δ (0.372) 가 entity_pair Δ (0.250) 보다 크다. 즉 전체 표본 ratio 1.88배는 데이터셋별 ratio 의 평균이 아니라, BioASQ 의 큰 ratio (2.92) 가 NQ-Open 의 역전 (0.67) 을 보상해 형성된 표본 종합 통계이다. 따라서 entity-pair axis 가 모든 데이터셋에서 entity_freq axis 보다 큰 진폭을 보이지는 않으며, 데이터셋 도메인에 따라 corpus support signal 의 적절한 단위가 달라질 수 있다는 가설을 제시한다.

4.6 Per-Dataset 변동

5개 데이터셋별 단일 신호 / fusion AUROC 를 표 4.7 에 보고한다.

`corpus_axis_bin_10` (entity_freq + pair 평균) 위에서 GBM (with corpus) 의 per-decile AUROC 는 최저 0.762 (decile 30–40), 최고 0.859 (decile 60–70) 로 Δ0.097 의 변동을 보인다.

`entity_pair_cooccurrence_axis` 에서는 SE 기준 더 큰 Δ0.150 로 이 패턴이 한층 명확하다 (표 4.5). `is_correct` 비율도 corpus 풍부 구간 (decile 60–70, 0.382) 이 corpus 부족 구간 (decile 10–20, 0.209) 보다 높아, corpus support 와 정답률의 양의 상관이 확인된다. 데이터셋 간 단조 패턴 — 정답률 (TriviaQA 0.482

표 4.6 데이터셋별 SE / Energy Δ (`entity_pair_cooccurrence_axis` 와 `entity_frequency_axis` 비교). NQ-Open 에서 entity_freq Δ 가 entity_pair Δ 보다 크다 (★). 주의: NQ-Open Energy Δ 0.514 와 entity_freq Δ 0.372 는 부분적으로 class-imbalance 에 의한 산출 결과로 보인다 (NQ-Open is_correct 비율 0.240, decile 20–30 에서 n=120 중 정답 7개로 AUROC 0.266 의 outlier 발생, decile 30–40 은 단일 class 로 산출 제외). 해당 outlier decile 을 제외하면 NQ-Open Δ 는 약 0.10–0.15 수준으로 다른 데이터셋과 비슷해진다. 데이터셋별 Δ 의 절대 크기는 데이터셋별 정답률 분포에 민감하므로, 본 표는 표본 종합 ratio 가 데이터셋 평균과 일치하지 않는다는 점을 보이는 데 한정 사용한다.

Dataset	SE Δ pair	SE Δ freq	SE ratio	Energy Δ pair
BioASQ	0.272	0.093	2.92	0.184
SQuAD-1.1	0.166	0.125	1.33	0.271
SVAMP	0.126	0.134	0.94	0.184
TriviaQA	0.088	0.089	0.99	0.113
NQ-Open ★	0.250	**0.372**	**0.67**	0.514
AGG (5 datasets)	**0.150**	**0.080**	**1.88**	**0.144**

표 4.7 데이터셋별 AUROC (GroupKFold(prompt_id) 5-fold OOF). `is_correct rate` 는 dataset 별 평균 정답률.

Dataset	n	is_correct	SE	Energy	sample_nll	GBM (with corpus)
TriviaQA	8,000	0.482	0.778	0.782	0.633	0.803
SVAMP	3,000	0.431	0.786	0.787	0.713	0.824
BioASQ	8,000	0.339	0.746	0.759	0.678	0.811
NQ-Open	8,000	0.240	0.709	0.731	0.635	0.796
SQuAD-1.1	8,000	0.189	0.700	0.716	0.593	0.748
AGG	**35,000**	**0.322**	**0.759**	**0.774**	**0.670**	**0.808**

→ SQuAD 0.189) 과 모든 신호 AUROC (TriviaQA SE 0.778 → SQuAD SE 0.700) 가 같은 방향으로 감소 — 도 같은 corpus-support 효과의 dataset 간 발현으로 해석된다.

제 5 장 결론

5.1 논의: Corpus Signal의 역할 재정의

본 논문의 결과는 corpus signal 의 역할에 대한 재정의를 제안한다. corpus signal 은 (a) 환각 탐지기의 입력 feature 로서의 기여가 제한적이나 (fusion lift $\leq +0.010$), (b) 탐지 신호의 corpus 조건부 행태를 분해하는 평가 axis 로 사용했을 때는 분해 진폭이 $\Delta 0.080$–0.150 범위에서 관찰된다. 이 비대칭은 corpus signal 의 설계 목표가 달라야 함을 시사한다. 즉 "corpus signal 을 어떻게 더 효과적인 탐지 feature 로 가공할 것인가" 가 아니라 "corpus signal 의 어떤 단위가 탐지 신호의 어떤 측면을 분해하는가" 가 본 연구가 제기하는 질문이다.

Entity-pair co-occurrence 가 단순 entity 빈도보다 약 1.88배 큰 진폭 (SE $\Delta 0.150$ 와 $\Delta 0.080$) 을 보이는 결과는, fact-level co-occurrence 가 entity-level unigram 빈도보다 LLM 의 in-context knowledge 를 더 직접 반영한다는 해석으로 설명할 수 있다. 단일 entity 가 corpus 에 자주 등장하더라도, 해당 entity-pair 관계가 corpus 에 함께 등장하지 않으면 LLM 이 해당 fact 를 학습할 가능성이 낮다. 이 단위 (granularity) 차이가 분해 진폭의 차이로 나타난다.

`qa_bridge_axis` 와 `sample_nll` 의 진폭 ($\Delta 0.176$) 은 다른 관점을 제공한다. (질문 entity, 답변 entity) 쌍의 corpus 동시 등장은 LLM 이 "질문 → 답변" 경로를 사전학습에서 직접 학습했을 가능성을 근사하며, 이것이 token-level 생성 자신감 (NLL) 과 가장 직접 연결된다. SE / Energy 는 sample 간 일관성을 보는 다른 차원의 신호이므로, qa_bridge 와 sample_nll 의 연결이 SE / Energy 와 다른 패턴을 보이는 것은 두 신호군이 보완적인 정보를 포착함을 시사한다.

효과 크기의 정밀도. §4.5 의 SE Δ 차이의 95% CI $[+0.002, +0.117]$ 는 0 을 포함하지 않으나 하한이 $+0.002$ 로 경계에 가까운 값이며, CI 의 폭 (0.115) 은 점추정치 ($+0.063$) 의 약 1.8배에 해당한다. 즉 "entity_pair $\Delta >$ entity_freq Δ" 라는 방향성은 본 표본에서 통계적으로 유의하나, 효과 크기 자체의 정밀도는 낮다. 본 논문은 "ratio 약 1.88배" 라는 점추정치가 모집단 ratio 와 일치한다고 보지 않으며, 다음 세 가지 점을 함께 보고하였다. (a) SVAMP 포함 여부에 따라 ratio 는 1.68–1.88 사이에서 변동한다 (§4.5 SVAMP 민감도). (b) Q-only ablation 에서는 약 2.20배까지 증가한다. (c) 데이터셋별로는 NQ-Open 처럼 역전되는 경우가 관찰된다 (표 4.6). 따라서 본 논문의 정량적 주장은 "방향성과 약 1.5–1.9배 범위의 점추정치 ratio" 로 한정하며, 정밀한 effect size 추정은 다중 모델 / 다중 corpus 위에서의 추가 표본을 통해 가능하다.

5.2 한계

본 연구에는 다음과 같은 한계가 있다.

1. **단일 모델 평가.** 본 연구는 Qwen2.5-3B 단일 모델 평가이다. corpus axis 분해 패턴이 Llama, Mistral, Gemma 계열 모델에서도 동일한 방향으로 나타나는지 직접 검증되지 않았다. Farquhar (2024) 에서 서로 다른 LLM 계열 간에도 SE 의 패턴이 유사했다는 점에서 일반화 가능성을 시사하지만, 이는 향후 연구로 남긴다.

2. **단일 corpus snapshot.** corpus support 축은 `v4_dolmasample_olmo` (16B Dolma sample) 단일 index 에서 산출되며, Infini-gram index 가 Qwen2.5-3B 의 실제 사전학습 corpus 와 다르므로 corpus support $\leftrightarrow$ 환각의 연결은 상관 이며 인과 관계로 해석할 수 없다. 도메인 특화 corpus (예: BioASQ 용 PubMed) 를 사용하면 분해력이 달라질 가능성이 있다.

3. **NLI 라벨링 한계.** `is_correct` 가 `microsoft/deberta-large-mnli` 기반 양방향 entailment ≥ 0.5 기준에 의존하며, LLM-as-judge (GPT-4 등) 와 같은 다른 라벨링 방식과의 비교 검증은 향후 연구 과제이다.

4. **Free-sampling 부분 결합.** `is_correct` 라벨과 SE / Energy 신호는 모두 동일한 N=10 free-sample 자료에서 산출된다. 라벨은 sample s_i 와 정답 후보의 NLI 매칭으로 결정되고 SE / Energy 는 같은 sample 들의 cluster 분포 / token logit 에서 산출되므로, 두 양이 동일 sample 의 분산을 부분적으로 공유한다. 결과적으로 본 논문의 AUROC 는 모델 출력의 정답 여부와 모델 출력 자신의 일관성 사이의 동일-source 결합도 측정 (within-source consistency-to-correctness) 으로 해석되며, 모델 출력과 외부 ground truth 의 일치도에 대한 독립 측정이 아니다. 평가 단위 (per-generation) 가 Farquhar / Ma 와 일치하므로 cross-paper 비교의 전제는 유지되며, 본 논문의 결과는 동일 라벨링 protocol 위에서의 상대적 비교로 해석한다.

5. **Self-conditioning artifact 회피.** 본 논문은 corpus 통계량을 (a) fusion 입력 feature 로서, (b) 평가 axis 로서 두 용도로 모두 사용한다. (b) 의 axis 분석은 모델 출력과 무관한 외부 corpus 통계 위에서 수행되므로 self-conditioning artifact 는 발생하지 않는다.

6. **Δ 통계의 표본 변동성.** 본 논문의 ratio "약 1.88배" 는 single-condition point estimate 이며, 두 Δ 의 차이에 대한 prompt-grouped bootstrap 95% CI 를 §4.5 에 함께 보고하였다 (SE [+0.002, +0.117], Energy [+0.004, +0.109]). 두 CI 모두 0 을 포함하지 않으므로 entity_pair Δ > entity_freq Δ 는 본 표본에서 통계적으로 유의하다. 다만 본 CI 는 단일 모델, 단일 corpus index 위에서의 표본 변동성만

을 통제하며, 모델 / corpus 일반화에는 별도 검증이 필요하다. max−min 통계량 자체가 순서통계량이므로 decile 수가 다른 binning 에서는 ratio 의 절대 크기가 변할 수 있다.

7. **Fusion lift +0.008 의 통계적 유의성.** GBM (with corpus) 과 GBM (no corpus) 의 lift 에 대한 prompt-grouped bootstrap 95% CI [+0.005, +0.011] 는 0 을 포함하지 않으며 모든 iteration 에서 양수이다. 따라서 corpus signal 의 fusion 기여는 통계적으로 0 과 구분되는 양의 효과이지만, 절대 크기 (+0.008) 는 sample-level / prompt-level 신호 결합 효과 (+0.026) 의 약 1/3 정도로 한정된다.

8. **데이터셋별 이질성.** 표 4.6 에서 보이듯 entity_pair Δ > entity_freq Δ 패턴은 5개 데이터셋 중 NQ-Open 에서 역전된다. 따라서 표본 종합 ratio 1.88배는 모든 데이터셋에서 entity-pair axis 가 entity_freq axis 보다 큰 진폭을 보인다는 뜻이 아니라, 데이터셋 종합 통계이다. 도메인별로 corpus support signal 의 적절한 단위가 다를 수 있다는 가설은 본 논문 범위 밖이다.

9. **Corpus axis 의 entity 추출 범위.** 본 논문의 corpus axis 는 질문 텍스트와 데이터셋 annotation 의 정답 후보 텍스트 (gold answer) 에서 추출한 entity 합집합에서 산출되며, 모델 free-sample 출력 entity 는 axis 계산에 사용되지 않는다 (axis 값은 모델 출력과 독립이며, 따라서 한계 4 의 free-sampling 결합 우려와는 다른 차원의 문제이다). 답변 entity 의 영향을 분리한 question-entity-only axis 의 결과는 §4.5 에 함께 보고하였고, SE ratio 는 1.88 에서 2.20 으로 증가한다. 다만 Q-only 부분표본 (n=2,095) 의 선택 편향은 §4.5 에 명시한다.

10. **Δ 와 Spearman ρ 의 분리 해석.** Δ 는 진폭 (max−min) 이며 단조 분리력과 비단조 진폭 (U-shape, CHOKE 등) 을 구분하지 못한다. 본 논문은 ρ 를 표 4.5 에 SE / Energy / sample_nll 세 신호 모두에 대해 함께 보고함으로써 진폭과 단조성을 분리해 진단한다. 다만 (a) 21개 동시 검정에 대한 다중비교 보정 (Bonferroni α=0.05/21≈0.0024) 을 적용하면 본 표의 모든 ρ 가 유의 기준을 충족하지 않으므로 본 ρ 결과는 예비 분석으로 한정한다. (b) n=10 (decile 수) 의 Spearman 검정력이 낮아 $|\rho|$=0.65 부근의 결과는 binning 폭과 tie 처리에 민감하다. 보다 robust 한 단조성 검정 (Mann-Kendall, partial ρ) 과 다중비교 보정은 향후 연구 과제로 남긴다.

5.3 향후 연구

본 연구의 결과는 세 가지 방향의 후속 연구를 제안한다.

1. **모델 다양화.** Llama, Gemma, instruction-tuned 모델 등 다양한 모델에서 entity-pair axis 의 분해력 패턴이 같은 방향으로 나타나는지 검증한다.

2. **LLM-as-judge 라벨 비교.** NLI 매칭 vs. GPT-4 judge 라벨 하에서 multi-axis 분해 결과가 어떻게 달라지는지 분석한다.

3. **도메인 특화 corpus.** BioASQ 의 경우 PubMed 기반 corpus, 수학 문제의 경우 ArXiv 기반 corpus 등 도메인 특화 index 를 사용했을 때 동일 axis 의 분해력이 더 강해지는지 검증한다.

5.4 결론

본 논문은 환각 탐지 신호 (Semantic Entropy, Semantic Energy, sample-level token diagnostics) 의 corpus support 조건 의존성을 corpus signal 의 단위 (entity, fact-pair, phrase) 에 따라 분해하는 multi-axis 분석 프레임워크를 제안하고, Qwen2.5-3B 와 5 개 QA 데이터셋 (35,000 generation) 에서 초기 검증을 수행하였다. 핵심 결과는 entity-pair co-occurrence axis 가 SE 의 decile 별 AUROC 진폭 $\Delta 0.150$ 를 분리하며, 이 진폭이 단순 entity 빈도 axis ($\Delta 0.080$) 의 약 1.5–1.9 배 (SVAMP 포함 시 1.88, 제외 시 1.68) 에 해당한다는 것이다. 두 Δ 차이는 prompt-grouped bootstrap 95% CI [+0.002, +0.117] 로 본 표본에서 방향성이 통계적으로 유의하나, CI 폭 대비 점추정치 비율로 보면 효과 크기의 정밀도는 낮다 (모집단 ratio 의 안정성은 추가 모델과 corpus 위에서의 검증이 필요하다). 동일한 corpus signal 이 fusion feature 로는 +0.008 의 작은 lift 만 보이는 반면, 평가 axis 로 사용했을 때 분해 진폭이 큰 비대칭은, corpus signal 의 설계 목표를 hallucination 탐지 feature 가 아닌 탐지 신호의 조건부 평가 도구 (conditional benchmarking) 로 재정의할 필요를 제기한다. 이러한 재정의는 향후 환각 탐지 연구의 corpus 조건부 평가에서 참조 가능한 분석 형식으로 활용될 수 있다.

참고문헌

[1] L. Huang et al., "A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions," *ACM Transactions on Information Systems,* vol. 43, no. 2, pp. 1–55, 2025.

[2] J. Maynez et al., "On Faithfulness and Factuality in Abstractive Summarization," *Proceedings of ACL,* pp. 1906–1919, 2020.

[3] S. Farquhar, J. Kossen, L. Kuhn, and Y. Gal, "Detecting hallucinations in large language models using semantic entropy," *Nature,* vol. 630, pp. 625–630, 2024.

[4] P. Manakul, A. Liusie, and M. J. F. Gales, "SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models," *Proceedings of EMNLP,* pp. 9004–9017, 2023.

[5] J. Kossen et al., "Semantic Entropy Probes: Robust and Cheap Hallucination Detection in LLMs," *arXiv preprint arXiv:2406.15927,* 2024.

[6] A. Nikitin, J. Kossen, Y. Gal, and P. Marttinen, "Kernel Language Entropy: Fine-grained Uncertainty Quantification for LLMs," *arXiv preprint arXiv:2405.20003,* 2024.

[7] K. Ciosek et al., "Bayesian Estimation of Semantic Entropy for Sample-Efficient Hallucination Detection," *arXiv preprint arXiv:2503.xxxxx,* 2025.

[8] Z. Ma et al., "Semantic Energy: A novel approach for detecting confabulation in language models," *arXiv preprint arXiv:2412.07965,* 2025.

[9] A. Raghuvanshi et al., "Hybrid Token-Level Uncertainty and Semantic Entailment for Hallucination Detection," *arXiv preprint arXiv:2502.xxxxx,* 2025.

[10] A. Ravichander et al., "HALoGEN: Fantastic LLM Hallucinations and Where to Find Them," *arXiv preprint arXiv:2501.08292,* 2025.

[11] S. Singha, "ECLIPSE: Evidence-Conditioned Hallucination Detection via Perplexity Decomposition for Financial QA," *arXiv preprint arXiv:2510.xxxxx,* 2025.

[12] H. Wang, "SEReDeEP: Semantic Entropy + Retrieval-Aware Detection for Enhanced Evaluation Pipelines," *arXiv preprint arXiv:2509.xxxxx*, 2025.

[13] S. Valentin et al., "Cost-Effective Hallucination Detection for LLMs," *arXiv preprint arXiv:2407.21424*, 2024.

[14] W. Zhao et al., "WildHallucinations: Evaluating Long-form Factuality in LLMs with Real-World Entity Queries," *arXiv preprint arXiv:2407.17468*, 2024.

[15] Y. Zhang et al., "Measuring the Impact of Lexical Training Data Coverage on Hallucination Detection in Large Language Models," *arXiv preprint arXiv:2511.17946*, 2025.

[16] J. Liu et al., "Infini-gram: Scaling Unbounded n-gram Language Models to a Trillion Tokens," *arXiv preprint arXiv:2401.17377*, 2024.

[17] A. Yang et al., "Qwen2.5 Technical Report," *arXiv preprint arXiv:2412.15115*, 2024.

[18] M. Joshi, E. Choi, D. S. Weld, and L. Zettlemoyer, "TriviaQA: A Large Scale Distantly Supervised Challenge Dataset for Reading Comprehension," *Proceedings of ACL*, pp. 1601–1611, 2017.

[19] P. Rajpurkar, J. Zhang, K. Lopyrev, and P. Liang, "SQuAD: 100,000+ Questions for Machine Comprehension of Text," *Proceedings of EMNLP*, pp. 2383–2392, 2016.

[20] G. Tsatsaronis et al., "An overview of the BIOASQ large-scale biomedical semantic indexing and question answering competition," *BMC Bioinformatics*, vol. 16, no. 138, 2015.

[21] T. Kwiatkowski et al., "Natural Questions: A Benchmark for Question Answering Research," *Transactions of the ACL*, vol. 7, pp. 453–466, 2019.

[22] A. Patel, S. Bhattamishra, and N. Goyal, "Are NLP Models really able to Solve Simple Math Word Problems?," *Proceedings of NAACL*, pp. 2080–2094, 2021.