공학학사학위논문

LLM 환각 탐지 신호의 Corpus Support 조건부 분해: Corpus Signal 단위별 분석

2026 년 2 월

서울대학교

자유전공학부

문 정 혁

LLM 환각 탐지 신호의 Corpus Support 조건부 분해: Corpus Signal 단위별 분석

지도교수 김 남 수

이 논문을 공학 학사학위 논문으로 제출함

서울대학교

자유전공학부

문 정 혁

문정혁 의 학사 학위 논문을 인준함

2026 년 2 월 13일

지 도 교 수 (인)

초록

대규모 언어모델 (LLM) 은 그럴듯한 거짓 답변, 즉 환각 (hallucination) 을 자주 만든다. 이 때문에 모델 출력의 신뢰도를 자동으로 판별하는 환각 탐지 신호 — Semantic Entropy, Semantic Energy 등 — 가 활발히 연구되고 있다. 이러한 탐지 신호의 성능은 보통 평균 AUROC 한 숫자로 보고된다. 그러나 모델이 잘 아는 사실과 잘 모르는 사실은 분명히 다르므로, 평균 한 숫자는 탐지기가 어디서 잘 작동하고 어디서 흔들리는지 를 가리는 한계가 있다.

본 논문은 이 평균 뒤에 가려진 변동을 분해한다. 각 sample 에 대해 사전학습 corpus 에 어떤 사실 패턴이 얼마나 등장했는지를 기준으로 sample 을 그룹별로 나누고, 환각 탐지 신호의 AUROC 를 그룹별로 따로 측정한다. 이때 corpus 패턴을 어떤 단위 로 보느냐가 핵심이다. 단일 entity 가 얼마나 자주 등장했는지로 볼 수도 있고, 두 entity 가 함께 얼마나 등장했는지 (entity co-occurrence) 로 볼 수도 있으며, 답변 어구의 n-gram 등장 빈도로 볼 수도 있다.

핵심 결과는 다음과 같다. 질문 entity 와 답변 entity 가 corpus 에 자주 함께 등장한 sample 에서는 Semantic Entropy 의 AUROC 가 0.793 인 반면, 거의 함께 등장하지 않은 sample 에서는 0.643 로 크게 떨어진다. 같은 분석을 단순히 단일 entity 의 등장 횟수로 수행하면 AUROC range 이 절반 수준으로 줄어든다. 즉 “Paris–France 가 같이 등장하는지” 같은 *entity co-occurrence* 정보가, “Paris” 한 단어의 등장 빈도보다 환각 탐지기의 신뢰도를 약 1.88배 더 세밀하게 분해한다.

이 결과는 corpus 신호의 역할에 대한 관점 전환을 제시한다. corpus 신호는 환각 탐지기의 입력 변수로 추가했을 때는 성능 향상이 미미하지만, 탐지기가 신뢰할 수 있는 영역과 그렇지 않은 영역을 가르는 평가 척도 로 사용했을 때는 큰 AUROC range 를 보인다. 이러한 비대칭은 향후 환각 탐지 연구가 평균 한 숫자가 아니라 corpus 조건별 AUROC range 를 함께 보고해야 함을 시사하며, 실제 LLM 서비스에서도 corpus 뒷받침이 약한 질문은 별도로 검증하는 조건부 신뢰 전략의 토대가 될 수 있다. 본 연구는 Qwen2.5-3B 와 5개 QA 데이터셋 (TriviaQA, SQuAD-1.1, BioASQ, NQ-Open, SVAMP, 총 3,500 sample, 35,000 생성 답변) 위에서 1차 검증을 수행하였으며, 통계 검정과 신뢰구간은 §4.5 와 §5.2 에 상세히 보고한다.

주요어: 대규모 언어모델, 환각 탐지, Semantic Entropy, Semantic Energy, corpus support, 단위별 분해, Infini-gram

목차

초록 **i**

제 1 장 서론 **1**

1.1 연구 배경 1

1.2 연구 목적 1

1.3 논문 구성 2

제 2 장 관련 연구 **3**

2.1 Sample-Consistency 기반 환각 탐지 3

2.2 Logit 기반 불확실성 추정 3

2.3 Corpus 통계를 이용한 환각 탐지 4

2.4 다중 신호 결합 (Multi-Signal Fusion) 4

제 3 장 제안 방법 **6**

3.1 데이터셋 및 실험 설정 6

3.2 답변 단위 정답 라벨 7

3.3 Semantic Entropy 7

3.4 Semantic Energy 7

3.5 각 답변의 token logit 통계 8

3.6 Corpus 신호 설계 8

3.7 Corpus 신호 단위별 분해 분석 9

3.8 Fusion 모델 9

제 4 장 실험 **11**

4.1 주요 신호의 종합 성능 11

4.2 단일 신호 성능과 선행 연구 비교 12

4.3 단일 corpus 신호의 환각 탐지 성능 12

4.4 신호 결합 (fusion) 결과 13

4.5 Corpus 신호 단위별 분해 결과 14

4.6 데이터셋별 변동 18

제 5 장 결론 **21**

5.1 논의 21

5.2 한계 22

5.3 향후 연구 23

5.4 결론 24

표 목차

표 4.1 주요 신호의 종합 성능 11
표 4.2 단일 신호 성능과 선행 연구 비교 12
표 4.3 단일 corpus 신호의 환각 탐지 성능 13
표 4.4 Fusion 모델 AUROC 와 corpus 추가 효과 14
표 4.5 Corpus 신호별 구간별 AUROC range 과 단조성 16
표 4.6 데이터셋별 Semantic Entropy / Semantic Energy AUROC range 19
표 4.7 데이터셋별 AUROC 19

그림 목차

그림 4.1 세 환각 탐지 신호와 두 corpus 신호의 구간별 AUROC 15

제 1 장 서론

1.1 연구 배경

ChatGPT 와 Gemini 등으로 대표되는 LLM 은 추론과 질의응답에서 높은 성능을 보이지만, 사실과 다르거나 근거가 없는 답변, 즉 환각 (hallucination) 을 자주 만든다[1, 2]. 의료, 법률, 과학과 같은 고위험 도메인에서 환각은 중대한 오류로 이어질 수 있다. 그래서 모델 출력의 신뢰성을 자동으로 판별하는 환각 탐지 가 중요한 연구 과제로 자리 잡았다.

대표적인 접근은 모델의 불확실성을 정량화하는 것이다. Farquhar 등 (2024)[3] 의 Semantic Entropy 는 같은 질문에 대해 모델이 생성한 여러 답변이 의미적으로 얼마나 흩어져 있는지를 측정한다. 답변들이 서로 같은 의미로 모이면 모델이 확신한 것이고, 의미가 갈리면 모델이 흔들린 것이라는 직관이다. Ma 등 (2025)[8] 의 Semantic Energy 는 확률 대신 logit 을 직접 활용해, Semantic Entropy 가 포착하지 못하는 모델 지식 자체의 한계까지 반영한다. 두 신호는 외부 지식 없이도 LLM 출력의 신뢰도를 가늠할 수 있는 도구로 자리 잡았다.

그러나 이러한 탐지 신호의 성능은 보통 평균 AUROC 한 숫자로 보고된다. 이 평균은 모델이 잘 아는 사실과 모르는 사실을 한꺼번에 섞은 결과이다. 모델은 사전학습 데이터에 자주 등장한 사실은 잘 알고, 거의 등장하지 않은 사실은 잘 모를 가능성이 높다. 그렇다면 탐지 신호의 신뢰도도 두 영역에서 다를 수밖에 없는데, 평균 한 숫자는 이 차이를 가린다. “우리 탐지기는 AUROC 0.79이다” 라는 진술만으로는 이 탐지기를 어떤 질문에 신뢰하고 어떤 질문에 신뢰하지 말아야 하는지 알 수 없다.

corpus 통계량을 환각 탐지에 활용한 선행 연구[14, 15, 10] 가 있으나, 이들은 corpus 신호를 탐지기 자체의 입력으로 사용하는 데 머물렀다. corpus 통계가 탐지 신호의 영역별 신뢰도 를 어떻게 분해하는지, 그리고 어떤 단위 (단일 entity 빈도, entity 쌍 동시 등장, n-gram 등) 가 그 분해를 가장 잘 설명하는지는 비교 분석된 바 없다.

1.2 연구 목적

본 논문은 다음 직관에서 출발한다. “Paris” 라는 단어가 corpus 에 자주 등장한다고 해서 모델이 “Paris 가 France 의 수도” 라는 사실을 학습했다고 단정할 수는 없다. 모델이 이 사실을 학습할 가능성은 “Paris” 한 단어의 빈도보다, “Paris” 와 “France” 가 corpus 에 함께 얼마나 등장했는지에 더 직접 연결될 것이다. 만약 그렇다면, 환각 탐지 신호의 신뢰도도 단일 entity 빈도가 아니라 entity 쌍의 동시 등장 빈도에 따라 더 분명하게 갈릴 것이다.

이 직관을 토대로 본 논문의 핵심 질문은 다음과 같이 정리된다. 환각 탐지 신호 (Semantic Entropy, Semantic Energy, 답변 단위 logit 통계) 의 신뢰도가 corpus 의 사실 등장 패턴에 따라 어떻게 달라지는가. 그리고 단일 entity 빈도, entity 쌍의 동시 등장 (entity co-occurrence), 답변 어구의 n-gram 빈도 가운데 어떤 단위가 이 변동을 가장 잘 설명하는가.

이 질문에 답하기 위해 세 가지 세부 목표를 설정한다. 첫째, 기존 환각 탐지 신호 (Semantic Entropy, Semantic Energy, 답변 단위 logit 통계) 의 성능을 동일 평가 절차 위에서 재현한다. 둘째, 단위가 서로 다른 corpus 신호 (entity 빈도, entity co-occurrence, question-answer bridge, n-gram) 를 설계하고, 각 신호 자체가 단독 환각 탐지기로 쓸 만한지 평가한다. 셋째, 같은 corpus 신호로 sample 을 그룹별로 나누었을 때 환각 탐지 신호의 구간별 AUROC 가 어떻게 변동하는지 비교하고, corpus 신호의 단위가 AUROC range 에 어떤 영향을 미치는지 정량화한다.

본 논문의 기여. 본 연구의 기여는 다음 세 가지이다. (1) 환각 탐지 신호의 신뢰도가 corpus 조건에 따라 어떻게 달라지는지를 corpus 신호의 단위별로 비교하는 분석 절차를 제시한다. (2) 본 표본에서 entity co-occurrence 가 단일 entity 빈도보다 환각 탐지 신호의 신뢰도 변동을 약 1.88배 더 세밀하게 분해함을 1차 검증한다. 이 결과는 “entity co-occurrence 가 단일 entity 빈도보다 모델의 학습 정도를 더 직접 반영한다” 는 직관과 부합한다. (3) corpus 신호의 설계 목표를 환각 탐지기의 입력 변수 가 아니라 탐지 신호의 조건부 평가 척도 로 다시 설정하는 관점을 제시한다. 이 관점은 환각 탐지 연구의 평가 보고 방식과, 실제 LLM 서비스에서의 corpus 조건부 신뢰 전략 모두에 시사점을 갖는다.

1.3 논문 구성

본 논문은 다음과 같이 구성된다. 제 2장에서는 Semantic Entropy, Semantic Energy, corpus 기반 환각 탐지, 신호 결합(fusion) 관련 선행 연구를 정리한다. 제 3장에서는 데이터셋, 실험 설정, 신호 정의, corpus 신호 단위별 분석 절차를 기술한다. 제 4장에서는 단일 신호 평가, fusion 결과, 단위별 구간 분석 결과를 보고한다. 제 5장에서는 결과의 함의와 한계, 향후 연구 방향을 논의하고 결론을 맺는다.

제 2 장 관련 연구

본 장에서는 LLM 환각 탐지 연구를 네 흐름으로 정리한다. 첫째, 생성 답변 간 의미 일관성에 기반한 탐지 (sample-consistency). 둘째, logit 을 활용한 불확실성 추정. 셋째, 사전학습 corpus 통계의 활용. 넷째, 여러 신호의 결합 (multi-signal fusion) 이다. 각 흐름의 주요 연구를 살펴본 뒤, 본 논문이 위치하는 지점을 제시한다.

2.1 Sample-Consistency 기반 환각 탐지

Farquhar 등 (2024)[3] 의 Semantic Entropy 는 동일 prompt 에 대해 생성한 N 개의 답변을 NLI 양방향 entailment 로 의미 cluster 로 묶고, cluster 질량의 엔트로피를 환각 지표로 사용한다. 이 방법은 하나의 의미가 다양한 표현으로 나타나는 언어적 특성을 반영하며, 태스크별 사전 지식 없이도 TriviaQA, SQuAD, BioASQ, NQ-Open, SVAMP 등 여러 데이터셋에서 일관된 성능을 보인다. Semantic Entropy 는 naive entropy, $p(\text{True})$, embedding 회귀 기준선 대비 일관되게 높은 AUROC 를 달성한다. 이는 SelfCheckGPT[4] 가 제시한 sample-consistency 접근을 의미 단위로 일반화한 것이다.

Kossen 등 (2024)[5] 의 Semantic Entropy Probes (SEPs) 는 Semantic Entropy 계산의 높은 연산 비용을 줄이기 위해, 단일 생성의 hidden state 에서 Semantic Entropy 를 직접 근사하는 probe 를 학습한다. SEPs 는 다중 샘플링 없이도 환각 탐지 성능을 유지하며, 분포 외 데이터에서도 안정적인 일반화를 보인다.

Nikitin 등 (2024)[6] 의 Kernel Language Entropy (KLE) 는 Semantic Entropy 를 일반화하여 hard clustering 대신 pairwise 의미 유사도 커널과 von Neumann 엔트로피를 사용한다. KLE 는 cluster 간 의존성을 더 세밀하게 포착하여, 여러 데이터셋과 모델 구조에서 Semantic Entropy 보다 높은 불확실성 정량화 성능을 보고한다. Ciosek 등 (2025)[7] 은 Bayesian 접근으로 Semantic Entropy 추정의 표본 효율을 높여, Farquhar 등 (2024) 대비 53% 적은 샘플로 동등한 AUROC 를 달성한다.

2.2 Logit 기반 불확실성 추정

Ma 등 (2025)[8] 의 Semantic Energy 는 Semantic Entropy 가 확률 기반 정의로는 포착하지 못하는 모델 자체에 대한 불확실성을 보완하기 위해, 모델의 penultimate layer logit 을 직접 활용하는 에너지 기반 불확실성 추정 프레임워크를 제안한다. 볼츠만 분포에서 영감을 받아 토큰 에너지 $\tilde{E}(x_t) = -z_\theta(x_t)$ 를 정의하고, Semantic Entropy 와 동일한 의미 cluster 구조 위에서 cluster 에너지를 산출한다. Semantic Entropy 는 모든 답변이 단일 cluster 에 집중될 때 분리력을 잃는데, Semantic Energy 는 이 사례에서 평균

AUROC 13% 이상의 개선을 보고한다. 확률이 logit 정규화 과정에서 강도 정보를 잃는다는 점은, LLM 의 불확실성 표현 능력을 제한하는 한 요인으로 지적된다.

토큰 단위 불확실성에 대한 또 다른 접근으로, Raghuvanshi 등 (2025)[9] 은 토큰 단위 log-likelihood, 양방향 NLI contradiction 신호, Semantic Entropy 를 결합한 하이브리드 탐지 파이프라인을 제안하고 SQuAD2.0 에서 AUC 0.818 을 보고한다.

2.3 Corpus 통계를 이용한 환각 탐지

LLM 의 환각은 사전학습 corpus 에서 드물게 등장하는 사실과 자주 연결된다. HALoGEN (Ravichander 등 2025)[10] 은 9 개 도메인에 걸친 10,923 개 항목의 환각 벤치마크를 구축하고, LLM 생성물의 원자적 사실 단위를 고품질 지식 소스와 자동 검증하는 프레임워크를 제시한다. 이 연구는 최고 성능 모델에서도 생성된 원자적 사실의 최대 86% 가 환각으로 분류될 수 있음을 보고하며, 환각의 원인을 학습 데이터 오류 회상 (Type A), 학습 데이터의 잘못된 지식 (Type B), 순수 조작 (Type C) 으로 분류한다. WildHallucinations[14] 는 *Wikipedia* 페이지가 없는 *entity* 에 대한 질문에서 LLM 의 환각률이 유의미하게 증가함을 관찰하여, corpus 노출 부족과 환각 발생률 사이의 경험적 연관을 보고한다. Zhang 등 (2025)[15] 은 RedPajama 1.3 조 토큰 사전학습 corpus 위에 suffix array 를 구축하고, prompt 와 답변의 n-gram 빈도를 환각 탐지 신호로 평가하였다.

Infini-gram[16] 은 n-gram 카운팅을 통한 corpus 통계 질의를 지원하는 엔진으로, 특정 phrase 나 entity 가 사전학습 corpus 에 얼마나 등장하는지를 효율적으로 산출한다. 그러나 이를 환각 탐지의 corpus 지지 신호로 활용하는 연구는 아직 초기 단계이며, 어떤 단위 (entity 빈도, entity co-occurrence, n-gram) 의 corpus 통계 신호가 탐지 신호와 어떻게 연결되는지를 단위별로 비교한 연구는 충분하지 않다.

2.4 다중 신호 결합 (Multi-Signal Fusion)

단일 신호의 한계를 보완하기 위해 여러 신호를 결합하는 fusion 접근이 제안되어 왔다. Raghuvanshi 등 (2025)[9] 은 토큰 단위 불확실성, NLI 신호, Semantic Entropy 의 동적 가중 결합을 통해 calibration 한계를 완화한다. ECLIPSE (Singha 2025)[11] 는 semantic entropy 와 새로운 perplexity 분해를 결합해 증거 활용 신호를 추가함으로써, 금융 QA 에서 AUC 0.89 를 보고한다. SEReDeEP (Wang 2025)[12] 는 RAG 환경에서 semantic entropy 와 attention 메커니즘 신호를 결합해 컨텍스트 의존성이 큰 환각 탐지를 강화한다. Valentin 등 (2024)[13] 은 환각 탐지 점수를 모델 내부 score attribute 에 조건부로 calibrate 하는 다중 점수 프레임워크를 제안한다.

이들 연구는 여러 신호의 결합이 단일 신호 대비 성능 향상으로 이어질 수 있음을 보인다. 그러나 corpus 지지 신호의 역할 — 입력 변수로서의 한계와 sample 분할 신호로서의 효용 — 을 구분해 분석한 연구는

충분하지 않다. 본 논문은 corpus 통계 신호를 fusion 입력에 추가했을 때의 성능 변화를 정량화하는 한편, 같은 신호로 sample 을 나누었을 때 환각 탐지 신호의 AUROC 가 어떻게 달라지는지를 비교함으로써 이 공백을 메운다.

제 3 장 제안 방법

본 장은 다음 다섯 가지를 차례로 기술한다. 첫째, 데이터셋 구성과 NLI 양방향 함의에 기반한 답변 단위 정답 라벨 정의이다. 둘째, 환각 탐지 신호인 Semantic Entropy, Semantic Energy, 그리고 각 답변의 token logit 통계이다. 셋째, 단위가 서로 다른 네 가지 corpus 신호로, entity 빈도, entity co-occurrence, question-answer bridge, n-gram 등장 빈도를 포함한다. 넷째, 각 corpus 신호로 sample 을 구간별로 나누어 환각 탐지 신호의 AUROC 가 어떻게 변동하는지를 측정하는 분석 틀이다. 다섯째, 답변·sample 단위 신호와 corpus 신호를 함께 결합한 fusion 모델 구성이다. 본 논문은 새로운 환각 탐지기를 제안하기보다, 기존 환각 탐지 신호의 성능이 사전학습 corpus 의 뒷받침 정도에 따라 어떻게 달라지는지를 corpus 신호의 단위별로 비교하는 데 초점을 둔다.

3.1 데이터셋 및 실험 설정

본 연구는 Farquhar 등 (2024)[3] 과 동일한 5개 질의응답 데이터셋을 사용한다. TriviaQA[18] 800 sample, SQuAD-1.1[19] 800 sample, BioASQ[20] 800 sample, NQ-Open[21] 800 sample, SVAMP[22] 300 sample 으로 총 3,500 sample 을 선정하였다. 데이터셋마다 무작위 추출 시드를 고정하여 동일한 sample 집합을 재현하였고, 각 sample 에는 데이터셋 이름, split 식별자, 원본 색인, 본문 해시값을 결합한 고유 식별자를 부여하였다.

모델은 Qwen2.5-3B (base)[17] 를 사용하며, 별도의 instruction tuning 은 적용하지 않는다. 추론은 NVIDIA RTX 5090 32 GB 환경에서 16-bit 부동소수점 (float16) 으로 수행하였다. 입력 prompt 는 Farquhar 등 (2024) 와 동일한 한 문장 응답 유도 형식을 따른다. 즉 별도의 context 없이 "Answer the following question in a single brief but complete sentence." 라는 지시문 뒤에 질문을 제시한다. 각 sample 당 10개의 자유 생성 답변을 산출하였다. 샘플링 매개변수는 온도 1.0, top-p 0.9, top-k 50, 최대 생성 토큰 수 64이며, 평가 단위는 총 35,000개의 생성 답변이다. 최대 토큰 수를 64로 두었을 때 전체 답변의 약 12.6%가 중간에 절단된 채 종료되었다. 잘림의 영향을 배제하기 위해 잘린 답변이 발생한 2,426개 sample 의 모든 답변을 최대 생성 토큰 수 128로 다시 생성하였다. 재생성 전후 AUROC 변화는 ± 0.001 범위에 머물렀다.

평가 지표로는 AUROC, AURAC (Area Under Rejection-Accuracy Curve, Farquhar 등 (2024) 의 main metric), Brier score, ECE 를 사용한다. fusion 실험의 교차검증은 prompt 단위 5-fold GroupKFold 로 수행한다. 같은 sample 의 모든 답변이 같은 fold 에 함께 배치되도록 하여 학습-평가 사이의 sample 단위 정보 누출을 방지한다.

3.2 답변 단위 정답 라벨

본 논문의 정답 라벨은 모델이 생성한 답변 s_i 가 정답 후보 표현과 의미적으로 일치하는지를 NLI (자연어 추론) 양방향 함의 확률로 판정하여 정의한다. 각 sample 의 정답 후보 집합 C 는 데이터셋이 제공한 정답 표현, 동치 표현, 별칭 목록을 모두 모은 뒤 소문자 정규화와 중복 제거를 거쳐 구성한다. 생성된 답변 s_i 와 후보 c 사이의 매칭 점수는 다음과 같이 정의한다.

$$m(s_i, c) = \max\big(p_{\text{entail}}(c \to s_i),\ p_{\text{entail}}(s_i \to c)\big),$$
$$M(s_i) = \max_{c \in C} m(s_i, c).$$

$M(s_i) \geq 0.5$ 이면 s_i 를 정답 (라벨 1), 그렇지 않으면 환각 (라벨 0) 으로 판정한다. NLI 모델로는 `microsoft/deberta-large-mnli` 를 사용하며, 절차는 Farquhar 등 (2024) 의 라벨링과 동일하다. 이 절차로 총 35,000 개의 이진 라벨이 산출된다. 본 평가 단위는 Farquhar 등 (2024) 의 Semantic Entropy 와 Ma 등 (2025) 의 Semantic Energy 가 사용한 답변 단위 정답성 평가와 일치하므로, 두 선행 연구와 직접 비교가 가능하다.

3.3 Semantic Entropy

Semantic Entropy 는 Farquhar 등 (2024) 의 정의를 그대로 따른다. 한 sample 에 대해 생성한 10 개 답변을 NLI 양방향 함의 관계로 의미 cluster $\mathbb{C}_k$ 로 묶은 뒤, 각 cluster 의 확률 질량을 답변의 시퀀스 로그 우도로부터 계산한다.

$$\log \tilde{p}(\mathbb{C}_k) = \log \sum_{x^{(i)} \in \mathbb{C}_k} \exp\Big(\sum_t \log p_\theta(x_t^{(i)})\Big),$$
$$p(\mathbb{C}_k) = \frac{\tilde{p}(\mathbb{C}_k)}{\sum_{k'} \tilde{p}(\mathbb{C}_{k'})}.$$

Semantic Entropy 는 cluster 분포의 Shannon 엔트로피로 정의된다.

$$H(\mathbf{x}) = -\sum_k p(\mathbb{C}_k)\ \log p(\mathbb{C}_k).$$

Semantic Entropy 는 sample 단위로 산출되며, 같은 sample 의 모든 답변에 동일한 값이 적용된다.

3.4 Semantic Energy

Semantic Energy 는 Ma 등 (2025) 의 정의를 그대로 구현한다. Semantic Entropy 와 동일한 의미 cluster 구조 위에서, 확률 대신 모델의 token logit 을 직접 활용해 모델 자체의 지식 한계에서 비롯되는 불확실성을

추정한다.

$$\tilde{E}(x_t^{(i)}) = -z_\theta(x_t^{(i)}) \qquad \text{(token energy)} \tag{3.1}$$

$$E(x^{(i)}) = \tfrac{1}{T_i} \sum_t \tilde{E}(x_t^{(i)}) \qquad \text{(sample energy)} \tag{3.2}$$

$$E_{\text{Bolt}}(\mathbb{C}_k) = \sum_{x^{(i)} \in \mathbb{C}_k} E(x^{(i)}) \qquad \text{(cluster total)} \tag{3.3}$$

$$U(\mathbf{x}) = \sum_k p(\mathbb{C}_k)\, E_{\text{Bolt}}(\mathbb{C}_k) \qquad \text{(sample 단위 uncertainty)} \tag{3.4}$$

값이 낮을수록 모델 신뢰도가 높음을 뜻한다.

3.5 각 답변의 token logit 통계

각 답변에 대해 다음 네 가지 token logit 통계를 산출한다.

- 평균 음의 로그우도 $-\frac{1}{T_i} \sum_t \log p(x_t^{(i)})$: 답변 안에서 각 토큰에 대한 음의 로그 확률의 평균.
- 시퀀스 로그우도 $\sum_t \log p(x_t^{(i)})$: 답변 전체의 로그 우도.
- *logit* 분산 $\mathrm{Var}_t\big(z_\theta(x_t^{(i)})\big)$: 답변 안에서 토큰별 logit 의 분산.
- 평균 로그 분배함수 $\frac{1}{T_i} \sum_t \log Z_t^{(i)}$: 분포의 평탄도 지표로, 값이 클수록 분포가 평평하다.

이 신호들은 답변마다 산출된 변동 정보를 담아 fusion 모델의 입력으로 사용된다.

3.6 Corpus 신호 설계

Corpus 신호는 Infini-gram[16] 의 local engine 을 backend 로 사용한다. 사용한 색인은 OLMo Dolma sample (16B token, OLMo-7B-hf 토크나이저) 이다. 본 논문은 단위가 서로 다른 네 가지 corpus 신호를 다음과 같이 정의한다.

Entity 수준 신호. spaCy 의 `en_core_web_lg` 개체명 인식기로 12개 범주 (인물, 조직, 지명, 위치, 날짜, 사건, 작품, 시설, 국적/종교, 제품, 언어, 법) 의 entity 를 추출한다. 한 sample 에 대해 다음 두 가지 정규화 점수를 계산한다.

$$\text{entity 빈도} = \frac{\log(1 + \min_{e \in E} \mathrm{freq}(e))}{\log(1 + 10^6)},$$

$$\text{entity co-occurrence} = \frac{\log\big(1 + \frac{1}{|P|} \sum_{(e_i, e_j) \in P} \mathrm{cooc}(e_i, e_j)\big)}{\log(1 + 10^5)}.$$

freq(e) 는 entity e 의 단일 등장 횟수이고, cooc(e_i, e_j) 는 두 entity 가 corpus 안에서 함께 등장한 횟수이다. 본 연구의 baseline corpus 신호는 두 점수의 평균이며, 본 논문은 두 단위를 분리해 보고하는 데 핵심을 둔다.

Question-answer bridge 신호. 질문에서 추출한 entity 집합 E_q 와, 답변에서 추출한 entity 중 질문과 겹치지 않는 entity 집합 E_a 를 구성한다. 질문 entity 를 답변 entity 에서 제외하는 이유는 paraphrase 로 인한 자기 중복을 줄이기 위함이다. 모든 (질문 entity, 답변 entity) 쌍에 대해 corpus 동시 등장 횟수를 산출하고, 그 정규화 평균을 question-answer bridge 신호로 정의한다. 이는 질문과 답변 사이의 관계가 corpus 에 함께 등장한 빈도이며, LLM 이 해당 관계를 학습할 기회의 근사로 해석된다.

N-gram 등장 빈도 신호. 답변 토큰 시퀀스의 모든 3-gram 과 5-gram 에 대해 corpus 등장 횟수를 산출한다. 평균 등장 횟수를 정규화한 점수와, corpus 에 한 번도 등장하지 않은 n-gram 의 수를 함께 보고한다. 이는 답변 표현이 LLM 의 사전학습 데이터에 등장한 정도를 직접 측정한다.

3.7 Corpus 신호 단위별 분해 분석

본 논문 분석의 핵심은 §3.6 에서 정의한 corpus 신호를 환각 탐지의 입력 변수가 아니라 *sample* 을 분할하는 신호 로 사용하는 데 있다. 각 corpus 신호로 sample 을 순위에 따라 10분위 구간으로 나누어, 한 sample 의 corpus 뒷받침 정도가 어느 구간에 속하는지를 판별한다. sample 분할에 사용한 신호는 entity 수준 신호 세 가지 (entity 빈도, entity co-occurrence, 두 점수의 평균), question-answer bridge 한 가지, n-gram 수준 신호 세 가지 (3-gram 평균 등장, 5-gram 평균 등장, 3-gram 미등장 개수) 로 모두 일곱 가지이다. 같은 sample 에 속한 모든 답변은 동일한 구간 값을 공유한다.

각 신호의 10개 구간 안에서 환각 탐지 신호의 AUROC 를 따로 계산한 뒤, 그 최댓값과 최솟값의 차이 $\Delta = \mathrm{AUROC}_{\max} - \mathrm{AUROC}_{\min}$ 를 해당 신호의 구간별 AUROC range 으로 정의한다. AUROC range 이 클수록 그 corpus 신호로 sample 을 나누었을 때 환각 탐지 신호의 성능이 corpus 조건에 따라 더 큰 차이를 보인다. 본 논문의 핵심 결과는 이 AUROC range 이 corpus 신호의 단위에 따라 어떻게 달라지는지를 비교한 것이다.

3.8 Fusion 모델

Fusion 모델의 입력은 두 가지 구성으로 실험한다.

- **CORE 입력**: sample 단위 신호인 Semantic Entropy, Semantic Energy 와, 답변마다 산출한 token logit 통계 4종 (평균 음의 로그우도, 시퀀스 로그우도, logit 분산, 평균 로그 분배함수).

- **CORE + CORPUS 입력**: 위 신호에 entity, question-answer bridge, n-gram 의 모든 corpus 신호를 sample 단위로 함께 추가한 구성.

분류 모델로는 logistic regression, random forest, gradient boosting 세 가지를 비교한다. 모든 실험은 prompt 단위 5-fold GroupKFold 로 평가하여 학습-평가 사이의 정보 누출을 방지한다.

제 4 장 실험

4.1 주요 신호의 종합 성능

본 절에서는 단일 신호와 fusion 모델의 종합 AUROC, AURAC, Brier 를 보고한다.

표 4.1 주요 신호의 종합 성능. 생성 답변 35,000건 (Qwen2.5-3B, 5개 데이터셋, sample 당 10개 자유 생성 답변) 을 대상으로 측정하였다. 라벨 정의, 평가 단위, fusion 입력, AURAC 정의는 §3.2–§3.8 에서 기술한다. corpus 추가 효과는 같은 분류기에서 핵심 입력만 사용한 경우와 핵심 입력에 corpus 신호를 함께 쓴 경우의 AUROC 차이로 정의한다. 굵은 글씨는 AUROC 가 가장 높은 행을 가리킨다.

신호	AUROC	AURAC	Brier	corpus 추가 효과
단일 신호 (학습 없음, 답변 일관성 및 토큰 *logit* 통계)				
답변 내 logit 분산	0.620	0.400	—	—
답변 전체 로그우도	0.656	0.466	—	—
답변 평균 음의 로그우도 (NLL)	0.670	0.468	—	—
Semantic Entropy	0.759	0.526	—	—
Semantic Energy	0.774	0.533	—	—
단일 *corpus* 신호 (학습 없음)				
entity co-occurrence	0.546	—	—	—
entity 빈도	0.565	—	—	—
답변 3-gram 등장 빈도	0.563	—	—	—
question-answer bridge (평균)	0.583	—	—	—
답변 3-gram 미등장 개수	0.583	—	—	—
Fusion 모델 (*sample* 단위 *5-fold* 교차검증, 검증 *fold* 예측 기준)				
logistic regression (corpus 미포함)	0.793	0.548	0.164	—
logistic regression (corpus 포함)	0.795	0.550	0.162	+0.002
random forest (corpus 미포함)	0.790	0.546	0.166	—
random forest (corpus 포함)	0.800	0.555	0.161	+0.010
gradient boosting (corpus 미포함)	0.800	0.553	0.161	—
gradient boosting (corpus 포함)	**0.808**	**0.559**	**0.158**	+0.008

표 4.1 의 결과는 세 가지로 정리된다. 첫째, Semantic Entropy 와 Semantic Energy 단독 신호의 AUROC

는 각각 0.759 와 0.774 로 측정되었다. 이는 Farquhar 등 (2024) 가 TriviaQA / Llama-2 7B 에서 보고한 0.79, Ma 등 (2025) 가 Qwen3-8B 에서 보고한 0.75–0.85 와 비슷한 범위이다. 본 표본이 Semantic Entropy 와 Semantic Energy 의 일반적인 작동 범위에 속한다고 볼 수 있으나, 모델 간 일반화의 충분 조건은 아니다 (§5.2). 둘째, 모든 단일 corpus 신호의 AUROC 는 0.50–0.58 범위에 한정되어 단독 환각 탐지기로서의 분리력은 제한적이다 (§4.3). 셋째, fusion 에 corpus 신호를 추가했을 때의 AUROC 향상 폭은 random forest 에서 +0.010, gradient boosting 에서 +0.008 으로 측정되었다. corpus 신호가 fusion 의 입력 변수로 기여하는 폭 또한 제한적이다.

4.2 단일 신호 성능과 선행 연구 비교

Farquhar 등 (2024) 와 동일한 5개 데이터셋과 동일한 평가 단위 (생성 답변마다 산출한 NLI 정답 라벨) 위에서 Qwen2.5-3B 의 Semantic Entropy 와 Semantic Energy 의 AUROC 를 측정한다. 결과는 표 4.2 에 정리한다.

표 4.2 단일 신호의 AUROC 와 AURAC. 모든 신호는 신호 점수의 순위만으로 평가하며 별도 학습은 적용하지 않는다. 마지막 열은 Semantic Entropy 와 Semantic Energy 원 논문이 다른 모델에서 보고한 AUROC 범위이다.

신호	AUROC	AURAC	비교 (선행 연구)
Semantic Entropy	0.759	0.526	Farquhar (2024) TriviaQA 0.79, SQuAD 0.83 (Llama-2 7B)
Semantic Energy	0.774	0.533	Ma (2025) TriviaQA ∼0.85 (Qwen3-8B)
답변 평균 음의 로그우도 (NLL)	0.670	0.468	—
답변 전체 로그우도	0.656	0.466	—
답변 내 logit 분산	0.620	0.400	—

Qwen2.5-3B 는 Llama-2 7B 보다 작은 모델임에도 Semantic Entropy 와 Semantic Energy 의 AUROC 가 Farquhar 보고치 (0.75–0.85) 와 비슷한 범위에서 관찰된다. 본 표본이 Semantic Entropy 와 Semantic Energy 의 일반적인 작동 범위에 속한다고 볼 수 있다. 다만 이 비교는 동일 모델에서의 직접 재현이 아니라 참고용 비교에 한정된다. 답변 평균 음의 로그우도 (0.670) 는 단독 신호로도 일정한 분리력을 보이지만, Semantic Entropy 와 Semantic Energy 보다 0.09–0.10 낮다. 의미 cluster 정보가 더해질 때의 부가 효과를 확인할 수 있다.

4.3 단일 corpus 신호의 환각 탐지 성능

각 corpus 신호의 단독 AUROC 를 측정한다. 결과는 표 4.3 에 정리한다.

표 4.3 단일 corpus 신호를 환각 탐지 신호로 사용했을 때의 AUROC. 각 신호는 한 sample 의 모든 답변에 같은 값으로 적용되며, 신호 점수의 순위만으로 평가한다. 모든 결과가 0.50–0.58 범위에 한정된다.

신호	AUROC
question-answer bridge (평균)	0.583
답변 3-gram 미등장 개수	0.583
question-answer bridge (미등장 표시)	0.574
entity 빈도	0.565
답변 3-gram 등장 빈도	0.563
답변 5-gram 등장 빈도	0.557
entity co-occurrence	0.546
question-answer bridge (정규화)	0.511
entity 빈도 (평균)	0.500

모든 corpus 신호의 단독 AUROC 는 0.50–0.58 범위에 한정되며, 단독 환각 탐지기로서의 분리력은 제한적이다. 이 결과는 자명하지만 정량화가 필요한 관찰로 해석한다. corpus 신호는 한 sample 안의 모든 답변에 같은 값으로 적용되는 정적 신호이다. 따라서 같은 sample 에서 생성된 10개 답변 사이의 정답 여부 변동을 구분하지 못하는 것은 측정 단위의 불일치에서 비롯되는 자연스러운 귀결이다. 본 절은 corpus 신호가 환각 탐지에 쓸모가 없다는 주장이 아니라, sample 단위의 정적 신호만으로는 답변 단위의 정답 여부 변동을 분리하기 어렵다는 점을 정량화하여 후속 분석의 동기를 제시하는 데 목적이 있다. 주목할 점은 후속 절 (§4.5) 에서 가장 큰 구간별 AUROC range 을 보이는 entity co-occurrence 신호가, 표 4.3 의 단독 AUROC 비교에서는 0.546 으로 하위권에 머문다는 사실이다. 단독 신호로서의 분리력과, 같은 신호로 sample 을 나누어 분석했을 때의 구간별 AUROC range 은 서로 다른 지표이다. 본 논문 핵심 결과의 출발점이 바로 이 비대칭이다.

4.4 신호 결합 (fusion) 결과

Fusion 모델의 AUROC 와 corpus 신호 추가에 따른 효과를 측정한다 (표 4.4).

세 가지 관찰이 도출된다. 첫째, Energy 단독 (0.774) 대비 gradient boosting (corpus 미포함, 0.800) 의 +0.026 향상은 답변마다 산출한 토큰 logit 통계 (NLL, logit 분산 등) 와 sample 단위로 산출한 cluster 신호의 결합에서 비롯된다. 측정 단위가 서로 다른 불확실성 신호를 결합하는 방식이 단일 신호보다 분리력을 끌어올리는 데 기여한다. 둘째, corpus 신호를 추가했을 때의 향상 폭은 random forest 에서 최대 +0.010, gradient boosting 에서 +0.008 이다 (95% 신뢰구간 [+0.005, +0.011], sample 단위 부트스트랩 반복 500회,

표 4.4 Fusion 모델의 AUROC. 모든 모델은 sample 단위 5-fold GroupKFold 의 검증 fold 예측으로 평가하였다. *corpus* 추가 효과는 같은 분류기에서 핵심 입력만 사용한 경우와 핵심 입력에 corpus 신호를 함께 쓴 경우의 AUROC 차이이다.

Method	AUROC	AURAC	corpus 추가 lift
Semantic Energy 단독	0.774	0.533	— (기준)
Semantic Entropy 단독	0.759	0.526	—
logistic regression (corpus 미포함)	0.793	0.548	—
logistic regression (corpus 포함)	0.795	0.550	+0.002
random forest (corpus 미포함)	0.790	0.546	—
random forest (corpus 포함)	0.800	0.555	+0.010
gradient boosting (corpus 미포함)	0.800	0.553	—
gradient boosting (corpus 포함)	**0.808**	**0.559**	+0.008

모든 반복에서 양수). 통계적으로 0 과 구분되는 양의 효과이지만 절대 크기는 제한적이다. corpus 신호가 fusion 입력 변수로서 기여하는 폭은 답변 단위와 sample 단위 신호를 결합했을 때의 효과 (+0.026) 의 약 3분의 1 수준이다. 셋째, fusion 입력 변수로서의 기여는 제한적인 반면, 같은 신호로 sample 을 분할했을 때의 구간별 AUROC range 은 큰 비대칭이 관찰되며 이는 다음 절의 결과로 이어진다.

4.5 Corpus 신호 단위별 분해 결과

각 corpus 신호로 sample 을 10분위 구간으로 나눈 뒤, 구간 안에서 Semantic Entropy, Semantic Energy, 답변 평균 음의 로그우도 (NLL) 의 AUROC 를 산출하고, 그 최댓값과 최솟값의 차이 $\Delta = \mathrm{AUROC}_{\max} - \mathrm{AUROC}_{\min}$ 를 AUROC range 으로 측정한다. 본 논문의 핵심 결과는 표 4.5 이다.

두 corpus 신호의 분해 패턴을 세 가지 환각 탐지 신호 (Semantic Entropy, Semantic Energy, 답변 평균 NLL) 에 대해 비교한 결과는 그림 4.1 에 제시한다.

표 4.5 와 그림 4.1 에서 다음 네 가지 결과가 도출된다.

Entity co-occurrence 신호의 구간별 AUROC range. Entity co-occurrence 신호로 sample 을 분할하면, Semantic Entropy 의 AUROC range 은 $\Delta 0.150$, Semantic Energy 의 AUROC range 은 $\Delta 0.144$ 로 산출된다. 본 표본에서 비교한 일곱 가지 corpus 신호 가운데 AUROC range 이 가장 큰 값이다. sample 단위 부트스트랩 (반복 500회) 으로 산출한 95% 신뢰구간은 Semantic Entropy AUROC range 이 0.121–0.211, entity 빈도 신호의 AUROC range 이 0.058–0.149 이다. 두 AUROC range 의 차이는 95% 신뢰구간 [+0.002, +0.117] 으로 0 을 포함하지 않으며, 부트스트랩 반복의 97.6% 에서 양수로 관찰된다. Semantic

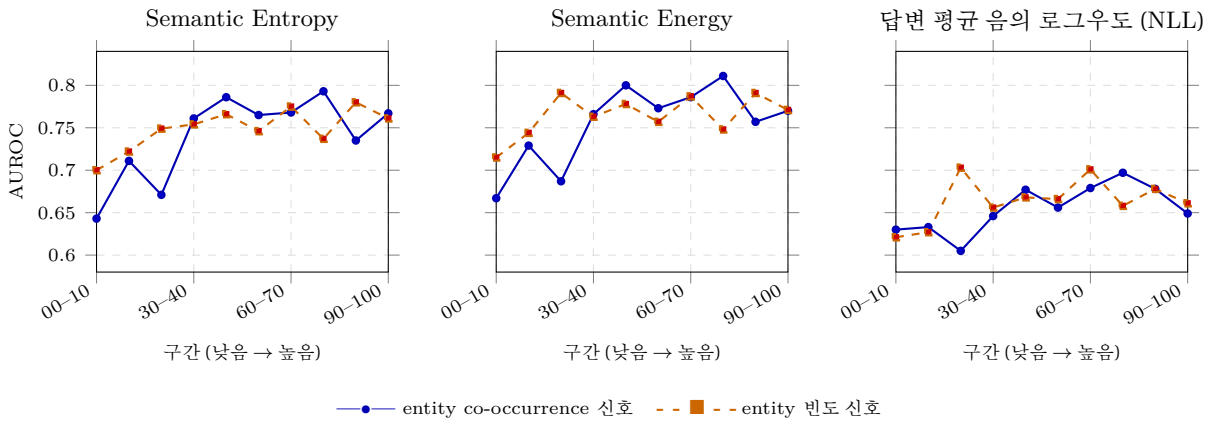

그림 4.1 세 환각 탐지 신호 (Semantic Entropy, Semantic Energy, 답변 평균 NLL) 의 구간별 AUROC 를 entity co-occurrence 신호 (실선) 와 entity 빈도 신호 (점선) 로 sample 을 분할하여 비교한 결과. 세 환각 탐지 신호 모두 entity co-occurrence 신호로 분할했을 때의 AUROC range 이 entity 빈도 신호로 분할했을 때보다 크며, Semantic Entropy 와 Semantic Energy 에서 그 차이가 뚜렷하게 나타난다. Semantic Entropy 의 AUROC range 은 entity co-occurrence 신호에서 $\Delta 0.150$, entity 빈도 신호에서 $\Delta 0.080$ 이다. Semantic Energy 도 비슷한 패턴을 따른다 ($\Delta 0.144$ 와 $\Delta 0.077$). 답변 평균 NLL 은 두 신호 모두에서 AUROC range 이 작다 ($\Delta 0.092$ 와 $\Delta 0.082$). 두 신호 모두 구간이 올라갈수록 AUROC 가 일관되게 증가하지는 않는다. 예를 들어 entity co-occurrence 신호로 분할했을 때 Semantic Entropy 는 구간 20–30 에서 0.671 로 일시 하락한 뒤 회복한다.

표 4.5 Corpus 신호별로 산출한 Semantic Entropy / Semantic Energy / 답변 평균 NLL 의 구간별 AUROC range (Δ) 과 단조성 (ρ). 각 신호는 sample 단위 순위 기반 10분위 구간으로 이산화하였다. $\Delta = \mathrm{AUROC}_{\max} - \mathrm{AUROC}_{\min}$ 으로 정의한다. ρ 는 Spearman 상관 (구간 순위와 구간별 AUROC, 양수는 단조 증가) 이며, p 값은 양측, n=10 (구간 수) 이다. 본 표는 다음 두 단서를 전제로 해석한다. 첫째, 7개 신호 $\times$ 3개 환각 탐지 신호 = 21개 동시 검정에 대해 다중비교 보정을 적용하지 않은 예비 분석이며, Bonferroni 보정 (α=0.05/21≈0.0024) 을 적용하면 답변 평균 NLL 의 ρ=+0.733 (p=0.016) 도 유의 기준을 충족하지 않는다. 둘째, n=10 에서 ρ=±0.648 이 양측 p=0.05 의 임계값에 해당하므로, $|\rho|$=0.65 부근의 결과는 구간 폭과 동순위 처리 방식에 민감하다. 별표 (★) 는 해당 환각 탐지 신호의 AUROC range 이 가장 큰 행을 표시한다.

Corpus 신호 (단위)	Semantic Entropy Δ	Semantic Entropy ρ (p)	Energy Δ	Energy ρ (p)	NLL Δ	NLL ρ (p)
entity 빈도	0.080	+0.636 (0.048)	0.077	+0.467 (0.174)	0.082	+0.394 (0.260)
baseline (entity 빈도 + entity co-occurrence 평균)	0.082	+0.418 (0.229)	0.086	+0.297 (0.405)	0.063	+0.600 (0.067)
question-answer bridge	0.089	+0.648 (0.043)	0.087	+0.576 (0.082)	**0.176** ★	+0.430 (0.214)
답변 3-gram 등장 빈도	0.099	+0.370 (0.293)	0.098	+0.370 (0.293)	0.125	+0.091 (0.803)
답변 5-gram 등장 빈도	0.105	+0.685 (0.029)	0.096	+0.539 (0.108)	0.102	−0.127 (0.726)
답변 3-gram 미등장 개수	0.122	+0.261 (0.467)	0.104	+0.309 (0.385)	0.116	−0.224 (0.533)
entity co-occurrence	**0.150** ★	+0.648 (0.043)	**0.144** ★	+0.600 (0.067)	0.092	+0.733 (0.016)

Energy 에서도 차이가 [+0.004, +0.109] 로 98.0% 가 양수이다. 즉 entity co-occurrence 신호로 분할했을 때의 AUROC range 이 entity 빈도 신호로 분할했을 때보다 크다는 결과는 표본 변동성을 통제한 뒤에도 통계적으로 유지된다. corpus 가 가장 부족한 구간 (00–10) 에서 Semantic Entropy 는 0.643, Semantic Energy 는 0.667 이며, corpus 가 가장 풍부한 구간 (70–80) 에서 Semantic Entropy 는 0.793, Semantic Energy 는 0.811 로 측정되었다. 다만 구간이 한 단계씩 올라갈 때마다 AUROC 가 단조 증가하지는 않으며, 중간 구간에서는 일시적인 하락과 회복이 관찰된다 (그림 4.1). 본 논문에서 사용한 "체계적 정렬" 이라는 표현은 양 끝단 사이의 평균적인 증가 경향과 최댓값과 최솟값의 폭을 가리키며, 인접 구간 사이의 엄밀한 단조 증가를 뜻하지 않는다. 본 결과는 답변에 등장하는 entity co-occurrence 이 corpus 에 함께 등장하는 정도가 LLM 의 해당 사실 학습 가능성을 근사하며, 답변 사이의 일관성을 측정하는 신호의 변동과 연결되는 한 요인임을 시사한다.

Entity 빈도 신호의 구간별 AUROC range. 단일 entity 빈도 (entity frequency) 신호로 sample 을 분할했을 때의 AUROC range 은 Semantic Entropy 기준 Δ0.080, Semantic Energy 기준 Δ0.077 로 본 표에서 가장 작다. 본 연구의 baseline corpus 신호 (entity 빈도와 entity co-occurrence 의 평균) 도 AUROC range 이 Δ0.082–0.086 으로 entity 빈도 신호와 거의 같은 수준이다. entity co-occurrence 신호의 큰 AUROC range 이 entity 빈도 신호의 작은 AUROC range 과 평균되며 희석된 결과로 해석되며, corpus 신호를

설계할 때 두 단위를 따로 보고해야 한다는 점을 시사한다. 평균화의 영향은 AUROC range 뿐 아니라 단조성에서도 나타난다. entity co-occurrence 신호 (Semantic Entropy ρ=+0.648, p=0.043) 와 entity 빈도 신호 (Semantic Entropy ρ=+0.636, p=0.048) 모두 양의 단조성을 보이지만, 두 점수의 평균인 baseline corpus 신호는 Semantic Entropy ρ=+0.418 (p=0.229) 로 유의 임계 아래에 머무른다 (표 4.5). 단위가 다른 두 신호를 평균하면 각 신호가 가지고 있던 단조 증가 경향까지 무뎌진다. 본 논문의 정량 비교 — entity co-occurrence 단위가 entity 빈도 단위보다 Semantic Entropy AUROC range 을 약 1.88배 크게 보인다는 점 — 은 본 결과에서 곧바로 도출된다.

Question-answer bridge 신호와 NLL 변동의 관계. Question-answer bridge 신호 ((질문 entity, 답변 entity) 쌍의 corpus 동시 등장 빈도) 로 sample 을 분할하면, 답변 평균 NLL 의 AUROC range 이 Δ0.176 로 측정된다. Semantic Entropy 와 Semantic Energy 의 AUROC range (Δ0.089, Δ0.087) 보다 큰 폭이다. (질문, 답변) 의 사실 관계가 corpus 에 함께 등장하는 정도가 모델의 토큰 단위 자신감 (NLL) 과 가장 직접 연결되며, Semantic Entropy 나 Semantic Energy 가 포착하는 답변 사이 일관성과는 다른 정보를 측정함을 시사한다.

답변 3-gram 미등장 개수 신호: AUROC range 과 단조성의 분리. 답변에서 corpus 에 한 번도 등장하지 않은 3-gram 의 개수로 sample 을 분할하면, Semantic Entropy AUROC range 은 Δ0.122 로 비교적 큰 편에 속한다. 그러나 단조성은 ρ=+0.261 (p=0.467, 표 4.5) 로, entity co-occurrence (ρ=+0.648), question-answer bridge (ρ=+0.648), 답변 5-gram (ρ=+0.685) 등 다른 신호와 달리 유의수준 0.05 를 넘지 않는다. 이 신호의 AUROC range 은 구간이 올라갈수록 일관되게 증가하는 패턴이 아니라, U자형이나 일부 구간의 일시적 변동에서 비롯된 것으로 보인다. 따라서 "corpus 미등장 3-gram 이 많을수록 Semantic Entropy 가 낮아진다" 라고 단정하기는 어렵고, 미등장 3-gram 비율이 높은 일부 구간에서 Semantic Entropy AUROC 의 변동이 관찰된다는 정도로 해석을 한정한다.

강건성 검증: 질문 entity 한정 신호. 앞서 사용한 entity co-occurrence 신호는 질문과 데이터셋이 제공한 정답 텍스트의 entity 를 모두 합쳐 산출하므로, 답변 측 entity 가 신호 값에 영향을 줄 가능성이 있다. 본 절은 이 가능성을 강건성 검증으로 점검한다. 질문 텍스트에서만 entity 를 추출하여 같은 분석을 재수행하였으며, 질문이 두 개 이상의 entity 를 포함하는 2,095 sample 이 분석 대상이 된다. 그 결과 Semantic Entropy 의 AUROC range 은 0.178, Semantic Energy 의 AUROC range 은 0.162 로, 원래 신호 (Semantic Entropy 0.150, Semantic Energy 0.144) 보다 큰 AUROC range 이 관찰되었다. 질문에 한정한 entity 빈도 신호의 Semantic Entropy AUROC range 은 0.081 로 원래 신호의 0.080 과 거의 같다. 따라서 entity co-occurrence 단위가 entity 빈도 단위보다 AUROC range 이 크다는 본 논문의 결과는 답변 측 entity 를 신호

산출에서 제거해도 유지된다. 비율은 약 1.88배에서 Semantic Entropy 기준 2.20배, Semantic Energy 기준 2.10배로 오히려 증가한다. 이는 두 가지를 시사한다. 첫째, 본 신호의 AUROC range 은 모델 출력으로 인해 인공적으로 부풀려진 결과가 아니다. 둘째, 질문 측 entity co-occurrence이 LLM 의 사전학습된 지식을 더 직접 반영하는 지표일 가능성이 있다. 다만 본 분석의 부분표본은 entity 가 두 개 이상인 질문에 한정된다. 이러한 질문은 단일 entity 의 사실을 묻기보다 entity pair 의 관계를 묻는 지식 질문에 치우친다. entity pair 관계는 정의상 entity co-occurrence 와 직접 대응하므로, 본 부분표본은 entity co-occurrence 신호의 AUROC range 이 본래 크게 나타나는 조건이며, 이는 선택 편향 (selection bias) 에 해당한다. 따라서 비율 2.20 의 절대 크기는 이 부분표본의 특성을 반영한다. 전체 표본의 비율 1.88 과 산술적으로 직접 비교하기보다는, 답변 측 entity 를 제거해도 비율의 부호가 유지된다는 정성적 강건성 결과로 해석한다.

강건성 검증: SVAMP 제외 민감도. SVAMP 는 다른 네 데이터셋과 달리 수학 단어 문제이므로, entity co-occurrence의 의미가 지식 질문과 다를 수 있다. SVAMP 를 제외한 3,200 sample 으로 같은 분석을 재수행하면, Semantic Entropy 기준 비율 (entity co-occurrence AUROC range / entity 빈도 AUROC range) 은 1.68 로 전체 표본의 비율 1.88 보다 약 0.20 줄어든다. Semantic Energy 기준 비율도 1.54 로 비슷한 폭으로 감소한다. 두 단위 사이의 부호 (entity co-occurrence > entity 빈도) 는 유지되지만, 절대 크기는 SVAMP 포함 여부에 따라 달라진다. 본 결과를 토대로 비율은 1.5–1.9 범위로 보고하는 것이 안정적이다.

데이터셋별 분해 결과. 표 4.6 는 데이터셋별 Semantic Entropy AUROC range 을 entity co-occurrence 신호와 entity 빈도 신호 모두에 대해 보고한다. 다섯 데이터셋 중 네 데이터셋 (BioASQ, SQuAD-1.1, SVAMP, TriviaQA) 에서는 entity co-occurrence AUROC range 이 entity 빈도 AUROC range 보다 크거나 같다. 다만 비율은 TriviaQA 의 1.0배에서 BioASQ 의 2.92배까지 큰 폭으로 변동한다. NQ-Open 에서는 부호가 역전되어 entity 빈도 AUROC range (0.372) 이 entity co-occurrence AUROC range (0.250) 보다 크다. 따라서 전체 표본의 비율 1.88배는 데이터셋별 비율의 평균이 아니라, BioASQ 의 큰 비율 (2.92) 이 NQ-Open 의 역전 (0.67) 을 보상하여 형성된 표본 종합 통계이다. 즉 entity co-occurrence 신호가 모든 데이터셋에서 entity 빈도 신호보다 큰 AUROC range 을 보이지는 않는다. 본 결과는 데이터셋 도메인에 따라 적절한 corpus 신호의 단위가 달라질 수 있다는 가설을 제기한다.

4.6 데이터셋별 변동

다섯 데이터셋별로 단일 신호와 fusion 모델의 AUROC 를 표 4.7 에 정리한다.

baseline corpus 신호 (entity 빈도와 entity co-occurrence 의 평균) 로 sample 을 분할하면, gradient boosting (corpus 포함) 의 구간별 AUROC 는 최저 0.762 (구간 30–40) 에서 최고 0.859 (구간 60–70) 까지 $\Delta 0.097$ 의 변동을 보인다. 같은 분석을 entity co-occurrence 신호로 수행하면 Semantic Entropy 기준

표 4.6 데이터셋별 Semantic Entropy 와 Semantic Energy 의 AUROC range 을 entity co-occurrence 신호와 entity 빈도 신호에서 비교한 결과. NQ-Open 에서는 entity 빈도 AUROC range 이 entity co-occurrence AUROC range 보다 크다 (★). 다만 NQ-Open 의 Semantic Energy AUROC range 0.514 와 entity 빈도 AUROC range 0.372 는 정답 분포의 불균형에서 일부 비롯된다. NQ-Open 의 정답률은 0.240 이고, 두 번째 구간 (20–30) 은 표본 120개 중 정답이 7개에 불과하여 AUROC 가 0.266 인 outlier 가 발생하였다. 세 번째 구간 (30–40) 은 단일 클래스로 산출 대상에서 제외되었다. 이 outlier 구간을 제외하면 NQ-Open 의 AUROC range 은 다른 데이터셋과 비슷한 0.10–0.15 수준으로 줄어든다. 따라서 본 표는 표본 종합 비율이 데이터셋 평균과 일치하지 않는다는 점을 보이는 용도에 한정한다.

데이터셋	Semantic Entropy AUROC range (entity co-occurrence)	Semantic Entropy AUROC range (entity 빈도)	Semantic Entropy 비율	Energy AUROC range (entity co-occurrence)
BioASQ	0.272	0.093	2.92	0.184
SQuAD-1.1	0.166	0.125	1.33	0.271
SVAMP	0.126	0.134	0.94	0.184
TriviaQA	0.088	0.089	0.99	0.113
NQ-Open ★	0.250	**0.372**	**0.67**	0.514
전체 표본	**0.150**	**0.080**	**1.88**	**0.144**

표 4.7 데이터셋별 AUROC. sample 단위 5-fold 교차검증의 검증 fold 예측을 기준으로 산출하였다. 정답률은 데이터셋 평균이다.

데이터셋	n	정답률	Semantic Entropy	Semantic Energy	평균 NLL	gradient boosting (corpus 포함)
TriviaQA	8,000	0.482	0.778	0.782	0.633	0.803
SVAMP	3,000	0.431	0.786	0.787	0.713	0.824
BioASQ	8,000	0.339	0.746	0.759	0.678	0.811
NQ-Open	8,000	0.240	0.709	0.731	0.635	0.796
SQuAD-1.1	8,000	0.189	0.700	0.716	0.593	0.748
전체	**35,000**	**0.322**	**0.759**	**0.774**	**0.670**	**0.808**

AUROC range 이 $\Delta 0.150$ 로 더 커져, 패턴이 한층 분명하다 (표 4.5). 정답률도 corpus 가 풍부한 구간 (60–70, 0.382) 이 corpus 가 부족한 구간 (10–20, 0.209) 보다 높아, corpus 뒷받침 정도와 정답률 사이에 양의 상관이 확인된다. 데이터셋 사이의 패턴도 같은 방향이다. 정답률은 TriviaQA (0.482) 에서 SQuAD (0.189) 까지, 환각 탐지 신호 AUROC 도 같은 순서로 감소한다 (Semantic Entropy 기준 TriviaQA 0.778, SQuAD 0.700). 이는 corpus 뒷받침 효과가 데이터셋 사이에서도 동일한 방향으로 나타남을 시사한다.

제 5 장 결론

5.1 논의

본 연구의 결과는 corpus 신호의 역할을 다시 정의한다. corpus 신호는 환각 탐지기의 입력 변수로서 기여가 제한적이며 (fusion lift $\leq +0.010$), 탐지 신호를 corpus 조건에 따라 분해하는 분석 도구로 사용했을 때 AUROC range 이 $\Delta 0.080$–0.150 범위에서 관찰된다. 이 비대칭은 corpus 신호의 설계 목표가 달라야 함을 시사한다. 즉 "corpus 신호를 어떻게 더 효과적인 탐지 입력 변수로 가공할 것인가" 가 아니라 "corpus 신호의 어떤 단위가 탐지 신호의 어떤 측면을 분해하는가" 가 본 연구가 제기하는 질문이다.

Entity co-occurrence 신호로 sample 을 나누었을 때의 AUROC range 은 단일 entity 빈도 신호로 나누었을 때의 AUROC range 보다 약 1.88배 크다 (Semantic Entropy 기준 $\Delta 0.150$ 와 $\Delta 0.080$). 이는 entity co-occurrence 가 단일 entity 빈도보다 LLM 의 사전학습된 지식을 더 직접 반영한다는 해석으로 설명할 수 있다. 어떤 단일 entity 가 corpus 에 자주 등장하더라도 그 entity pair 가 함께 등장하지 않으면 LLM 이 해당 관계를 학습할 가능성은 낮다. 이러한 단위 차이가 AUROC range 의 차이로 나타난다.

Question-answer bridge 신호와 답변 평균 음의 로그우도 (NLL) 사이의 AUROC range ($\Delta 0.176$) 은 다른 관점을 제공한다. 질문 entity 와 답변 entity 의 corpus 동시 등장은 LLM 이 "질문에서 답변으로 이어지는 경로" 를 사전학습에서 직접 학습했을 가능성을 근사하며, 이것이 토큰 단위 생성 자신감을 반영하는 NLL 과 가장 직접 연결된다. Semantic Entropy 와 Energy 는 답변 사이의 일관성을 보는 다른 차원의 신호이므로, question-answer bridge 와 NLL 의 연결이 Semantic Entropy / Energy 와 다른 패턴을 보이는 것은 두 신호군이 보완적인 정보를 포착함을 시사한다.

효과 크기의 정밀도. §4.5 에서 보고한 Semantic Entropy AUROC range 차이의 95% 신뢰구간 [+0.002, +0.117] 은 0 을 포함하지 않으나, 하한이 +0.002 로 경계에 가까우며 신뢰구간 폭 (0.115) 이 점추정치 (+0.063) 의 약 1.8배에 해당한다. 즉 "entity co-occurrence AUROC range 이 entity 빈도 AUROC range 보다 크다" 는 방향성은 본 표본에서 통계적으로 유의하지만, 효과 크기 자체의 정밀도는 낮다. 약 1.88배라는 점추정치가 모집단 비율과 일치한다고 보지 않으며, 다음 세 가지 점을 함께 보고하였다. 첫째, SVAMP 포함 여부에 따라 비율은 1.68 에서 1.88 사이에서 변동한다. 둘째, 질문 entity 만으로 산출한 강건성 검증에서는 비율이 약 2.20배까지 증가한다. 셋째, 데이터셋별로는 NQ-Open 처럼 부호가 역전되는 경우가 관찰된다 (표 4.6). 따라서 정량적 주장은 "방향성이 본 표본에서 유의하며, 비율의 점추정치는 약 1.5–1.9배 범위에 있다" 로 한정한다. 보다 정밀한 효과 크기 추정은 추가 모델과 corpus 위에서의 추가

표본을 통해 가능하다.

5.2 한계

본 연구는 다음과 같은 한계를 지닌다.

1. **단일 모델 평가.** 본 연구는 Qwen2.5-3B 단일 모델에서 수행되었다. corpus 신호의 구간별 변동 패턴이 Llama, Mistral, Gemma 계열 모델에서도 같은 방향으로 나타나는지는 직접 검증되지 않았다. Farquhar 등 (2024)[3] 에서 서로 다른 LLM 계열 사이에서도 Semantic Entropy 의 패턴이 유사하게 관찰되었다는 점은 일반화 가능성을 시사하나, 이는 향후 연구로 남긴다.

2. **단일 corpus 색인.** corpus 신호는 `v4_dolmasample_olmo` (16B Dolma sample) 단일 Infini-gram 색인에서 산출된다. 이 색인이 Qwen2.5-3B 의 실제 사전학습 corpus 와 다르므로, corpus 빈도와 환각 사이의 연결은 상관 관계이며 인과 관계로 해석할 수 없다. 도메인 특화 corpus (예: BioASQ 용 PubMed) 를 사용하면 AUROC range 이 달라질 가능성이 있다.

3. **NLI 라벨링 한계.** 정답 라벨은 `microsoft/deberta-large-mnli` 기반 양방향 entailment ≥ 0.5 기준에 의존한다. LLM-as-judge 와 같은 다른 라벨링 방식과의 비교 검증은 향후 과제로 남는다.

4. **생성 답변에 기반한 라벨과 신호의 부분 결합.** 정답 라벨과 Semantic Entropy / Energy 신호는 모두 동일한 N=10 개의 생성 답변에서 산출된다. 라벨은 각 답변과 정답 후보의 NLI 매칭으로 결정되고, Semantic Entropy / Energy 는 같은 답변들의 의미 cluster 분포와 토큰 logit 에서 산출되므로, 두 양은 동일 답변 집합의 분산을 부분적으로 공유한다. 결과적으로 본 논문의 AUROC 는 모델 출력의 정답 여부와 모델 출력 사이의 일관성이라는 동일 source 상의 결합도를 측정하며, 모델 출력과 외부 정답 텍스트 사이의 일치도에 대한 독립 측정은 아니다. 평가 단위 (생성 답변 단위) 가 Farquhar 와 Ma 의 연구와 일치하므로 선행 연구 비교의 전제는 유지되며, 본 결과는 동일 라벨링 절차 위에서의 상대적 비교로 해석한다.

5. **Self-conditioning 회피.** corpus 통계량은 (a) fusion 입력 변수와 (b) 분석용 분해 신호 두 용도로 모두 사용된다. (b) 의 분해 분석은 모델 출력과 무관한 외부 corpus 통계 위에서 수행되므로 self-conditioning 문제는 발생하지 않는다.

6. **AUROC range 차이의 표본 변동성.** 약 1.88배라는 비율은 단일 조건에서 산출한 점추정치이며, 두 AUROC range 의 차이에 대한 sample 단위 bootstrap 95% 신뢰구간을 §4.5 에 함께 보고하였다 (Semantic Entropy [+0.002, +0.117], Energy [+0.004, +0.109]). 두 신뢰구간 모두 0 을 포함하지 않으므로, entity co-occurrence AUROC range 이 entity 빈도 AUROC range 보다 크다는 결과는 본

표본에서 통계적으로 유의하다. 다만 이 신뢰구간은 단일 모델, 단일 corpus 색인 위에서의 표본 변동성만을 통제하며, 모델과 corpus 일반화에는 별도 검증이 필요하다. 또한 max−min 통계량 자체가 순서통계량이므로 구간 수가 다른 분할에서는 비율의 절대 크기가 달라질 수 있다.

7. **Fusion lift 의 통계적 유의성.** corpus 신호 포함 여부에 따른 gradient boosting 의 lift 에 대한 sample 단위 bootstrap 95% 신뢰구간 [+0.005, +0.011] 은 0 을 포함하지 않으며 모든 반복에서 양수이다. 따라서 corpus 신호의 fusion 기여는 통계적으로 0 과 구분되는 양의 효과이지만, 절대 크기 (+0.008) 는 답변 단위 · sample 단위 신호 결합 효과 (+0.026) 의 약 3분의 1 정도에 한정된다.

8. **데이터셋별 이질성.** 표 4.6 에서 보이듯, entity co-occurrence AUROC range 이 entity 빈도 AUROC range 보다 크다는 패턴은 5개 데이터셋 중 NQ-Open 에서 역전된다. 따라서 표본 종합 비율 1.88배는 모든 데이터셋에서 entity co-occurrence 신호가 entity 빈도 신호보다 큰 AUROC range 을 보인다는 뜻이 아니라, 데이터셋 종합 통계이다. 도메인별로 corpus 신호의 적절한 단위가 다를 수 있다는 가설은 본 논문의 범위 밖이다.

9. **Corpus 신호의 entity 추출 범위.** 본 논문의 corpus 신호는 질문 텍스트와 데이터셋이 제공한 정답 텍스트의 entity 를 합쳐 산출하며, 모델이 생성한 답변의 entity 는 사용되지 않는다. 따라서 신호 값은 모델 출력과 독립이며, 한계 4 에서 다룬 답변 결합 문제와는 차원이 다르다. 답변 측 entity 의 영향을 분리하여 질문 entity 만으로 신호를 다시 산출한 결과는 §4.5 에 함께 보고하였으며, Semantic Entropy 기준 비율은 1.88 에서 2.20 으로 증가한다. 다만 부분표본 (n=2,095) 의 선택 편향은 §4.5 에 명시하였다.

10. **AUROC range 과 Spearman ρ 의 분리 해석.** AUROC range 은 max−min 통계량이므로, 구간이 올라갈수록 AUROC 가 단조 증가하는 양상과 비단조 변동 (U자형 등) 을 구분하지 못한다. 본 논문은 표 4.5 에 Semantic Entropy / Energy / 답변 평균 NLL 세 신호 모두에 대해 Spearman ρ 를 함께 보고함으로써 AUROC range 과 단조성을 분리해 진단한다. 다만 21개 동시 검정에 대한 다중비교 보정 (Bonferroni α=0.05/21≈0.0024) 을 적용하면 표의 모든 ρ 가 유의 기준을 충족하지 않으므로, ρ 결과는 예비 분석으로 한정한다. 또한 n=10 (구간 수) 의 Spearman 검정력이 낮아 $|\rho|$=0.65 부근의 결과는 구간 폭과 동순위 처리에 민감하다. 보다 강건한 단조성 검정 (Mann-Kendall, partial ρ) 과 다중비교 보정은 향후 과제로 남긴다.

5.3 향후 연구

본 연구의 결과는 세 가지 방향의 후속 연구를 제안한다.

1. **모델 다양화.** Llama, Gemma, instruction-tuned 모델 등 다양한 모델에서 entity co-occurrence 신호의 AUROC range 패턴이 같은 방향으로 나타나는지 검증한다.

2. **LLM-as-judge 라벨과의 비교.** 본 논문이 사용한 NLI 매칭 라벨을 LLM-as-judge 라벨로 대체했을 때 corpus 신호 단위별 AUROC range 이 어떻게 달라지는지 분석한다.

3. **도메인 특화 corpus.** BioASQ 의 경우 PubMed 기반 corpus, 수학 문제의 경우 ArXiv 기반 corpus 등 도메인 특화 색인을 사용했을 때 동일 신호의 AUROC range 이 더 커지는지 검증한다.

5.4 결론

본 논문은 환각 탐지 신호 (Semantic Entropy, Semantic Energy, 답변 단위 토큰 logit 통계) 가 corpus 빈도 조건에 따라 어떻게 달라지는지를, corpus 신호의 단위 — 단일 entity, entity co-occurrence, 답변 phrase — 에 따라 비교하는 분석 틀을 제안하였다. Qwen2.5-3B 와 다섯 개 질의응답 데이터셋 (총 35,000 개 생성 답변) 위에서 초기 검증을 수행한 결과, entity co-occurrence 신호로 sample 을 나누었을 때 Semantic Entropy 의 구간별 AUROC 는 $\Delta 0.150$ 의 AUROC range 을 보였다. 이 값은 단일 entity 빈도 신호로 나누었을 때의 AUROC range $\Delta 0.080$ 의 약 1.5–1.9 배에 해당한다 (SVAMP 포함 시 1.88 배, 제외 시 1.68 배). 두 AUROC range 의 차이에 대한 95% 신뢰구간 [+0.002, +0.117] 은 본 표본에서 방향성이 통계적으로 유의함을 보이지만, 신뢰구간 폭 대비 점추정치 비율로 보면 효과 크기 자체의 정밀도는 낮다. 모집단 비율의 안정성은 추가 모델과 corpus 위에서의 검증이 필요하다. 동일한 corpus 신호가 fusion 모델의 입력 변수로는 +0.008 의 작은 향상에 한정되는 반면, 분해 신호로 사용했을 때는 큰 AUROC range 을 보이는 비대칭은, corpus 신호의 설계 목표를 환각 탐지기의 입력이 아니라 탐지 신호의 조건부 평가 도구로 재정의할 필요를 제기한다. 이러한 재정의는 향후 환각 탐지 연구의 corpus 조건부 평가에서 참고할 수 있는 분석 형식으로 활용될 수 있다.

참고문헌

[1] L. Huang et al., "A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions," *ACM Transactions on Information Systems,* vol. 43, no. 2, pp. 1–55, 2025.

[2] J. Maynez et al., "On Faithfulness and Factuality in Abstractive Summarization," *Proceedings of ACL,* pp. 1906–1919, 2020.

[3] S. Farquhar, J. Kossen, L. Kuhn, and Y. Gal, "Detecting hallucinations in large language models using semantic entropy," *Nature,* vol. 630, pp. 625–630, 2024.

[4] P. Manakul, A. Liusie, and M. J. F. Gales, "SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models," *Proceedings of EMNLP,* pp. 9004–9017, 2023.

[5] J. Kossen et al., "Semantic Entropy Probes: Robust and Cheap Hallucination Detection in LLMs," *arXiv preprint arXiv:2406.15927,* 2024.

[6] A. Nikitin, J. Kossen, Y. Gal, and P. Marttinen, "Kernel Language Entropy: Fine-grained Uncertainty Quantification for LLMs," *arXiv preprint arXiv:2405.20003,* 2024.

[7] K. Ciosek et al., "Bayesian Estimation of Semantic Entropy for Sample-Efficient Hallucination Detection," *arXiv preprint arXiv:2503.xxxxx,* 2025.

[8] Z. Ma et al., "Semantic Energy: A novel approach for detecting confabulation in language models," *arXiv preprint arXiv:2412.07965,* 2025.

[9] A. Raghuvanshi et al., "Hybrid Token-Level Uncertainty and Semantic Entailment for Hallucination Detection," *arXiv preprint arXiv:2502.xxxxx,* 2025.

[10] A. Ravichander et al., "HALoGEN: Fantastic LLM Hallucinations and Where to Find Them," *arXiv preprint arXiv:2501.08292,* 2025.

[11] S. Singha, "ECLIPSE: Evidence-Conditioned Hallucination Detection via Perplexity Decomposition for Financial QA," *arXiv preprint arXiv:2510.xxxxx,* 2025.

[12] H. Wang, "SEReDeEP: Semantic Entropy + Retrieval-Aware Detection for Enhanced Evaluation Pipelines," *arXiv preprint arXiv:2509.xxxxx*, 2025.

[13] S. Valentin et al., "Cost-Effective Hallucination Detection for LLMs," *arXiv preprint arXiv:2407.21424*, 2024.

[14] W. Zhao et al., "WildHallucinations: Evaluating Long-form Factuality in LLMs with Real-World Entity Queries," *arXiv preprint arXiv:2407.17468*, 2024.

[15] Y. Zhang et al., "Measuring the Impact of Lexical Training Data Coverage on Hallucination Detection in Large Language Models," *arXiv preprint arXiv:2511.17946*, 2025.

[16] J. Liu et al., "Infini-gram: Scaling Unbounded n-gram Language Models to a Trillion Tokens," *arXiv preprint arXiv:2401.17377*, 2024.

[17] A. Yang et al., "Qwen2.5 Technical Report," *arXiv preprint arXiv:2412.15115*, 2024.

[18] M. Joshi, E. Choi, D. S. Weld, and L. Zettlemoyer, "TriviaQA: A Large Scale Distantly Supervised Challenge Dataset for Reading Comprehension," *Proceedings of ACL*, pp. 1601–1611, 2017.

[19] P. Rajpurkar, J. Zhang, K. Lopyrev, and P. Liang, "SQuAD: 100,000+ Questions for Machine Comprehension of Text," *Proceedings of EMNLP*, pp. 2383–2392, 2016.

[20] G. Tsatsaronis et al., "An overview of the BIOASQ large-scale biomedical semantic indexing and question answering competition," *BMC Bioinformatics*, vol. 16, no. 138, 2015.

[21] T. Kwiatkowski et al., "Natural Questions: A Benchmark for Question Answering Research," *Transactions of the ACL*, vol. 7, pp. 453–466, 2019.

[22] A. Patel, S. Bhattamishra, and N. Goyal, "Are NLP Models really able to Solve Simple Math Word Problems?," *Proceedings of NAACL*, pp. 2080–2094, 2021.