공학학사학위논문

LLM 환각 탐지 신호의 Corpus Support 조건부 분해: Corpus Signal 단위별 분석

2026 년 2 월

서울대학교

자유전공학부

문 정 혁

LLM 환각 탐지 신호의 Corpus Support 조건부 분해: Corpus Signal 단위별 분석

지도교수 김 남 수

이 논문을 공학 학사학위 논문으로 제출함

서울대학교

자유전공학부

문 정 혁

문정혁 의 학사 학위 논문을 인준함

2026 년 2 월 13일

지 도 교 수 (인)

초록

대규모 언어모델 (LLM) 은 그럴듯한 거짓 답변, 즉 환각 (hallucination) 을 자주 생성한다. 이를 자동으로 판별하기 위한 환각 탐지 신호 — Semantic Entropy, Semantic Energy 등 — 가 활발히 연구되고 있다. 이러한 신호의 성능은 보통 평균 AUROC 한 숫자로 보고된다. 그러나 모델이 잘 아는 사실과 잘 모르는 사실은 분명히 다르므로, 평균만으로는 탐지 성능이 어느 영역에서 안정적이고 어느 영역에서 떨어지는지를 알기 어렵다.

본 논문은 평균 AUROC 를 sample 그룹별로 분해하여 측정한다. 사전학습 corpus 에서 특정 사실 패턴의 등장 빈도를 기준으로 sample 을 그룹화한 뒤, 각 그룹별로 환각 탐지 신호의 AUROC 를 따로 계산한다. 분석에서 가장 중요한 선택은 *corpus* 패턴을 어떤 단위로 측정하느냐 하는 것이다. 단일 entity 의 등장 빈도로 측정할 수도 있고, 두 entity 가 함께 등장한 빈도 (entity co-occurrence), 또는 답변 어구의 n-gram 등장 빈도로 측정할 수도 있다.

핵심 결과는 다음과 같다. 질문 entity 와 답변 entity 가 corpus 에 자주 함께 등장한 sample 에서는 Semantic Entropy 의 AUROC 가 0.793 인 반면, 거의 함께 등장하지 않은 sample 에서는 0.643 로 크게 떨어진다. 같은 분석을 단일 entity 등장 빈도로 수행하면 AUROC range 가 절반 수준으로 줄어든다. 즉 "Paris–France 가 함께 등장하는지" 와 같은 entity co-occurrence 정보는 단일 entity 빈도보다 환각 탐지 신호의 신뢰도를 약 1.5~1.9 배 더 명확하게 구분한다. 다만 단일 조건 점추정치는 1.88 배이며, 95% 신뢰구간 하한이 +0.002 로 0 에 매우 근접하므로, 방향성은 유의하지만 효과 크기의 정밀도는 다소 낮다고 보수적으로 평가한다.

이 결과는 corpus 신호의 역할을 새롭게 조명한다. corpus 신호는 환각 탐지기의 입력 변수로 추가했을 때는 성능 향상이 미미하지만, 탐지 성능이 안정적인 영역과 그렇지 않은 영역을 가르는 평가 척도로 사용했을 때는 큰 AUROC range 를 보인다. 이러한 비대칭은 향후 환각 탐지 연구에서 평균 한 숫자가 아니라 corpus 조건별 AUROC range 를 함께 보고해야 함을 시사한다. 또한 실제 LLM 서비스에서도 corpus 뒷받침이 약한 질문을 별도로 검증하는 신호별 조건부 신뢰 절차 의 토대로 활용될 수 있다. 본 연구는 Qwen2.5-3B 와 5 개 QA 데이터셋 (TriviaQA, SQuAD-1.1, BioASQ, NQ-Open, SVAMP, 총 3,500 sample, 35,000 생성 답변) 위에서 정량 분석을 수행하였으며, 통계 검정과 신뢰구간은 §4.6 와 §5.2 에 상세히 보고한다.

주요어: 대규모 언어모델, 환각 탐지, Semantic Entropy, Semantic Energy, corpus support, 단위별 분해, Infini-gram

목차

초록 **i**

제 1 장 서론 **1**

1.1 연구 배경 1

1.2 연구 목적 2

1.3 논문 구성 3

제 2 장 관련 연구 **4**

2.1 Sample-Consistency 기반 환각 탐지 4

2.2 Logit 기반 불확실성 추정 5

2.3 Corpus 통계를 이용한 환각 탐지 5

2.4 다중 신호 결합 (Multi-Signal Fusion) 6

제 3 장 제안 방법 **8**

3.1 데이터셋 및 실험 설정 8

3.2 답변 단위 정답 라벨 8

3.3 Semantic Entropy 9

3.4 Semantic Energy 9

3.5 각 답변의 token logit 통계 10

3.6 Corpus 신호 설계 10

3.7 Corpus 신호 단위별 분해 분석 11

3.8 Fusion 모델 11

제 4 장 실험 **12**

4.1 주요 신호의 종합 성능 12

4.2 단일 신호 성능과 선행 연구 비교 12

4.3 단일 corpus 신호의 환각 탐지 성능 12

4.4 신호 결합 (fusion) 결과 15

4.5 비대칭 메커니즘 부분 분석 16

4.6 Corpus 신호 단위별 분해 결과 18
4.7 데이터셋별 변동 23

제 5 장 결론 **24**
5.1 논의 24
5.2 한계 25
5.3 향후 연구 28
5.4 결론 28

표 목차

표 4.1 주요 신호의 종합 성능 13
표 4.2 단일 신호 성능과 선행 연구 비교 14
표 4.3 단일 corpus 신호의 환각 탐지 성능 14
표 4.4 Fusion 모델 AUROC 와 corpus 추가 효과 15
표 4.5 Semantic Entropy 와 corpus 신호 사이의 Spearman 상관 16
표 4.6 Corpus 영역별 Semantic Entropy 의 calibration 17
표 4.7 Corpus 신호별 구간별 AUROC range 와 단조성 18
표 4.8 데이터셋별 Semantic Entropy / Semantic Energy AUROC range 22
표 4.9 데이터셋별 AUROC 23

그림 목차

그림 4.1 세 환각 탐지 신호와 두 corpus 신호의 구간별 AUROC 19

제 1 장 서론

1.1 연구 배경

ChatGPT 와 Gemini 로 대표되는 대규모 언어 모델 (LLM) 은 추론과 질의응답에서 뛰어난 성능을 보이지만, 사실과 다른 그럴듯한 답변, 이른바 환각 (hallucination) 을 자주 생성한다[5, 6]. 의료, 법률, 과학 등 고위험 도메인에서 환각은 심각한 오류로 이어질 수 있다. 따라서 모델 출력의 신뢰성을 자동으로 판별하는 환각 탐지 연구가 중요한 과제로 자리 잡았다.

대표적인 접근법은 모델의 불확실성을 정량화하는 것이다. Farquhar 등 (2024)[7] 이 제안한 Semantic Entropy 는 동일 질문에 대해 생성된 여러 답변이 의미적으로 얼마나 흩어져 있는지를 측정한다. 답변들이 하나의 의미로 모이면 모델이 확신하는 경우로, 의미가 갈리면 확신하지 못하는 경우로 해석된다. Ma 등 (2025)[12] 의 Semantic Energy 는 확률 대신 logit 을 직접 활용하여, Semantic Entropy 가 놓치는 모델 지식 자체의 한계까지 반영한다. 이 두 신호는 외부 지식 없이도 LLM 출력의 신뢰도를 가늠할 수 있는 실질적인 도구로 자리매김했다.

그러나 이러한 탐지 신호의 성능은 대부분 평균 AUROC 라는 하나의 숫자로만 보고된다. 이 평균은 모델이 잘 아는 사실과 잘 모르는 사실을 한꺼번에 섞은 결과물이다. 모델은 사전학습 데이터에 자주 등장한 사실은 잘 기억하지만, 거의 등장하지 않은 사실은 잘 모를 가능성이 높다. 따라서 탐지 신호의 신뢰도도 두 영역에서 크게 다를 수밖에 없는데, 평균 숫자 하나만으로는 이 차이를 전혀 알 수 없다. “평균 AUROC 0.79” 라는 보고만으로는 어떤 질문에 대해 탐지 결과를 신뢰할 수 있고, 어떤 질문에 대해 신뢰하기 어려운지 판단하기 어렵다.

사전학습 corpus 통계량을 환각 탐지에 활용한 선행 연구[17, 18, 13] 도 있지만, 이들은 대부분 corpus 신호를 탐지기 자체의 입력 변수로 사용하는 데 그쳤다. corpus 통계가 탐지 신호의 영역별 신뢰도를 어떻게 분해하는지, 그리고 단일 entity 빈도, entity 쌍 동시 등장, n-gram 등 어느 단위가 분해를 가장 잘 설명하는지에 대한 체계적인 비교 분석은 아직 이루어지지 않았다.

본 연구의 핵심 결과는 다음과 같다. 동일 corpus 신호를 탐지기의 입력 변수로 추가했을 때는 성능 향상이 미미한 반면, 조건부 평가 척도로 사용했을 때는 AUROC 에 큰 폭의 변동이 나타난다. 이 비대칭 현상이 본 연구가 집중적으로 분석하는 대상이며, 이하의 내용은 이 비대칭을 정량적으로 규명하는 데 초점을 맞춘다. 본 연구에서 다루는 환각은 주로 사전학습 데이터의 사실 회상 (HALoGEN[13] 의 Type A) 영역이며, 모델 내부의 잘못된 지식 (Type B) 이나 순수 조작 (Type C) 과의 차이는 후속 연구로 남긴다.

1.2 연구 목적

본 연구는 다음과 같은 직관에서 출발한다. “Paris” 라는 단어가 corpus 에 자주 등장한다고 해서 모델이 “Paris 가 France 의 수도” 라는 사실을 학습했다고 단정할 수는 없다. 이 사실을 학습할 가능성은 “Paris” 단일 단어의 빈도보다 “Paris” 와 “France” 가 corpus 에서 함께 등장한 빈도와 훨씬 더 직접적으로 연결될 것이다. 이러한 직관은 Kandpal 등 (2023)[1] 이 사전학습 corpus 에서 (질문 entity, 답변 entity) 쌍의 동시 등장 횟수가 단일 entity 빈도보다 LLM 의 사실 정답률을 더 잘 예측한다는 것을 정량적으로 보인 결과와 직접적으로 맞닿아 있다. 그렇다면 환각 탐지 신호의 신뢰도 역시 단일 entity 빈도가 아니라 entity 쌍의 동시 등장 빈도에 따라 더 뚜렷하게 갈릴 것이다.

이 직관을 바탕으로 본 연구의 핵심 질문은 다음과 같이 정리된다. 환각 탐지 신호 (Semantic Entropy, Semantic Energy, 답변 단위 logit 통계) 의 신뢰도가 corpus 의 사실 등장 패턴에 따라 어떻게 달라지는가? 그리고 단일 entity 빈도, entity co-occurrence, 답변 어구의 n-gram 빈도 가운데 어느 단위가 이 변동을 가장 잘 설명하는가?

이를 위해 세 가지 세부 목표를 설정하였다.

- 첫째, 기존 환각 탐지 신호 (Semantic Entropy, Semantic Energy, 답변 단위 logit 통계) 의 성능을 동일한 평가 절차 아래에서 재현한다.
- 둘째, 단위가 서로 다른 corpus 신호 (entity 빈도, entity co-occurrence, question-answer bridge, n-gram) 를 설계하고, 각 신호가 단독 환각 탐지기로서 어느 정도의 성능을 보이는지 평가한다.
- 셋째, 동일 corpus 신호로 sample 을 그룹별로 나누었을 때 환각 탐지 신호의 구간별 AUROC 가 어떻게 변동하는지 비교·분석한다. 이를 통해 corpus 신호의 단위가 AUROC range 에 미치는 영향을 정량적으로 규명한다.

본 연구의 주요 기여는 다음과 같다.

- (1) 환각 탐지 신호의 신뢰도가 corpus 조건에 따라 어떻게 달라지는지를 corpus 신호의 단위별로 비교하는 분석 프레임워크를 제시한다.
- (2) Kandpal 등 (2023)[1] 이 모델 정답률에 대해 보고한 entity co-occurrence 의 우월성이 환각 탐지 신호의 신뢰도 영역 분해에서도 같은 방향으로 나타남을 본 표본에서 확인한다 (entity co-occurrence 가 단일 entity 빈도보다 환각 탐지 신호의 신뢰도 변동을 약 1.5~1.9 배 더 명확하게 구분; 단일 조건 점추정치 1.88 배, 95% 신뢰구간 하한 +0.002, SVAMP 제외 시 1.68 배). 핵심은 측정 대상을 모델 정답률 에서 환각 탐지 신호의 *AUROC* 로 한 단계 더 높은 수준으로 옮겼음에도 같은 방향성이 유지된다는 점이다.

- (3) corpus 신호의 설계 목표를 “탐지기의 입력 변수” 에서 “탐지 신호의 조건부 평가 척도” 로 재설정하는 새로운 관점을 제안한다. 이 관점은 향후 환각 탐지 연구의 평가 방식과 실제 LLM 서비스에서의 조건부 신뢰 전략 모두에 시사점을 준다.

1.3 논문 구성

본 논문은 다음과 같이 구성된다. 제 2장에서는 Semantic Entropy, Semantic Energy, corpus 기반 환각 탐지, 다중 신호 결합 (Multi-Signal Fusion) 관련 선행 연구를 정리한다. 제 3장에서는 데이터셋, 실험 설정, 신호 정의, corpus 신호 단위별 분해 분석 절차를 기술한다. 제 4장에서는 단일 신호 평가, fusion 결과, 단위별 구간 분석 결과를 보고한다. 제 5장에서는 연구 결과의 함의, 한계, 향후 연구 방향을 논의하고 결론을 맺는다.

제 2 장 관련 연구

본 장에서는 LLM 환각 탐지 연구를 네 가지 주요 흐름으로 정리한다. 첫째, 생성된 답변 간 의미 일관성에 기반한 탐지 (sample-consistency). 둘째, logit 을 활용한 불확실성 추정. 셋째, 사전학습 corpus 통계의 활용. 넷째, 여러 신호를 결합하는 multi-signal fusion 이다. 각 흐름의 대표 연구를 간략히 살펴본 뒤, 본 연구의 위치를 명확히 한다.

2.1 Sample-Consistency 기반 환각 탐지

Semantic Entropy 의 개념적 기원은 Kuhn 등 (2023)[2] 의 *Semantic Uncertainty* 논문에 있다. Kuhn 등은 자연어 생성에서 의미적 등가 (서로 다른 표현이 같은 뜻을 가질 수 있다) 라는 linguistic invariance 를 명시적으로 다루는 entropy 를 정의하여, 후속 hallucination detection 연구의 이론적 토대를 제공했다. Farquhar 등 (2024)[7] 의 Semantic Entropy 는 이를 hallucination detection 으로 구체화한 후속 연구이다. 본 논문은 후자의 framing 을 따르되, 원형 방법론의 기원을 명시하여 방법의 계보를 분명히 한다.

Farquhar 등 (2024)[7] 이 제안한 Semantic Entropy 는 동일 prompt 에 대해 생성된 N 개의 답변을 NLI 양방향 함의 (entailment) 관계로 의미 cluster 로 묶은 뒤, cluster 질량의 엔트로피를 환각 지표로 사용한다. 이 방법은 하나의 의미가 다양한 표현으로 나타날 수 있는 언어적 특성을 잘 반영하며, 태스크별 사전 지식 없이도 TriviaQA, SQuAD, BioASQ, NQ-Open, SVAMP 등 여러 데이터셋에서 일관된 성능을 보인다. Semantic Entropy 는 naive entropy, p(True), embedding 회귀 기준선 대비 안정적으로 높은 AUROC 를 달성한다. 이는 SelfCheckGPT[8] 가 제시한 sample-consistency 접근을 의미 단위로 일반화한 결과로 평가된다.

Kossen 등 (2024)[9] 의 Semantic Entropy Probes (SEPs) 는 Semantic Entropy 계산의 높은 연산 비용을 줄이기 위해, 단일 생성의 hidden state 로부터 Semantic Entropy 를 직접 근사하는 probe 를 학습한다. SEPs 는 다중 샘플링 없이도 환각 탐지 성능을 유지하며, 분포 외 데이터에서도 안정적인 일반화를 보인다.

Nikitin 등 (2024)[10] 의 Kernel Language Entropy (KLE) 는 Semantic Entropy 를 일반화하여 hard clustering 대신 pairwise 의미 유사도 커널과 von Neumann 엔트로피를 사용한다. KLE 는 cluster 간 의존성을 더 세밀하게 포착하여, 여러 데이터셋과 모델 구조에서 Semantic Entropy 보다 우수한 불확실성 정량화 성능을 보고한다. Ciosek 등 (2025)[11] 은 Bayesian 접근으로 Semantic Entropy 추정의 표본 효율을 높여, Farquhar 등 (2024) 대비 53% 적은 샘플로 동등한 AUROC 를 달성했다.

2.2 Logit 기반 불확실성 추정

Ma 등 (2025)[12] 의 Semantic Energy 는 Semantic Entropy 의 한계를 보완하기 위해 logit 기반 에너지 모델을 도입한다. Semantic Entropy 는 모든 답변이 단일 cluster 에 집중될 때 분리력을 잃지만, Semantic Energy 는 모델의 penultimate layer logit 을 직접 활용하여 이러한 경우까지 포착한다. 토큰 에너지 $\tilde{E}(x_t) = -z_\theta(x_t)$ 를 정의하고, Semantic Entropy 와 동일한 의미 cluster 구조 위에서 cluster 에너지를 산출한다. 보고된 개선 폭은 평균 AUROC 13% 이상이다. 확률이 logit 정규화 과정에서 강도 정보를 잃는다는 점은 LLM 의 불확실성 표현 능력을 제한하는 주요 요인으로 지적된다.

2.3 Corpus 통계를 이용한 환각 탐지

LLM 의 환각은 사전학습 corpus 에서 드물게 등장하는 사실과 강하게 연관된다. HALoGEN (Ravichander 등, 2025)[13] 은 9 개 도메인에 걸친 10,923 개 항목의 환각 벤치마크를 구축하고, LLM 생성물의 원자적 사실 단위를 고품질 지식 소스와 자동 검증하는 프레임워크를 제시했다. 이 연구는 최고 성능 모델에서도 생성된 원자적 사실의 최대 86% 가 환각으로 분류될 수 있음을 보여주며, 환각 원인을 학습 데이터 오류 회상 (Type A), 학습 데이터의 잘못된 지식 (Type B), 순수 조작 (Type C) 으로 분류했다.

corpus 노출의 어떤 측도가 모델의 사실 회상을 가장 잘 예측하는가에 대한 정량 연구로는 Kandpal 등 (2023)[1] 과 Mallen 등 (2023)[4] 이 본 연구의 직접적인 선행 연구이다. Kandpal 등 (2023) 은 The Pile 과 ROOTS 사전학습 corpus 에서 (질문 entity, 답변 entity) 쌍의 동시 등장 횟수를 산출하고, 이 횟수와 LLM 의 정답률 사이에 강한 양의 상관이 있음을 보였다. 특히 단일 entity 빈도보다 entity 쌍 동시 등장이 정답률을 더 잘 예측한다는 점을 명시적으로 보고했다. Mallen 등 (2023) 은 답변 entity 의 Wikipedia 페이지뷰 (popularity) 를 corpus 노출의 proxy 로 삼아 PopQA 데이터셋의 sample 을 popularity bin 으로 나누고, popularity 가 낮은 bin 에서 LLM 정답률이 급격히 떨어지는 패턴을 보였다. Razeghi 등 (2022)[3] 은 few-shot numerical reasoning 태스크에서 사전학습 term 빈도와 모델 정답률 사이의 강한 양의 상관을 정량적으로 보였다. Kandpal 등 (2023) 의 factual QA, Mallen 등 (2023) 의 popularity 기반 분석과 함께, 사전학습 corpus 노출 정도와 모델 성능의 양의 관계가 특정 task 를 넘어 reasoning 전반에 걸쳐 안정적으로 나타난다는 점을 뒷받침한다. 본 연구가 AUROC 수준으로 한 단계 더 끌어올려 분석한 기반이 된다.

WildHallucinations[17] 는 Wikipedia 페이지가 없는 entity 에 대한 질문에서 LLM 의 환각률이 유의미하게 증가한다는 점을 관찰하여, corpus 노출 부족과 환각 발생률 사이의 경험적 연관성을 보고했다. Zhang 등 (2025)[18] 은 RedPajama 1.3 조 토큰 corpus 위에 suffix array 를 구축하고, prompt 와 답변의 n-gram 빈도를 환각 탐지 신호로 평가했다. 그들은 occurrence 기반 feature 가 단독 사용 시 예측력이 제한적이며, log-probability 와 결합할 때 modest 한 성능 향상을 보인다고 보고했다. 본 연구는 이 결론에서 한 걸음

더 나아가, 동일한 corpus 신호를 fusion 입력 feature 로 사용할 때와 sample 을 분할하는 기준으로 사용할 때의 효과를 명시적으로 분리하여 측정한다. 또한 Zhang 등 (2025) 이 다루지 않은 corpus 신호의 단위 비교 (entity 빈도 vs. entity co-occurrence vs. n-gram) 를 동일한 AUROC range 척도 위에서 수행함으로써, corpus 신호 단위의 상대적 효용을 정량적으로 규명한다.

Min 등 (2025)[19] 의 QuCo-RAG 는 사전학습 corpus 의 low-frequency entity 와 entity co-occurrence 를 Infini-gram 으로 검증하여 RAG retrieval trigger 로 활용한다. 본 연구와 동일한 두 corpus 신호 (entity 빈도, entity co-occurrence) 와 동일한 도구 (Infini-gram) 를 사용하지만, 목적이 retrieval trigger 라는 점에서 다르다. QuCo-RAG 는 RAG 환경에서 uncertainty quantification 을 corpus-grounded 로 전환하는 데 초점을 맞추는 반면, 본 연구는 환각 탐지 신호의 조건부 신뢰도를 corpus 단위별로 분해하는 데 목적을 둔다. 또한 QuCo-RAG 는 단위 비교 없이 두 신호를 함께 사용하지만, 본 연구는 일곱 가지 단위를 같은 평가 척도 위에서 비교한다.

Infini-gram[20] 은 n-gram 카운팅을 통해 corpus 통계 질의를 지원하는 엔진으로, 특정 phrase 나 entity 의 등장 빈도를 효율적으로 산출한다. 그러나 이를 환각 탐지의 corpus 지지 신호로 활용하는 연구는 아직 초기 단계이며, 단위 (entity 빈도, entity co-occurrence, n-gram) 별로 corpus 통계 신호가 탐지 신호와 어떻게 연관되는지를 비교한 연구는 충분하지 않다.

2.4 다중 신호 결합 (Multi-Signal Fusion)

단일 신호의 한계를 극복하기 위해 여러 신호를 결합하는 fusion 접근이 활발히 연구되고 있다. ECLIPSE (Singha, 2025)[14] 는 perplexity 분해로 증거 활용 신호 (ΔL) 를 추출하여 금융 QA 에서 AUC 0.89 (entropy-only baseline 0.50 대비 큰 폭 개선) 를 달성했다. SEReDeEP (Wang, 2025)[15] 는 RAG 환경에서 semantic entropy 와 context-parameter knowledge 균형 신호를 결합하여, ReDeEP 대비 3% 이상 / SEP 대비 10% 이상의 환각 예측 정확도 향상을 보고했다. Valentin 등 (2024)[16] 은 환각 탐지 점수를 모델 내부 score attribute 에 조건부로 calibrate 하는 다중 점수 프레임워크를 제안했다.

이들 연구는 여러 신호의 결합이 단일 신호 대비 성능 향상으로 이어질 수 있음을 보여준다. 그러나 선행 연구들은 공통적으로 corpus 통계를 탐지 신호 자체 또는 탐지기의 입력 변수로만 사용했을 뿐, 동일 신호가 탐지 신호의 영역별 신뢰도를 분해하는 평가 척도로서 어떤 효용을 가지는지는 비교하지 않았다.

본 연구는 이 두 역할을 명확히 분리하여 정량화한다. corpus 통계 신호를 fusion 입력에 추가했을 때의 성능 변화를 측정하는 한편, 동일 신호로 샘플을 나누었을 때 환각 탐지 신호의 AUROC 가 어떻게 달라지는지를 비교한다. 이 두 결과의 비대칭이 corpus 신호의 설계 목표 자체를 재정립할 필요성을 제기한다.

선행 연구와의 차이를 명시하면 다음과 같다. Kandpal 등 (2023)[1] 은 corpus 노출과 모델 정답률, Mallen 등 (2023)[4] 은 entity popularity 와 정답률의 관계를 보였다. 본 연구는 동일한 corpus 신호 (entity

빈도, entity 쌍 동시 등장) 를 사용하되, 측정 대상을 모델 정답률 이 아니라 환각 탐지 신호의 *AUROC* 로 한 단계 더 높은 분석 수준으로 끌어올렸다. 두 지표는 자동으로 비례하지 않는다. 정답률이 높은 영역과 낮은 영역에서도 Semantic Entropy 의 AUROC 는 동일할 수 있고, 정답률이 균일한 영역에서도 AUROC 가 영역마다 다를 수 있다. 또한 동일 corpus 신호의 두 역할 — 탐지기 입력 변수와 영역별 평가 척도 — 사이의 비대칭은 두 선행 연구에는 정의 자체가 없는 분석 축이다. 본 연구가 일곱 가지 corpus 신호 단위 (entity 빈도, entity co-occurrence, baseline, question-answer bridge, 답변 3-gram / 5-gram, 3-gram 미등장) 를 같은 평가 척도 위에서 비교한 것도 두 선행 연구의 범위 밖이다.

제 3 장 제안 방법

본 장에서는 연구에 사용된 데이터셋과 실험 설정, 정답 라벨링 방식, 환각 탐지 신호 정의, corpus 신호 설계, 단위별 분해 분석 절차, 그리고 fusion 모델 구성까지 차례로 설명한다. 본 연구는 새로운 환각 탐지기를 제안하는 것이 아니라, 기존 탐지 신호의 성능이 사전학습 corpus 의 뒷받침 정도에 따라 어떻게 달라지는지를 *corpus* 신호의 단위별로 체계적으로 비교하는 데 초점을 맞춘다.

3.1 데이터셋 및 실험 설정

본 연구는 Farquhar 등 (2024)[7] 과 동일한 다섯 개의 질의응답 데이터셋을 사용한다. TriviaQA[22] 800개, SQuAD-1.1[23] 800개, BioASQ[24] 800개, NQ-Open[25] 800개, SVAMP[26] 300개로 총 3,500개 sample 을 선정하였다. 각 데이터셋마다 무작위 추출 시드를 고정하여 동일한 sample 집합을 재현하였으며, 각 sample 에는 데이터셋 이름, split 식별자, 원본 색인, 본문 해시값을 결합한 고유 식별자를 부여하였다.

사용한 모델은 Qwen2.5-3B (base)[21] 이며, 별도의 instruction tuning 은 적용하지 않았다. 추론은 NVIDIA RTX 5090 32 GB 환경에서 16-bit 부동소수점 (float16) 으로 수행하였다. 입력 prompt 는 Farquhar 등 (2024) 와 동일하게 “Answer the following question in a single brief but complete sentence.” 라는 한 문장 응답 유도 형식을 따랐다. 각 sample 당 10개의 자유 생성 답변을 산출하였다. 샘플링 매개변수는 온도 1.0, top-p 0.9, top-k 50, 최대 생성 토큰 수 64로 설정하였다. 총 평가 단위는 35,000개의 생성 답변이다.

최대 토큰 수 64로 생성했을 때 전체 답변의 약 12.6% 가 중간에 절단되었다. 절단의 영향을 배제하기 위해 절단된 답변이 발생한 2,426개 sample 의 모든 답변을 최대 토큰 수 128로 다시 생성하였다. 재생성 전후 AUROC 변화는 ± 0.001 범위에 머물렀다.

평가 지표로는 AUROC, AURAC (Area Under Rejection-Accuracy Curve, Farquhar 등 (2024) 의 주요 지표), Brier score, ECE 를 사용하였다. fusion 실험의 교차검증은 prompt 단위 5-fold GroupKFold 로 수행하였다. 같은 sample 의 모든 답변이 동일 fold 에 배치되도록 하여 학습-평가 간 sample 단위 정보 누출을 방지하였다.

3.2 답변 단위 정답 라벨

본 논문의 정답 라벨은 모델이 생성한 답변 s_i 가 정답 후보 표현과 의미적으로 일치하는지를 NLI (자연어 추론) 양방향 함의 확률로 판정하여 정의한다. 각 sample 의 정답 후보 집합 C 는 데이터셋이 제공한 정답 표현, 동의 표현, 별칭 목록을 모두 모은 뒤 소문자 정규화와 중복 제거를 거쳐 구성한다. 생성된 답변

s_i 와 후보 c 사이의 매칭 점수는 다음과 같이 정의한다.

$$m(s_i, c) = \max\big(p_{\text{entail}}(c \to s_i),\ p_{\text{entail}}(s_i \to c)\big),$$
$$M(s_i) = \max_{c \in C} m(s_i, c).$$

$M(s_i) \geq 0.5$ 이면 s_i 를 정답 (라벨 1), 그렇지 않으면 환각 (라벨 0) 으로 판정한다. NLI 모델로는 `microsoft/deberta-large-mnli` 를 사용하였으며, 절차는 Farquhar 등 (2024) 의 라벨링과 동일하다. 이 절차로 총 35,000 개의 이진 라벨이 산출되었다. 본 평가 단위는 Farquhar 등 (2024) 의 Semantic Entropy 와 Ma 등 (2025) 의 Semantic Energy 가 사용한 답변 단위 정답성 평가와 일치하므로, 두 선행 연구와 직접 비교가 가능하다.

3.3 Semantic Entropy

Semantic Entropy 는 Farquhar 등 (2024) 의 정의를 그대로 따른다. 한 sample 에 대해 생성한 10 개 답변을 NLI 양방향 함의 관계로 의미 cluster $\mathbb{C}_k$ 로 묶은 뒤, 각 cluster 의 확률 질량을 답변의 시퀀스 로그 우도로부터 계산한다.

$$\log \tilde{p}(\mathbb{C}_k) = \log \sum_{x^{(i)} \in \mathbb{C}_k} \exp\Big(\sum_t \log p_\theta(x_t^{(i)})\Big),$$
$$p(\mathbb{C}_k) = \frac{\tilde{p}(\mathbb{C}_k)}{\sum_{k'} \tilde{p}(\mathbb{C}_{k'})}.$$

Semantic Entropy 는 cluster 분포의 Shannon 엔트로피로 정의된다.

$$H(\mathbf{x}) = -\sum_k p(\mathbb{C}_k)\ \log p(\mathbb{C}_k).$$

Semantic Entropy 는 sample 단위로 산출되며, 같은 sample 의 모든 답변에 동일한 값이 적용된다.

3.4 Semantic Energy

Semantic Energy 는 Ma 등 (2025) 의 정의를 그대로 구현한다. Semantic Entropy 와 동일한 의미 cluster 구조 위에서, 확률 대신 모델의 token logit 을 직접 활용하여 모델 자체의 지식 한계에서 비롯되는 불확실

성을 추정한다.

$$\tilde{E}(x_t^{(i)}) = -z_\theta(x_t^{(i)}) \qquad \text{(token energy)} \tag{3.1}$$

$$E(x^{(i)}) = \tfrac{1}{T_i} \sum_t \tilde{E}(x_t^{(i)}) \qquad \text{(sample energy)} \tag{3.2}$$

$$E_{\text{Bolt}}(\mathbb{C}_k) = \sum_{x^{(i)} \in \mathbb{C}_k} E(x^{(i)}) \qquad \text{(cluster total)} \tag{3.3}$$

$$U(\mathbf{x}) = \sum_k p(\mathbb{C}_k)\, E_{\text{Bolt}}(\mathbb{C}_k) \qquad \text{(sample 단위 uncertainty)} \tag{3.4}$$

값이 낮을수록 모델 신뢰도가 높음을 의미한다.

3.5 각 답변의 token logit 통계

각 답변에 대해 다음 네 가지 token logit 통계를 산출한다.

- 평균 음의 로그우도: $-\frac{1}{T_i} \sum_t \log p(x_t^{(i)})$.
- 시퀀스 로그우도: $\sum_t \log p(x_t^{(i)})$.
- logit 분산: $\mathrm{Var}_t\big(z_\theta(x_t^{(i)})\big)$.
- 평균 로그 분배함수: $\frac{1}{T_i} \sum_t \log Z_t^{(i)}$ (분포의 평탄도 지표).

이 신호들은 답변마다 산출된 변동 정보를 담아 fusion 모델의 입력으로 사용된다.

3.6 Corpus 신호 설계

Corpus 신호는 Infini-gram[20] 의 local engine 을 backend 로 사용한다. 사용한 색인은 OLMo Dolma sample (16B token, OLMo-7B-hf 토크나이저) 이다. 본 연구는 단위가 서로 다른 네 가지 corpus 신호를 다음과 같이 정의한다.

Entity 수준 신호. spaCy 의 `en_core_web_lg` entity 인식기 (NER) 로 12개 범주 (인물, 조직, 지명, 위치, 날짜, 사건, 작품, 시설, 국적/종교, 제품, 언어, 법) 의 entity 를 추출한다. 한 sample 에 대해 다음 두 가지 정규화 점수를 계산한다.

$$\text{entity 빈도} = \frac{\log(1 + \min_{e \in E} \mathrm{freq}(e))}{\log(1 + 10^6)},$$

$$\text{entity co-occurrence} = \frac{\log\big(1 + \frac{1}{|P|} \sum_{(e_i, e_j) \in P} \mathrm{cooc}(e_i, e_j)\big)}{\log(1 + 10^5)}.$$

$\mathrm{freq}(e)$ 는 entity e 의 단일 등장 횟수이고, $\mathrm{cooc}(e_i, e_j)$ 는 두 entity 가 corpus 안에서 함께 등장한 횟수이다. 본 연구의 baseline corpus 신호는 두 점수의 평균이며, 두 단위를 분리하여 비교하는 데 초점을 맞춘다.

Question-answer bridge 신호. 질문에서 추출한 entity 집합 E_q 와, 답변에서 추출한 entity 중 질문과 겹치지 않는 entity 집합 E_a 를 구성한다. 질문 entity 를 답변 entity 에서 제외하는 이유는 paraphrase 로 인한 자기 중복을 줄이기 위함이다. 모든 (질문 entity, 답변 entity) 쌍에 대해 corpus 동시 등장 횟수를 산출하고, 그 정규화 평균을 question-answer bridge 신호로 정의한다.

N-gram 등장 빈도 신호. 답변 토큰 시퀀스의 모든 3-gram 과 5-gram 에 대해 corpus 등장 횟수를 산출한다. 평균 등장 횟수를 정규화한 점수와, corpus 에 한 번도 등장하지 않은 n-gram 의 수를 함께 보고한다.

3.7 Corpus 신호 단위별 분해 분석

본 논문 분석의 핵심은 §3.6 에서 정의한 corpus 신호를 환각 탐지의 입력 변수가 아니라 *sample* 을 분할하는 신호 로 사용하는 데 있다. 각 corpus 신호로 sample 을 순위에 따라 10분위 구간으로 나누어, 한 sample 의 corpus 뒷받침 정도가 어느 구간에 속하는지를 판별한다. sample 분할에 사용한 신호는 entity 수준 신호 세 가지 (entity 빈도, entity co-occurrence, 두 점수의 평균), question-answer bridge 한 가지, n-gram 수준 신호 세 가지 (3-gram 평균 등장, 5-gram 평균 등장, 3-gram 미등장 개수) 로 총 일곱 가지이다. 같은 sample 에 속한 모든 답변은 동일한 구간값을 공유한다.

각 신호의 10개 구간 안에서 환각 탐지 신호의 AUROC 를 따로 계산한 뒤, 그 최댓값과 최솟값의 차이 $\Delta = \mathrm{AUROC}_{\max} - \mathrm{AUROC}_{\min}$ 를 해당 신호의 구간별 *AUROC range* 으로 정의한다. AUROC range 가 클수록 해당 corpus 신호로 sample 을 나누었을 때 환각 탐지 신호의 성능이 corpus 조건에 따라 더 큰 차이를 보인다는 의미이다. 본 논문의 핵심 결과는 이 AUROC range 가 corpus 신호의 단위에 따라 어떻게 달라지는지를 비교한 것이다.

3.8 Fusion 모델

Fusion 모델의 입력은 두 가지 구성으로 실험한다.

- **CORE 입력**: sample 단위 신호인 Semantic Entropy, Semantic Energy 와, 답변마다 산출한 token logit 통계 4종 (평균 음의 로그우도, 시퀀스 로그우도, logit 분산, 평균 로그 분배함수).
- **CORE + CORPUS 입력**: 위 신호에 entity, question-answer bridge, n-gram 의 모든 corpus 신호를 sample 단위로 함께 추가한 구성.

분류 모델로는 logistic regression, random forest, gradient boosting 세 가지를 비교한다. 모든 실험은 prompt 단위 5-fold GroupKFold 로 평가하여 학습-평가 사이의 정보 누출을 방지한다.

제 4 장 실험

본 장에서는 주요 환각 탐지 신호와 corpus 신호의 종합 성능을 평가하고, 단일 신호 성능을 선행 연구와 비교하며, fusion 모델의 효과와 corpus 신호의 단위별 분해 결과를 보고한다. 마지막으로 데이터셋별 변동성을 분석한다.

4.1 주요 신호의 종합 성능

본 절에서는 단일 신호와 fusion 모델의 종합 AUROC, AURAC, Brier score 를 제시한다.

표 4.1 의 결과는 세 가지로 요약된다. 첫째, Semantic Entropy (0.759) 와 Semantic Energy (0.774) 단독 신호의 AUROC 는 Farquhar 등 (2024) 와 Ma 등 (2025) 의 보고 범위와 비슷하다 (다만 모델 간 일반화의 충분 조건은 아니다 — §5.2). 둘째, 모든 단일 corpus 신호의 AUROC 는 0.50–0.58 범위에 머물러 단독 탐지기로서의 분리력은 제한적이다 (§4.3). 셋째, fusion 모델에 corpus 신호를 추가했을 때 AUROC 향상 폭은 random forest 에서 +0.010, gradient boosting 에서 +0.008 으로 매우 작다. corpus 신호의 fusion 입력 변수로서의 기여는 제한적이다.

4.2 단일 신호 성능과 선행 연구 비교

Farquhar 등 (2024) 과 동일한 다섯 개 데이터셋과 동일한 평가 단위 (생성 답변마다 산출한 NLI 정답 라벨) 에서 Qwen2.5-3B 의 Semantic Entropy 와 Semantic Energy AUROC 를 측정하였다. 결과는 표 4.2 에 정리되어 있다.

Qwen2.5-3B 는 Llama-2 7B 보다 작은 모델임에도 두 신호의 AUROC 가 선행 연구 보고 범위 (0.75–0.85) 안에 들어간다. 이는 본 표본이 Semantic Entropy 와 Semantic Energy 의 일반적인 작동 범위에 속한다는 점을 보여준다. 다만 이는 직접 재현이 아닌 참고용 비교이며, 답변 평균 NLL (0.670) 은 단독 신호로도 일정한 분리력을 보이지만 의미 cluster 정보를 추가했을 때 부가 효과가 크다.

4.3 단일 corpus 신호의 환각 탐지 성능

각 corpus 신호를 단독으로 환각 탐지 신호로 사용했을 때의 AUROC 를 측정하였다. 결과는 표 4.3 에 정리되어 있다.

모든 corpus 신호의 단독 AUROC 는 0.50–0.58 범위에 머물러 단독 탐지기로서의 분리력은 제한적이

표 4.1 주요 신호의 종합 성능. 생성 답변 35,000건 (Qwen2.5-3B, 5개 데이터셋, sample 당 10개 자유 생성 답변) 을 대상으로 측정하였다. 라벨 정의, 평가 단위, fusion 입력, AURAC 정의는 §3.2–§3.8 에서 기술한다. corpus 추가 효과는 같은 분류기에서 핵심 입력만 사용한 경우와 핵심 입력에 corpus 신호를 함께 쓴 경우의 AUROC 차이로 정의한다. 굵은 글씨는 AUROC 가 가장 높은 행을 가리킨다.

신호	AUROC	AURAC	Brier	corpus 추가 효과
단일 신호 (학습 없음, 답변 일관성 및 토큰 *logit* 통계)				
답변 내 logit 분산	0.620	0.400	—	—
답변 전체 로그우도	0.656	0.466	—	—
답변 평균 음의 로그우도 (NLL)	0.670	0.468	—	—
Semantic Entropy	0.759	0.526	—	—
Semantic Energy	0.774	0.533	—	—
단일 *corpus* 신호 (학습 없음)				
entity co-occurrence	0.546	—	—	—
entity 빈도	0.565	—	—	—
답변 3-gram 등장 빈도	0.563	—	—	—
question-answer bridge (평균)	0.583	—	—	—
답변 3-gram 미등장 개수	0.583	—	—	—
Fusion 모델 (*sample* 단위 *5-fold* 교차검증, 검증 *fold* 예측 기준)				
logistic regression (corpus 미포함)	0.793	0.548	0.164	—
logistic regression (corpus 포함)	0.795	0.550	0.162	+0.002
random forest (corpus 미포함)	0.790	0.546	0.166	—
random forest (corpus 포함)	0.800	0.555	0.161	+0.010
gradient boosting (corpus 미포함)	0.800	0.553	0.161	—
gradient boosting (corpus 포함)	**0.808**	**0.559**	**0.158**	+0.008

표 4.2 단일 신호의 AUROC 와 AURAC. 모든 신호는 신호 점수의 순위만으로 평가하며 별도 학습은 적용하지 않는다. 마지막 열은 Semantic Entropy 와 Semantic Energy 원 논문이 다른 모델에서 보고한 AUROC 범위이다.

신호	AUROC	AURAC	비교 (선행 연구)
Semantic Entropy	0.759	0.526	Farquhar (2024) TriviaQA 0.79, SQuAD 0.83 (Llama-2 7B)
Semantic Energy	0.774	0.533	Ma (2025) TriviaQA ∼0.85 (Qwen3-8B)
답변 평균 음의 로그우도 (NLL)	0.670	0.468	—
답변 전체 로그우도	0.656	0.466	—
답변 내 logit 분산	0.620	0.400	—

표 4.3 단일 corpus 신호를 환각 탐지 신호로 사용했을 때의 AUROC. 각 신호는 한 sample 의 모든 답변에 같은 값으로 적용되며, 신호 점수의 순위만으로 평가한다. 모든 결과가 0.50–0.58 범위에 한정된다.

신호	AUROC
question-answer bridge (평균)	0.583
답변 3-gram 미등장 개수	0.583
question-answer bridge (미등장 표시)	0.574
entity 빈도	0.565
답변 3-gram 등장 빈도	0.563
답변 5-gram 등장 빈도	0.557
entity co-occurrence	0.546
question-answer bridge (정규화)	0.511
entity 빈도 (평균)	0.500

다. 이는 corpus 신호가 sample 단위의 정적 신호라는 특성상, 같은 sample 안 10개 답변 사이의 정답 여부 변동을 구분하기 어렵기 때문이다. 따라서 본 절은 corpus 신호가 환각 탐지에 무용하다는 주장이 아니라, sample 단위 정적 신호만으로는 답변 단위 정답 여부 변동을 분리하기 어렵다는 점을 정량화하여 후속 분석의 동기를 제시한다.

주목할 점은 후속 절 (§4.6) 에서 가장 큰 구간별 AUROC range 를 보이는 entity co-occurrence 신호가, 표 4.3 의 단독 AUROC 비교에서는 0.546 으로 하위권에 머문다는 사실이다. 단독 신호로서의 분리력과 같은 신호로 sample 을 나누어 분석했을 때의 구간별 AUROC range 는 서로 다른 지표이며, 이 비대칭이 본 연구 핵심 결과의 출발점이다.

4.4 신호 결합 (fusion) 결과

Fusion 모델의 AUROC 와 corpus 신호 추가 효과를 표 4.4 에 정리하였다.

표 4.4 Fusion 모델의 AUROC. 모든 모델은 sample 단위 5-fold GroupKFold 의 검증 fold 예측으로 평가하였다. *corpus* 추가 효과 는 같은 분류기에서 핵심 입력만 사용한 경우와 핵심 입력에 corpus 신호를 함께 쓴 경우의 AUROC 차이이다.

Method	AUROC	AURAC	corpus 추가 lift
Semantic Energy 단독	0.774	0.533	— (기준)
Semantic Entropy 단독	0.759	0.526	—
logistic regression (corpus 미포함)	0.793	0.548	—
logistic regression (corpus 포함)	0.795	0.550	+0.002
random forest (corpus 미포함)	0.790	0.546	—
random forest (corpus 포함)	0.800	0.555	+0.010
gradient boosting (corpus 미포함)	0.800	0.553	—
gradient boosting (corpus 포함)	**0.808**	**0.559**	+0.008

Semantic Energy 단독 (0.774) 대비 gradient boosting (corpus 미포함, 0.800) 의 +0.026 향상은 답변 단위 logit 통계 (NLL, logit 분산 등) 와 sample 단위 cluster 신호의 결합에서 비롯된다. 측정 단위가 서로 다른 불확실성 신호를 결합하는 방식이 단일 신호보다 분리력을 끌어올리는 데 기여한다. corpus 신호 추가 효과는 random forest 에서 +0.010, gradient boosting 에서 +0.008 이다 (95% 신뢰구간 [+0.005, +0.011], sample 단위 부트스트랩 반복 500회, 모든 반복에서 양수). 통계적으로 유의하지만 절대 크기는 작으며, 답변 단위와 sample 단위 신호 결합 효과 (+0.026) 의 약 3분의 1 수준이다. fusion 입력 변수로서의 기여는 제한적인 반면, 같은 신호로 sample 을 분할했을 때의 구간별 AUROC range 는 큰 비대칭을 보인다 (다음

절 참조).

4.5 비대칭 메커니즘 부분 분석

§4.4 의 fusion lift (+0.008) 와 §4.6 의 구간별 AUROC range (Δ0.150) 사이의 큰 비대칭은 corpus 신호가 환각 탐지 신호의 선형 예측 변수 로서가 아니라 영역별 신뢰도를 조절하는 요인 (effect modifier) 으로 작동할 가능성을 시사한다. 본 절은 세 가지 보조 분석으로 이 가설을 부분 검증한다.

1) Semantic Entropy 와 corpus 신호 사이의 직접 상관. 표 4.5 는 Semantic Entropy 와 6 개 corpus 신호 사이의 Spearman ρ 를 보고한다. 모든 절대값이 0.02–0.16 범위에 머물러 두 신호군이 거의 직교하는 것에 가깝다. "corpus 신호의 fusion lift 가 작은 이유는 SE 와 이미 상관이 높아 한계 정보가 작기 때문" 이라는 가설은 이 데이터에서 강하게 지지되지 않는다. corpus 신호가 SE 와 무관함에도 불구하고 fusion 입력으로 +0.008 만 기여한다는 사실은, corpus 신호가 개별 *sample* 의 정답 확률을 직접 예측하는 신호로는 약하다는 점을 의미한다.

표 4.5 Semantic Entropy / Semantic Energy 와 6 개 corpus 신호 사이의 Spearman ρ (n=35,000). $|\rho|$ 가 모두 0.16 이하로 두 신호군은 거의 직교한다. p 값은 양측 검정.

Corpus 신호	Semantic Entropy ρ	Semantic Energy ρ
entity 빈도 (entity_frequency_axis)	−0.124	−0.125
entity co-occurrence (entity_pair_cooccurrence_axis)	−0.121	−0.117
question-answer bridge (qa_bridge_axis)	−0.142	−0.151
답변 3-gram 등장 (ans_ngram_3_axis)	+0.095	+0.108
답변 5-gram 등장 (ans_ngram_5_axis)	+0.021	+0.030
답변 3-gram 미등장 (ans_ngram_3_zero_count)	+0.147	+0.164

2) SE × corpus interaction term 의 회귀 계수. 표준화된 입력 (−Semantic Entropy, entity_pair_cooccurrence_axis, 그리고 두 변수의 곱) 위에서 logistic regression 을 prompt 단위 5-fold GroupKFold OOF 로 학습한다. 두 모델을 비교한다. 첫째는 main effect 만 (SE + corpus), 둘째는 interaction term 까지 포함 (SE + corpus + SE×corpus). 표준화 계수는 SE +1.13, corpus −0.35, interaction −0.37 로, interaction 의 절대 크기가 corpus main effect 와 같은 수준이다. 그러나 OOF AUROC 는 0.7585 (no interaction) → 0.7590 (with interaction) 로 +0.0005 만 변동한다. interaction 자체는 통계적으로 0 이 아니지만, 예측 분리력을 끌어올리는 데는 기여하지 않는다. corpus 신호가 SE 의 개별 답변 단위 확률 을 조절한다기보다는 SE 가 신뢰할 수 있는 영역의 경계 를 정한다는 해석에 부합한다.

3) Corpus 영역별 calibration. 표 4.6 는 entity co-occurrence 10분위 구간 안에서 Semantic Entropy 의 sample 단위 정답률, AUROC, Brier, ECE 를 함께 보고한다. corpus 가 가장 부족한 구간 (00–10) 의 정답률은 0.27 인데 가장 풍부한 구간 (70–80) 은 0.38 로, 정답률이 약 1.4배 높다. AUROC 는 0.643 에서 0.793 으로 Δ0.150 변동하며, ECE (calibration 오차) 도 구간 사이에서 0.07–0.28 의 큰 변동을 보인다. 즉 SE 의 *ranking* 분리력 (AUROC) 과 확률 *calibration* (ECE) 모두 corpus 영역에 따라 달라진다. 이는 SE 의 성능 자체가 corpus 영역에 의해 조절되는 effect modification 패턴이며, 특정 평가 지표에서만 나타나는 분석 절차의 부산물이 아니라 다중 평가 지표에서 일관되게 관찰되는 본질적 특성임을 보여준다.

표 4.6 entity co-occurrence 10분위 구간 안에서 Semantic Entropy 를 score 로 사용했을 때의 sample 단위 정답률, AUROC, Brier, ECE. 모든 구간 n=3,500 (35,000 / 10). AUROC 와 ECE 모두 corpus 영역에 따라 큰 폭으로 변동.

Bin (entity co-occurrence 10분위)	n	정답률	AUROC	Brier	ECE
00–10 (corpus 가장 부족)	3,500	0.274	0.643	0.211	0.156
10–20	3,500	0.178	0.711	0.142	0.113
20–30	3,500	0.157	0.671	0.127	0.073
30–40	3,500	0.400	0.761	0.248	0.234
40–50	3,500	0.365	0.786	0.219	0.202
50–60	3,500	0.453	0.765	0.278	0.275
60–70	3,500	0.356	0.768	0.225	0.203
70–80 (corpus 가장 풍부)	3,500	0.379	0.793	0.214	0.191
80–90	3,500	0.354	0.735	0.231	0.197
90–100	3,500	0.309	0.767	0.196	0.158
전체	**35,000**	**0.322**	**0.759**	**0.211**	**0.180**

종합 해석. 세 보조 분석을 종합하면 비대칭의 부분적 메커니즘은 다음과 같다. (i) corpus 신호와 SE 는 거의 직교한다 ($|\rho| \leq 0.16$). (ii) corpus 신호는 SE 의 sample 단위 확률 예측 자체를 보강하지는 않는다 (interaction term 이 OOF AUROC 에 +0.0005 만 기여). (iii) 그럼에도 corpus 영역별로 SE 의 AUROC 와 ECE 가 큰 폭으로 변동하며 (Δ0.150 / ECE 0.07–0.28), 이는 SE 의 성능 자체 가 corpus 영역에 의해

조절되는 effect modification 패턴이다.

즉 corpus 신호는 "어느 영역에서 SE 를 신뢰해야 하는가" 라는 메타 정보 로 작용하며, "개별 답변이 환각인가" 를 직접 예측하는 정보로는 약하다. 본 비대칭은 이 두 역할의 차이를 정량화한 결과이며, 특정 분석 방식에서만 우연히 나타난 결과 (예: ranking metric 의 분포 의존성) 가 아니라 corpus 환경에 따른 모델 행동 변화를 반영한다고 해석된다. 다만 본 절은 부분 분석이며, 가능한 다른 메커니즘 (예: fusion 모델의 비선형성 한계, 10분위 이산화 효과) 의 완전한 배제는 향후 과제로 남긴다.

4.6 Corpus 신호 단위별 분해 결과

각 corpus 신호로 sample 을 10분위 구간으로 나눈 뒤, 구간 안에서 Semantic Entropy, Semantic Energy, 답변 평균 NLL 의 AUROC 를 계산하고 최댓값과 최솟값의 차이 $\Delta = \mathrm{AUROC}_{\max} - \mathrm{AUROC}_{\min}$ 를 AUROC range 로 측정하였다. 본 논문의 핵심 결과는 표 4.7 와 그림 4.1 이다.

표 4.7 Corpus 신호별로 산출한 Semantic Entropy / Semantic Energy / 답변 평균 NLL 의 구간별 AUROC range 와 단조성 (ρ). 본 표 이하 본문 전체에서 *AUROC range* 는 $\Delta = \mathrm{AUROC}_{\max} - \mathrm{AUROC}_{\min}$ 으로 정의하며, 표 헤더 / 본문에서 두 표기를 동등하게 사용한다. 각 신호는 sample 단위 순위 기반 10분위 구간으로 이산화하였다. ρ 는 Spearman 상관 (구간 순위와 구간별 AUROC, 양수는 단조 증가) 이며, p 값은 양측, n=10 (구간 수) 이다. 본 표는 다음 두 단서를 전제로 해석한다. 첫째, 7개 신호 × 3개 환각 탐지 신호 = 21개 동시 검정에 대해 다중비교 보정을 적용하지 않은 예비 분석이며, Bonferroni 보정 (α=0.05/21≈0.0024) 을 적용하면 본 표의 모든 ρ 가 유의 기준을 충족하지 않으며 (가장 강한 답변 평균 NLL 의 ρ=+0.733, p=0.016 도 임계를 통과하지 못한다), 따라서 본 ρ 결과는 예비 분석으로 한정한다. 둘째, n=10 에서 ρ=±0.648 이 양측 p=0.05 의 임계값에 해당하므로, $|\rho|$=0.65 부근의 결과는 구간 폭과 동순위 처리 방식에 민감하다. 별표 (★) 는 해당 환각 탐지 신호의 AUROC range 가 가장 큰 행을 표시한다.

Corpus 신호 (단위)	Semantic Entropy Δ	Semantic Entropy ρ (p)	Energy Δ	Energy ρ (p)	NLL Δ	NLL ρ (p)
entity 빈도	0.080	+0.636 (0.048)	0.077	+0.467 (0.174)	0.082	+0.394 (0.260)
baseline (entity 빈도 + entity co-occurrence 평균)	0.082	+0.418 (0.229)	0.086	+0.297 (0.405)	0.063	+0.600 (0.067)
question-answer bridge	0.089	+0.648 (0.043)	0.087	+0.576 (0.082)	**0.176** ★	+0.430 (0.214)
답변 3-gram 등장 빈도	0.099	+0.370 (0.293)	0.098	+0.370 (0.293)	0.125	+0.091 (0.803)
답변 5-gram 등장 빈도	0.105	+0.685 (0.029)	0.096	+0.539 (0.108)	0.102	−0.127 (0.726)
답변 3-gram 미등장 개수	0.122	+0.261 (0.467)	0.104	+0.309 (0.385)	0.116	−0.224 (0.533)
entity co-occurrence	**0.150** ★	+0.648 (0.043)	**0.144** ★	+0.600 (0.067)	0.092	+0.733 (0.016)

두 corpus 신호의 분해 패턴을 세 환각 탐지 신호 (Semantic Entropy, Semantic Energy, 답변 평균 NLL) 에 대해 비교한 결과를 그림 4.1 에 제시한다.

표 4.7 와 그림 4.1 에서 다음 결과가 도출된다.

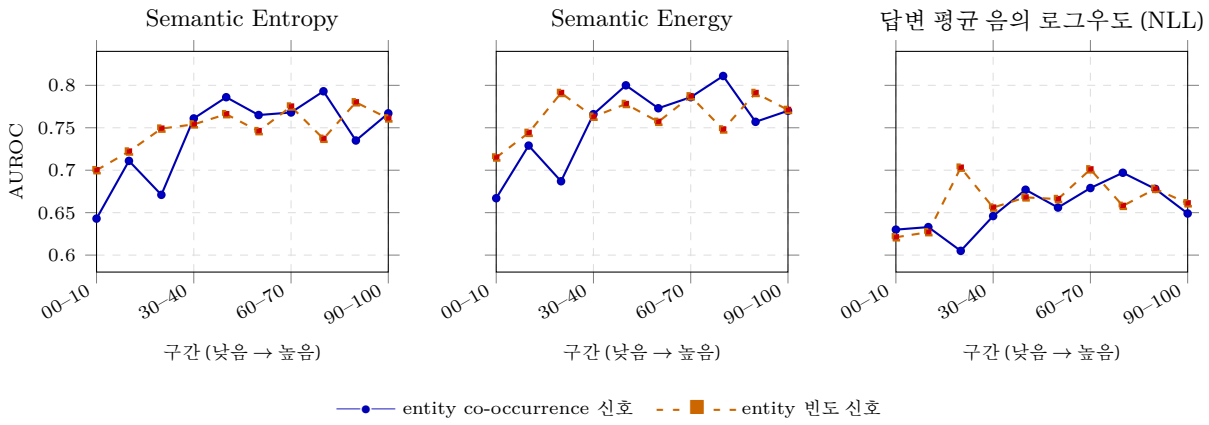

그림 4.1 세 환각 탐지 신호 (Semantic Entropy, Semantic Energy, 답변 평균 NLL) 의 구간별 AUROC 를 entity co-occurrence 신호 (실선) 와 entity 빈도 신호 (점선) 로 sample 을 분할하여 비교한 결과. 세 환각 탐지 신호 모두 entity co-occurrence 신호로 분할했을 때의 AUROC range 가 entity 빈도 신호로 분할했을 때보다 크며, Semantic Entropy 와 Semantic Energy 에서 그 차이가 뚜렷하게 나타난다. Semantic Entropy 의 AUROC range 는 entity co-occurrence 신호에서 $\Delta 0.150$, entity 빈도 신호에서 $\Delta 0.080$ 이다. Semantic Energy 도 비슷한 패턴을 따른다 ($\Delta 0.144$ 와 $\Delta 0.077$). 답변 평균 NLL 은 두 신호 모두에서 AUROC range 가 작다 ($\Delta 0.092$ 와 $\Delta 0.082$). 두 신호 모두 구간이 올라갈수록 AUROC 가 일관되게 증가하지는 않는다. 예를 들어 entity co-occurrence 신호로 분할했을 때 Semantic Entropy 는 구간 20–30 에서 0.671 로 일시 하락한 뒤 회복한다.

Entity co-occurrence 신호의 구간별 AUROC range. entity co-occurrence 신호로 sample 을 10분위 구간으로 나눌 때, Semantic Entropy 의 AUROC range (Δ) 는 0.150, Semantic Energy 는 0.144 로 나타났다. 이는 본 연구에서 비교한 일곱 가지 corpus 신호 가운데 가장 큰 범위이다.

sample 단위 부트스트랩 (500회 반복) 으로 계산한 95% 신뢰구간은 Semantic Entropy AUROC range 가 0.121–0.211, entity 빈도 신호는 0.058–0.149 였다. 두 값의 차이는 95% 신뢰구간 [+0.002, +0.117] 으로 0 을 포함하지 않으며, 부트스트랩 반복의 97.6% 에서 양의 값으로 관찰되었다. Semantic Energy 에서도 차이가 [+0.004, +0.109] 로 98.0% 가 양수였다. 따라서 entity co-occurrence 신호로 분할했을 때의 AUROC range 가 entity 빈도 신호보다 크다는 결과는, 표본 변동성을 통제한 뒤에도 통계적으로 유지된다.

corpus 가 가장 부족한 구간 (00–10) 에서는 Semantic Entropy 가 0.643, Semantic Energy 가 0.667 로 관찰되었으며, 가장 풍부한 구간 (70–80) 에서는 각각 0.793, 0.811 로 측정되었다. 다만 구간이 한 단계씩 올라갈 때마다 AUROC 가 단조 증가하지는 않으며, 중간 구간에서는 일시적인 하락과 회복이 관찰된다 (그림 4.1). "체계적 정렬" 이라는 표현은 양 끝단 사이의 평균적인 증가 경향과 최댓값과 최솟값의 폭을 가리키며, 인접 구간 사이의 엄밀한 단조 증가를 뜻하지 않는다.

이러한 결과는 답변에 등장하는 entity 쌍이 corpus 에 함께 등장하는 정도가 LLM 의 해당 사실 학습 가능성을 반영하는 지표로 작용하며, 답변 간 일관성을 측정하는 신호의 변동과 연결되는 한 요인임을 시사한다.

Entity 빈도 신호의 구간별 AUROC range. 단일 entity 빈도 (entity frequency) 신호로 sample 을 분할했을 때의 AUROC range 는 Semantic Entropy 기준 Δ0.080, Semantic Energy 기준 Δ0.077 로 본 표에서 가장 작다. 본 연구의 baseline corpus 신호 (entity 빈도와 entity co-occurrence의 평균) 도 AUROC range 가 Δ0.082–0.086 으로 entity 빈도 신호와 거의 같은 수준이다. entity co-occurrence 신호의 큰 AUROC range 가 entity 빈도 신호의 작은 AUROC range 와 평균되며 희석된 결과로 해석되며, corpus 신호를 설계할 때 두 단위를 따로 보고해야 한다는 점을 시사한다. 평균화의 영향은 AUROC range 뿐 아니라 단조성에서도 나타난다. entity co-occurrence 신호 (Semantic Entropy ρ=+0.648, p=0.043) 와 entity 빈도 신호 (Semantic Entropy ρ=+0.636, p=0.048) 모두 양의 단조성을 보이지만, 두 점수의 평균인 baseline corpus 신호는 Semantic Entropy ρ=+0.418 (p=0.229) 로 유의 임계 아래에 머무른다 (표 4.7). 단위가 다른 두 신호를 평균하면 각 신호가 가지고 있던 단조 증가 경향까지 무뎌진다. 본 논문의 정량 비교 — entity co-occurrence 단위가 entity 빈도 단위보다 Semantic Entropy AUROC range 를 약 1.88배 크게 보인다는 점 — 은 본 결과에서 곧바로 도출된다.

Question-answer bridge 신호와 NLL 변동의 관계. Question-answer bridge 신호 ((질문 entity, 답변 entity) 쌍의 corpus 동시 등장 빈도) 로 sample 을 분할하면, 답변 평균 NLL 의 AUROC range 가 Δ0.176

로 측정된다. Semantic Entropy 와 Semantic Energy 의 AUROC range (Δ0.089, Δ0.087) 보다 큰 폭이다. (질문, 답변) 의 사실 관계가 corpus 에 함께 등장하는 정도가 모델의 토큰 단위 자신감 (NLL) 과 가장 직접 연결되며, Semantic Entropy 나 Semantic Energy 가 포착하는 답변 사이 일관성과는 다른 정보를 측정함을 시사한다.

답변 3-gram 미등장 개수 신호: AUROC range 와 단조성의 분리. 답변에서 corpus 에 한 번도 등장하지 않은 3-gram 의 개수로 sample 을 분할하면, Semantic Entropy AUROC range 는 Δ0.122 로 비교적 큰 편에 속한다. 그러나 단조성은 ρ=+0.261 (p=0.467, 표 4.7) 로, entity co-occurrence (ρ=+0.648), question-answer bridge (ρ=+0.648), 답변 5-gram (ρ=+0.685) 등 다른 신호와 달리 유의수준 0.05 를 넘지 않는다. 이 신호의 AUROC range 는 구간이 올라갈수록 일관되게 증가하는 패턴이 아니라, U자형이나 일부 구간의 일시적 변동에서 비롯된 것으로 보인다. 따라서 "corpus 미등장 3-gram 이 많을수록 Semantic Entropy 가 낮아진다" 라고 단정하기는 어렵고, 미등장 3-gram 비율이 높은 일부 구간에서 Semantic Entropy AUROC 의 변동이 관찰된다는 정도로 해석을 한정한다.

강건성 검증: 질문 entity 한정 신호. 앞서 사용한 entity co-occurrence 신호는 질문과 데이터셋이 제공한 정답 텍스트의 entity 를 모두 합쳐 산출하므로, 답변 측 entity 가 신호 값에 영향을 줄 가능성이 있다. 본 절은 이 가능성을 강건성 검증으로 점검한다. 질문 텍스트에서만 entity 를 추출하여 같은 분석을 재수행하였으며, 질문이 두 개 이상의 entity 를 포함하는 2,095 sample 이 분석 대상이 된다. 그 결과 Semantic Entropy 의 AUROC range 는 0.178, Semantic Energy 의 AUROC range 는 0.162 로, 원래 신호 (Semantic Entropy 0.150, Semantic Energy 0.144) 보다 큰 AUROC range 가 관찰되었다. 질문에 한정한 entity 빈도 신호의 Semantic Entropy AUROC range 는 0.081 로 원래 신호의 0.080 과 거의 같다. 따라서 entity co-occurrence 단위가 entity 빈도 단위보다 AUROC range 가 크다는 본 논문의 결과는 답변 측 entity 를 신호 산출에서 제거해도 유지된다. 비율은 약 1.88배에서 Semantic Entropy 기준 2.20배, Semantic Energy 기준 2.10배로 오히려 증가한다. 이는 두 가지를 시사한다. 첫째, 본 신호의 AUROC range 는 모델 출력으로 인해 인공적으로 부풀려진 결과가 아니다. 둘째, 질문 측 entity co-occurrence 이 LLM 의 사전학습된 지식을 더 직접 반영하는 지표일 가능성이 있다. 다만 본 분석의 부분표본은 entity 가 두 개 이상인 질문에 한정된다. 이러한 질문은 단일 entity 의 사실을 묻기보다 entity pair 의 관계를 묻는 지식 질문에 치우친다. entity pair 관계는 정의상 entity co-occurrence 와 직접 대응하므로, 본 부분표본은 entity co-occurrence 신호의 AUROC range 가 본래 크게 나타나는 조건이며, 이는 선택 편향 (selection bias) 에 해당한다. 따라서 비율 2.20 의 절대 크기는 이 부분표본의 특성을 반영한다. 전체 표본의 비율 1.88 과 산술적으로 직접 비교하기보다는, 답변 측 entity 를 제거해도 비율의 부호가 유지된다는 정성적 강건성 결과로 해석한다.

강건성 검증: SVAMP 제외 민감도. SVAMP 는 다른 네 데이터셋과 달리 수학 단어 문제이므로, entity co-occurrence의 의미가 지식 질문과 다를 수 있다. SVAMP 를 제외한 3,200 sample 으로 같은 분석을 재수행하면, Semantic Entropy 기준 비율 (entity co-occurrence AUROC range / entity 빈도 AUROC range) 은 1.68 로 전체 표본의 비율 1.88 보다 약 0.20 줄어든다. Semantic Energy 기준 비율도 1.54 로 비슷한 폭으로 감소한다. 두 단위 사이의 부호 (entity co-occurrence > entity 빈도) 는 유지되지만, 절대 크기는 SVAMP 포함 여부에 따라 달라진다. 본 결과를 토대로 비율은 1.5–1.9 범위로 보고하는 것이 안정적이다.

데이터셋별 분해 결과. 표 4.8 는 데이터셋별 Semantic Entropy AUROC range 를 entity co-occurrence 신호와 entity 빈도 신호 모두에 대해 보고한다. 다섯 데이터셋 중 네 데이터셋 (BioASQ, SQuAD-1.1, SVAMP, TriviaQA) 에서는 entity co-occurrence AUROC range 가 entity 빈도 AUROC range 보다 크거나 같다. 다만 비율은 TriviaQA 의 1.0배에서 BioASQ 의 2.92배까지 큰 폭으로 변동한다. NQ-Open 에서는 부호가 역전되어 entity 빈도 AUROC range (0.372) 이 entity co-occurrence AUROC range (0.250) 보다 크다. 따라서 전체 표본의 비율 1.88배는 데이터셋별 비율의 평균이 아니라, BioASQ 의 큰 비율 (2.92) 이 NQ-Open 의 역전 (0.67) 을 보상하여 형성된 표본 종합 통계이다. 즉 entity co-occurrence 신호가 모든 데이터셋에서 entity 빈도 신호보다 큰 AUROC range 를 보이지는 않는다. 본 결과는 데이터셋 도메인에 따라 적절한 corpus 신호의 단위가 달라질 수 있다는 가설을 제기한다.

표 4.8 데이터셋별 Semantic Entropy 와 Semantic Energy 의 AUROC range 를 entity co-occurrence 신호와 entity 빈도 신호에서 비교한 결과. NQ-Open 에서는 entity 빈도 AUROC range 가 entity co-occurrence AUROC range 보다 크다 (★). 다만 NQ-Open 의 Semantic Energy AUROC range 0.514 와 entity 빈도 AUROC range 0.372 는 정답 분포의 불균형에서 일부 비롯된다. NQ-Open 의 정답률은 0.240 이고, 두 번째 구간 (20–30) 은 표본 120개 중 정답이 7개에 불과하여 AUROC 가 0.266 인 outlier 가 발생하였다. 세 번째 구간 (30–40) 은 단일 클래스로 산출 대상에서 제외되었다. 이 outlier 구간을 제외하면 NQ-Open 의 AUROC range 는 다른 데이터셋과 비슷한 0.10–0.15 수준으로 줄어든다. 따라서 본 표는 표본 종합 비율이 데이터셋 평균과 일치하지 않는다는 점을 보이는 용도에 한정한다.

데이터셋	Semantic Entropy AUROC range (entity co-occurrence)	Semantic Entropy AUROC range (entity 빈도)	Semantic Entropy 비율	Energy AUROC range (entity co-occurrence)
BioASQ	0.272	0.093	2.92	0.184
SQuAD-1.1	0.166	0.125	1.33	0.271
SVAMP	0.126	0.134	0.94	0.184
TriviaQA	0.088	0.089	0.99	0.113
NQ-Open ★	0.250	**0.372**	**0.67**	0.514
전체 표본	**0.150**	**0.080**	**1.88**	**0.144**

4.7 데이터셋별 변동

다섯 데이터셋별 단일 신호와 fusion 모델의 AUROC 를 표 4.9 에 정리하였다.

표 4.9 데이터셋별 AUROC. sample 단위 5-fold 교차검증의 검증 fold 예측을 기준으로 산출하였다. 정답률은 데이터셋 평균이다.

데이터셋	n	정답률	Semantic Entropy	Semantic Energy	평균 NLL	gradient boosting (corpus 포함)
TriviaQA	8,000	0.482	0.778	0.782	0.633	0.803
SVAMP	3,000	0.431	0.786	0.787	0.713	0.824
BioASQ	8,000	0.339	0.746	0.759	0.678	0.811
NQ-Open	8,000	0.240	0.709	0.731	0.635	0.796
SQuAD-1.1	8,000	0.189	0.700	0.716	0.593	0.748
전체	**35,000**	**0.322**	**0.759**	**0.774**	**0.670**	**0.808**

baseline corpus 신호 (entity 빈도와 entity co-occurrence 의 평균) 로 sample 을 분할하면, gradient boosting (corpus 포함) 의 AUROC 는 구간 30–40 에서 최저 0.762, 구간 60–70 에서 최고 0.859 까지 $\Delta 0.097$ 의 변동을 보인다. 같은 분석을 entity co-occurrence 신호로 수행하면 Semantic Entropy 기준 AUROC range 가 $\Delta 0.150$ 로 더 커져, 패턴이 한층 분명하다 (표 4.7). 정답률도 corpus 가 풍부한 구간 (60–70, 0.382) 이 부족한 구간 (10–20, 0.209) 보다 높아, corpus 뒷받침 정도와 정답률 사이의 양의 상관이 확인된다. 데이터셋 사이의 패턴도 같은 방향으로 나타난다. 정답률은 TriviaQA (0.482) 에서 SQuAD (0.189) 로 감소하며, 환각 탐지 신호 AUROC 도 같은 순서로 감소한다 (Semantic Entropy 기준 TriviaQA 0.778, SQuAD 0.700). 이는 corpus 뒷받침 효과가 데이터셋 사이에서도 동일한 방향으로 나타남을 시사한다.

제 5 장 결론

5.1 논의

본 연구는 환각 탐지 신호의 성능이 사전학습 corpus 의 뒷받침 정도에 따라 크게 달라진다는 사실을 체계적으로 보여주었다. 특히 entity co-occurrence 신호로 sample 을 분할했을 때 Semantic Entropy 와 Semantic Energy 의 AUROC range 가 entity 빈도 신호보다 약 1.5–1.9 배 컸다 (Semantic Entropy 기준 $\Delta 0.150$ 와 $\Delta 0.080$). 이는 "Paris–France 가 함께 등장하는지" 와 같은 entity pair 정보가 단일 entity 빈도보다 모델의 사실 학습 정도를 더 직접 반영한다는 직관과 일치한다.

가장 중요한 발견은 비대칭이다. 동일 corpus 신호를 fusion 모델 입력 변수로 추가했을 때 AUROC 향상 폭은 +0.008–+0.010 에 머물렀으나, 조건부 평가 척도로 사용했을 때 AUROC range 는 $\Delta 0.150$ 에 달했다. 이는 corpus 신호의 설계 목표를 "탐지기의 입력 변수" 에서 "탐지 신호의 영역별 신뢰도 분해 도구" 로 재설정할 필요를 시사한다. 향후 환각 탐지 연구에서는 평균 AUROC 뿐 아니라 corpus 조건에 따른 AUROC range 를 함께 보고하는 형식이 자리 잡는 것이 바람직하다.

실제 LLM 서비스 관점에서도 함의가 있다. corpus 뒷받침이 약한 질문 (예: entity co-occurrence 가 낮은 구간) 은 Semantic Entropy 와 Semantic Energy 의 신뢰도가 큰 폭으로 떨어지므로, 별도 검증 절차 (RAG 호출, 인간 검토, 더 강력한 fusion 모델 적용 등) 를 거치는 조건부 신뢰 전략을 도입할 수 있다. Question-answer bridge 신호와 답변 평균 NLL 사이의 AUROC range ($\Delta 0.176$) 은 같은 맥락의 보완 정보를 제공한다. 질문 entity 와 답변 entity 의 corpus 동시 등장은 LLM 이 "질문에서 답변으로 이어지는 경로" 를 사전학습에서 직접 학습했을 가능성을 근사하며, 이것이 토큰 단위 자신감을 반영하는 NLL 과 가장 직접 연결된다. Semantic Entropy 와 Semantic Energy 는 답변 사이 일관성을 보는 다른 차원의 신호이므로, 두 신호군이 서로 보완적인 정보를 포착한다고 해석할 수 있다.

효과 크기의 정밀도. §4.6 에서 보고한 Semantic Entropy AUROC range 차이의 95% 신뢰구간 [+0.002, +0.117] 은 0 을 포함하지 않으나, 하한이 +0.002 로 경계에 가까우며 신뢰구간 폭 (0.115) 이 점추정치 (+0.063) 의 약 1.8 배에 해당한다. 즉 "entity co-occurrence AUROC range 가 entity 빈도 AUROC range 보다 크다" 는 방향성은 본 표본에서 통계적으로 유의하지만, 효과 크기 자체의 정밀도는 낮다. 약 1.88 배라는 점추정치가 모집단 비율과 일치한다고 보지 않으며, 다음 세 가지 점을 함께 보고하였다. 첫째, SVAMP 포함 여부에 따라 비율은 1.68 에서 1.88 사이에서 변동한다. 둘째, 질문 entity 만으로 산출한 강건성 검증에서는 비율이 약 2.20 배까지 증가한다. 셋째, 데이터셋별로는 NQ-Open 처럼 부호가 역전되는

경우가 관찰된다 (표 4.8). 따라서 정량적 주장은 "방향성이 본 표본에서 유의하며, 비율의 점추정치는 약 1.5–1.9배 범위에 있다" 로 한정한다. 보다 정밀한 효과 크기 추정은 추가 모델과 corpus 위에서의 추가 표본을 통해 가능하다.

5.2 한계

Proxy corpus index 의 사용. 본 논문은 corpus 신호 산출에 Infini-gram 색인 `v4_dolmasample_olmo` (OLMo 의 16B Dolma sample) 을 사용하였다. 이는 Qwen2.5-3B 의 실제 사전학습 corpus 가 아니며, Qwen 의 사전학습 데이터는 공개되지 않았다. 따라서 본 논문이 측정한 "corpus 뒷받침" 은 모델이 실제로 학습한 데이터의 양이 아니라 투명하고 포괄적인 web-scale 색인 위에서 측정한 사실 등장 빈도이다.

이러한 proxy 사용은 다음과 같은 근거로 정당화된다. Web-scale 사전학습 corpus (Dolma, RedPajama, C4 등) 는 Common Crawl 기반의 공통 source 를 상당 부분 공유하므로, 하나의 transparent corpus 에서 산출한 통계가 다른 LLM 의 학습 노출에 대한 합리적 proxy 역할을 할 수 있다는 가정은 선행 연구에서도 널리 채택되어 왔다 (예: Min 등 2025[19] 의 QuCo-RAG). 그러나 이 proxy 대체는 형식적으로 보장되지 않으며, 본 논문 결과의 해석에 두 가지 제약을 가한다.

첫째, corpus 뒷받침이 큰 sample 에서 Semantic Entropy AUROC 가 높게 관찰되는 결과는 "모델이 학습해서 잘 안다" 라는 인과 진술이 아니라, "Dolma 와 같은 web 분포에서 자주 등장하는 사실은 Qwen 학습에서도 자주 등장했을 가능성이 높다" 라는 간접 추론을 통해서만 해석될 수 있다. 둘째, entity co-occurrence 가 entity 빈도보다 약 1.88배 큰 분해를 보인다는 비율 또한 Dolma 색인에 한정된 관찰이며, Qwen 의 실제 corpus 나 다른 모델의 corpus 에서는 두 단위의 비율이 달라질 수 있다.

따라서 본 결과는 corpus 빈도와 환각 사이의 상관 관찰에 한정되며, 모델 학습 가능성에 대한 인과 진술로 해석해서는 안 된다. 이 한계는 모델 제공자가 사전학습 corpus 를 공개하기 전까지 본 연구 설계에 내재하며, 후속 연구가 corpus 색인을 모델별 실제 학습 데이터로 교체하기 전에는 수치 자체의 외부 타당성에 분명한 제약이 있다.

이외에도 다음과 같은 한계가 있다.

1. **단일 모델 평가.** 본 연구는 Qwen2.5-3B 단일 모델에서 수행되었다. corpus 신호의 구간별 변동 패턴이 Llama, Mistral, Gemma 계열 모델에서도 같은 방향으로 나타나는지는 직접 검증되지 않았다. Farquhar 등 (2024)[7] 에서 서로 다른 LLM 계열 사이에서도 Semantic Entropy 의 패턴이 유사하게 관찰되었다는 점은 일반화 가능성을 시사하나, 이는 향후 연구로 남긴다.

2. **NLI 라벨링 한계.** 정답 라벨은 `microsoft/deberta-large-mnli` 기반 양방향 entailment ≥ 0.5 기준에 의존한다. LLM-as-judge 와 같은 다른 라벨링 방식과의 비교 검증은 향후 과제로 남는다.

3. **라벨과 신호의 부분 결합.** 정답 라벨과 Semantic Entropy / Semantic Energy 신호는 모두 동일한 N=10 개 생성 답변에서 산출된다. 라벨은 각 답변과 정답 후보의 NLI 매칭으로 결정되고, Semantic Entropy / Semantic Energy 는 같은 답변들의 의미 cluster 분포와 토큰 logit 에서 산출되므로, 두 양은 동일 답변 집합의 분산을 부분적으로 공유한다. 결과적으로 본 논문의 AUROC 는 모델 출력의 정답 여부와 모델 출력 사이 일관성이라는 동일 source 상의 결합도를 측정하며, 모델 출력과 외부 정답 텍스트 사이 일치도에 대한 독립 측정은 아니다. 평가 단위 (생성 답변 단위) 가 Farquhar 와 Ma 의 연구와 일치하므로 선행 연구 비교의 전제는 유지되며, 본 결과는 동일 라벨링 절차 위에서의 상대적 비교로 해석한다.

4. **Self-conditioning 회피.** corpus 통계량은 fusion 입력 변수와 분해 분석 신호 두 용도로 사용된다. 분해 분석은 모델 출력과 무관한 외부 corpus 통계 위에서 수행되므로 self-conditioning 문제는 발생하지 않는다.

5. **AUROC range 차이의 표본 변동성.** 약 1.88배라는 비율은 단일 조건에서 산출한 점추정치이며, 두 AUROC range 의 차이에 대한 sample 단위 bootstrap 95% 신뢰구간을 §4.6 에 함께 보고하였다 (Semantic Entropy [+0.002, +0.117], Energy [+0.004, +0.109]). 두 신뢰구간 모두 0 을 포함하지 않으므로, entity co-occurrence AUROC range 가 entity 빈도 AUROC range 보다 크다는 결과는 본 표본에서 통계적으로 유의하다. 다만 이 신뢰구간은 단일 모델, 단일 corpus 색인 위에서의 표본 변동성만을 통제하며, 모델과 corpus 일반화에는 별도 검증이 필요하다. 또한 max−min 통계량 자체가 순서통계량이므로 구간 수가 다른 분할에서는 비율의 절대 크기가 달라질 수 있다.

6. **Fusion lift 의 통계적 유의성.** corpus 신호 포함 여부에 따른 gradient boosting 의 lift 에 대한 sample 단위 bootstrap 95% 신뢰구간 [+0.005, +0.011] 은 0 을 포함하지 않으며 모든 반복에서 양수이다. 따라서 corpus 신호의 fusion 기여는 통계적으로 0 과 구분되는 양의 효과이지만, 절대 크기 (+0.008) 는 답변 단위 · sample 단위 신호 결합 효과 (+0.026) 의 약 3분의 1 정도에 한정된다.

7. **데이터셋별 이질성.** 표 4.8 에서 보이듯, entity co-occurrence AUROC range 가 entity 빈도 AUROC range 보다 크다는 패턴은 다섯 데이터셋 중 NQ-Open 에서 역전된다. 따라서 표본 종합 비율 1.88 배는 모든 데이터셋에서 entity co-occurrence 신호가 entity 빈도 신호보다 큰 AUROC range 를 보인다는 뜻이 아니라 데이터셋 종합 통계이다. 도메인별로 corpus 신호의 적절한 단위가 달라질 수 있다는 가설은 본 논문의 범위 밖이다.

8. **Corpus 신호의 entity 추출 범위.** 본 논문의 corpus 신호는 질문 텍스트와 데이터셋이 제공한 정답 텍스트의 entity 를 합쳐 산출하며, 모델이 생성한 답변의 entity 는 사용되지 않는다. 따라서 신호 값은 모델 출력과 독립이며, 한계 4 에서 다룬 답변 결합 문제와는 차원이 다르다. 답변 측 entity 의

영향을 분리하여 질문 entity 만으로 신호를 다시 산출한 결과는 §4.6 에 함께 보고하였으며, Semantic Entropy 기준 비율은 1.88 에서 2.20 으로 증가한다. 다만 부분표본 (n=2,095) 의 선택 편향은 §4.6 에 명시하였다.

9. **AUROC range 와 Spearman ρ 의 분리 해석.** AUROC range 는 max−min 통계량이므로, 구간이 올라갈수록 AUROC 가 단조 증가하는 양상과 비단조 변동 (U자형 등) 을 구분하지 못한다. 본 논문은 표 4.7 에 Semantic Entropy / Energy / 답변 평균 NLL 세 신호 모두에 대해 Spearman ρ 를 함께 보고함으로써 AUROC range 와 단조성을 분리해 진단한다. 다만 21 개 동시 검정에 대한 다중비교 보정 (Bonferroni α=0.05/21≈0.0024) 을 적용하면 표의 모든 ρ 가 유의 기준을 충족하지 않으므로, ρ 결과는 예비 분석으로 한정한다. 또한 n=10 (구간 수) 의 Spearman 검정력이 낮아 $|\rho|$=0.65 부근의 결과는 구간 폭과 동순위 처리에 민감하다. 보다 강건한 단조성 검정 (Mann-Kendall, partial ρ) 과 다중비교 보정은 향후 과제로 남긴다.

10. **NLI 임계값 0.5 의 민감도 미검증.** 본 논문은 정답 라벨을 양방향 entailment 확률 0.5 임계로 정의하였다. 임계값을 0.4 또는 0.6 으로 변경했을 때 AUROC range 와 비율이 어떻게 달라지는지에 대한 민감도 분석은 수행하지 않았으며, 본 결과가 임계 0.5 에 어느 정도 의존하는지는 후속 검증이 필요하다.

11. **Fusion 입력 변수의 기여도 분해 미수행.** fusion 모델의 +0.026 향상이 SE / Energy / 답변 단위 logit 통계 가운데 어느 신호의 결합에서 비롯되었는지를 분해하는 분석 (예: permutation importance, SHAP) 은 수행하지 않았다. 본 논문은 fusion 결과를 종합 AUROC 수준에서만 보고하며, 입력 변수별 기여도 분리는 후속 과제로 남긴다.

12. **NQ-Open 의 부분 구간 outlier 원인 미규명.** NQ-Open 의 두 번째 구간 (20–30) 에서 AUROC 가 0.266 까지 떨어지는 outlier 는 정답률 0.058 (표본 120 개 중 정답 7 개) 의 클래스 불균형에서 일부 비롯된 것으로 보이지만, 이러한 분포 skew 의 근본 원인 (질문 유형, entity 분포 등) 에 대한 추가 분석은 수행하지 않았다.

13. **단순 prompt 설정.** 본 연구는 추가 context 없는 한 문장 응답 prompt 위에서 수행되었다. 실무 LLM 서비스에서 표준이 된 RAG 환경이나 multi-turn agentic 설정에서의 일반화는 검증 대상이다. 본 결과를 retrieval-augmented 환경에 그대로 적용하기 전에 별도 검증이 필요하다.

14. **선행 연구 인용의 검증 한계.** 본 논문이 인용한 2025 년 arXiv preprint 일부 (Singha 2025[14], Wang 2025[15], Zhang 2025[18], Min 2025[19] 등) 는 본 논문 제출 시점 (2026 년 2 월) 기준 peer review 를 거치지 않은 작업이며, 보고된 수치의 재현 가능성은 독립적 검증이 필요하다. 특히 단일 저자 preprint 의 self-reported 개선폭은 보수적으로 해석한다. 본 논문 §2 의 인용은 갈래 정리 (배경 / 동기 부여)

목적에 한정하며, 본 논문 메인 결과의 비교 기준 (Farquhar 2024 Nature[7], Ma 2025[12], Kandpal 2023 ICML[1], Mallen 2023 ACL[4]) 은 모두 peer-reviewed venue 출판물이다.

5.3 향후 연구

본 연구의 결과를 토대로 다음 방향의 후속 연구를 제안한다.

1. **모델 다양화.** Llama, Gemma, Mistral, instruction-tuned 모델 등 다양한 모델에서 entity co-occurrence 신호의 AUROC range 패턴이 같은 방향으로 나타나는지 검증한다.
2. **실제 사전학습 corpus 사용.** 본 연구가 사용한 OLMo Dolma sample proxy 색인을 Qwen2.5 의 실제 사전학습 corpus 또는 모델별 학습 데이터에 가까운 색인으로 교체하여 proxy corpus 의 한계를 극복한다.
3. **도메인 특화 corpus.** BioASQ 의 PubMed, 수학 문제의 ArXiv 등 도메인 특화 색인을 사용했을 때 동일 신호의 AUROC range 가 더 커지는지 확인한다.
4. **LLM-as-judge 라벨과의 비교.** NLI 매칭 라벨을 LLM-as-judge 라벨로 대체했을 때 corpus 신호 단위별 AUROC range 가 어떻게 달라지는지 분석한다.
5. **RAG 및 agentic 환경 확장.** retrieval 없는 단순 prompt 설정을 RAG 환경이나 multi-turn agentic 설정으로 확장하여, corpus 뒷받침 정도와 retrieval 결과가 환각 탐지 신호의 신뢰도를 어떻게 함께 결정하는지를 검증한다.
6. **환각 원인 유형별 분해.** 본 연구는 사실 회상 (Type A) 영역을 주로 다루었다. 모델 내부 잘못된 지식 (Type B) 과 순수 조작 (Type C) 에서 corpus 신호 단위별 AUROC range 가 어떻게 달라지는지에 대한 별도 분석이 필요하다.
7. **정교한 corpus 신호 설계와 표준 벤치마크.** entity co-occurrence 외에 syntactic pattern, semantic similarity 기반 co-occurrence, temporal decay 를 고려한 최근성 가중치 등 정교한 corpus 신호를 설계하고, 데이터셋과 도메인별 최적 단위를 자동 선택하는 meta-learner 를 연구할 가치가 있다. 동시에 AUROC range 를 표준 평가 지표로 포함하는 새로운 환각 탐지 벤치마크의 제안도 자연스러운 확장이다.

5.4 결론

본 논문은 LLM 환각 탐지 신호 (Semantic Entropy, Semantic Energy, 답변 단위 token logit 통계) 의 성능이 사전학습 corpus 의 사실 등장 패턴에 따라 크게 달라진다는 점을 정량적으로 입증하였다. Qwen2.5-

3B 와 다섯 개 질의응답 데이터셋 (총 35,000 개 생성 답변) 위에서 분석한 결과, entity co-occurrence 신호로 sample 을 나누었을 때 Semantic Entropy 의 구간별 AUROC range 는 $\Delta 0.150$ 로, 단일 entity 빈도 신호의 AUROC range $\Delta 0.080$ 의 약 1.5–1.9 배에 해당한다 (SVAMP 포함 시 1.88 배, 제외 시 1.68 배). 두 AUROC range 차이에 대한 95% 신뢰구간 [+0.002, +0.117] 은 본 표본에서 방향성이 통계적으로 유의함을 보여주지만, 효과 크기의 정밀도는 낮으며 본 결과는 corpus 빈도와 환각 사이의 상관 관계 관찰로 해석한다 (현 색인이 모델의 실제 사전학습 corpus 와 다르므로 인과 해석은 불가).

가장 중요한 발견은 비대칭이다. 동일 corpus 신호가 fusion 모델 입력 변수로는 +0.008 의 작은 향상에 한정되는 반면, 조건부 분해 신호로 사용했을 때는 큰 AUROC range 를 보인다. 이 비대칭은 corpus 신호의 설계 목표를 환각 탐지기의 입력 변수가 아니라 탐지 신호의 조건부 평가 도구로 재정의할 필요를 제기하며, 평균 AUROC 하나만 보고하는 기존 관행을 넘어 corpus 조건에 따른 AUROC range 를 함께 보고하는 평가 형식을 제안한다. 동시에 실제 LLM 서비스에서 corpus 뒷받침이 약한 질문을 별도로 검증하는 조건부 신뢰 전략의 이론적 근거를 제공한다.

본 연구는 학사 논문으로서 단일 모델, proxy corpus, 표본 규모 등의 분명한 한계를 갖는다. 그럼에도 환각 탐지 연구에 corpus 중심의 조건부 분석이라는 새로운 관점을 제시했다는 점에서 의의가 있다. 더 다양한 모델과 실제 corpus 위에서의 후속 연구를 통해 본 관점이 한층 견고해지기를 기대한다.

참고문헌

[1] N. Kandpal, H. Deng, A. Roberts, E. Wallace, and C. Raffel, "Large Language Models Struggle to Learn Long-Tail Knowledge," *Proceedings of the 40th International Conference on Machine Learning (ICML),* vol. 202, pp. 15696–15707, 2023. arXiv:2211.08411.

[2] L. Kuhn, Y. Gal, and S. Farquhar, "Semantic Uncertainty: Linguistic Invariances for Uncertainty Estimation in Natural Language Generation," *Proceedings of ICLR,* 2023. arXiv:2302.09664.

[3] Y. Razeghi, R. L. Logan IV, M. Gardner, and S. Singh, "Impact of Pretraining Term Frequencies on Few-Shot Numerical Reasoning," *Findings of the Association for Computational Linguistics: EMNLP,* pp. 840–854, 2022. arXiv:2202.07206.

[4] A. Mallen, A. Asai, V. Zhong, R. Das, D. Khashabi, and H. Hajishirzi, "When Not to Trust Language Models: Investigating Effectiveness of Parametric and Non-Parametric Memories," *Proceedings of ACL,* pp. 9802–9822, 2023. arXiv:2212.10511.

[5] L. Huang et al., "A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions," *ACM Transactions on Information Systems,* vol. 43, no. 2, pp. 1–55, 2025.

[6] J. Maynez et al., "On Faithfulness and Factuality in Abstractive Summarization," *Proceedings of ACL,* pp. 1906–1919, 2020.

[7] S. Farquhar, J. Kossen, L. Kuhn, and Y. Gal, "Detecting hallucinations in large language models using semantic entropy," *Nature,* vol. 630, pp. 625–630, 2024.

[8] P. Manakul, A. Liusie, and M. J. F. Gales, "SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models," *Proceedings of EMNLP,* pp. 9004–9017, 2023.

[9] J. Kossen et al., "Semantic Entropy Probes: Robust and Cheap Hallucination Detection in LLMs," *arXiv preprint arXiv:2406.15927,* 2024.

[10] A. Nikitin, J. Kossen, Y. Gal, and P. Marttinen, "Kernel Language Entropy: Fine-grained Uncertainty Quantification for LLMs," *arXiv preprint arXiv:2405.20003,* 2024.

[11] K. Ciosek et al., "Hallucination Detection on a Budget: Efficient Bayesian Estimation of Semantic Entropy," *arXiv preprint arXiv:2504.03579,* 2025.

[12] Z. Ma et al., "Semantic Energy: A novel approach for detecting confabulation in language models," *arXiv preprint arXiv:2412.07965,* 2025.

[13] A. Ravichander et al., "HALoGEN: Fantastic LLM Hallucinations and Where to Find Them," *arXiv preprint arXiv:2501.08292,* 2025.

[14] S. Singha, "Detecting AI Hallucinations in Finance: An Information-Theoretic Method Cuts Hallucination Rate by 92%," *arXiv preprint arXiv:2512.03107,* 2025.

[15] L. Wang, "SEReDeEP: Hallucination Detection in Retrieval-Augmented Models via Semantic Entropy and Context-Parameter Fusion," *arXiv preprint arXiv:2505.07528,* 2025.

[16] S. Valentin et al., "Cost-Effective Hallucination Detection for LLMs," *arXiv preprint arXiv:2407.21424,* 2024.

[17] W. Zhao et al., "WildHallucinations: Evaluating Long-form Factuality in LLMs with Real-World Entity Queries," *arXiv preprint arXiv:2407.17468,* 2024.

[18] Y. Zhang et al., "Measuring the Impact of Lexical Training Data Coverage on Hallucination Detection in Large Language Models," *arXiv preprint arXiv:2511.17946,* 2025.

[19] D. Min et al., "QuCo-RAG: Quantifying Uncertainty from the Pre-training Corpus for Dynamic Retrieval-Augmented Generation," *arXiv preprint arXiv:2512.19134,* 2025.

[20] J. Liu et al., "Infini-gram: Scaling Unbounded n-gram Language Models to a Trillion Tokens," *arXiv preprint arXiv:2401.17377,* 2024.

[21] A. Yang et al., "Qwen2.5 Technical Report," *arXiv preprint arXiv:2412.15115,* 2024.

[22] M. Joshi, E. Choi, D. S. Weld, and L. Zettlemoyer, "TriviaQA: A Large Scale Distantly Supervised Challenge Dataset for Reading Comprehension," *Proceedings of ACL,* pp. 1601–1611, 2017.

[23] P. Rajpurkar, J. Zhang, K. Lopyrev, and P. Liang, "SQuAD: 100,000+ Questions for Machine Comprehension of Text," *Proceedings of EMNLP,* pp. 2383–2392, 2016.

[24] G. Tsatsaronis et al., "An overview of the BIOASQ large-scale biomedical semantic indexing and question answering competition," *BMC Bioinformatics,* vol. 16, no. 138, 2015.

[25] T. Kwiatkowski et al., "Natural Questions: A Benchmark for Question Answering Research," *Transactions of the ACL,* vol. 7, pp. 453–466, 2019.

[26] A. Patel, S. Bhattamishra, and N. Goyal, "Are NLP Models really able to Solve Simple Math Word Problems?," *Proceedings of NAACL,* pp. 2080–2094, 2021.