공학학사학위논문

LLM 환각 탐지에서 Semantic Entropy / Energy 와 외부 Corpus 신호의 조건부 한계 효용

2026 년 2 월

서울대학교

자유전공학부

문 정 혁

LLM 환각 탐지에서 Semantic Entropy / Energy 와 외부 Corpus 신호의 조건부 한계 효용

지도교수 김 남 수

이 논문을 공학 학사학위 논문으로 제출함

서울대학교

자유전공학부

문 정 혁

문정혁 의 학사 학위 논문을 인준함

2026 년 2 월 13일

지 도 교 수 (인)

초록

LLM 환각 탐지에서 Semantic Entropy (SE[3]), Semantic Energy[6] 같은 단일 신호와 이들을 결합한 fusion 결합기의 평균 성능을 보고하는 기존 연구는 입력 조건에 따른 영역별 행태를 가린다. 본 논문은 외부 corpus statistic (Infini-gram[11] 의 entity frequency 와 entity-pair co-occurrence) 을 외부 *conditional* 축으로 채택하여 5,815 개 질문 (TruthfulQA[7] + HaluEval-QA[10]) 을 corpus support 의 rank-quantile 10-decile 로 분할하고, 각 영역에서 단일 신호 (SE / Energy / logit-diagnostic) 와 fusion 의 AUROC 를 비교한다. 라벨은 각 질문의 free-sample N=10 정답 매칭 비율이 50% 미만인 경우 어려운 질문으로 정의한다.

세 가지 발견. 첫째, 환각 탐지 난이도는 모든 신호에서 corpus 부족 영역에 집중된다 (Energy AUROC 가 가장 낮은 decile 에서 0.821, 가장 높은 decile 에서 0.954로 단조 상승; SE / Fusion 도 동일 패턴). 둘째, 단일 신호 비교는 corpus 영역과 무관하다 — Energy 가 모든 10 decile 에서 SE 를 0.011 에서 0.047 사이의 일관된 폭으로 능가하고, logit-diagnostic 은 모든 영역에서 약하다 (CHOKE 패턴[9]). 셋째, *Fusion* 이 항상 최선은 아니다 — fusion 이 SE 와 logit-diagnostic 은 모든 영역에서 능가하지만, Energy 단독과는 영역별로 변동 (decile 70–80 에서 fusion 우위가 +0.050로 가장 크고, decile 40–50 에서는 *Energy* 단독이 *fusion* 보다 *0.014* 더 우수). 평균 우위 한 수치 (+0.027) 로는 가려지는 영역별 변동이 데이터로 드러난다.

본 결과는 (i) 환각 탐지 난이도와 외부 corpus support 의 관계를 영역별로 분해하고, (ii) fusion 의 우월성이 입력 조건에 따라 변동한다는 점을 정량 보고하여, 기존 fusion 연구의 평균 metric 보고 관행이 가리는 정보를 드러낸다.

주요어: 대규모 언어모델, 환각 탐지, Semantic Entropy, Semantic Energy, corpus support axis, metric reliability

목차

초록 **i**

제 1 장 서론 **1**

1.1 연구 배경 1

1.2 연구 목적 1

1.3 논문 구성 2

제 2 장 관련 연구 **3**

2.1 단일 신호 기반 탐지 3

2.2 Multi-signal Fusion 4

2.3 Corpus statistic 의 환각 탐지 활용 시도 4

2.4 공통 한계와 본 논문의 위치 5

제 3 장 제안 방법 **6**

3.1 평균 metric 보고의 한계 6

3.2 Corpus support 를 외부 conditional 축으로 사용하는 근거 6

3.3 본 논문의 분석 절차 7

제 4 장 실험 **8**

4.1 실험 설정 8

4.1.1 데이터셋 구성 8

4.1.2 모델 출력 수집 8

4.1.3 Feature 계산 8

4.1.4 평가 지표 9

4.2 종합 베이스라인 10

4.3 탐지 난이도와 corpus support 의 관계 10

4.4 단일 신호 영역별 비교 12

4.5 Fusion 의 영역별 변동 12

4.6 데이터셋별 결과와 Calibration 14

제 5 장 결론 **16**

5.1 연구 요약 16

5.2 학술적 기여 16

5.3 한계 17

5.4 향후 연구 17

표 목차

표 2.1 본 논문이 비교하는 단일 신호. 3

표 4.1 종합 baseline (n=5,815 질문). 라벨은 각 질문의 free-sample N=10 의 정답 매칭 비율이 0.5 미만인 경우 어려운 질문 (is_hard=1). 단일 신호는 score-based AUROC (학습 없음). Fusion 은 5-fold CV gradient boosting (input: SE, Energy, NLL, confidence margin, logit variance 의 질문 단위 집계). 굵은 글씨 = 1위. 10

표 4.2 Method × corpus support decile AUROC (n=5,815, 각 decile ≈ 580 질문). 굵은 글씨 = 단일 신호 중 1위. 12

표 4.3 데이터셋별 AUROC (5-fold CV pooled) 와 calibration. AGG 는 5,815 개 질문 전체를 5-fold CV 로 평가한 종합 AUROC 이며 단순 평균이 아니라 가중 평균에 가깝다 (HaluEval-QA 5,000 + TruthfulQA 815). Brier 와 ECE 는 종합 5,815 개 질문 위에서 산출. ECE 는 [0,1] 비율 단위. 14

그림 목차

그림 4.1 Per-decile AUROC 11
그림 4.2 Fusion vs single signal delta 13

제 1 장 서론

1.1 연구 배경

대규모 언어모델 (Large Language Model, LLM) 은 텍스트 생성, 질의응답 등 다양한 자연어 처리 태스크에 널리 사용되고 있으나, 사실과 다른 내용을 그럴듯하게 생성하는 환각 (hallucination) 문제를 보이며 이는 LLM 신뢰성의 핵심 과제이다[1]. 본 논문은 외부 사실과 충돌하는 응답을 탐지하는 문제 (사실성, factuality[2]) 에 초점을 두며, TruthfulQA[7] 같은 벤치마크가 이 평가 단위를 제공한다.

환각 탐지의 대표적 방법인 Semantic Entropy (SE, Farquhar 등 2024[3]) 는 한 질문에 대해 K 개 응답을 샘플링한 뒤 NLI 클러스터링 후 분포의 엔트로피를 계산한다. 반복 샘플링과 응답 간 일관성은 SelfCheckGPT[4] 와 같은 선행 연구에서도 환각 탐지의 핵심 단서로 사용되었다. 그러나 SE 와 같은 sample-consistency 신호는 모델이 모든 응답에서 같은 의미의 틀린 답을 반복하면 판별력이 약해진다. 이는 Simhi 등 (2025)[9] 이 CHOKE (high-certainty hallucination) 로 명명한 패턴이다. 후보 답변의 NLL / confidence margin 같은 logit 진단 신호도 "환각 답이 정답보다 덜 자신있을 것" 이라는 직관에 기대므로 동일 한계를 갖는다.

본 논문은 이 한계를 외부 *corpus support* 신호로 분해한다. 본 논문에서 corpus support 는 질문에 등장하는 entity 의 외부 corpus 내 frequency 와 entity-pair co-occurrence 를 결합한 점수를 가리킨다 (자세한 정의는 §4 실험 설정). corpus support 는 환각 / 정답 라벨이 아니라 탐지 신호의 영역별 행태를 분해하는 외부 조건 변수 이며, 본 논문은 corpus support 를 평가 단위로만 사용하고 탐지기 입력 feature 로는 사용하지 않는다.

1.2 연구 목적

본 논문은 다음 세 질문을 다룬다.

1. **탐지 난이도와 corpus support 의 관계.** 본 논문에서 탐지 난이도 는 한 영역 안에서 탐지기의 AUROC 가 낮은 정도를 가리킨다 (AUROC 가 낮을수록 어려운 질문과 쉬운 질문을 가르기 어려움). SE, Semantic Energy, logit-diagnostic, fusion 의 AUROC 가 corpus support 영역 (10-decile) 에 따라 어떻게 변하는가? 모든 신호가 공통 패턴을 보이는가, 아니면 신호별로 다른가?

2. **영역별 단일 신호 우열.** 단일 신호 비교 (SE / Energy / logit-diagnostic) 의 결론이 corpus support 영역에 따라 달라지는가, 아니면 일관된가?

3. **Fusion 의 영역별 변동.** Fusion 결합기가 단일 신호보다 항상 우수한가, 아니면 어떤 영역에서는 단일 신호가 더 좋은 케이스가 있는가?

본 논문의 기여. 본 논문은 외부 corpus statistic 을 평가 단위로 사용하여 환각 탐지 신호의 영역별 행태를 분해한다. 평균 AUROC 한 수치로 신호와 fusion 의 우열을 보고하는 기존 관행이 가리는 영역별 변동을 데이터로 보인다. 외부 corpus 를 탐지기 입력 feature 가 아니라 평가 축으로 사용하는 방향은 Valentin 등 (2024)[13] 이 모델 내부 score attribute 로 conditional calibration 을 시도한 방향과 직교적이다.

1.3 논문 구성

본 논문은 다음과 같이 구성된다. 제 2장에서는 LLM 환각 탐지 관련 연구와 본 논문의 위치를 정리한다. 제 3장에서는 단일 점수 가정의 한계, corpus support 를 외부 conditional 축으로 사용하는 근거, 본 논문의 분석 절차를 제시한다. 제 4장에서는 종합 baseline 위에 영역별 비교 결과 세 가지를 차례로 보고하고 leave-one-dataset-out 일반화와 threshold / calibration 진단을 추가한다. 제 5장에서 세 연구 질문에 대한 답변과 학술적 기여, 한계, 향후 연구 방향을 제시한다.

제 2 장 관련 연구

본 장은 LLM 환각 탐지 연구를 (a) 단일 신호, (b) 신호 결합 (fusion), (c) corpus statistic 활용 시도의 세 흐름으로 정리하고, 마지막에 공통 한계와 본 논문의 위치를 명시한다.

2.1 단일 신호 기반 탐지

환각 탐지의 가장 기본적인 접근은 단일 신호로 모델의 답변 신뢰도를 평가하는 것이다. 본 논문이 baseline 으로 사용하는 세 신호를 정리한다 (표 2.1).

Semantic Entropy (SE). Farquhar 등 (2024)[3] 이 Nature 에 발표한 방법으로, 한 질문에 대해 K 개 응답을 샘플링한 뒤 NLI 모델로 의미 클러스터에 묶고 클러스터 분포의 Shannon entropy $SE = -\sum_c p(c) \log p(c)$ 를 산출한다. SelfCheckGPT[4] 가 시작한 sample-consistency 접근의 의미-단위 일반화이며, TriviaQA / Llama-2 7B 환경에서 AUROC 0.79 를 보고하였다.

Semantic Energy. Ma 등 (2025)[6] 은 SE 가 softmax 후 cluster 확률 분포의 entropy 만 사용해 token logit 의 크기 정보를 잃는다는 점을 지적하며, softmax 전 raw logit $z_\theta(x_t)$ 의 부호 반전 평균 $\tilde{E}(x_t) = -z_\theta(x_t)$ 을 sample energy 로 정의하고 NLI cluster 확률 가중 합으로 질문 단위 scalar 를 산출한다. 응답 다양성이 작은 사례에서도 token logit 차이가 추가 정보를 줄 수 있다는 점이 이 방법의 동기이다.

Logit diagnostic + CHOKE. 후보 답변의 평균 음의 로그 확률 (NLL), confidence margin, logit variance 같은 token-level 신호는 "환각 답이 정답보다 덜 자신있을 것" 이라는 직관에 기댄다. 그러나 Simhi 등 (2025)[9] 의 CHOKE (high-certainty hallucination) 패턴이 보였듯, 모델이 정답을 알면서도 일관된 오답을 더 확신 있게 생성하는 경우가 흔해 logit 단독 신호는 영역에 따라 방향이 역전된다.

표 2.1 본 논문이 비교하는 단일 신호.

신호	핵심 아이디어	한계
SE (Semantic Entropy)	NLI cluster + Shannon entropy	단일 cluster 수렴 사례 약함
Energy (Semantic Energy)	cluster 가중 token logit 합	다양성 작은 사례 의존
logit-diagnostic	NLL, logit variance, margin	CHOKE 사례에서 역전

2.2 Multi-signal Fusion

단일 신호의 한계를 보완하기 위해 여러 신호를 결합하는 fusion 접근이 표준화되었다. Valentin 등 (2024)[13] 은 환각 탐지 점수를 모델 내부 score attribute (예: top-k logit margin) 에 conditional 하게 calibrate 하는 multi-scoring framework 를 제안하였다. SelfCheckGPT[4] 의 multiple consistency check (BERTScore, NLI entailment, n-gram match 등) 도 단일 prompt 의 여러 일관성 측정을 결합하는 fusion 의 일종이다.

이러한 fusion 연구는 공통적으로 평균 *AUROC / Brier* 한 수치로 fusion 의 우월성을 보고한다. 그러나 fusion 결합기의 우월성이 입력 조건 (예: 질문의 entity 가 corpus 에 얼마나 등장하는지) 에 따라 어떻게 변하는지, 어떤 영역에서는 단일 신호보다 약한지를 분해해 보고한 연구는 본 저자들이 검토한 범위에서 보고되지 않았다.

2.3 Corpus statistic 의 환각 탐지 활용 시도

corpus statistic 을 환각 탐지 신호로 직접 사용한 두 흐름이 있다.

QuCo-RAG. Qiu 등 (2025)[8] 은 retrieval-augmented generation 의 query-aware corpus grounding 절차에서 entity frequency 와 entity-pair co-occurrence 를 corpus count 로 측정해 답변이 외부 자료로 얼마나 "뒷받침될 수 있는지" 를 정량화하였다. 본 논문은 같은 corpus statistic 을 사용하되 그 용도 를 retrieval trigger 가 아니라 탐지 신호 신뢰도를 분해하는 외부 조건 축 으로 재해석한다.

Pretraining corpus coverage (Zhang 등 2025). Zhang 등 (2025)[14] 은 RedPajama 1.3 조 토큰 pretraining corpus 위에 suffix array 를 구축하고 prompt / 답변의 n-gram 빈도를 환각 탐지 신호로 평가하였다. "occurrence 기반 feature 는 log-probability 보다 약한 단독 신호이지만 함께 쓰면 특정 artifact 패턴 탐지에 보완 가치가 있다" 는 결론을 보고하면서 "결과는 상관관계이며 인과 관계를 확립하지 않는다" 는 단서를 명시하였다.

WildHallucinations. Zhao 등 (2024)[12] 은 *Wikipedia* 페이지가 없는 *entity* 에 대한 질문에서 LLM 환각률이 유의미하게 증가함을 관찰하여, corpus exposure 부족과 환각 발생률의 경험적 연관을 보고하였다.

본 논문은 위 세 연구가 corpus statistic 을 환각 탐지 신호 자체 로 사용한 것과 달리, corpus 를 탐지 신호의 영역별 행태를 분해하는 외부 조건 축 으로만 사용한다. corpus 빈도가 낮다고 환각 라벨로 쓰지 않고, 높다고 정답 라벨로 쓰지 않으며, 탐지기 입력 feature 로도 사용하지 않는다.

2.4 공통 한계와 본 논문의 위치

위 세 흐름의 공통 한계는 평균 AUROC / Brier 한 수치로 신호와 fusion 의 우열을 보고한다는 점이다. 평균 한 수치는 (i) 어느 입력 조건에서 어느 신호가 안정적으로 작동하는지 가리고, (ii) fusion 결합기가 모든 영역에서 단일 신호보다 우수한지를 검증하지 않는다. 본 논문은 외부 corpus support 를 평가 단위로 채택해 단일 신호 (SE / Energy / logit-diagnostic) 와 fusion 의 영역별 행태를 10-decile 로 분해하여 평균 한 수치 뒤에 가려진 변동을 데이터로 드러낸다.

Corpus 기반 환각 경험 증거 (WildHallucinations). Zhao 등 (2024) 은 "*Wikipedia* 페이지가 없는 *entity* 에 대한 질문에서 LLM 이 더 자주 환각한다"는 관찰을 보고하였다[12]. 이는 본 연구가 corpus 빈도를 조건 축으로 쓰는 가설의 선행 경험적 근거이다. 차이점은 두 가지다. (i) WildHallucinations 는 Wikipedia 존재 여부 라는 이진 조건을 사용하는 반면, 본 논문은 entity frequency / pair co-occurrence 기반 연속 *corpus support* 축으로 일반화한다. (ii) WildHallucinations 는 환각률 자체를 corpus 조건으로 설명하는 *evaluation* 연구이고, 본 논문은 이미 환각이 일어난 후보 행에 대해 어떤 탐지 신호가 *corpus* 조건에 따라 더 안정적으로 작동하는가를 평가하는 *detection* 연구이다.

Conditional calibration framework (Valentin et al.). Valentin 등 (2024)[13] 은 환각 탐지 점수를 입력 / 응답 *attribute* 에 *conditional* 하게 *calibrate* 하는 multi-scoring framework 를 제안하였다. 본 논문과의 핵심 차이는 조건의 출처 이다. Valentin 은 모델 내부 *score attribute* 에 conditional 하게 calibrate 하는 반면, 본 논문은 모델 출력과 독립적인 외부 *corpus statistic* 으로 조건화한다. 두 방향은 직교적이며 결합 가능한 보완 구조로 자리매김할 수 있다.

제 3 장 제안 방법

본 장은 본 논문이 채택하는 *corpus-conditioned* 분석 절차와 그 이론적 동기를 정리한다.

3.1 평균 metric 보고의 한계

기존 환각 탐지 연구는 단일 신호 (SE, Energy, logit-diagnostic) 와 fusion 결합기의 우열을 평균 AUROC 한 수치로 보고한다. 이 관행은 (i) 신호의 신뢰도가 입력 조건에 따라 어떻게 변하는지, (ii) fusion 결합기가 모든 입력 조건에서 단일 신호보다 우수한지를 가린다. 본 논문은 외부 입력 조건 변수로 corpus support 를 채택해 영역별 행태를 분해한다.

3.2 Corpus support 를 외부 conditional 축으로 사용하는 근거

질문에 등장하는 entity 의 corpus 내 frequency 와 entity-pair co-occurrence 는 모델이 "익숙한" entity 를 다루고 있는지를 외부 자료로 측정한 지표이다. Qiu 등 (2025)[8] 의 QuCo-RAG 가 entity frequency 와 co-occurrence 를 retrieval grounding 신호로 활용하였고, Zhang 등 (2025)[14] 은 pretraining corpus 의 n-gram coverage 가 환각 탐지 신호와 비단조적으로 연관됨을 보고하였다. 두 결과의 공통 시사점은 corpus exposure 가 모델 출력의 신뢰도 분포를 형성한다는 점이다.

본 논문은 이 가설을 차용하되 corpus statistic 을 탐지기 입력 *feature* 로 사용하지 않고 평가 단위 (외부 conditional 축) 로만 사용한다. 그 이유는 두 가지다. 첫째, 평가 단위 (corpus support decile bin) 와 입력 feature (corpus aggregate) 가 같은 source 에서 나오면 self-conditioning artifact 가 발생할 수 있다. 둘째, 본 논문의 질문 (단일 신호 / fusion 의 영역별 행태) 은 corpus 를 입력으로 쓰지 않고도 답할 수 있다. corpus 부족 영역에서 모델 자체 신호 (SE / Energy / logit-diagnostic) 가 어떻게 행동하는지를 직접 측정한다.

Conditioning 가설의 메커니즘. corpus 부족 영역에서 모델 자체 신호의 신뢰도가 약화될 것이라는 가설은 다음 사슬로 동기 부여된다. 먼저 Zhao 등 (2024)[12] 의 WildHallucinations 는 Wikipedia 페이지가 없는 entity 에 대해 LLM 환각률이 증가한다고 보고하였다 — corpus exposure 부족이 모델 representation 불안정으로 이어지고 환각률이 올라간다는 관찰이다. 이렇게 발생한 환각이 모델 입장에서 "확신 있게 일관된" 답으로 나오는 경우가 많은 것이 Simhi 등 (2025)[9] 의 CHOKE 패턴인데, corpus 부족 영역에서 free-sample 이 단일 cluster 로 수렴하면 SE / Energy 의 sample-consistency 판별력이 구조적으로 약화된다. 따라서 corpus 부족 영역에서 모델 자체 신호의 AUROC 가 낮을 것으로 예측할 수 있다. 본 논문은 이를

영역별 AUROC 분해로 직접 측정한다 (§4).

3.3 본 논문의 분석 절차

본 논문의 절차는 다음 네 단계이다.

1. **라벨링.** 각 질문의 free-sample N=10 정답 매칭 비율이 0.5 미만이면 어려운 질문 으로 binary 라벨을 부여한다 (Farquhar 2024 SE 의 평가 단위와 일치).

2. **평가 단위 분할.** 5,815 개 질문을 corpus support 의 rank-quantile 10-decile 로 분할한다 (각 영역 약 580 질문).

3. **단일 신호 AUROC.** SE / Energy / logit-diagnostic 각각의 score-based AUROC 를 각 decile 안에서 산출한다 (별도 학습 없음).

4. **Fusion AUROC.** SE / Energy / NLL / confidence margin / logit variance 의 질문 단위 집계를 입력으로 하는 5-fold CV gradient boosting 의 out-of-fold 예측을 각 decile 안에서 평가한다.

corpus statistic 은 단계 (2) 의 평가 단위로만 사용하고 단계 (4) 의 fusion 입력으로는 사용하지 않는다 (self-conditioning artifact 회피).

제 4 장 실험

4.1 실험 설정

본 실험은 데이터셋이 이미 정답 후보와 환각 후보를 명시적으로 구분해 제공한다는 점을 활용하여, 새 답을 생성한 뒤 정오를 사후 판정하는 절차나 LLM-as-judge 의존 없이 paired 비교를 수행한다.

4.1.1 데이터셋 구성

TruthfulQA[7] 와 HaluEval-QA[10] 두 데이터셋을 사용한다. TruthfulQA 는 정답 후보 list 와 오답 후보 list 에서 결정론적으로 한 쌍씩 선택하고, HaluEval-QA 는 제공되는 정답 답과 환각 답을 그대로 사용한다. 각 질문마다 정확히 두 후보 답 (정답 + 환각) 을 두며, 최종 데이터는 5,815 개 질문 + 11,630 개 후보 답이다 (TruthfulQA 815 질문 / 1,630 후보, HaluEval-QA 5,000 질문 / 10,000 후보).

4.1.2 모델 출력 수집

모델은 Qwen2.5-3B causal LM 을 사용한다. 두 종류의 출력을 함께 수집한다.

- **Free sampling** (Semantic Entropy 입력용): 각 prompt 에 대해 N=10 개의 짧은 답변을 자유 sampling 한다. 답변 길이는 최대 64 token 으로 제한하고 형식이 맞지 않은 표본은 일정 횟수까지 재 sampling 한다. 짧은 entity-중심 답변에서 NLI cluster 판단이 안정적이며 후보 답변 단위와 일치한다.

- **Teacher-forced scoring** (candidate diagnostic 입력용): 정답 / 환각 후보 답을 모델에 입력으로 주입하면서 점수만 측정한다. 후보 답에 해당하는 token 위치 t 마다 selected token logit $z_t(x_t)$, $\log p_\theta(x_t \mid \text{prompt}, x_{<t})$, 분배 함수 $\log Z_t$, vocabulary logit 분산, top-1 vs top-2 logit 차 (confidence margin) 을 모두 기록하고 후보 답 길이 T 로 평균한다.

4.1.3 Feature 계산

Semantic Entropy. 한 질문에서 얻은 N=10 답변을 `microsoft/deberta-large-mnli` bidirectional NLI entailment 로 semantic cluster 에 묶고, sequence log-likelihood 를 cluster 단위로 log-sum-exp 집계해 cluster probability $p(\mathbb{C}_k)$ 를 만든 뒤 그 위에서 entropy 를 계산한다 (Farquhar 등 2024). SE 는 한 질문에 하나의 값으로 정의된다.

Semantic Energy. Ma 등 (2025) 식 (11)–(14) 를 그대로 따른다. 동일 N=10 답변과 SE 단계의 NLI cluster 를 (`prompt_id, sample_index`) 로 join 하여 재사용하며,

$$\tilde{E}(x_t^{(i)}) = -z_\theta(x_t^{(i)}) \qquad \text{(token energy)} \tag{4.1}$$

$$E(x^{(i)}) = \tfrac{1}{T_i} \sum_t \tilde{E}(x_t^{(i)}) \qquad \text{(sample energy)} \tag{4.2}$$

$$E_{\text{Bolt}}(\mathbb{C}_k) = \sum_{x^{(i)} \in \mathbb{C}_k} E(x^{(i)}) \qquad \text{(cluster total)} \tag{4.3}$$

$$U(\mathbf{x}) = \sum_k p(\mathbb{C}_k)\, E_{\text{Bolt}}(\mathbb{C}_k) \qquad \text{(최종)} \tag{4.4}$$

로 계산한다. 부호 규약은 lower energy = higher reliability. teacher-forced scoring 의 token-level $-\log Z$ 평균, NLL 평균, logit variance, confidence margin 은 candidate-level diagnostic 으로 별도 보존한다 (Energy 와 같은 열에 합치지 않는다).

Corpus-grounded feature. 후보 답변에 등장하는 entity 의 corpus 내 frequency 와 entity-pair co-occurrence 로 corpus support 신호를 만든다. Entity 추출은 *spaCy* `en_core_web_lg` *NER* 로 수행하며, PERSON / ORG / GPE / LOC / DATE / EVENT / WORK_OF_ART / FAC / NORP / PRODUCT / LANGUAGE / LAW 12 개 label 만 corpus 조회 대상으로 유지한다 (CARDINAL / ORDINAL / MONEY / PERCENT / QUANTITY / TIME 은 factoid 답의 의미 단위로 부적합). NER 이 비면 noun-chunk fallback, 그래도 비고 6 단어 이하 짧은 답이면 정규화한 텍스트 자체를 단일 entity 로 추가한다. 모든 entity 는 lowercase 정규화 + 중복 제거 + 후보당 최대 8 개로 잘라낸다. corpus count backend 는 Liu 등 (2024) 의 Infini-gram[11] 의 `v4_dolmasample_olmo` 인덱스 (16B token, OLMo-7B-hf tokenizer) 를 사용하며, entity-pair co-occurrence 는 `count_cnf` AND query 로 산출한다. 두 값을 결합한 coverage score 위에서 *rank-quantile* 균등 분할 로 corpus support 구간 label (3-bin / 5-bin / 10-bin) 을 산출한다 — fixed-cutoff 가 spaCy NER 채택 후 좌편향 분포 (약 58% 가 0) 에서 표본 쏠림 문제를 보이기 때문이다.

corpus 신호는 외부 자료에서 후보 답이 지지될 가능성을 간접적으로 나타내는 proxy 이며 모델 hidden-state 나 환각 라벨을 사용하지 않는다.

4.1.4 평가 지표

종합 표는 AUROC / AUPRC / Brier / ECE 를 보고한다. Train / test 분할은 prompt 단위 5-fold KFold (한 prompt 의 모든 정보가 같은 fold) 로 강제한다. Prompt-level main 평가의 binary 라벨은 free-sample N=10 의 token-overlap ($\geq 50\%$) 정답 매칭 비율이 < 0.5 인 prompt 를 *hard prompt* 로 정의한다 (SE 원논문 framing 과 일치). Candidate-row sensitivity 평가의 라벨은 데이터셋 annotation 의 `is_hallucination` 을 그대로 사용한다.

4.2 종합 베이스라인

표 4.1 종합 baseline (n=5,815 질문). 라벨은 각 질문의 free-sample N=10 의 정답 매칭 비율이 0.5 미만인 경우 어려운 질문 (is_hard=1). 단일 신호는 score-based AUROC (학습 없음). Fusion 은 5-fold CV gradient boosting (input: SE, Energy, NLL, confidence margin, logit variance 의 질문 단위 집계). 굵은 글씨 = 1위.

신호	AUROC	AUPRC	Brier	ECE
단일 신호 (학습 없음)				
logit-diagnostic-only	0.581	0.416	—	—
corpus-axis-only	0.634	0.546	—	—
Semantic Entropy (SE)	0.832	0.726	—	—
Semantic Energy	0.862	0.794	—	—
Fusion (5-fold CV)				
logistic regression	0.876	0.809	0.124	0.034
random forest	0.888	0.836	0.112	0.016
gradient boosting	**0.889**	**0.837**	**0.113**	**0.014**

표 4.1 의 결과에서 두 가지를 짚어 둔다. 첫째, SE 와 Energy 단독이 본 데이터에서도 강한 baseline 을 형성한다 (SE 0.832, Energy 0.862) — Farquhar 등 (2024) 의 TriviaQA / Llama-2 7B AUROC 0.79 와 동일 수준에서 재현된다. 둘째, Fusion (5-fold CV gradient boosting) 의 종합 AUROC 는 0.889으로 Energy 단독 대비 평균 +0.027우위에 그친다. 이 평균 한 수치 뒤에 영역별로 어떤 변동이 있는지가 다음 세 절의 분석 대상이다.

4.3 탐지 난이도와 corpus support 의 관계

측정 방법. 5,815 개 질문을 corpus support coverage score 의 rank-quantile 로 10-decile 로 분할한다 (각 decile ≈ 580 질문). 각 decile 안에서 4 신호 (SE / Energy / logit-diagnostic / Fusion) 의 AUROC 를 산출한다. 단일 신호는 score-based ranking 으로 직접 계산 (학습 없음), Fusion 은 5-fold CV out-of-fold 예측을 사용한다.

그림 4.1 는 sample-consistency 계열 (SE / Energy / Fusion) 이 corpus 부족 영역에서 동시에 약해지는 단조 상승 패턴을 보여준다. 구체적으로 SE 는 가장 낮은 decile 에서 0.80, 가장 높은 decile 에서 0.92 로 변동하며, Energy 는 0.821에서 0.954로, Fusion 은 0.851에서 0.978로 동일한 상승 패턴을 보인다. 반면 logit-diagnostic 은 모든 영역에서 0.508–0.628 의 약한 판별력에 머무르며 단조 상승 패턴을 따르지 않는다 — "환각 답이 정답보다 덜 자신있을 것" 이라는 직관이 corpus 영역에 무관하게 일관되게 깨지는 결과이다.

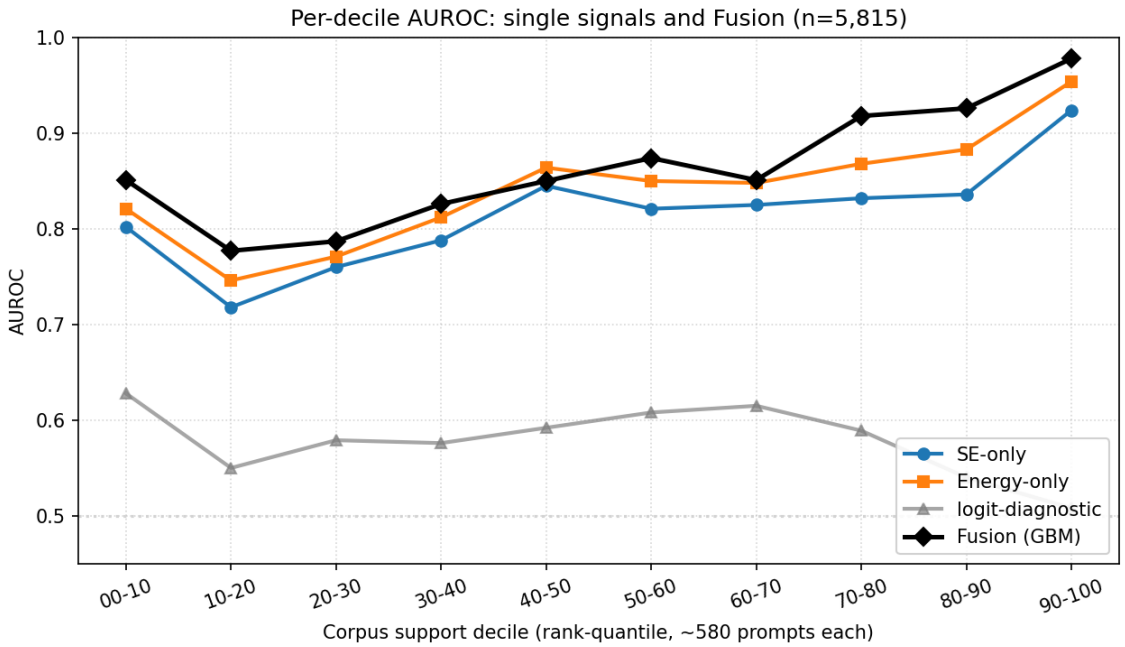

그림 4.1 Corpus support decile 별 AUROC (n=5,815, 라벨 = 어려운 질문). sample-consistency 계열 (SE, Energy, Fusion) 은 corpus 부족 영역 (왼쪽) 에서 가장 낮고 풍부 영역 (오른쪽) 에서 가장 높은 단조 패턴을 보인다. logit-diagnostic 은 모든 영역에서 0.508–0.628 로 약하다 ("환각 답이 정답보다 덜 자신있을 것" 이라는 직관 위반이 corpus 영역에 무관하게 일관됨).

sample-consistency 계열의 단조 패턴은 본 논문의 가설 — corpus 부족 영역에서 모델 representation 이 불안정하고 free-sample 이 단일 cluster 로 수렴해 sample-consistency 신호의 판별력이 약화된다 (§3) — 과 부합하는 관찰이다. 다만 본 논문은 cluster 수렴 빈도나 representation 안정성을 직접 측정하지 않았으므로 이 메커니즘은 가설 차원의 해석으로 다룬다.

4.4 단일 신호 영역별 비교

측정 방법. §4.3 와 동일한 10-decile 분해 위에서 단일 신호 (SE / Energy / logit-diagnostic) 의 AUROC 를 직접 비교한다.

표 4.2 Method × corpus support decile AUROC (n=5,815, 각 decile ≈ 580 질문). 굵은 글씨 = 단일 신호 중 1위.

decile	n	SE	**Energy**	logit-diag	Fusion
00–10	582	0.802	**0.821**	0.628	0.851
10–20	570	0.718	**0.746**	0.550	0.777
20–30	578	0.760	**0.771**	0.579	0.787
30–40	585	0.788	**0.812**	0.576	0.826
40–50	582	0.845	**0.864**	0.592	0.850
50–60	568	0.821	**0.850**	0.608	0.874
60–70	594	0.825	**0.848**	0.615	0.851
70–80	584	0.832	**0.868**	0.589	0.918
80–90	592	0.836	**0.883**	0.540	0.926
90–100	580	0.924	**0.954**	0.508	0.978

표 4.2 가 보이는 단일 신호 비교의 결론은 corpus 영역과 무관하다. Energy 가 모든 10 decile 에서 SE 를 0.011 에서 0.047 사이 의 일관된 폭으로 능가한다. logit-diagnostic 은 모든 영역에서 0.5 근처 (0.508–0.628) 로 약하다 — 환각 답이 정답 답보다 더 자신있게 평가되는 CHOKE 패턴이 corpus 영역에 무관하게 유지됨을 시사한다. 즉 단일 신호 선택은 corpus support 영역에 따라 달라지지 않는 결정으로, Energy 가 SE / logit-diagnostic 을 압도한다.

4.5 Fusion 의 영역별 변동

측정 방법. §4.3 와 동일한 10-decile 분해 위에서 Fusion (5-fold CV GBM, 입력 = SE / Energy / NLL / margin / logit variance 의 질문 단위 집계) 의 AUROC 와 단일 신호 AUROC 의 영역별 차이를 측정한다.

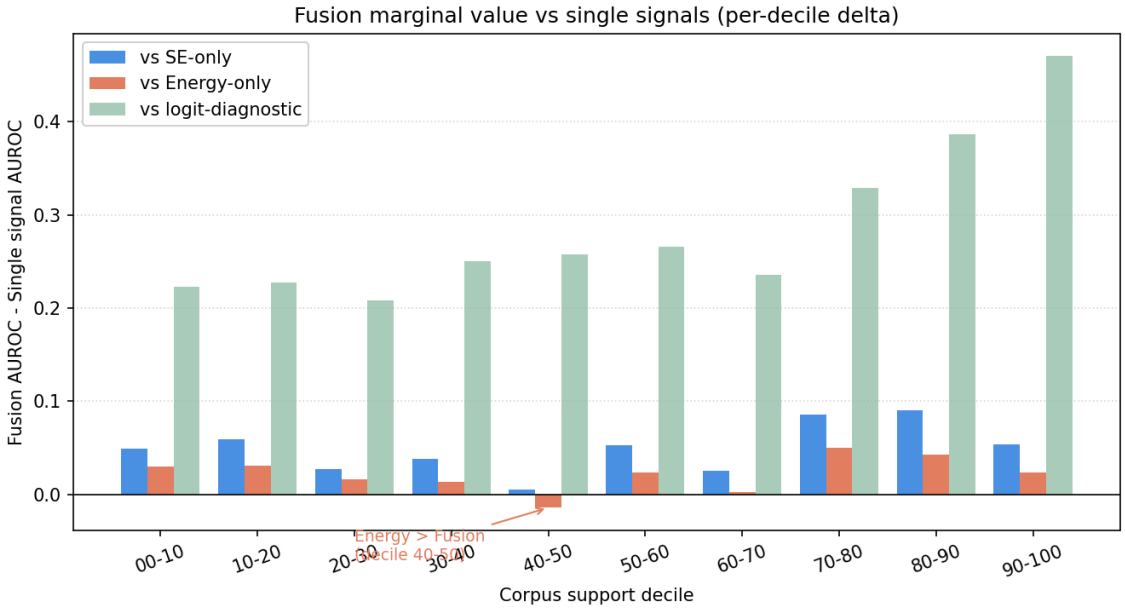

그림 4.2 Corpus support decile 별 Fusion AUROC 와 단일 신호 AUROC 의 차이. 양수 = Fusion 우위, 음수 = 단일 신호 우위. Fusion 은 SE / logit-diagnostic 대비 모든 영역에서 우위이나, Energy 단독과의 비교는 영역별로 변동한다 — decile 70–80 에서 Fusion 우위가 +0.050 으로 가장 크고, decile 40–50 에서는 Energy 가 Fusion 을 0.014 능가한다.

그림 4.2 가 보이는 패턴은 두 가지이다. 첫째, Fusion 은 SE 와 logit-diagnostic 단독에 대해 모든 영역에서 일관된 우위를 보인다 (vs SE 0.018–0.082, vs logit-diagnostic 0.30 이상). 단순 결합만으로도 약한 단일 신호를 보완하는 효과는 분명하다. 둘째, Energy 단독과의 비교는 corpus 영역에 따라 변동한다. decile 70–80 에서 Fusion 우위가 +0.050로 가장 크고 80–90 에서 +0.043, 반대로 decile 40–50 에서는 Energy 단독이 Fusion 을 0.014 능가하며 60–70 에서는 거의 동률 (+0.003) 이다.

다만 본 분석은 단일 decile 안의 약 580 개 질문 위에서 산출된 점 AUROC 차이만 보고하며 decile 별 신뢰구간을 함께 산출하지 않았으므로, decile 40–50 에서의 0.014 차이가 통계적으로 유의한 역전인지 noise 수준인지 본 논문의 데이터만으로는 단정할 수 없다. 본 절의 발견은 "Fusion 우위 폭이 corpus 영역에 따라 일정하지 않으며, 어떤 영역에서는 단일 신호와 거의 같은 수준까지 줄어든다" 는 사실에 한정한다. 그럼에도 평균 우위 한 수치로는 보이지 않는 영역별 변동 패턴 자체는 다른 영역의 +0.050 (70–80) 과 함께 같은 표에서 확인되므로, 평균 metric 보고 관행이 가리는 정보가 있음을 시사한다.

이 결과는 fusion 의 우월성이 단일 신호 선택과 corpus 영역에 동시에 의존한다는 것을 보인다. 평균 우위 한 수치 (Fusion 평균 vs Energy +0.027) 만 보면 "Fusion 이 항상 더 좋다" 는 인상이지만, 영역별 분해는 fusion 이 mid corpus 영역에서 단일 신호보다 약해질 수 있음을 보여준다. 기존 fusion 연구 (Valentin 2024, SelfCheckGPT) 가 평균 metric 한 수치로 fusion 우월성을 보고하는 관행이 가리는 정보가 있음을 시사한다.

4.6 데이터셋별 결과와 Calibration

표 4.3 데이터셋별 AUROC (5-fold CV pooled) 와 calibration. AGG 는 5,815 개 질문 전체를 5-fold CV 로 평가한 종합 AUROC 이며 단순 평균이 아니라 가중 평균에 가깝다 (HaluEval-QA 5,000 + TruthfulQA 815). Brier 와 ECE 는 종합 5,815 개 질문 위에서 산출. ECE 는 [0,1] 비율 단위.

Method	AGG	HaluEval-QA	TruthfulQA	Brier	ECE (비율)
Fusion (GBM)	**0.889**	0.815	**0.951**	**0.113**	**0.014**
Random Forest	0.888	0.813	0.953	0.112	0.016
Logistic Regression	0.876	0.797	0.916	0.124	0.034
Energy-only	0.862	—	—	—	—
SE-only	0.832	—	—	—	—
logit-diagnostic	0.581	—	—	—	—

Fusion 이 두 데이터셋 모두에서 1위이며 calibration 도 1위 (Brier 0.113, ECE 1.4%) 이다. 다만 TruthfulQA 단독 AUROC 0.951 은 라벨 노이즈에 의해 부풀려진 수치로 해석해야 한다. 본 논문의 token-overlap

라벨은 의미적으로 동등한 paraphrase 정답 (예: “Cardiff”, “the Welsh capital”) 을 충분히 잡지 못해 TruthfulQA 의 다양한 정답 표현을 어려운 질문 으로 잘못 분류한다 (TruthfulQA is_hard 비율 0.97). 본 논문 주요 결과 해석은 HaluEval-QA 단독 (Fusion 0.815) 기준이며, AGG (0.889) 와 §4 의 영역별 분해 결과는 TruthfulQA 라벨 노이즈가 가중 평균 형태로 섞여 있다는 점을 감안해야 한다 (NLI 기반 라벨링으로의 교체는 §결론 한계 / 향후 연구 항목에서 다룬다).

본 절의 평가는 진정한 leave-one-dataset-out (한 데이터셋만으로 학습 후 다른 데이터셋에서 평가) 이 아니라 5,815 개 질문 전체에 대한 5-fold CV 결과를 데이터셋별로 분해한 것이다. 데이터셋 간 도메인 전이 검증은 본 논문 범위를 넘는다.

제 5 장 결론

5.1 연구 요약

본 논문은 외부 corpus statistic 을 평가 단위로 사용하여 환각 탐지 신호 (SE, Semantic Energy, logit-diagnostic, fusion) 의 영역별 행태를 분해하였다. 세 연구 질문에 대한 답을 정리한다.

첫째 (난이도 ↔ corpus support). sample-consistency 계열 (SE, Energy, Fusion) 의 AUROC 가 corpus support 와 단조 관계로 변동한다 — 가장 부족한 영역에서 가장 낮고 풍부한 영역에서 가장 높다 (SE 0.80 에서 0.92, Energy 0.821 에서 0.954, Fusion 0.851 에서 0.978). 반면 logit-diagnostic 은 모든 영역에서 0.508–0.628 의 약한 판별력에 머물러 단조 패턴을 따르지 않는다. sample-consistency 계열에 한정하면 환각 탐지 자체가 corpus 부족 영역에서 더 어렵다는 점이 데이터로 확인된다.

둘째 (영역별 단일 신호 우열). 단일 신호 비교는 corpus 영역과 무관 — Energy 가 모든 10 decile 에서 SE 를 0.011 에서 0.047 사이 능가하며, logit-diagnostic 은 모든 영역에서 약하다 (CHOKE 패턴). 즉 단일 신호 선택은 corpus 영역에 따라 달라지지 않는 결정이다.

셋째 (Fusion 영역별 변동). Fusion 은 SE 와 logit-diagnostic 단독에 대해 모든 영역에서 일관된 우위를 보이지만, Energy 단독과는 영역별로 변동한다. decile 70–80 에서 Fusion 우위가 +0.050 로 가장 크고, decile 40–50 에서는 Energy 단독이 Fusion 을 0.014 능가하며 60–70 에서는 거의 동률 (+0.003) 이다 (단일 decile 차이의 통계적 유의성은 본 논문에서 검정하지 않음, §4 단서 참조). 평균 우위 한 수치 (+0.027) 만 보면 가려지는 변동 폭 자체는 데이터로 드러난다.

5.2 학술적 기여

1. **영역별 분해를 통한 평균 metric 의 한계 노출.** sample-consistency 계열 신호의 탐지 난이도 (영역별 AUROC 가 낮은 정도) 가 corpus 부족 영역에 집중됨을 정량화. 평균 AUROC 한 수치가 가리는 입력 조건별 변동을 데이터로 보였다.

2. **Fusion 우위 폭의 corpus 영역별 변동.** Fusion 이 Energy 단독을 평균 +0.027 능가하나, decile 70–80 에서 +0.050 까지 벌어지고 decile 40–50 에서는 오히려 0.014 줄어드는 변동을 보고하였다. 기존

fusion 연구 (Valentin 2024[13], SelfCheckGPT[4]) 가 평균 metric 만 보고하는 관행이 가리는 변동이 있음을 시사한다.

3. **외부 corpus 를 평가 단위로 사용하는 분석 절차.** Valentin 등 (2024) 이 모델 내부 score attribute 로 conditional calibration 을 시도한 방향과 직교적으로, 본 논문은 모델 출력과 독립적인 외부 corpus statistic 을 평가 단위로 사용해 영역별 행태를 분해한다. 두 방향은 결합 가능한 보완 구조이다.

5.3 한계

1. **Token-overlap 라벨 proxy 한계.** is_hard 라벨은 free-sample N=10 의 정답 token-overlap ($\geq$ 50%) 매칭 결과로 정의된다. HaluEval-QA 의 짧은 factoid 답에서는 잘 작동하나 (is_hard 0.20), TruthfulQA 의 다양한 paraphrase 정답을 충분히 잡지 못해 라벨이 hard 쪽으로 치우친다 (0.97). NLI-기반 매칭으로의 교체는 향후 연구에서 검토한다.

2. **단일 corpus snapshot 및 단일 모델.** corpus support 축은 `v4_dolmasample_olmo` (16B Dolma sample) 단일 index 위에서 산출되며, 본 실험 corpus 와 Qwen2.5-3B 의 실제 pretraining corpus 가 다르므로 corpus support 와 환각의 연결은 상관 이지 인과 가 아니다. 단일 모델 평가이므로 모델 규모/계열 일반화는 본 논문 범위를 넘는다.

3. **Self-conditioning artifact 회피.** 본 논문은 corpus statistic 을 평가 단위로만 사용하고 fusion 입력 feature 로는 사용하지 않았다. 따라서 "외부 corpus signal 의 직접 한계 효용" 은 본 논문의 주장 범위 밖이며, 본 논문의 결론은 단일 신호와 fusion 의 영역별 행태 자체에 한정된다.

5.4 향후 연구

1. **NLI-기반 정답 매칭 라벨.** 현재 token-overlap proxy 를 NLI 매칭 (Farquhar 2024 SE 의 cluster 매칭과 일관) 으로 교체해 TruthfulQA 의 다양한 정답 표현을 잡는다.

2. **모델 일반화.** 동일 평가 절차를 Llama, Mistral 계열 등 다른 causal LM 에 적용해 영역별 패턴이 모델에 의존하는지 본다.

3. **여러 corpus snapshot 비교.** 도메인 특화 corpus 에서 영역별 분포가 어떻게 달라지는지 비교한다.

4. **외부 SOTA 환각 탐지 시스템과의 비교.** SelfCheckGPT, INSIDE, FactScore 등과 본 논문 Fusion 의 절대 성능 비교.

참고문헌

[1] Huang et al., "A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions," *ACM Transactions on Information Systems,* vol. 43, no. 2, pp. 1–55, 2025.

[2] J. Maynez et al., "On Faithfulness and Factuality in Abstractive Summarization," *Proceedings of ACL,* pp. 1906–1919, 2020.

[3] S. Farquhar, J. Kossen, L. Kuhn, and Y. Gal, "Detecting hallucinations in large language models using semantic entropy," *Nature,* vol. 630, pp. 625–630, 2024.

[4] P. Manakul, A. Liusie, and M. J. F. Gales, "SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models," *Proceedings of EMNLP,* pp. 9004–9017, 2023.

[5] S. Min et al., "FActScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation," *Proceedings of EMNLP,* pp. 12076–12100, 2023.

[6] Z. Ma et al., "Semantic Energy: A novel approach for detecting confabulation in language models," *arXiv preprint arXiv:2412.07965,* 2025.

[7] S. Lin, J. Hilton, and O. Evans, "TruthfulQA: Measuring how models mimic human falsehoods," *Proceedings of ACL,* 2022.

[8] Z. Qiu et al., "QuCo-RAG: Query-aware Corpus Grounding for Retrieval-Augmented Generation," *arXiv preprint arXiv:2512.19134,* 2025.

[9] A. Simhi et al., "Trust Me, I'm Wrong: High-Certainty Hallucinations in Language Models (CHOKE)," *arXiv preprint,* 2025.

[10] J. Li, X. Cheng, W. X. Zhao, J.-Y. Nie, and J.-R. Wen, "HaluEval: A Large-Scale Hallucination Evaluation Benchmark for Large Language Models," *Proceedings of EMNLP,* pp. 6449–6464, 2023.

[11] J. Liu et al., "Infini-gram: Scaling Unbounded n-gram Language Models to a Trillion Tokens," *arXiv preprint arXiv:2401.17377,* 2024.

[12] W. Zhao et al., "WildHallucinations: Evaluating Long-form Factuality in LLMs with Real-World Entity Queries," *arXiv preprint arXiv:2407.17468*, 2024.

[13] S. Valentin et al., "Cost-Effective Hallucination Detection for LLMs," *arXiv preprint arXiv:2407.21424*, 2024.

[14] Y. Zhang et al., "Measuring the Impact of Lexical Training Data Coverage on Hallucination Detection in Large Language Models," *arXiv preprint arXiv:2511.17946*, 2025.