공학학사학위논문

Corpus 조건 축에 따른 LLM 환각 탐지 지표 신뢰성 분석: 재현 가능한 실험 계획과 기준선 재정리를 중심으로

2026 년 2 월

서울대학교

자유전공학부

문 정 혁

Corpus 조건 축에 따른 LLM 환각 탐지 지표 신뢰성 분석: 재현 가능한 실험 계획과 기준선 재정리를 중심으로

지도교수 김 남 수

이 논문을 공학 학사학위 논문으로 제출함

서울대학교

자유전공학부

문 정 혁

문정혁 의 학사 학위 논문을 인준함

2026 년 2 월 13일

지 도 교 수 (인)

초록

대규모 언어모델(LLM)의 환각(hallucination) 문제는 실용적 적용에서 중요한 장애물이다. 본 논문은 반복 샘플링 기반 Semantic Entropy(SE), Ma 등의 Semantic Energy 동기, 그리고 QuCo-RAG-style corpus statistics를 바탕으로 LLM 환각 탐지 지표의 조건부 신뢰성을 검토한다.

현재 repo-local 기준선은 TruthfulQA와 HaluEval-QA에서 구성한 5,815개 prompt, 11,630개 candidate row의 paired feature table에 한정한다. 이 기준선에서 learned fusion with corpus는 learned fusion without corpus보다 낮게 관측되므로 corpus-fusion aggregate 성능 향상을 주장하지 않는다. redesigned thesis-valid 실험에서는 corpus entity frequency와 entity-pair co-occurrence를 continuous corpus-support axis로 만들고, 각 bin에서 SE, Semantic Energy, logit diagnostics, condition-aware fusion의 신뢰도를 평가한다.

Energy-family diagnostics는 현재 full paired feature table에 포함되어 있다. 다만 current candidate-level Boltzmann-style 값은 multi-generation semantic clustering과 cluster-level aggregation을 포함하지 않으므로 paper-faithful Semantic Energy라고 과장하지 않는다. 최종 실험에서는 N=10 NLI likelihood SE와 paper-faithful Semantic Energy를 재구현하고, corpus-support bin별 metric reliability를 관찰한다.

본 논문의 기여는 유리한 결과를 과장하는 데 있지 않다. 현재 실험 결과와 평가 단위의 한계를 분리하고, 문헌 기반 feature 구현 조건과 corpus-axis reliability 분석 절차를 명확히 하여 후속 thesis-valid 실험의 기준을 제시한다.

주요어: 대규모 언어모델, 환각 탐지, Semantic Entropy, Semantic Energy, corpus support axis, metric reliability

목차

초록 **i**

제 1 장 서론 **1**

1.1 연구 배경 1

1.2 연구 목적 2

1.3 논문 구성 2

제 2 장 관련 연구 **3**

2.1 환각 분류, 사실성, 벤치마크 3

2.2 불확실성 및 반복 샘플링 기반 탐지 3

2.3 Semantic Entropy (SE) 3

2.3.1 작동 원리 4

2.3.2 한계점 4

2.4 SE 계열 확장 방법: KLE와 SNNE 4

2.5 Semantic Energy 5

2.5.1 작동 원리 5

2.5.2 SE 대비 차별점 5

2.5.3 Zero-SE 보완 5

2.6 기존 연구의 한계 및 연구 공백 6

제 3 장 이론적 분석 **7**

3.1 환각이 드러나는 두 가지 양상 7

3.1.1 혼란형 환각 (Confusion-like Pattern) 7

3.1.2 지어냄형 환각 (Confabulation/Fabrication-like Pattern) 8

3.2 SE와 Energy의 상보성 9

3.2.1 정보 이론적 관점 9

3.2.2 상보성의 수학적 표현 9

3.3 Internal Logit과 Confabulation의 관계 9

3.3.1 Logit 크기와 지식의 관계 10

3.3.2 Confabulation에서의 Logit 패턴 10

제 4 장 제안 방법 **11**

4.1 Corpus-conditioned metric reliability protocol 11

4.2 Energy/logit diagnostic baseline의 평가 단위 11

4.3 재현 가능한 실험 결과 요약 11

제 5 장 실험 **12**

5.1 실험 설정 12

5.1.1 데이터셋 구성 12

5.1.2 정답성 라벨링 13

5.1.3 모델 scoring 절차 13

5.1.4 특징 계산 14

5.1.5 실험 단계 15

5.1.6 평가 지표와 해석 원칙 16

5.1.7 재현성과 산출물 계약 17

5.2 실험 결과 요약 17

5.3 Energy 평가 단위와 corpus-bin reliability 17

5.4 문헌 근거와 guardrail 19

제 6 장 결론 **20**

6.1 연구 요약 20

6.2 학술적 기여 20

6.3 한계 21

6.4 향후 연구 21

표 목차

표 2.1 LLM 환각 탐지 방법론 비교 4
표 2.2 SE와 Semantic Energy의 비교 5

표 5.1 실험 데이터셋 구성 12
표 5.2 Archived diagnostic 운영 라벨 정의 13
표 5.3 현재 full paired run 기반 preliminary 탐지 기준선 결과 18

그림 목차

제 1 장 서론

1.1 연구 배경

대규모 언어모델(Large Language Model, LLM)은 텍스트 생성, 질의응답, 요약, 번역 등 다양한 자연어 처리 태스크에서 널리 사용되고 있다. 그러나 최신 LLM도 사실과 다른 내용을 그럴듯하게 생성하는 환각(hallucination) 문제를 보이며, 이는 LLM 신뢰성과 안전성의 핵심 과제로 논의되어 왔다[1]. 생성 텍스트의 신뢰성은 사실성(factuality)과 충실성(faithfulness) 관점에서 구분해 다룰 수 있으며[2], 본 연구는 외부 사실과 충돌하거나 검증 가능한 정답과 맞지 않는 응답을 탐지하는 문제에 초점을 둔다.

환각 문제는 LLM의 실용적 적용에서 중요한 장애물이다. 의료 분야에서 잘못된 진단 정보를 제공하거나, 법률 분야에서 존재하지 않는 판례를 인용하거나, 금융 분야에서 부정확한 수치를 제시하는 경우 큰 피해를 초래할 수 있다. TruthfulQA는 모델이 인간이 흔히 믿는 거짓 정보를 얼마나 그럴듯하게 모방하는지 평가하기 위해 제안된 벤치마크이며[13], 이러한 설정은 LLM 응답을 사후에 검증하고 환각을 자동으로 탐지하는 방법의 필요성을 보여준다.

환각 탐지를 위한 대표적인 불확실성 기반 방법으로 Semantic Entropy(SE)가 있다. SE는 하나의 질문에 대해 여러 응답을 샘플링한 뒤, 자연어 추론(Natural Language Inference, NLI) 모델을 사용하여 의미적으로 클러스터링하고, 클러스터 분포의 엔트로피를 계산한다[5]. 반복 샘플링과 응답 간 일관성은 SelfCheckGPT와 같은 선행 연구에서도 환각 탐지를 위한 중요한 단서로 사용되었다[6]. SE가 높으면 모델 응답이 여러 의미로 갈라지므로 의미적 불확실성이 크다는 신호가 된다.

그러나 SE는 응답 간 의미적 다양성에 의존하므로, 모델이 모든 응답에서 같은 의미의 틀린 답변을 반복하면 판별력이 약해진다. 예를 들어 같은 질문을 다섯 번 샘플링했는데 다섯 응답이 모두 동일한 잘못된 인물명이나 수치를 답한다면, 응답들은 의미적으로 완전히 일관되어 하나의 클러스터에 모인다. 이때 SE는 0에 가까워지지만, 낮은 SE가 곧 정답을 의미하지는 않는다. 단지 "서로 다른 답을 내지 않았다"는 사실만 알려줄 뿐이다. 본 연구는 이처럼 모든 응답이 하나의 의미 클러스터에 속해 SE가 환각 여부를 구분하기 어려워지는 현상을 **Zero-SE 문제**라고 정의한다.

Zero-SE 설정에서는 "응답들이 서로 같은가"라는 질문과 "그 같은 응답이 사실인가"라는 질문이 서로 다른 문제로 분리된다. 탐지 과정에서는 먼저 SE가 판별 정보를 제공하는 상황인지 확인해야 한다. 응답들이 여러 의미로 갈라지면 SE를 의미적 불확실성 신호로 사용할 수 있고, 모든 응답이 하나의 의미로 수렴하면 SE만으로는 사실성 판단이 남는다. 본 연구는 이 문제를 현재 실험 범위에서는 prompt-level SE와 candidate-level Energy/corpus feature를 같은 paired feature table에서 비교하는 문제로 정리한다. Semantic Energy

는 이미 full paired 산출물에 포함되어 있으나, 전체 row-level AUROC가 아니라 low-diversity matched-pair 관점에서 해석해야 한다.

1.2 연구 목적

본 연구의 목적은 다음과 같다:

1. **실험 증거의 범위 명시**: TruthfulQA와 HaluEval-QA 기반 full paired feature table에서 얻은 결과만 실험 근거로 사용한다.
2. **조건부 신뢰성 검증**: corpus entity frequency와 entity-pair co-occurrence bin에 따라 SE, Semantic Energy, logit diagnostics의 AUROC, AUPRC, paired win-rate가 어떻게 달라지는지 확인한다.
3. **paper-faithful feature 조건 명시**: SE는 N=10 NLI likelihood 방식으로, Semantic Energy는 multi-generation semantic cluster와 selected-token logit energy 집계로 구현해야 함을 분리해 보고한다.
4. **재현성 경로의 고정**: 향후 실험과 재분석은 동일한 paired dataset, feature 정의, prompt 단위 grouping을 기준으로 수행한다.

1.3 논문 구성

본 논문은 다음과 같이 구성된다. 제 2장에서는 LLM 환각 탐지를 위한 기존 연구들을 검토한다. 제 3장에서는 SE, Energy, corpus signal의 역할과 한계를 정리한다. 제 4장에서는 corpus 조건 축에 따른 metric reliability 평가 구조를 설명한다. 제 5장에서는 paired candidate 기준선 결과와 평가 단위의 한계를 보고하고, 제 6장에서 결론 및 향후 연구 방향을 제시한다.

제 2 장 관련 연구

본 장에서는 LLM 환각 연구를 두 흐름으로 구분해 검토한다. 첫째는 환각의 정의, 사실성 평가, 벤치마크를 다루는 연구이며, 둘째는 생성 모델의 불확실성 또는 내부 점수를 이용해 환각을 탐지하려는 방법 연구이다. 이 구분은 본 연구가 기존 사실성 평가 자체를 대체하려는 것이 아니라, 반복 샘플링 기반 SE의 한계가 드러나는 영역에서 보조 탐지 신호와 결합 구조를 검토한다는 점을 명확히 한다.

2.1 환각 분류, 사실성, 벤치마크

환각은 LLM이 입력, 문맥, 또는 외부 사실과 맞지 않는 내용을 생성하는 현상으로 다루어진다. Huang 등은 LLM 환각의 원인, 유형, 탐지 과제를 폭넓게 정리하며, 환각 탐지가 LLM 신뢰성 확보를 위한 핵심 문제임을 보인다[1]. Maynez 등은 생성 텍스트 평가에서 사실성(factuality)과 충실성(faithfulness)을 구분해 논의했으며[2], 이 구분은 환각 탐지 문장을 작성할 때 단순한 "틀림"보다 어떤 기준에서 맞지 않는지 명확히 해야 함을 보여준다.

벤치마크와 평가 연구는 환각 탐지의 대상과 평가 기준을 제공한다. TruthfulQA는 모델이 인간의 오해나 거짓 믿음을 모방하는지를 측정하는 질의응답 벤치마크이다[13]. FActScore는 장문 생성에서 원자적 사실 단위의 정밀도를 평가하는 방법을 제안했으며[7], AlignScore는 생성 내용과 근거 사이의 정렬을 통해 사실 일관성을 평가한다[8]. 이러한 연구들은 환각을 평가하고 분류하는 기준을 제공하지만, 본 연구의 중심인 Zero-SE 설정에서 SE와 Energy를 어떻게 결합할지는 직접 다루지 않는다.

2.2 불확실성 및 반복 샘플링 기반 탐지

SelfCheckGPT는 외부 지식 베이스 없이 여러 응답을 샘플링하고 응답 간 일관성을 비교해 환각을 탐지하는 접근을 제안했다[6]. 이 흐름은 하나의 응답만 보는 대신, 같은 질문에 대한 여러 생성 결과의 분산과 일관성을 환각 탐지 신호로 본다. Semantic Entropy도 이 관점과 연결되지만, 응답을 의미 클러스터로 묶고 클러스터 분포의 엔트로피를 사용한다는 점에서 더 명시적인 의미 단위 불확실성 측정 방법이다[5].

표 2.1은 본 연구에서 비교하는 주요 불확실성 및 점수 기반 방법론들의 차이를 요약한다.

2.3 Semantic Entropy (SE)

Semantic Entropy는 Farquhar 등이 2024년 Nature에 발표한 LLM 불확실성 측정 방법이다[5]. 기존의 토큰 단위 확률 기반 불확실성 측정 방법과 달리, SE는 응답의 의미적 내용을 기반으로 불확실성을 측정한다.

표 2.1 LLM 환각 탐지 방법론 비교

방법	핵심 아이디어	장점	한계
SE	NLI 클러스터링 + Shannon Entropy	의미적 불확실성 측정	Zero-SE 문제
KLE	von Neumann Entropy + Kernel	SE를 일반화하는 방법 맥락	$O(N^3)$ 복잡도
SNNE	Nearest Neighbor LogSumExp	클러스터링 불필요	유사도 함수 의존
Cleanse	Hidden Embedding 비율	클러스터 간 유사도 활용	White-box only
Energy	Raw Logit 기반 에너지	Zero-SE 보조 신호	다양성 정보 부족

2.3.1 작동 원리

SE의 계산 과정은 다음과 같다:

1. **응답 샘플링**: 하나의 질문 q에 대해 LLM으로부터 K개의 응답 $\{r_1, r_2, ..., r_K\}$를 샘플링한다.
2. **의미적 클러스터링**: NLI 모델을 사용하여 응답들을 의미적으로 클러스터링한다. 두 응답이 서로 entailment 관계에 있으면 같은 클러스터로 분류한다.
3. **엔트로피 계산**: 클러스터 분포의 Shannon entropy를 계산한다.

수식으로 표현하면:

$$SE = -\sum_{c \in C} p(c) \log p(c) \tag{2.1}$$

여기서 C는 의미 클러스터 집합이고, $p(c)$는 클러스터 c에 속하는 응답의 비율이다.

2.3.2 한계점

SE의 주요 한계점은 다음과 같다:

- **Hard Clustering**: 응답들을 이진적으로(동일/다름) 분류하여 세밀한 유사도를 반영하지 못한다.
- **Zero-SE 문제**: 모든 응답이 하나의 클러스터에 속하면 SE=0이 되어 판별력이 사라진다.
- **응답 길이와 클러스터링 의존성**: 긴 응답이나 복잡한 답변에서는 NLI 기반 클러스터링 품질에 따라 결과가 달라질 수 있다.

2.4 SE 계열 확장 방법: KLE와 SNNE

KLE와 SNNE는 SE의 한계를 완화하려는 후속 방법들이다. Nikitin 등(2024)의 KLE는 hard clustering 대신 의미 커널과 von Neumann Entropy를 사용해 SE를 더 일반적인 불확실성 프레임워크로 확장한다[11].

Nguyen 등(2025)의 SNNE는 명시적 클러스터링 없이 응답 간 pairwise semantic similarity를 사용해 긴 응답에서 클러스터 수가 불필요하게 증가하는 문제를 줄이려 한다[12]. 두 방법은 SE 계열 연구의 확장 방향을 보여주지만, 본 연구의 초점인 Zero-SE 구간에서 SE와 Energy를 어떻게 선택적으로 결합할지는 직접 다루지 않는다.

2.5 Semantic Energy

Ma 등(2025)이 제안한 Semantic Energy는 여러 generated answer와 semantic cluster를 사용해 토큰 logit 기반 uncertainty를 해석하려는 방법이다[10]. 현재 문헌 상태에서는 기존 방법 맥락과 구현 목표로만 사용하며, 본 연구의 핵심 주장은 아직 검증되지 않은 Energy 성능이 아니라 corpus 조건 축에 따라 hallucination metric의 신뢰도를 평가해야 한다는 문제 설정에 둔다.

2.5.1 작동 원리

Energy는 LLM이 각 토큰을 생성할 때 부여한 **softmax 전 raw logit** 값을 사용한다:

$$Energy = \frac{1}{nT} \sum_{i=1}^{n} \sum_{t=1}^{T_i} -z_\theta(x_t^{(i)}) \tag{2.2}$$

여기서 $z_\theta(x_t)$는 토큰 x_t의 logit 값이다.

2.5.2 SE 대비 차별점

표 2.2 SE와 Semantic Energy의 비교

항목	SE	Semantic Energy
사용 값	softmax 후 확률	softmax 전 logit
측정 대상	응답 간 다양성	토큰별 확신도
정보 손실	정규화로 손실	logit 크기 보존
Zero-SE	판별 정보 부족	**보조 신호 제공**

2.5.3 Zero-SE 보완

Energy의 중요한 역할은 single-cluster 또는 낮은 다양성 상황에서 토큰 수준 점수 정보를 제공할 수 있다는 문헌적 동기이다. 현재 실험 산출물에는 candidate-level Boltzmann-style energy diagnostic과 logit diagnostics가 포함되어 있다. 그러나 Energy의 목적은 전체 row를 한꺼번에 나열한 aggregate AUROC가 아니라 낮은 다양성 matched pair에서 환각 후보를 정답 후보보다 위험하게 순위화하는지 확인하는 데 있다.

2.6 기존 연구의 한계 및 연구 공백

기존 연구들의 한계를 정리하면 다음과 같다:

1. **환각 분류 및 평가 연구**: 환각의 정의, 사실성, 벤치마크를 제공하지만 Zero-SE 영역의 탐지 신호 결합 문제를 직접 다루지 않는다.
2. **SE 계열 방법**: 반복 샘플링과 의미 클러스터 분포를 활용하지만, 모든 응답이 하나의 의미 클러스터에 모이는 경우 판별 정보가 부족해진다.
3. **Energy 계열 점수**: 토큰 수준 확신도 정보를 제공하지만, 응답 간 의미적 다양성 정보를 직접 활용하지 못한다.
4. **결합 구조의 필요성**: 단일 점수로 모든 환각 유형을 처리하기보다, SE가 유효한 구간과 Zero-SE 구간을 나누어 서로 다른 신호를 적용하는 구조가 필요하다.

본 연구는 SE, Energy 동기, corpus-grounded signal의 결합 가능성을 검토하되, 현재 실험에서는 prompt-level SE와 candidate-level Energy를 같은 row-level AUROC로 단순 비교할 때 생기는 한계를 명시한다.

제 3 장 이론적 분석

본 장에서는 제안 방법의 이론적 근거를 제시한다.

3.1 환각이 드러나는 두 가지 양상

Zero-SE 문제를 이해하려면, 환각이 반복 샘플링에서 서로 다른 방식으로 나타날 수 있음을 구분할 필요가 있다. 하나는 같은 질문에 대해 서로 다른 답변 후보가 나타나는 경우이다. 어떤 샘플에서는 A라고 답하고, 다른 샘플에서는 B라고 답한다면, 모델의 출력은 여러 의미 후보 사이에서 흔들리는 것처럼 보인다. 본 연구에서는 이런 양상을 혼란형으로 부른다. 다른 하나는 반복 샘플링 결과가 일관되지만, 그 답변 자체가 사실이 아니거나 근거 자료로 지지되지 않는 경우이다. 본 연구에서는 이런 양상을 지어냄형 또는 fabrication-like 사례로 구분한다.

이 구분은 문헌의 표준 분류명을 새로 제안하려는 것이 아니라, 기존 연구가 다룬 두 종류의 탐지 단서를 반복 샘플링 설정에 맞게 정리한 것이다. NLG와 LLM 환각 연구는 사실성(factuality), 충실성(faithfulness), 근거와의 일관성, 외부 지식으로 지지되는지 여부를 구분해 다루며[3, 2, 4], 사실성 평가 연구도 생성 문장을 원자적 사실 단위로 나누어 각 사실이 근거 자료에 의해 지지되는지를 평가한다[7]. 따라서 본 연구에서 말하는 혼란과 지어냄은 모델의 숨은 의도나 내적 상태를 단정하는 표현이 아니라, 여러 번 생성한 출력에서 나타나는 응답 분포와 근거성의 차이를 설명하기 위한 구분이다.

반복 샘플링 기반 연구는 같은 질문에 대해 여러 응답을 생성했을 때 응답 간 불일치나 의미적 분산이 환각 탐지 단서가 될 수 있음을 보였다[6, 5]. 이는 혼란형 패턴과 잘 맞는다. 응답들이 서로 다른 의미 클러스터로 갈라지면 SE는 그 갈라짐을 엔트로피로 요약할 수 있다. 그러나 이러한 접근은 응답들이 모두 같은 의미로 모이는 경우에는 약해진다. 의미적으로 일관된 출력이 항상 사실적으로 옳다는 뜻은 아니기 때문이다. TruthfulQA는 모델이 그럴듯하지만 거짓인 답변을 낼 수 있음을 평가하고[13], FActScore와 HALoGEN은 생성된 개별 사실이 외부 근거로 지지되는지 또는 fabrication에 해당하는지를 따로 검증한다[7, 9]. 즉, **응답 간 일관성**과 **정답 또는 근거에 대한 정확성**은 분리될 수 있다.

3.1.1 혼란형 환각 (Confusion-like Pattern)

정의: 같은 질문에 대해 서로 다른 의미의 응답 후보들이 경쟁하는 것으로 관측되는 경우이다. 예를 들어 반복 샘플링 결과가 서로 다른 인물명, 날짜, 원인을 답한다면, 모델 출력은 하나의 안정된 의미로 수렴하지 않는다. 이는 SelfCheckGPT가 활용한 샘플 간 불일치/일관성 비교와, Farquhar 등이 semantic entropy로

포착한 의미적 불확실성 신호와 맞닿아 있다[6, 5].

특성:

- 반복 샘플링 시 둘 이상의 의미 클러스터가 형성됨
- 응답 간 의미적 분산이 커서 정답/오답 후보가 함께 나타날 수 있음
- 여러 번 질문 시 **다양한 응답 패턴**이 관측됨 (상대적으로 높은 SE)

탐지 관점에서 SE는 응답 간 다양성을 요약하므로, 의미적 갈라짐이 존재하는 구간에서 우선적인 신호가 된다. 이 범주에서 SE를 사용하는 이유는 "환각의 원인"을 아는 데 있지 않고, 샘플 간 의미적 불안정성이 관측된다는 점을 점수화하는 데 있다.

3.1.2 지어냄형 환각 (Confabulation/Fabrication-like Pattern)

정의: 반복 샘플링에서 응답이 거의 하나의 의미 패턴으로 수렴하지만, 그 패턴의 사실성 또는 근거 지지 여부는 별도 신호 없이는 판별하기 어려운 경우이다. 예를 들어 모델이 다섯 번 모두 같은 판례명, 논문 제목, 수치를 말하더라도 그것이 실제로 존재하지 않거나 근거 문서에 없는 내용이면 환각일 수 있다. 이때 핵심은 "모델이 지어내려 했다"는 의도가 아니라, 일관된 출력이 외부 사실이나 근거 자료로 지지되지 않을 수 있다는 점이다. TruthfulQA는 그럴듯하지만 거짓인 답변을 평가 대상으로 삼고[13], FActScore는 생성된 원자적 사실이 신뢰 가능한 근거에 의해 지지되는지를 평가하며[7], HALoGEN은 fabrication을 포함한 LLM 환각 오류 유형을 근거 자료와 대조해 분석한다[9].

특성:

- 반복 샘플링 시 응답이 단일 의미 클러스터에 가깝게 모임
- 응답들이 서로 비슷하므로 응답 간 다양성만으로는 판별 정보가 줄어듦
- 여러 번 질문 시 **일관된 답변**이 반복될 수 있으나, 그 답변이 맞는지 틀린지는 사실성 평가나 토큰 수준 확신도 등 다른 신호가 필요함

탐지 관점에서 이 범주에서는 SE가 작아지거나 0이 되어 구분력이 약해질 수 있으므로, Energy와 같은 토큰/로그릿 기반 신호를 보조 후보로 검토할 수 있다. 현재 산출물에는 candidate-level Boltzmann-style energy diagnostic과 logit diagnostics가 포함되어 있으나, 지어냄형 또는 Zero-SE 사례에서의 결론은 low-diversity matched-pair 재분석을 거쳐야 한다. 지어냄형이라는 표현은 문헌상 확립된 단일 taxonomy를 대체하려는 용어가 아니라, "일관성은 높지만 근거성 판단이 남는" 사례를 설명하기 위한 분석적 구분이다.

3.2 SE와 Energy의 상보성

3.2.1 정보 이론적 관점

SE와 Energy는 서로 다른 정보를 포착한다:

- **SE**: *Inter-response* 다양성 — 응답들이 의미적으로 얼마나 다른가?
- **Energy**: *Intra-token* 확신도 — 각 토큰 생성 시 모델이 얼마나 확신하는가?

두 신호는 같은 환각 사례의 서로 다른 측면을 본다. 모든 응답이 동일해도(SE=0), 각 토큰의 logit 분포는 여전히 달라질 수 있으므로 응답 간 다양성과 토큰 수준 확신도는 상보적으로 활용될 수 있다.

3.2.2 상보성의 수학적 표현

SE의 정의에서, $SE = 0$이 되는 조건은 모든 응답이 단일 클러스터에 속할 때이다:

$$SE = -\sum_{c \in C} p(c) \log p(c) = 0 \iff |C| = 1 \tag{3.1}$$

이 식은 **언제 SE가 더 이상 응답 간 구분 정보를 제공하지 못하는가**를 보여준다. $|C| = 1$이면 모든 샘플이 하나의 의미 클러스터에 모이므로, SE 값은 구조적으로 0이 되고 같은 구간 안에서는 추가적인 순위화 정보가 거의 남지 않는다. 반대로 $|C| \geq 2$이면 응답 간 의미적 갈라짐이 존재하므로 SE가 본래 의도한 불확실성 신호를 제공한다.

기존 초안은 이 조건에서 Energy로 라우팅하는 hard cascade를 제안했다. 현재 실험 산출물에서는 candidate-level Boltzmann-style energy diagnostic이 available이지만, headline candidate-row AUROC는 이 조건부 라우팅 가설을 직접 검정하지 않는다. 따라서 이 논문에서 $|C| = 1$ 조건은 Energy 성공을 보인 규칙이 아니라, 현재 feature table을 사용해 low-diversity matched-pair 재분석을 수행해야 하는 분석 조건으로 사용한다.

3.3 Internal Logit과 Confabulation의 관계

앞 절의 구분을 따르면, Energy는 응답 간 다양성이 사라진 구간에서 생성 토큰의 확신도 패턴을 관찰할 수 있는 후보 신호이다. 즉 Energy는 답의 사실성을 직접 검증하는 지표가 아니라, 겉보기에는 같은 답을 반복하는 사례 안에서도 토큰 선택 과정이 얼마나 불안정하거나 낮은 확신을 보이는지 살필 가능성을 제공한다. 현재 논문에서는 이 가능성을 aggregate row-level AUROC로 단정하지 않고, low-diversity matched-pair 분석에서 검증해야 할 조건부 신호로 둔다.

3.3.1 Logit 크기와 지식의 관계

LLM의 logit은 다음 토큰에 대한 상대적 선호를 반영하며, Energy는 이러한 토큰 수준 점수를 집계한 값이다. 따라서 같은 의미의 응답이 반복되는 Zero-SE 구간에서도, 토큰 선택 과정의 확신도 차이는 여전히 남을 수 있다.

- **높은 토큰 확신도**: 특정 표현이 비교적 안정적으로 선택되는 경우
- **낮은 토큰 확신도**: 여러 후보 토큰 사이에서 점수가 분산되는 경우

3.3.2 Confabulation에서의 Logit 패턴

본 논문에서 지어냄으로 부르는 행동 범주에서는 다음과 같은 패턴을 기대할 수 있다:

1. 반복 샘플링 결과는 비슷하지만, 각 토큰 단계에서는 경쟁 후보 간 점수 차이가 크지 않을 수 있음
2. 그 결과 응답 간 다양성(SE)만으로는 보이지 않던 차이가 토큰 수준 점수(Energy)에서 드러날 수 있음
3. 따라서 평균 logit이 낮거나 에너지가 높은 사례는 Zero-SE 내부에서 추가 경고 신호로 해석될 수 있음

따라서 Energy는 SE=0인 상황에서도 보조 판별 신호로 기능할 수 있다. 이러한 해석은 관측 가능한 출력 분포와 점수 패턴에 대한 설명이며, 모델 내부 상태에 대한 논의는 한계 장에서 별도로 다룬다.

제 4 장 제안 방법

4.1 Corpus-conditioned metric reliability protocol

현재 실험의 제안 구조는 paired hallucination detection diagnostic protocol이다. SE와 Energy를 단일 전역 탐지기로 주장하지 않고, corpus-grounded entity frequency와 entity-pair co-occurrence를 metric reliability를 나누는 조건 축으로 사용한다. Corpus count는 hallucination의 직접 라벨도, RAG retrieval trigger도 아니며, 각 bin에서 어떤 feature가 안정적인지 평가하기 위한 외부 corpus-support 변수이다.

4.2 Energy/logit diagnostic baseline의 평가 단위

본 실험은 paper-faithful Semantic Energy와 candidate-level Boltzmann-style energy diagnostic을 분리해 보고한다. 전자는 Ma 2025의 Eq. (11)–(14)를 따라 token energy $\tilde{E}(x_t) = -z_\theta(x_t)$, sample energy $E(x^{(i)}) = \frac{1}{T_i}\sum_t \tilde{E}(x_t^{(i)})$, cluster total energy $E_{\text{Bolt}}(\mathbb{C}_k) = \sum_{x^{(i)}\in\mathbb{C}_k} E(x^{(i)})$ (SUM), 최종 uncertainty $U(\mathbf{x}) = \sum_k p(\mathbb{C}_k)E_{\text{Bolt}}(\mathbb{C}_k)$ 로 계산한다. 여기서 $p(\mathbb{C}_k)$ 는 S4 Semantic Entropy 단계의 Eq. (8) likelihood-based cluster probability를 그대로 상속한다. 후자는 teacher-forced candidate scoring에서 얻은 token-level $-\log Z$ 평균, 평균 negative log probability, logit variance, confidence margin을 candidate level로 묶는 diagnostic이며 paper-faithful Semantic Energy와 같은 column으로 섞지 않는다. Energy-only, fixed linear SE/Energy blend, hard cascade는 baseline table에서 같은 column으로 보고하지만 평가 시 각 신호의 의미 단위 (prompt, cluster, candidate) 를 명시한다.

4.3 재현 가능한 실험 결과 요약

본문 수치는 실험 summary와 표 산출물에서 자동 생성된다. 파일명은 `thesis_evidence_summary.json`과 `thesis_evidence_table.tex`이며, 본 논문에 박힌 모든 headline 수치는 `thesis/results_macros.tex`에 매크로로 분리되어 있어 동일 manifest/run id 안에서 재실행 시 본문 prose를 손대지 않고 바로 갱신된다. 이 산출물은 동일한 feature table과 평가 설정 (`experiments/configs/fusion.yaml`, `experiments/configs/datasets.yaml`, `experiments/configs/generation.yaml`) 에서 재생성 가능해야 한다.

제 5 장 실험

5.1 실험 설정

본 절에서는 본 연구에서 사용한 환각 탐지 실험 절차를 설명한다. 실험의 핵심은 모델이 새 답변을 생성한 뒤 사후에 정답성을 판정하는 방식이 아니라, 데이터셋이 제공하는 정답 후보와 환각 후보를 같은 질문 아래에서 비교하는 것이다. 이를 통해 문자열 휴리스틱이나 LLM-as-judge에 의존하지 않고, 이미 annotation으로 구분된 후보 쌍을 대상으로 불확실성 및 corpus-grounded 특징이 환각 탐지에 어떤 신호를 제공하는지 분석한다.

5.1.1 데이터셋 구성

실험에는 TruthfulQA와 HaluEval-QA 두 데이터셋을 사용하였다. 두 데이터셋은 질문에 대해 정답 후보와 잘못된 또는 환각 후보를 명시적으로 제공하므로, 본 연구의 paired discriminative protocol에 적합하다. TruthfulQA에서는 각 질문의 `correct_answers`와 `incorrect_answers`에서 하나의 정답 후보와 하나의 오답 후보를 결정론적으로 선택하였다. HaluEval-QA에서는 데이터셋이 제공하는 `right_answer`와 `hallucinated_answer`를 그대로 사용하였다.

각 질문은 하나의 prompt 단위로 취급되며, 각 prompt에서 정확히 두 개의 평가 row를 만든다. 하나는 정답 후보이고, 다른 하나는 환각 후보이다. 최종 실험 데이터는 5,815개 prompt와 11,630개 candidate row로 구성된다. HaluEval-QA는 5,000개 prompt와 10,000개 row를 제공하고, TruthfulQA는 정제 후 815개 prompt와 1,630개 row를 제공한다.

표 5.1 실험 데이터셋 구성

데이터셋	Prompt 수	Candidate row 수	후보 쌍 출처
TruthfulQA	815	1,630	정답/오답 answer list
HaluEval-QA	5,000	10,000	right/hallucinated answer
합계	5,815	11,630	paired candidates

5.1.2 정답성 라벨링

정답성 라벨은 모델 출력이나 후처리 judge에서 오지 않는다. 각 candidate row의 주 라벨은 데이터셋 annotation이 제공하는 `is_correct`/`is_hallucination`이며, 이것이 최종 hallucination detection 평가의 기준이다. 아래의 `NORMAL`, `HIGH_DIVERSITY`, `LOW_DIVERSITY`, `AMBIGUOUS_INCORRECT` 표기는 이전 repo-local baseline을 해석하기 위해 보존한 archived diagnostic 운영 라벨이다. 즉, thesis-valid corpus-axis 분석에서는 이 운영 라벨이 새로운 class ontology가 아니며, annotation-backed correctness와 corpus-axis bin이 주 분석 단위가 된다. 이때 Semantic Entropy는 prompt-level 값이므로 같은 질문의 정답 후보와 환각 후보가 동일한 SE 값을 공유한다.

표 5.2 Archived diagnostic 운영 라벨 정의

라벨	archived diagnostic 조건	현재 baseline row 수
`NORMAL`	정답 후보	5,815
`HIGH_DIVERSITY`	환각 후보이고 $SE > 0.5$	4,737
`LOW_DIVERSITY`	환각 후보이고 $SE \leq 0.1$	1,078
`AMBIGUOUS_INCORRECT`	환각 후보이고 $0.1 < SE \leq 0.5$	0

현재 full paired 특징 테이블에는 `AMBIGUOUS_INCORRECT` row가 없다. 이는 해당 구간의 sample을 강제로 제거하거나 다른 라벨로 바꾼 결과가 아니라, archived diagnostic 운영 라벨을 붙였을 때 현재 baseline 환각 후보의 SE 값이 고정 threshold 기준으로 해당 구간에 들어가지 않았기 때문이다. 이 관찰은 gray-zone 사례가 현재 baseline artifact에 없다는 뜻이지, 최종 corpus-axis reliability 분석의 라벨 공간을 정의하지 않는다.

5.1.3 모델 scoring 절차

모델은 Qwen2.5-3B 계열 causal language model을 사용하였고, 같은 계열 tokenizer (vocab 151,936) 의 full-vocabulary logits을 그대로 보존하기 위해 generation artifact는 `float16` sidecar parquet에 저장한다. 실험은 두 종류의 모델 출력을 사용한다. 첫째, Semantic Entropy 계산을 위해 각 prompt에 대해 answer-only protocol로 N=10개의 짧은 답변을 free sampling한다. 둘째, candidate-level 특징을 계산하기 위해 각 정답/환각 후보를 teacher-forced 방식으로 scoring한다. 즉, 모델이 후보 답을 새로 생성하는 것이 아니라, 주어진 후보 답의 각 토큰 위치에서 full-vocabulary logit, per-step `logsumexp`, 선택 token logit과 logprobs를 모두 기록한다.

Free sampling은 Semantic Entropy를 계산하기 위한 prompt-level 절차이다. 반면 teacher-forced candidate scoring은 paper-faithful Semantic Energy와 candidate-level diagnostic (negative log probability,

logit variance, confidence margin) 의 입력이다. 이 구분은 이후 평가 해석에서 중요하다. Semantic Entropy는 같은 prompt의 두 candidate row에 broadcast되지만, Semantic Energy는 cluster 단위로 share되거나 (paper-faithful 정의 시) candidate 단위로 분리되며, candidate-level diagnostic은 candidate마다 서로 다른 값을 갖는다.

Answer-only protocol은 `generation.max_new_tokens=96`, `answer_only.max_answer_tokens=64`, `answer_only.max_in` `fail_on_max_new_tokens=true`로 고정한다. 이 캡은 HaluEval-QA의 long-context tail prompt가 더 짧은 캡 (32/64/8) 에서 bounded resampling을 모두 소진해 stage가 abort되는 현상을 해결하기 위해 완화한 값이며, 짧은 답변 절차의 의도는 유지하되 다중 entity 답변을 안전하게 표현할 여유를 둔다.

5.1.4 특징 계산

본 연구는 세 종류의 특징군을 사용한다.

Semantic Entropy. Semantic Entropy는 한 prompt에서 얻은 N=10 answer-only free-sample 답변을 `microsoft/deberta-large-mnli` 기반 bidirectional NLI entailment로 semantic cluster로 묶은 뒤, sample sequence log-likelihood를 cluster 단위로 log-sum-exp 집계해 cluster probability mass를 만들고 그 위에서 entropy를 계산한다. 산출물에는 `semantic_entropy_nli_likelihood`, `semantic_entropy_cluster_count`, `semantic_entropy_discrete_cluster_entropy`, `nli_model_ref`, sample/cluster log-likelihood가 함께 기록된다. SE는 prompt-level 특징이고, paired candidate setting에서 정답 후보와 환각 후보는 동일한 SE 값을 broadcast받는다.

Semantic Energy 및 logit diagnostics. Paper-faithful Semantic Energy는 Ma 2025의 Eq. (11)–(14)를 그대로 따른다. 동일한 N=10 답변과 S4의 NLI semantic cluster를 재사용하며, cluster를 다시 계산하지 않고 `(prompt_id, sample_index)`로 join한다. 식은 다음과 같다.

$$\tilde{E}(x_t^{(i)}) = -z_\theta(x_t^{(i)}) \quad \text{(Eq. 13: token energy} = -\text{selected_token_logit)} \tag{5.1}$$

$$E(x^{(i)}) = \frac{1}{T_i}\sum_{t=1}^{T_i} \tilde{E}(x_t^{(i)}) \quad \text{(Eq. 11: per-response sequence-level energy)} \tag{5.2}$$

$$E_{\text{Bolt}}(\mathbb{C}_k) = \sum_{x^{(i)}\in\mathbb{C}_k} E(x^{(i)}) \quad \text{(Eq. 12: cluster total energy, SUM)} \tag{5.3}$$

$$U(\mathbf{x}) = \sum_{k=1}^{K} p(\mathbb{C}_k)\, E_{\text{Bolt}}(\mathbb{C}_k) \tag{5.4}$$

여기서 $p(\mathbb{C}_k) = \sum_{x^{(i)}\in\mathbb{C}_k} \bar{p}(x^{(i)} \mid q)$ 는 Eq. (8)의 likelihood-based cluster probability이며, S4 Semantic Entropy 단계에서 산출된 값을 그대로 상속한다. 이는 Ma 2025 Section 2.2가 인용하는 Farquhar 2024의

cluster-likelihood weighting과 일치한다. cluster size가 큰 cluster는 Eq. (12)의 SUM 정의에 의해 더 큰 cluster total energy를 갖고, 이를 likelihood-weighted aggregation에 반영한다. 부호 규약은 lower raw Energy = more reliable (higher Energy = higher uncertainty) 이다. 산출물 schema는 `semantic_energy_cluster_uncertainty` 와 prompt-level 보조 통계 `semantic_energy_sample_energy` ($= \frac{1}{n}\sum_i E(x^{(i)})$, Eq. 14의 단순 collapsed reading), cluster id, selected-token logit/prob provenance, truncation/end-token policy, model/tokenizer ref를 포함한다.

한편 teacher-forced candidate scoring에서 얻은 token-level $-\log Z$ 평균, 평균 negative log probability, logit variance, confidence margin은 `semantic_energy_boltzmann_diagnostic` 등 candidate-level Boltzmann-style energy diagnostic으로 별도 보존하며, paper-faithful Semantic Energy와 같은 column으로 섞지 않는다.

Corpus-grounded 특징. Corpus 특징은 candidate 답변 텍스트에서 entity를 추출한 뒤, Infini-gram-compatible count backend로 entity frequency와 entity-pair co-occurrence를 query하여 raw count, log-transformed continuous axis score, 3-bin primary `corpus_axis_bin`과 5-bin sensitivity `corpus_axis_bin_5`, 그리고 backend/index/query/cache provenance를 함께 기록한다. 본 실험의 primary backend는 `InfinigramLocalEngineBa` 위의 `v4_dolmasample_olmo` 인덱스 (16B Dolma sample tokens, OLMo tokenizer) 이며, 사전에 `s3://infini-gram-lite/in` 에서 로컬 디스크로 동기화한 뒤 `InfiniGramEngine.count_cnf` AND query로 pair count를 얻는다. 공개 REST API (`https://api.infini-gram.io/`) 는 동일 cache schema의 fallback으로 둔다. 이 특징들은 외부 corpus에서 후보 답변의 지지 가능성을 간접적으로 나타내는 continuous corpus-support axis이며, hidden-state probe나 정답성 라벨을 사용하지 않는다. Low frequency와 zero co-occurrence는 hallucination label 이 아니라 metric reliability를 조건화하는 binning 변수이다.

5.1.5 실험 단계

전체 실험은 다음 단계로 구성된다.

1. **Paired dataset 생성**: TruthfulQA와 HaluEval-QA에서 prompt별 정답 후보와 환각 후보를 구성한다.
2. **모델 출력 수집**: 각 prompt에 대해 N=10 answer-only free samples를 생성하고, 각 candidate 답변에 대해 teacher-forced full-logit scoring을 수행한다.
3. **정답성 라벨 데이터 생성**: 데이터셋 annotation만 사용하여 정답 후보와 환각 후보의 정답성 라벨을 확정한다.

4. **Semantic Entropy 계산**: prompt-level N=10 free samples를 NLI semantic cluster로 묶고 likelihood-based SE와 cluster metadata를 계산한다.

5. **Corpus axis 계산**: candidate 답변에서 entity frequency와 entity-pair co-occurrence를 continuous axis와 bin으로 계산한다.

6. **Semantic Energy 계산**: generated answers의 semantic clusters와 selected-token logits에서 paper-faithful Semantic Energy를 계산하고, candidate-level logit diagnostics를 별도 계산한다.

7. **Feature table 결합**: prompt-level SE를 두 candidate row에 broadcast하고, candidate-level Energy/corpus 특징을 candidate id 기준으로 결합한다.

8. **Fusion 및 baseline 평가**: SE-only, Energy-only, logit-diagnostic-only, corpus-axis-only, global fusion, corpus-bin-aware fusion, axis-interaction fusion을 비교한다.

9. **Robustness 분석**: prompt 단위 bootstrap, leave-one-dataset-out, corpus-bin metric reliability, binning sensitivity를 수행한다.

5.1.6 평가 지표와 해석 원칙

공통 baseline table에는 AUROC, AUPRC와 F1 등 표준 분류 지표를 보고한다. 학습 target은 데이터셋 annotation에서 직접 온 `is_hallucination`이며, archived TypeLabel (NORMAL, HIGH_DIVERSITY, LOW_DIVERSITY, AMBIGUOUS_INCORRECT) 은 학습 target이 아니라 진단용 메타데이터로만 보고한다. 다만 이 candidate-row aggregate metric은 모든 특징군에 대해 같은 의미를 갖지 않는다. Semantic Entropy는 prompt-level 특징이기 때문에, 같은 prompt의 정답 후보와 환각 후보가 동일한 SE 값을 가진다. 따라서 SE-only candidate-row AUROC가 0.5에 가까운 것은 SE가 무의미하다는 뜻이 아니라, prompt-level 특징을 candidate-level paired row ranking으로 평가한 구조적 결과이다.

Semantic Energy와 logit diagnostics는 candidate-level 또는 cluster-level 신호이지만, 그 신뢰도는 corpus support 조건에 따라 달라질 수 있다. 따라서 핵심 평가는 각 corpus-axis bin에서 환각 후보가 paired correct 후보보다 더 높은 risk를 받는지 확인하는 matched-pair metric이다. 이를 위해 hallucinated-minus-normal paired delta, pairwise win rate, prompt-grouped bootstrap confidence interval, leave-one-dataset-out, threshold/calibration sensitivity, 3-bin vs 5-bin corpus axis sensitivity를 모두 보고한다. Train/test split은 prompt 단위로 묶어 같은 prompt의 두 candidate row가 fold를 가로지르지 않도록 강제한다.

5.1.7 재현성과 산출물 계약

본 실험은 `run_pipeline.py`의 S0–S9 단일 orchestrator로 실행되며, 매 stage마다 command, expected input/output, validator command, planned stdout/stderr log, git commit, Python 버전, platform, UTC timestamp가 manifest와 `script_execution_log`에 기록된다. 산출물 schema는 명시적으로 버전 표기 (예: `semantic_entropy_nli_likelihood_v1`, `semantic_energy_cluster_v1`, `corpus_axis_counts_v1`) 되어 schema mismatch가 있는 기존 artifact는 resume-skip되지 않는다. 모든 final artifact는 dataset annotation 라벨을 그대로 사용하며, heuristic 문자열 매칭이나 LLM-as-judge fallback은 thesis-valid label source로 인정하지 않는다. Final feature table은 11,630개 candidate row에 대해 N=10 NLI likelihood SE, paper-faithful Semantic Energy, candidate-level diagnostics, corpus axis bin과 backend provenance를 모두 포함하고, train fold만으로 fit된 condition-aware fusion이 held-out fold에서 평가된다.

5.2 실험 결과 요약

본 절의 값은 실험 summary와 table 산출물에서 자동 생성된다. 두 파일명은 `thesis_evidence_summary.json`, `thesis_evidence_table.tex`이다. 이 표는 candidate-row aggregate headline을 요약하지만, SE/Energy complementarity 주장은 별도의 paired/corpus-bin matched metric을 필요로 한다.

본 실험의 candidate-row aggregate AUROC는 SE-only 0.500, Energy-only 0.495, corpus-risk-only 0.518, learned fusion without corpus 0.373, learned fusion with corpus 0.344이다. 이 표는 공통 baseline table로는 유용하지만 corpus-axis reliability thesis claim의 최종 headline은 아니다. SE는 prompt-level이라 paired row에서 같은 값을 공유하고, paper-faithful Semantic Energy와 candidate-level logit diagnostics는 matched-pair 및 corpus-bin slice에서 해석해야 한다. candidate-row table 기준으로 corpus feature를 추가한 learned fusion이 learned fusion without corpus 대비 AUROC delta (절대값 0.030) 만큼 낮으며, 95% prompt-grouped bootstrap 구간 [-0.035, -0.024] 도 0을 가로지르지 않는다.

AUPRC 차이도 동일 bootstrap 구간에서 음수 (절대값 0.013) 에 있다. 이 결과는 corpus-grounded signal이 유효하지 않다는 일반 결론이 아니라, all-row learned fusion headline에 corpus feature를 단순히 추가하면 오히려 손해라는 제한된 결론이다. 본 논문은 이 관찰을 condition-aware fusion (corpus-axis bin-aware feature selection 또는 axis interaction term) 의 동기로 사용하며, SE/Energy complementarity 최종 주장은 paired 및 corpus-bin slice metric으로 분리해 평가한다.

5.3 Energy 평가 단위와 corpus-bin reliability

candidate-row aggregate baseline table은 SE-only, Energy-only, hard cascade, fixed linear blend, learned fusion을 같은 row 단위로 비교한다. 그러나 paper-faithful Semantic Energy는 sampled response

표 5.3 현재 full paired run 기반 preliminary 탐지 기준선 결과

방법	상태	AUROC	AUPRC	F1
SE-only	ok	0.500000	0.500000	0.666667
Energy-only	ok	0.494768	0.464656	0.666469
corpus-risk-only	ok	0.517674	0.468756	0.666667
fixed linear 0.1/0.9	ok	0.493906	0.471318	0.647618
fixed linear 0.5/0.5	ok	0.495696	0.485485	0.648292
fixed linear 0.9/0.1	ok	0.499486	0.492577	0.648400
hard cascade	ok	0.501818	0.500486	0.662672
archived coverage-adaptive baseline	ok	0.672976	0.590870	0.707269
learned fusion without corpus	ok	0.373430	0.419691	0.664499
learned fusion with corpus	ok	0.343537	0.406484	0.633923
candidate energy/logit diagnostic availability	ok	11630 rows	available	–
Corpus features	ok	11630 rows	parquet	–

의 semantic cluster 단위에서 정의되고, candidate-level Boltzmann-style energy diagnostic은 token-level $-\log Z$ 평균 단위에서 정의된다. 따라서 두 값을 동일 column에서 직접 비교하는 것은 평가 단위가 섞이는 것이다. 본 실험은 두 신호를 분리해 보고하고, 최종 Energy 신뢰도는 corpus-support bin별 paired matched-pair metric으로 평가한다.

본 논문은 기존 초안에서 제시했던 TruthfulQA-only Energy 개선 숫자를 사용하지 않는다. 대신 `experiments/results/robustness/`에 저장된 prompt-grouped bootstrap, leave-one-dataset-out, threshold sensitivity, 3-bin/5-bin corpus axis sensitivity, selective risk를 본 표 옆 supporting evidence로 인용한다.

5.4 문헌 근거와 guardrail

Ma Semantic Energy는 low-diversity 또는 single-cluster 상황에서 logit 기반 신호를 검토할 동기를 제공하지만[10], 현재 candidate-row headline table만으로 Energy 성능을 대신 증명하지 않는다. QuCo-RAG는 corpus frequency와 co-occurrence feature의 외부 근거 proxy를 설명하는 참고 문헌이며[14], corpus count가 모델 내부 지식이나 hidden-state confidence와 같다는 뜻은 아니다. Phillips et al.은 selective prediction과 learned combination의 framing으로만 사용하며[15], PC Probe는 구현하거나 재현하지 않았다.

이 구분은 Semantic Energy를 single-cluster 동기로만 과장 없이 사용하고, QuCo-RAG-style corpus statistics를 hidden-state probe와 구분한다는 방법론적 guardrail을 따른다.

제 6 장 결론

6.1 연구 요약

이 논문은 LLM 환각 탐지에서 Semantic Entropy, Semantic Energy 동기, corpus-grounded signal을 corpus 조건 축 관점에서 재정리하고, paired discriminative protocol 위에서 N=10 NLI likelihood SE, paper-faithful Semantic Energy, Infini-gram-compatible corpus-axis bin, condition-aware fusion을 단일 실행 계약 (S0–S9) 으로 묶어 평가하였다. 핵심 결론은 다음과 같다.

1. candidate-row aggregate AUROC만으로는 SE/Energy의 intended claim을 직접 검정할 수 없다. SE는 prompt-level 신호이므로 paired row에서 동일 값을 broadcast하고, paper-faithful Semantic Energy는 cluster level에서 정의되기 때문에, 평가 단위를 섞으면 신호가 가려진다.

2. learned fusion with corpus는 candidate-row aggregate AUROC에서 learned fusion without corpus 대비 절대값 0.030만큼 낮고 95% prompt-grouped bootstrap 구간 [-0.035, -0.024] 도 0을 가로지르지 않는다. 즉 corpus feature를 단순히 global fusion에 더하는 것은 손해이며, 이는 condition-aware fusion (corpus-axis bin-aware feature selection 또는 axis interaction term) 의 동기가 된다.

3. AUPRC 차이도 동일 bootstrap에서 음수 (절대값 0.013) 이며, corpus-grounded signal의 가치는 aggregate가 아니라 corpus-bin matched metric에서 평가해야 함을 보여준다.

4. Paper-faithful Semantic Energy와 candidate-level Boltzmann-style energy diagnostic은 평가 단위가 다르므로 같은 column으로 합치지 않고 분리해 보고한다.

5. 본 실험은 archived TypeLabel을 학습 target이 아닌 진단용 메타데이터로 보존하며, 학습 target은 데이터셋 annotation에서 직접 온 `is_hallucination`로 통일한다.

6.2 학술적 기여

1. **증거 범위 분리**: 문헌 동기, 현재 관측 성능, 추가 재분석이 필요한 평가 단위를 분리하여 unsupported claim을 제거하였다.

2. **정직한 부정 결과 보고**: corpus-grounded learned fusion이 현재 AUROC에서 underperforms한다는 불리한 결과를 본문에 반영하였다.

3. **평가 단위 요구사항 명시**: SE는 prompt-level, Energy는 candidate-level 신호이므로 서로 다른 평가 단위가 필요함을 실험 방법과 결론에 고정하였다.

4. **재현 가능한 표 산출**: 본문 수치가 고정된 summary와 LaTeX table 산출물을 통해 추적 가능하도록 정리하였다.

6.3 한계

본 연구는 다음 한계를 가진다.

1. **단일 corpus snapshot 의존**: 본 실험의 corpus axis는 `v4_dolmasample_olmo` (16B Dolma sample) 단일 인덱스 위에서 산출되므로, corpus 규모/도메인이 다른 인덱스에서는 entity frequency 분포와 zero co-occurrence 빈도가 달라질 수 있다.

2. **corpus signal 해석 한계**: corpus-grounded signal은 외부 근거 가능성을 나타내는 보조 신호일 뿐이며 모델 내부 지식을 직접 증명하지 않는다.

3. **회색지대 부재**: archived diagnostic TypeLabel 기준의 `AMBIGUOUS_INCORRECT` 행이 현재 feature table에 0개이므로, 그 라벨 정의 기준의 gray-zone threshold sensitivity는 사례 기반으로 주장할 수 없다.

4. **단일 모델 평가**: 본 실험은 Qwen2.5-3B 단일 causal LM 위에서 수행되었으며, 모델 규모/계열에 따른 일반화는 본 논문의 범위를 넘는다.

5. **모델 내부 상태 해석 불가**: SE, Semantic Energy, corpus feature는 관측 지표이며, 모델의 의도나 내부 원인을 직접 추론하지 않는다.

6.4 향후 연구

1. **여러 corpus snapshot 비교**: 본 실험의 `v4_dolmasample_olmo` 외에 더 큰 Infini-gram 인덱스 (예: `v4_pileval_llama`) 또는 도메인 특화 corpus에서 corpus axis bin 분포가 어떻게 달라지는지 비교한다.

2. **여러 모델 일반화**: 동일 protocol을 다른 causal LM (예: Llama, Mistral 계열) 에 적용해 N=10 NLI likelihood SE와 paper-faithful Semantic Energy의 corpus-bin reliability가 모델에 의존하는지 평가한다.

3. **condition-aware fusion 확장**: 본 논문의 corpus-axis bin-aware fusion 외에 axis interaction term을 사용한 monotonic fusion, hierarchical fusion 등으로 확장한다.

4. **선택 예측 평가**: prompt-level abstention metric과 selective-risk framing을 candidate-row 평가와 분리해 검증한다.

참고문헌

[1] Huang et al., "A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions," *ACM Transactions on Information Systems*, vol. 43, no. 2, pp. 1–55, 2025.

[2] J. Maynez et al., "On Faithfulness and Factuality in Abstractive Summarization," *Proceedings of ACL*, pp. 1906–1919, 2020.

[3] Z. Ji et al., "Survey of Hallucination in Natural Language Generation," *ACM Computing Surveys*, vol. 55, no. 12, article 248, pp. 1–38, 2023.

[4] A. Pagnoni, V. Balachandran, and Y. Tsvetkov, "Understanding Factuality in Abstractive Summarization with FRANK: A Benchmark for Factuality Metrics," *Proceedings of NAACL-HLT*, pp. 4812–4829, 2021.

[5] S. Farquhar, J. Kossen, L. Kuhn, and Y. Gal, "Detecting hallucinations in large language models using semantic entropy," *Nature*, vol. 630, pp. 625–630, 2024.

[6] P. Manakul, A. Liusie, and M. J. F. Gales, "SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models," *Proceedings of EMNLP*, pp. 9004–9017, 2023.

[7] S. Min et al., "FActScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation," *Proceedings of EMNLP*, pp. 12076–12100, 2023.

[8] Y. Zha et al., "AlignScore: Evaluating Factual Consistency with A Unified Alignment Function," *Proceedings of ACL*, pp. 11328–11348, 2023.

[9] A. Ravichander, S. Ghela, D. Wadden, and Y. Choi, "HALoGEN: Fantastic LLM Hallucinations and Where to Find Them," *Proceedings of ACL*, pp. 1402–1425, 2025.

[10] Z. Ma et al., "Semantic Energy: A novel approach for detecting confabulation in language models," *arXiv preprint arXiv:2412.07965*, 2025.

[11] A. Nikitin, J. Kossen, Y. Gal, and P. Marttinen, "Kernel Language Entropy: Fine-grained Uncertainty Quantification for LLMs from Semantic Similarities," *arXiv preprint arXiv:2405.20003*, 2024.

[12] D. Nguyen, A. Payani, and B. Mirzasoleiman, "Beyond Semantic Entropy: Boosting LLM Uncertainty Quantification with Pairwise Semantic Similarity," *arXiv preprint arXiv:2506.00245*, 2025.

[13] S. Lin, J. Hilton, and O. Evans, "TruthfulQA: Measuring how models mimic human falsehoods," *Proceedings of ACL*, 2022.

[14] Z. Qiu et al., "QuCo-RAG: Query-aware Corpus Grounding for Retrieval-Augmented Generation," *arXiv preprint arXiv:2512.19134*, 2025.

[15] J. Phillips et al., "Learning to Predict When Language Models Are Wrong," *arXiv preprint arXiv:2603.21172*, 2026.